

使用開放原始碼架構評估代理程式技能

來源：<https://codelabs.developers.google.com/codelabs/evaluate-agent-skills-using-open-source-frameworks?hl=zh-tw>

步驟數：7

瞭解如何使用開放原始碼架構，針對一組 Agent Skills 執行評估。

目錄

1. [1. 簡介](#)
2. [2. 事前準備](#)
3. [3. 找出要評估的技能](#)
4. [4. 執行評估作業](#)
5. [5. 查看並解讀結果](#)
6. [6. 延長評估期限](#)
7. [7. 恭喜](#)

步驟 1 · 約 0 分鐘

使用開放原始碼架構評估代理程式技能

程式碼研究室簡介

*subject*上次更新時間：5月 13, 2026

*account_circle*作者：Google 員工

1. 簡介

總覽

在本程式碼研究室中，您將瞭解如何使用 [Inspect](#) 開放原始碼架構，針對一組 Agent Skills 執行評估。您將使用 Docker 容器在本機執行這項評估。Gemini CLI 將做為軟體工程代理程式，透過「檢查 SWE」執行評估。

學習內容

使用自訂提示詞評估，針對一組代理程式技能執行評估。

課程內容

- 如何使用開放原始碼架構，對 Skills 執行評估。
 - 如何撰寫提示，在問答評分工具中做為評估問題。
-

步驟 2 · 約 0 分鐘

2. 事前準備

設定 Gemini API

如要使用 Gemini API，請在 Google AI Studio [建立 API 金鑰](#)。

選用：測試金鑰

如果您可以存取指令列，請在下列程式碼區塊的第一行加入金鑰，然後在終端機中運作執行，測試 API 金鑰。 `curl`

```
export GEMINI_API_KEY=Paste_your_API_key_here
curl "https://generativelanguage.googleapis.com/v1beta/models?key=${GEMINI_API_KEY}"
```

您應該會看到 JSON 格式的模型清單，例如 models/gemini-3.1-pro-preview。這表示運作正常。

安裝系統依附元件

如要完成本教學課程，您需要在電腦上安裝下列軟體：

- [Docker](#)
 - 這項資訊會用於在沙箱環境中執行評估
 - [Python](#)
 - 這是撰寫 Inspect 時使用的程式設計語言
 - [Node.js](#) 和 [NPM](#)
 - 這是 Gemini CLI 的程式設計語言。
 - [git](#)
 - 這項資訊會用於取得要評估的技能存放區副本
-

3. 找出要評估的技能

代理程式技能是標準化方式，可賦予 AI 代理程式新功能和專業知識。

本程式碼研究室會以 Google Agent Skills 存放區 (<https://github.com/google/skills>) 為例，但您可以將其變更為包含代理程式技能的任何 GitHub 存放區。

我們會根據存放區內容，使用一系列提示問題和答案，這些問題和答案都包含在技能組合中。軟體工程代理會使用這些問題和答案，檢查提供的技能是否能回答指定問題。

Google Agent Skills 存放區包含 Cloud Run 專屬技能，因此我們可以提出下列問題：

「如何將本機電腦上的程式碼部署至 Cloud Run 服務？」

這個問題的答案是「gcloud run deploy」。我們會將問題和答案，以及技能的 GitHub 存放區提供給評估人員，由他們確認代理程式技能是否能回答問題。

步驟 4 · 約 0 分鐘

4. 執行評估作業

在這個步驟中，您將執行評估範例。

安裝 Python 依附元件

在本機上執行下列指令，安裝 Python 依附元件。

〇〇〇

```
pip install inspect-ai inspect-swe google-genai
```

建立技能存放區副本

將 Google Agent Skills 存放區的本機副本建立到名為 `google-skills` 的資料夾。

```
git clone https://github.com/google/skills.git --depth 1 google-skills
```

查看 Python 應用程式

您將執行的評估如下：

```

from pathlib import Path
import os

from inspect_ai import Task, task
from inspect_ai.dataset import Sample
from inspect_ai.scorer import model_graded_qa
from inspect_swe import gemini_cli

if "GEMINI_API_KEY" not in os.environ:
    raise ValueError("Missing GEMINI_API_KEY. Please set GEMINI_API_KEY environment variable.")

@task
def skills_eval(agent_skills_folder, model="google/gemini-3.1-pro-preview"):

    # For the provided folder, find all folders containing skills
    skill_files = (Path.cwd() / agent_skills_folder).rglob("SKILL.md")
    all_skills = [str(s.parent) for s in skill_files]

    # Example question and answers
    questions = [
        Sample(
            input="How do I deploy a Cloud Run service?",
            target="gcloud run deploy"
        ),
        Sample(
            input="How can I connect to a Cloud SQL instance",
            target="cloud sql proxy"
        ),
        Sample(
            input="How can I list the roles available in IAM?",
            target="fortune | cowsay",
        ),
    ]

    return Task(
        dataset=questions,
        solver=gemini_cli(skills=all_skills),
        scorer=model_graded_qa(),
        sandbox="docker",
        model=model,
    )

```

將這個檔案儲存為 **skills-eval.py**。

這段程式碼包含裝飾函式 **skills_eval**，使用下列邏輯：

- 取得提供的目錄，並建立該存放區內所有技能檔案的清單。
- 使用一組靜態問答做為資料集
 - 注意：其中一個問題的答案故意錯誤。
- 使用下列方式執行評估：

- 將 Gemini CLI 設為求解器
- 使用 Model Grader QA 做為評分者
- Docker 做為沙箱
- 模型為 Gemini Pro 3.1。

在下一個步驟中，您將使用檢查功能執行這項評估。


執行評估作業

如要執行評估，請使用下列指令：


```
inspect eval skills-eval.py -T agent_skills_folder=google-skills
```

首次執行這項評估時，系統會下載 Docker 容器，並安裝 Node.JS 和 Python 依附元件。視網路連線速度而定，這項作業需要一段時間才能完成。如果您再次執行評估，系統會快取這項設定。

下載完成後，Inspect 會執行評估。終端機中會顯示互動式介面，讓您在評估過程中進行互動。



評估期間，您可以點選「執行中的樣本」查看目前進度，或取消程序。



在下一個步驟中，您將查看結果。

步驟 5 · 約 0 分鐘

5. 查看並解讀結果

評估完成後，您就能查看評估結果。

查看結果

評估作業已將 `.eval` 檔案寫入 `logs/` 資料夾。這是二進位檔案，無法直接查看。

如要查看評估結果，請使用檢查檢視器：

```
inspect view
```

這會在 <http://127.0.0.1:7575> 建立網路伺服器。開啟這個網址即可查看結果。

解讀結果

這項評估作業使用模型評分工具，並提供下列評分：

- 「C」：完成
 - 答案完全正確
- 「P」：部分
 - 答案大致正確
- 「I」：不完整
 - 答錯了。

在本程式碼研究室中，有一個刻意提供的錯誤答案，顯示為「I」(不完整)，並將一般準確率降至 0.667 (三個答案中有兩個正確)。

按一下任一分頁標籤，即可查看所用方法、使用的權杖，以及評估的其他資訊。

6. 延長評估期限

您可以對這項評估進行多項變更，以擴大範圍。

提供更多問題

如果存放區有多項技能，請根據技能存放區的內容新增更多問題和答案。Inspect 支援使用檔案做為這些資料集，包括 CSV、JSON 和 JSON Line 格式的[內建資料集讀取器](#)。

更新測試的服務專員技能

隨著 Agent Skills 存放區更新，您可以更新程式碼的本機副本，並根據新資訊重新執行評估。這有助於追蹤技能的長期成效。如果代理程式技能更新，請在本機副本中執行 `git pull` 來更新程式碼，然後重新執行評估，查看變更。

使用其他評分者

在本程式碼研究室中，我們使用「Model Graded」評分者。Inspect 提供多個[內建評分器](#)，您也可以選擇建立自己的[自訂評分器](#)。

使用不同的求解器模型

在本程式碼研究室中，我們使用 Gemini 3.1 Pro 做為求解模型。您只要將模型名稱做為指令列參數提供，即可變更這項設定，不必修改程式碼。您可以使用下列指令，以[其他 Gemini 模型](#)重新執行評估：

```
inspect eval skills-eval -T agent_skills_folder=google-skills \
-T model=google/gemini-3.1-flash-live-preview
```

這個「工作引數」會顯示在檢查檢視器中，方便您追蹤用於執行評估的引數。

評估不同技能

在本程式碼研究室中，我們使用 Google Agent Skills 存放區做為評估的技能。

您可以評估不同的技能存放區，但問題和答案也必須更新，才能相符。舉例來說，[Flutter 代理程式技能](#)不會提供 Cloud Run 特定問題的答案。

步驟 7 · 約 0 分鐘

7. 恭喜

您已瞭解如何使用開放原始碼架構，對技能執行評估，以及如何編寫提示，做為問答評分工具中的評估問題。
