

BigQuery 的內容快取：快速、符合成本效益，且以大數據為基礎的生成式 AI

來源：<https://codelabs.developers.google.com/bigquery-context-caching?hl=zh-tw>

步驟數：7

瞭解如何搭配使用 Gemini 脈絡快取與 BigQuery Gen AI 函式，加快分析速度並降低成本。

目錄

1. [1. 簡介](#)
2. [2. 事前準備](#)
3. [3. 準備 BigQuery 資料](#)
4. [4. 建立脈絡快取](#)
5. [5. 使用快取內容執行 AI.GENERATE](#)
6. [6. 清除所用資源](#)
7. [7. 恭喜](#)

1. 簡介

BigQuery 的[生成式 AI 函式](#)可讓您使用 SQL，透過大型語言模型 (LLM) 推論資料。您不必移動資料，就能分析情緒、生成摘要，以及為數百萬列資料中的圖片加上說明。

但如果提示需要大量脈絡 (例如政策、手冊或影片)，才能獲得準確可靠的結果，該怎麼辦？

[Gemini 脈絡快取](#)會將大量脈絡儲存在快取中，解決這個問題。後續提示會參照快取，而非每次都處理完整內容，因此延遲時間較短，輸入權杖最多可享 **90% 折扣**。

在本程式碼研究室中，您將建構「細則」退貨政策檢查工具，使用明確的內容快取，根據 BigQuery 中龐大的靜態退貨政策文件，分析顧客退貨要求。



BigQuery 內容快取工作流程 (圖片待更新)

學習內容

- 建立 BigQuery 資料集，並填入顧客退貨申請範例。
- 在 Gemini Enterprise Agent Platform (原稱 Vertex AI) 中建立 Context Cache，並指向儲存在 Cloud Storage 中的退貨政策文件。
- 使用 `AI.GENERATE` 執行查詢，參照快取，有效率地逐列評估要求。

軟硬體需求

- 網路瀏覽器，例如 [Chrome](#)
- 已啟用計費功能的 Google Cloud 雲端專案
- 存取 Google Cloud Shell

本程式碼研究室適合各種程度的開發人員，包括初學者。

本程式碼研究室建立的資源費用應低於 \$2 美元。

預計時間：完成本程式碼研究室大約需要 30 分鐘。

2. 事前準備

從做中學 免付費

立即取得 Google Cloud 抵免額，並完成這個實驗室。無須提供信用卡或付款方式。

[info](#)

從做中學 免付費

立即取得 Google Cloud 抵免額，並完成這個實驗室。無須提供信用卡或付款方式。

啟用

建立 Google Cloud 專案

1. 在 [Google Cloud 控制台](#) 的專案選取器頁面中，[選取或建立 Google Cloud 專案](#)。
2. 確認 Cloud 專案已啟用計費功能。瞭解如何[檢查專案是否已啟用計費功能](#)。

啟動 Cloud Shell

Cloud Shell 是在 Google Cloud 中運作的指令列環境，已預先載入必要工具。

1. 按一下 Google Cloud 控制台頂端的「啟用 Cloud Shell」圖示



。

2. 連至 Cloud Shell 後，請驗證您的驗證：

```
gcloud auth list
```

3. 確認專案已設定完成：

```
gcloud config get project
```

4. 如果專案未如預期設定，請設定專案：

```
gcloud config set project <YOUR_PROJECT_ID>
```

設定專案 ID 和位置

執行下列指令，擷取有效的 **Google Cloud 專案 ID**，並將預設位置設為環境變數，以便在本程式碼研究室中使用：

```
export PROJECT_ID=$(gcloud config get-value project)
export PROJECT_NUMBER=$(gcloud projects describe $PROJECT_ID --format="value(projectNumber)")
export LOCATION="us-central1"
```

啟用 API

執行下列指令來啟用必要的 **API**：

```
gcloud services enable \
  bigquery.googleapis.com \
  aiplatform.googleapis.com
```

步驟 3 · 約 5 分鐘

3. 準備 BigQuery 資料

在測試內容快取之前，我們需要資料集和填入範例顧客退貨要求的表格，才能執行查詢。

1. 建立資料集

在 Cloud Shell 中執行下列指令，建立名為 `cached_demo` 的 BigQuery 資料集：

```
bq mk --dataset $PROJECT_ID:cached_demo
```

2. 建立並填入資料表

執行下列指令，建立名為 `return_requests` 的資料表，並插入客戶退貨要求範例：

```

bq query \
  --use_legacy_sql=false \
  "CREATE OR REPLACE TABLE \`caching_demo.return_requests\` AS
SELECT
  10001 AS return_id,
  'P-1001' AS purchase_id,
  'I bought this jacket on Black Friday but it was too small.' AS return_comment,
  DATE('2025-11-28') AS purchase_date,
  DATE('2025-12-05') AS return_date,
  'ApexWear' AS product_brand,
  'Gold' AS customer_tier
UNION ALL
SELECT
  10002 AS return_id,
  'P-1002' AS purchase_id,
  'The item arrived broken, I want a refund. I don\'t have photos because I threw it away.'
AS return_comment,
  DATE('2026-04-01') AS purchase_date,
  DATE('2026-04-02') AS return_date,
  'GenericBrand' AS product_brand,
  'Standard' AS customer_tier
UNION ALL
SELECT
  10003 AS return_id,
  'P-1003' AS purchase_id,
  'I bought this ApexWear jacket, took the tags off to wear it once, but it doesn\'t fit
well.' AS return_comment,
  DATE('2026-02-15') AS purchase_date,
  DATE('2026-02-20') AS return_date,
  'ApexWear' AS product_brand,
  'Standard' AS customer_tier
UNION ALL
SELECT
  10004 AS return_id,
  'P-1004' AS purchase_id,
  'This was a holiday gift but doesn\'t fit.' AS return_comment,
  DATE('2025-12-20') AS purchase_date,
  DATE('2026-01-28') AS return_date,
  'StyleCorp' AS product_brand,
  'Standard' AS customer_tier
UNION ALL
SELECT
  10005 AS return_id,
  'P-1005' AS purchase_id,
  'I realized this doesn\'t fit' AS return_comment,
  DATE('2026-02-01') AS purchase_date,
  DATE('2026-03-15') AS return_date,
  'ApexWear' AS product_brand,
  'Gold' AS customer_tier;"

```

畫面上應會顯示成功訊息：

Created your-project-id.caching_demo.return_requests

現在可以建立快取了！

步驟 4 · 約 5 分鐘

4. 建立脈絡快取

您將使用 `curl`，透過 REST 呼叫 Gemini Enterprise Agent Platform (原稱 Vertex AI) 模型端點，建立快取。

在 Cloud Shell 中執行下列指令，**建立新的儲存空間 bucket**。這項設定將用於儲存要快取的檔案：

```
gcloud storage buckets create gs://${PROJECT_ID}-caching-demo --location=${LOCATION}
```

接著，將範例政策文件複製到新建立的值區：

```
gcloud storage cp gs://sample-data-and-media/context_caching_demo/return_policy.md  
gs://${PROJECT_ID}-caching-demo/
```

現在，請執行下列指令**建立快取**，並參照您新暫存的政策文件 (這項作業可能需要一分鐘左右才能完成)：

```
curl -X POST \  
  -H "Authorization: Bearer $(gcloud auth print-access-token)" \  
  -H "Content-Type: application/json" \  
  "https://${LOCATION}-  
aiplatform.googleapis.com/v1/projects/${PROJECT_ID}/locations/${LOCATION}/cachedContents" \  
  -d '{  
    "model":  
"projects/"'"${PROJECT_ID}"'/locations/"'"${LOCATION}"'/publishers/google/models/gemini-2.5-  
flash",  
    "contents": [  
      {  
        "role": "user",  
        "parts": [  
          {  
            "fileData": {  
              "mimeType": "text/markdown",  
              "fileUri": "gs://"'"${PROJECT_ID}"'-caching-demo/return_policy.md"  
            }  
          }  
        ]  
      }  
    ],  
    "ttl": "3600s"  
  }'
```

提示： `curl` 指令中的 TTL (存留時間) 參數會決定快取保持有效的時間長度。如果內容是靜態且經常使用，請考慮設定較長的 TTL，以免產生重建費用，但請注意每小時的儲存空間費用。

請記下 JSON 回應中傳回的 `name`，看起來會像這

樣：`projects/PROJECT_NUMBER/locations/LOCATION/cachedContents/CACHE_ID`。下一個步驟會用到該 `CACHE_ID`。

```
{  
  "name": "projects/123456789012/locations/us-  
central1/cachedContents/123456789012345"  
}
```

在 Cloud Shell 中將 **CACHE_ID** 儲存為環境變數：

```
export CACHE_ID="<YOUR_CACHE_ID>"
```

步驟 5 · 約 5 分鐘

5. 使用快取內容執行 AI.GENERATE

首先，請確認範例資料是否正確產生。前往 [BigQuery 控制台](#)，找出 `cachedemo` 資料集，然後按一下 `return_requests` 資料表。

在「預覽」分頁下方，您應該會看到我們稍早產生的顧客退貨要求：

☆

return_requests

🔍

Query

💬

Chat

📄

Open in ▾

👤

Share ▾

📄

Copy

📷

Snapshot

🗑️

Delete

⬆️

Export

↻

Refresh

Schema

Details

Preview

Table Explorer

Preview

Insights

Lineage

Data Profile

Data Quality

Row	return_id	purchase_id	return_comment	purchase_date	return_date	product_brand	customer_tier
1	10001	P-1001	I bought this jacket on Black Friday but it was too small.	2025-11-28	2025-12-05	ApexWear	Gold
2	10005	P-1005	I realized this doesn't fit	2026-02-01	2026-03-15	ApexWear	Gold
3	10003	P-1003	I bought this ApexWear jacket, took the tags off to wear it once, but it doesn't fit well.	2026-02-15	2026-02-20	ApexWear	Standard
4	10002	P-1002	The item arrived broken, I want a refund. I don't have photos because I threw it away.	2026-04-01	2026-04-02	GenericBrand	Standard
5	10004	P-1004	This was a holiday gift but doesn't fit.	2025-12-20	2026-01-28	StyleCorp	Standard

現在快取已建立並填入資料，您可以使用 `AI.GENERATE` 查詢，只要參照該快取 ID 即可評估退款要求。

為避免手動尋找及取代變數，請在 **Cloud Shell** 中執行下列指令。這會動態建構 **SQL** 查詢，使用現有的環境變數並列印到畫面上，方便您輕鬆複製。

```

cat << EOF > query.sql
WITH generated_returns AS (
  SELECT
    *,
    -- Call AI.GENERATE with the prompt, schema, and cache ID
    AI.GENERATE(
      -- Construct the prompt referencing the cached policy
      prompt => CONCAT(
        'Analyze this return request using the cached Return Policy. ',
        'Return Comment: "', return_comment, '". ',
        'Purchase Date: ', purchase_date, '. ',
        'Brand: ', product_brand, '. ',
        'Customer Tier: ', customer_tier, '. '
      ),
      -- Define the structured output schema
      output_schema => """
        eligible_for_refund STRING OPTIONS(description = 'True/False whether the request is
eligible for a refund based on the policy'),
        refund_type STRING OPTIONS(description = 'Classify as Full, Store Credit, or None'),
        reason_citation STRING OPTIONS(description = 'Quote the specific rule from the policy
applied to this decision')
      """
      -- Construct the endpoint string dynamically using variables
      endpoint => 'gemini-2.5-flash',

      -- Pass the cached content ID using bash interpolation for the literal
      model_params => JSON '{"cachedContent":
"projects/$PROJECT_NUMBER/locations/$LOCATION/cachedContents/$CACHE_ID"}'
    ) AS results
  FROM `caching_demo.return_requests`
)
SELECT
  *,
  -- Extract token usage metrics from the raw JSON response
  CAST(JSON_EXTRACT_SCALAR(results.full_response, '$.usage_metadata.prompt_token_count') AS
INT64) AS prompt_token_count,
  CAST(JSON_EXTRACT_SCALAR(results.full_response,
'$.usage_metadata.cached_content_token_count') AS INT64) AS cached_content_token_count,
  CAST(JSON_EXTRACT_SCALAR(results.full_response, '$.usage_metadata.candidates_token_count')
AS INT64) AS output_token_count,
  CAST(JSON_EXTRACT_SCALAR(results.full_response, '$.usage_metadata.total_token_count') AS
INT64) AS total_token_count,
  CAST(JSON_EXTRACT_SCALAR(results.full_response, '$.usage_metadata.thoughts_token_count') AS
INT64) AS thoughts_token_count,
  CAST(JSON_EXTRACT_SCALAR(results.full_response,
'$.usage_metadata.billable_prompt_usage.text_count') AS INT64) AS billable_prompt_text_count,
  CAST(JSON_EXTRACT_SCALAR(results.full_response,
'$.usage_metadata.billable_cached_content_usage.text_count') AS INT64) AS
billable_cached_text_count

FROM generated_returns;
EOF

```

cat query.sql

現在請複製終端機中的 SQL，在瀏覽器中前往 BigQuery 控制台，然後在查詢編輯器分頁中執行查詢。

```
1 WITH generated_returns AS (
2   SELECT
3     *,
4     -- Call AI.GENERATE with the prompt, schema, and cache ID
5     AI.GENERATE(
6       -- Construct the prompt referencing the cached policy
7       prompt => CONCAT(
8         'Analyze this return request using the cached Return Policy. ',
9         'Return Comment: ', return_comment, ' ',
10        'Purchase Date: ', purchase_date, ' ',
11        'Brand: ', product_brand, ' ',
12        'Customer Tier: ', customer_tier, ' '
13      ),
14       -- Define the structured output schema
15       output_schema => """
16         eligible_for_refund STRING OPTIONS(description = 'True/False whether the request is eligible for a refund based on the policy'),
17         refund_type STRING OPTIONS(description = 'Classify as Full, Store Credit, or None'),
18         reason_citation STRING OPTIONS(description = 'Quote the specific rule from the policy applied to this decision')
19       """
20       -- Construct the endpoint string dynamically using variables
21       endpoint => 'gemini-2.5-flash',
22       -- Pass the cached content ID using bash interpolation for the literal
23       model_params => JSON '{"cachedContent": "projects/123456789/locations/us-central1/cachedContents/123456789"}'
24     ) AS results
25   FROM `caching-demo.return_requests`
26 )
27 )
```

✓ This query will process 568 B when run.

以下詳細說明這個函式呼叫中的重要引數：

- **prompt**：包含每個客戶資料列的具體資訊。這段文字會附加到快取中已有的退貨政策文件。
- **output_schema**：定義模型回覆的預期 JSON 結構。
- **endpoint**：指定用於生成的 Agent Platform AI 模型端點 (在本例中為 Gemini 2.5 Flash)。
- **model_params**：重要參數，會使用 **cachedContent** 欄位傳遞產生的快取 ID。

畫面上應會顯示產生的結果，分析每項退貨要求是否符合儲存的政策。向右捲動即可查看擷取的權杖指標。

Query results

Chat

View all jobs

Save results

Open in

Job information		Results	Visualization	JSON	Execution details		Execution graph				
results_eligible_for_refund	results_reason_citation	results_refund_type	results_full_response	res...	prompt_token_count	cached_content_token_count	output_token_count	total_token_count	billable_prompt_text_count	billable_cached_text_count	
False	ApexWear: Returns are only accepted if all original tags are still attached to the garment. If tags are removed, the item is not eligible for a refund, regardless of the return window.	None	{\"candidates\": [{\"avg_jopp_robts\": 1.467100224024813, \"content\": {\"parts\": [\"text\": \"\\n\\eligible_for_refund\": \"		7599	7485	71	8367	401	30828	
True	Applicable Holiday Extended Return Windows (Section 3) for purchases made between November 15 and December 25, extending eligibility until January 31 of the following year. For Item does not fit well /	Full	{\"candidates\": [{\"avg_jopp_robts\": 4.453143016401544, \"content\": {\"parts\": [\"text\": \"\\n\\eligible_for_refund\": \"		7588	7485	166	9499	371	30828	
False	Exception: GenericBrand items are only covered if the damage is reported within this window and verified by photo evidence.	None	{\"candidates\": [{\"avg_jopp_robts\": 1.5380436290394177, \"content\": {\"parts\": [\"text\": \"\\n\\eligible_for_refund\": \"		7597	7485	55	8138	402	30828	
True	Applicable Purchase Dates: Any purchase made between November 15 and December 25 of any given year. Extended Return Deadline: Items purchased during this window plan are eligible for return until	Full	{\"candidates\": [{\"avg_jopp_robts\": 4.830104807035519, \"content\": {\"parts\": [\"text\": \"\\n\\eligible_for_refund\": \"		7586	7485	183	10261	362	30828	
False	ApexWear: Returns are only accepted if all original tags are still attached to the garment. If tags are removed, the item is not eligible for a refund, regardless of the return window. (Section 4)	None	{\"candidates\": [{\"avg_jopp_robts\": 25.720807527240954, \"content\": {\"parts\": [\"text\": \"\\n\\eligible_for_refund\": \"		7583	7485	76	11288	347	30828	

以下是您會看到的權杖指標細目：

- **prompt_token_count**：輸入提示中處理的權杖總數 (包括快取內容)。

- **cached_content_token_count**：從快取提供的權杖數量 (代表靜態退貨政策文件)。
- **output_token_count**：模型在回覆中生成的權杖數量。
- **total_token_count**：提示和輸出內容的權杖總數。
- **billable_prompt_text_count**：提示中未快取部分的計費字元數。
- **billable_cached_text_count**：快取內容中可計費的字元數。

查看 **billable_prompt_text_count** 欄，每列只會顯示幾百個字元，也就是顧客的具體要求。相較之下，完整退貨政策的 **billable_cached_text_count** 字元數超過 30,000 個。如果沒有內容快取，您就必須為每個資料列處理完整的政策文件，並支付相關費用。透過快取，您只需支付一次大型文件費用，後續資料列只會收取小型變更提示文字的費用。

這可大幅節省批次工作的費用！

步驟 6 · 約 0 分鐘

6. 清除所用資源

如要避免系統持續向您的 Google Cloud 帳戶收取費用，請刪除在本程式碼研究室中建立的資源。

在 **Cloud Shell** 中執行下列指令，刪除 BigQuery 資料集和資料表：

```
bq rm -r -f -d caching_demo
```

刪除為政策文件建立的暫存 **bucket**：

```
gcloud storage rm --recursive gs://${PROJECT_ID}-caching-demo
```

最後，請刪除內容快取，以免系統持續收取儲存空間費用 (使用您先前儲存的變數)：

```
curl -X DELETE \
  -H "Authorization: Bearer $(gcloud auth print-access-token)" \
  "https://${LOCATION}-aiplatform.googleapis.com/v1/projects/${PROJECT_ID}/locations/${LOCATION}/cachedContents/${CACHE_ID}"
```

步驟 7 · 約 0 分鐘

7. 恭喜

恭喜！您已在 Agent Platform 中成功建立內容快取，並在 BigQuery AI 函式中參照該快取，加快分析速度，同時降低輸入權杖處理成本。

目前所學內容

- 如何設定退貨要求分析的環境資料表。
- 如何使用 `curl` 呼叫 Agent Platform (Vertex AI) API，明確建立靜態文件內容快取。
- 如何在 `AI.GENERATE` SQL 查詢中使用產生的快取 ID，以排除有效提示中多餘的輸入權杖。

參考文件

- [BigQuery AI.GENERATE 語法](#)
 - [Agent Platform AI Context Caching Overview](#)
-