

如何使用 vLLM 在 Cloud Run GPU 上執行 LLM 推論

來源：<https://codelabs.developers.google.com/codelabs/how-to-run-inference-cloud-run-gpu-vllm?hl=zh-tw>

步驟數：8

瞭解如何使用 vLLM 在 Cloud Run GPU 上執行 LLM 推論

目錄

1. [1. 簡介](#)
2. [2. 設定和需求](#)
3. [3. 啟用 API 並設定環境變數](#)
4. [4. 建立服務帳戶](#)
5. [5. 部署服務](#)
6. [6. 測試服務](#)
7. [7. 恭喜！](#)
8. [8. 清除所用資源](#)

步驟 1 · 約 0 分鐘

1. 簡介

總覽

Cloud Run 是 Google Cloud 的容器平台，可讓您輕鬆在容器中執行程式碼，不必管理叢集。

Cloud Run 提供 L4 或 NVIDIA RTX PRO 6000 Blackwell GPU。每個 Cloud Run 執行個體有一個 GPU，且 Cloud Run 自動調整功能仍適用，包括在沒有任何要求時將執行個體數縮減至零。

GPU 的用途之一是執行您自己的開放式大型語言模型 (LLM)。本教學課程會逐步引導您部署執行 LLM 的服務。

本程式碼研究室說明如何使用預建容器和 [vLLM 推論程式庫](#)，在 Cloud Run 上部署 [Gemma 4 開放式模型](#)。

課程內容

- 如何在 Cloud Run 使用 GPU。
 - 如何使用 vLLM 做為推論引擎，在 Cloud Run 上部署 Google 的 Gemma 4 2B 指令微調模型。
-

步驟 2 · 約 0 分鐘

2. 設定和需求

必要條件

- 您已登入 Cloud Console。
 - 您先前已部署 Cloud Run 服務。舉例來說，您可以按照[從原始碼部署網路服務的快速入門導覽課程](#)，開始使用 Cloud Run。
-

步驟 3 · 約 0 分鐘

3. 啟用 API 並設定環境變數

啟用 API

開始進行本程式碼研究室之前，請先啟用數個 API。本程式碼研究室需要使用下列 API。執行下列指令即可啟用這些 API：



```
gcloud services enable run.googleapis.com \  
  cloudbuild.googleapis.com \  
  artifactregistry.googleapis.com
```

設定環境變數

在下方設定專案 ID。



```
export PROJECT_ID=<YOUR_PROJECT_ID>  
  
export REGION=europe-west4  
export SERVICE_NAME=gemma4-cr-codelab  
export SERVICE_ACCOUNT_NAME=gemma4-cr-sa  
export SERVICE_ACCOUNT_ADDRESS=$SERVICE_ACCOUNT_NAME@$PROJECT_ID.iam.gserviceaccount.com
```

步驟 4 · 約 0 分鐘

4. 建立服務帳戶

這個服務帳戶代表 Cloud Run 服務。

```
gcloud iam service-accounts create $SERVICE_ACCOUNT_NAME \  
  --display-name="Cloud Run gemma 4 SA"
```

步驟 5 · 約 0 分鐘

5. 部署服務

如要在 Cloud Run 上部署 Gemma 模型，請使用下列 gcloud CLI 指令，並採用建議設定：

```
CONTAINER_ARGS=(
  "serve"
  "google/gemma-4-E2B-it"
  "--enable-chunked-prefill"
  "--enable-prefix-caching"
  "--generation-config=auto"
  "--enable-auto-tool-choice"
  "--tool-call-parser=gemma4"
  "--reasoning-parser=gemma4"
  "--dtype=bfloat16"
  "--max-num-seqs=64"
  "--gpu-memory-utilization=0.95"
  "--tensor-parallel-size=1"
  "--port=8080"
  "--host=0.0.0.0"
)
gcloud beta run deploy $SERVICE_NAME \
  --image "us-docker.pkg.dev/vertex-ai/vertex-vision-model-garden-dockers/pytorch-vllm-serve:gemma4" \
  --project $PROJECT_ID \
  --region $REGION \
  --execution-environment gen2 \
  --no-allow-unauthenticated \
  --cpu 20 \
  --memory 80Gi \
  --gpu 1 \
  --gpu-type nvidia-rtx-pro-6000 \
  --no-gpu-zonal-redundancy \
  --no-cpu-throttling \
  --max-instances 3 \
  --concurrency 64 \
  --timeout 600 \
  --service-account $SERVICE_ACCOUNT_ADDRESS \
  --startup-probe
tcpSocket.port=8080,initialDelaySeconds=240,failureThreshold=1,timeoutSeconds=240,periodSeconds=240 \
  --command "vllm" \
  --args=$(IFS=' '; echo "${CONTAINER_ARGS[*]}")
```

步驟 6 · 約 0 分鐘

6. 測試服務

部署完成後，您可以[使用 Cloud Run 開發人員 Proxy 服務](#)，系統會自動為您新增 ID 權杖，也可以直接使用 curl 服務網址。

使用 Cloud Run 開發 Proxy 服務

首先，啟動 Proxy

```
gcloud run services proxy $SERVICE_NAME \
  --project $PROJECT \
  --region $REGION \
  --port=9090
```

執行下列指令，在另一個終端機分頁中傳送要求，讓 Proxy 保持執行狀態。Proxy 會在 localhost:9090 上執行

```
curl http://localhost:9090/v1/chat/completions \
  -H "Content-Type: application/json" \
  -d '{
    "model": "google/gemma-4-E2B-it",
    "messages": [{"role": "user", "content": "Why is the sky blue?"}],
    "chat_template_kwargs": {
      "enable_thinking": true
    },
    "skip_special_tokens": false
  }'
```

輸出結果應該會類似下列內容：


```
{
  "id": "chatcmpl-9cflabl450487047",
  "object": "chat.completion",
  "created": 1774904187,
  "model": "google/gemma-4-E2B-it",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "The short answer is a phenomenon called **Rayleigh scattering**...",
        "function_call": null,
        "tool_calls": [],
        "reasoning": "*   Question: \"Why is the sky blue?\"\\n\\n..."
      },
      "finish_reason": "stop",
      "stop_reason": 106
    }
  ],
  "usage": {
    "prompt_tokens": 21,
    "total_tokens": 877,
    "completion_tokens": 856
  }
}
```

直接使用服務網址

首先，請擷取已部署服務的網址。

```
SERVICE_URL=$(gcloud run services describe $SERVICE_NAME --region $REGION --format
'value(status.url)')
```

捲曲服務

```
curl $SERVICE_URL/v1/chat/completions \
-H "Authorization: bearer $(gcloud auth print-identity-token)" \
-H "Content-Type: application/json" \
-d '{
  "model": "google/gemma-4-E2B-it",
  "messages": [{"role": "user", "content": "Why is the sky blue?"}],
  "chat_template_kwargs": {
    "enable_thinking": true
  },
  "skip_special_tokens": false
}'
```


步驟 7 · 約 0 分鐘

7. 恭喜！

恭喜您完成本程式碼研究室！

建議您參閱 [Cloud Run](#) 說明文件

涵蓋內容

- 如何在 Cloud Run 使用 GPU。
 - 如何使用 vLLM 做為推論引擎，在 Cloud Run 上部署 Google 的 Gemma 4 (2B) 模型。
-

8. 清除所用資源

為避免產生意外費用 (例如，Cloud Run 服務意外叫用次數超過[免費層級的每月 Cloud Run 叫用次數配額](#))，您可以刪除 Cloud Run，或刪除您在步驟 2 中建立的專案。

如要刪除 Cloud Run 服務，請前往 Cloud Run Cloud 控制台 (<https://console.cloud.google.com/run>)，然後刪除 `gemma4-cr-codelab` 服務。您也可以刪除 `gemma4-cr-codelab-sa` 服務帳戶。

如要刪除整個專案，請前往 <https://console.cloud.google.com/cloud-resource-manager>，選取您在步驟 2 中建立的專案，然後選擇「刪除」。刪除專案後，您必須在 Cloud SDK 中變更專案。如要查看所有可用專案的清單，請執行 `gcloud projects list`。
