

運用 BigQuery 和 AI 輔助的資料科學

來源：<https://codelabs.developers.google.com/codelabs/bigquery-data-science-notebooks?hl=zh-tw>

步驟數：14

瞭解如何使用 BigQuery 進行多模態資料科學工作流程，包括使用房地產情境進行 AI 輔助資料擴充、叢集和向量搜尋。

目錄

1. 簡介
2. 事前準備
3. 在 BigQuery Studio 中開啟實驗室筆記本
4. 連線至執行階段並執行設定程式碼
5. 資料準備與特徵工程
6. 使用 AI 函式進行多模態擴充
7. 使用 K-means 分群模型訓練模型
8. 模型評估與預測
9. 視覺化及解讀叢集
10. 使用 Gemini 模型生成叢集說明
11. 使用資料科學代理自動建立模型
12. 使用嵌入和向量搜尋功能進行多模態搜尋
13. 清除
14. 恭喜！

1. 簡介

總覽

在本實驗室中，您將以房地產情境為架構，在 [BigQuery](#) 中探索多模態資料科學工作流程。您會先取得房屋資訊和圖片的原始資料集，然後使用 AI 擷取視覺特徵來擴充資料、建構分群模型來發掘不同的市場區隔，最後使用向量嵌入建立強大的影像搜尋工具。

您將使用 [資料科學代理](#)，透過簡單的文字提示自動生成以 Python 為基礎的分群模型，並比較這個 SQL 原生工作流程與現代生成式 AI 方法。

課程內容

- 準備房地產資訊的原始資料集，透過特徵工程進行分析。
- 使用 BigQuery 的 AI 函式分析房屋相片，找出主要視覺特徵，**豐富房源資訊**。
- 建構及評估 [BigQuery Machine Learning \(BQML\)](#) 的 K-means 模型，將房源劃分為不同群組。
- 使用資料科學代理程式以 Python 產生叢集模型，**自動建立模型**。
- 生成房屋圖片的嵌入內容，為影像搜尋工具提供支援，透過文字或圖片查詢尋找相似房屋。

必要條件

進入這個實驗室前，您應已熟悉下列概念：

- 基本的 SQL 和 Python 程式設計。
 - 在 Jupyter 筆記本執行 Python 程式碼。
-

步驟 2 · 約 5 分鐘

2. 事前準備

從做中學 免付費

立即取得 Google Cloud 抵免額，並完成這個實驗室。無須提供信用卡或付款方式。

info

從做中學 免付費

立即取得 Google Cloud 抵免額，並完成這個實驗室。無須提供信用卡或付款方式。

啟用

建立 Google Cloud 專案

1. 在 [Google Cloud 控制台](#) 的專案選取器頁面中，[選取或建立 Google Cloud 專案](#)。

Select a project New project

Recent Starred All

	Name	Type	ID	
✓	 my-sample-sandbox-project-1 ?	Project	my-sample-sandbox-project-1	☆

Cancel

2. 確認 Cloud 專案已啟用計費功能。瞭解如何[檢查專案是否已啟用計費功能](#)。

使用 Cloud Shell 啟用 API

[Cloud Shell](#) 是在 Google Cloud 中運作的指令列環境，已預先載入必要工具。

1. 在 Google Cloud 控制台頂端點選「啟用 Cloud Shell」：

 Google Cloud  my-sample-sandbox-project-1

Activate Cloud Shell (G then S)

2. 連線至 Cloud Shell 後，請執行下列指令，在 Cloud Shell 中驗證您的身分：

```
gcloud auth list
```

3. 執行下列指令，確認專案已設定為搭配 gcloud 使用：

```
gcloud config list project
```

4. 如果未設定專案，請使用下列指令來設定：

```
export PROJECT_ID=<YOUR_PROJECT_ID>  
gcloud config set project $PROJECT_ID
```

啟用 API

1. 執行下列指令，啟用所有必要 API 和服務：

```
gcloud services enable bigquery.googleapis.com \  
                        bigqueryunified.googleapis.com \  
                        clouddaicompanion.googleapis.com \  
                        aiplatform.googleapis.com
```

2. 成功執行指令後，您應該會看到類似下方的訊息：

```
Operation "operations/..." finished successfully.
```


3. 退出 Cloud Shell。

步驟 3 · 約 5 分鐘


3. 在 BigQuery Studio 中開啟實驗室筆記本

瀏覽使用者介面：

1. 在 Google Cloud 控制台中，依序前往「導覽選單」>「BigQuery」。



2. 在「BigQuery Studio」窗格中，按一下下拉式箭頭按鈕，將游標懸停在「筆記本」上，然後選取「上傳」。



3. 選取「網址」圓形按鈕，然後輸入下列網址：

```
https://github.com/GoogleCloudPlatform/generative-ai/blob/main/gemini/use-cases/applying-llms-to-data/ai-assisted-data-science/ai-assisted-data-science.ipynb
```

4. 將區域設為 `us-central1`，然後按一下「上傳」。

Upload Notebook

Upload from

☐ File upload

☒ URL


URL *
https://github.com/GoogleCloudPlatform/generative-ai/blob/main/gemini/us-
Enter the URL of the Notebook. We support GitHub URLs only. The Notebook should not be larger than 20MB.

Notebook name
ai-assisted-data-science
Can include up to 256 numbers, letters, spaces and special characters

Region *
us-central1 (Iowa)

Upload Cancel

5. 如要開啟筆記本，請點選「Explorer」窗格中包含專案 ID 的下拉式箭頭。然後點選「筆記本」的下拉式選單。按一下筆記本 `ai-assisted-data-science`。



6. (選用) 收合 **BigQuery** 導覽選單和 Notebook 的目錄，爭取更多空間。

BigQuery

Studio

Pipelines & Integration

Data transfers

Dataform

Scheduled queries

Scheduling

Governance

Sharing (Analytics Hub)

Policy tags

Metadata curation

Administration

Monitoring

Jobs explorer

Capacity management

BI Engine

Partner Center

Settings Preview

Release Notes

<I

Explorer

+ Add data

<

Search BigQuery resources

Show starred only

qwiklabs-gcp-04-0bb7ebc8...

Repositories

Queries

Notebooks

Untitled notebooks

Shared notebooks

ai-assisted-data-science

Data canvases

Data preparations

Pipelines

External connections

Repository

Preview

Repositories

Store code, edit files, and track changes using version control through repositories or via remote Git based repositories.

ai-assis... nce

Commands + Code + Text ▶ Run all

Table of contents

Multimodal Analysis and Vector Search with BigQuery ML

Overview

Setup

Create BigQuery Cloud resource connection

Configure environment and grant permissions

Enable interactive tables for DataFrames

Data Preparation and Feature Engineering

Load the raw data into a BigQuery table

Explore the data with ML.DESCRIBE_DATA

Clean, filter, and enrich the data


Variables

Terminal


Job history

4. 連線至執行階段並執行設定程式碼

1. 按一下「連結」，如果出現彈出式視窗，請使用您的使用者授權 Colab Enterprise。筆記本會自動連線至執行階段。這項作業可能需要幾分鐘才能完成。



2. 建立執行階段後，您會看到下列內容：



3. 在筆記本中，捲動至「設定」部分。按一下隱藏儲存格旁的「執行」按鈕。這會在專案中建立實驗室所需的幾項資源。這項程序可能需要一分鐘才能完成。在此期間，歡迎查看「設定」下方的儲存格。

> Setup

Before you can begin the analysis, you need creating a resource connection for BigQuery will use.

 ↪ 10 cells hidden

注意：開啟筆記本後，您現在主要會在 Colab Enterprise 環境中工作。筆記本包含整個工作流程的所有程式碼，以及每個儲存格的詳細說明。

本程式碼實驗室是高階指南，提供簡要摘要，協助您追蹤進度。

步驟 5 · 約 5 分鐘

5. 資料準備與特徵工程

在本節中，您將完成資料科學專案的第一個重要步驟：準備資料。首先，請建立 BigQuery 資料集來整理工作，然後將 Cloud Storage 中 CSV 檔案的原始房地產 / 房屋資料載入新資料表。

接著，您會將原始資料轉換為含有新特徵的清理後資料表。包括篩選房源資訊、建立新的 `property_age` 特徵，以及準備用於多模態分析的圖片資料。

步驟 6 · 約 5 分鐘

6. 使用 AI 函式進行多模態擴充

現在，您將運用生成式 AI 的強大功能充實資料。在本節中，您會使用 [BigQuery 的內建 AI 函式](#) 分析每個房屋物件的圖片。

將 BigQuery 連結至 [Gemini 模型](#)，即可直接透過 SQL 從圖片中擷取新的實用特徵 (例如房產是否靠近水域，以及房屋的簡短說明)。


步驟 7 · 約 5 分鐘

7. 使用 K-means 分群模型訓練模型


現在您已擁有經過擴增的資料集，可以開始建構機器學習模型。您的目標是將房屋物件分成不同群組，方法是使用 BigQuery 機器學習 (BQML) 直接在 BigQuery 中訓練 k-means 分群模型。在這個單一步驟中，您也會在 [Agent Platform AI Model Registry](#) 中註冊模型，讓模型立即在 Google Cloud 的廣泛 MLOps 生態系統中可用。

如要確認模型是否已成功註冊，請按照下列步驟在 Agent Platform Model Registry 中尋找模型：


1. 前往 Google Cloud 控制台，點選左上角的「導覽選單」圖示 (≡)。
2. 捲動至「代理程式平台」部分，然後點選「模型」。



3. 按一下螢幕截圖中標示的「Model Registry」按鈕。



4. 您會看到 BQML 模型與其他所有自訂模型一起列出。在模型清單中，找出名為「housing_clustering」
housing_clustering的模型。您可以採取下一步，[部署至端點](#)，讓模型在 BigQuery 環境以外提供即時線上預測。



探索 Model Registry 後，您可以按照下列步驟返回 BigQuery 中的 Colab 筆記本：

1. 在「導覽選單」(≡) 中，依序前往「BigQuery」>「Studio」。
2. 展開「探索」窗格中的選單，找出並開啟筆記本。

步驟 8 · 約 5 分鐘

8. 模型評估與預測

訓練模型後，下一步是瞭解模型建立的叢集。您可以使用 `ML.EVALUATE` 和 `ML.CENTROIDS` 等 BigQuery 機器學習函式，分析模型的品質和各區隔的定義特徵。

然後使用 `ML.PREDICT` 將每個住家指派給叢集。使用 `%%bigquery df` magic 指令執行這項查詢，即可將結果儲存在名為 `df` 的 pandas DataFrame 中。這樣一來，後續的 Python 步驟就能立即使用資料。這凸顯了 Colab Enterprise 中 SQL 和 Python 之間的互通性。

步驟 9 · 約 5 分鐘

9. 視覺化及解讀叢集

預測結果現在已載入 `DataFrame`，您可以建立視覺化效果，讓資料變得生動有趣。在本節中，您將使用 `Matplotlib` 等熱門 Python 程式庫，探索不同房屋區隔之間的差異。

您將建立盒鬚圖和長條圖，以視覺化方式比較價格和房產屋齡等重要特徵，輕鬆直覺地瞭解每個叢集。

10. 使用 Gemini 模型生成叢集說明

雖然數值重心和圖表功能強大，但生成式 AI 可讓您更進一步，為每個房屋區隔建立豐富的質性人物角色。這有助於瞭解叢集內容，以及叢集代表的對象。

在本節中，您會先彙整每個叢集的平均統計資料，例如價格和面積。接著，您會將這項資料傳遞至 Gemini 模型的提示。接著，指示模型扮演房地產專業人士，生成詳細摘要，包括各區隔的主要特徵和目標買家。結果會是一組清楚易懂的說明，行銷團隊可立即瞭解並採取行動。


您可以視需要修改提示，並嘗試生成結果！

11. 使用資料科學代理自動建立模型


現在，我們將探索強大的替代工作流程。您不必手動編寫程式碼，只要使用整合式 [資料科學代理](#)，就能透過單一自然語言提示，自動產生完整的叢集模型工作流程。

請按照下列步驟，使用代理程式生成及執行模型：


1. 在 **BigQuery Studio** 窗格中，按一下下拉式箭頭按鈕，將游標懸停在「Notebook」上，然後選取「Empty Notebook」。這樣可確保代理程式的程式碼不會干擾原始實驗室筆記本。



2. 資料科學代理的即時通訊介面會在筆記本底部開啟。按一下「移至面板」按鈕，將對話固定在右側。



3. 在即時通訊窗格中輸入 `@listing_multimodal`，然後按一下資料表。這會明確將 `listings_multimodal` 資料表設為脈絡。



4. 複製下列提示詞並輸入至 Agent Chat 方塊。然後按一下「傳送」，將提示詞提交給 Agent。

Use the selected table to generate a k-means clustering model with 3 clusters for housing listings. Then, help me understand the characteristics of each cluster so I can market to them as a real estate professional. Use Python.

Save Schedule Share Connect ▾ | ⚙️ ✦ ▾

Gemini ✕

⋮

Hello, student

How can I help you today?

Forecast with BigQuery ML

Create embeddings on my table

Load data as Spark Dataframe

🔍 qwiklabs-gcp-02-d39f93c4ca90.housing_dataset.listings_multimodal ✕

Use the selected table to generate a k-means clustering model with 3 clusters for housing listings. Then, help me understand the characteristics of each cluster so I can market to them as a real estate professional. Use Python.

⊕

▶

Send

5. 代理程式會思考並制定計畫。如果對這項計畫沒有異議，請按一下「接受並執行」。代理會在一個或多個新儲存格中生成 Python 程式碼。

The screenshot shows a Jupyter Notebook interface with a Gemini AI assistant panel. The panel displays a list of tasks: Feature Selection and Preprocessing, K-Means Clustering, Cluster Analysis, and Finish task. A red box highlights the 'Accept & Run' button.

```
import pandas as pd
from google.cloud import bigquery

# Initialize a BigQuery client
client = bigquery.Client()

# Define the SQL query
sql_query = """
SELECT *
FROM `qwiklabs-gcp-02-d39f93c4ca90.housing_dataset.listings`
"""

# Execute the query and load the results into a pandas DataFrame
df = client.query(sql_query).to_dataframe()

# Display the first 5 rows of the DataFrame
print("Data loaded successfully. First 5 rows:")
print(df.head())
```

Generating...

- ✓ Preparing
- ▢ Data Loading (Waiting on user input...)
- 🕒 Feature Selection and Preprocessing
- 🕒 K-Means Clustering
- 🕒 Cluster Analysis
- 🕒 Finish task

👍 🔄

▶ Accept & Run ✕ Cancel

What can I help you build?

7. 完成後，只要關閉這個新筆記本分頁，然後返回原始的 `ai-assisted-data-science.ipynb` 分頁，即可繼續完成實驗室的最後一個部分。

12. 使用嵌入和向量搜尋功能進行多模態搜尋

在最後一節中，您將直接在 BigQuery 中導入多模態搜尋功能。因此可以進行直覺式搜尋，例如根據文字說明尋找房屋，或是尋找與範例圖片相似的房屋。

這個程序會先將每張房屋圖片轉換為稱為「嵌入」的數字表示法，嵌入會擷取圖片的語意，讓您透過比較數值向量找出相似項目。

您將使用 [multimodalembembedding](#) 模型，為所有商店資訊產生這些向量。建立向量索引來加快查詢速度後，您就可以執行兩種相似度搜尋：文字轉圖像 (尋找符合描述的房屋) 和圖像轉圖像 (尋找與範例圖片相似的房屋)。

您將在 BigQuery 中完成所有作業，使用 [ML.GENERATE_EMBEDDING](#) 等函式生成嵌入，或使用 [VECTOR_SEARCH](#) 執行相似度搜尋。

13. 清除

如要清理此專案中使用的所有 Google Cloud 資源，請[刪除 Google Cloud 專案](#)。

或者，您也可以在筆記本的新儲存格中執行下列程式碼，刪除您建立的個別資源：

```
# Delete the BigQuery tables
!bq rm --table -f housing_dataset.listings
!bq rm --table -f housing_dataset.listings_multimodal
!bq rm --table -f housing_dataset.home_embeddings

# Delete the remote model
!bq rm --model -f housing_dataset.gemini
!bq rm --model -f housing_dataset.kmeans_clustering_model
!bq rm --model -f housing_dataset.multimodal_embedding_model

# Delete the remote connection
!bq rm --connection --project_id=$PROJECT_ID --location=us ai_connection

# Delete the BigQuery dataset
!bq rm -r -f $PROJECT_ID:housing_dataset
```

最後，你可以刪除筆記本本身：

1. 在 BigQuery Studio 的「Explorer」窗格中，展開專案和「Notebooks」節點。
 2. 按一下 `ai-assisted-data-science` 筆記本旁的三個垂直圓點。
 3. 選取 [刪除]。
-

步驟 14 · 約 1 分鐘

14. 恭喜！

恭喜您完成本程式碼研究室！

涵蓋內容

- 準備房地產資訊的原始資料集，透過特徵工程進行分析。
 - 使用 BigQuery 的 AI 函式分析房屋相片，找出主要視覺特徵，**豐富房源資訊**。
 - 使用 BigQuery Machine Learning (BQML) **建構及評估 K-means 模型**，將房源劃分為不同叢集。
 - 使用資料科學代理程式以 Python 產生叢集模型，**自動建立模型**。
 - **生成房屋圖片的嵌入內容**，為影像搜尋工具提供支援，透過文字或圖片查詢尋找相似房屋。
-