

運用 GKE 和 Gemini CLI 打造平台工程 AI

來源：<https://codelabs.developers.google.com/codelabs/gke/platform-engineering-ai-tools?hl=zh-tw>

步驟數：7

本實驗室將引導您使用 Gemini CLI 和 GKE Model Context Protocol (MCP) 伺服器，以自然語言佈建叢集、部署經過稽核的資訊清單，以及排解 Kubernetes 工作負載問題。

目錄

1. [1. 簡介](#)
2. [2. 專案設定](#)
3. [3. 設定 Gemini CLI](#)
4. [4. 佈建基礎架構](#)
5. [5. 部署與驗證](#)
6. [6. 維護與疑難排解](#)
7. [7. 結論](#)

1. 簡介

本實驗室將從技術層面介紹如何使用 Gemini CLI 和 GKE Model Context Protocol (MCP) 伺服器管理基礎架構。在傳統的 GKE 管理中，運算子會手動將基礎架構需求轉換為 `gcloud` 指令，並將應用程式定義轉換為 YAML 資訊清單。本實驗室將示範另一種做法：使用互動式介面，在 [Google Kubernetes Engine \(GKE\)](#) 上，將自然語言意圖與技術執行作業連結起來。這項轉變是平台工程領域的廣泛趨勢之一，重點從建構嚴格的自動化指令碼，轉移到管理智慧代理程式，以處理基礎架構作業的細微細節。

核心概念

- **平台工程**：這項實務做法是建構及維護內部工具和工作流程，讓軟體開發人員管理自己的基礎架構，不必精通所有基礎雲端服務。目標是減少技術阻礙，同時維持一致性和安全性。平台團隊建立標準化的黃金路徑，可確保應用程式開發人員安全快速地部署，同時平台團隊也能控管治理和成本。
- **Gemini CLI**：這是指令列介面，可讓您直接透過終端機與 Gemini 模型互動。與標準網路聊天機器人不同，CLI 專為開發環境而設計，可輕鬆將 AI 整合至現有的殼層工作流程。您可以直接將其他指令的輸出內容傳送至模型，並在不離開終端機環境的情況下執行指令。
- **Model Context Protocol (MCP)**：MCP 是一項開放標準，可讓 AI 模型連結特定工具或資料來源。如果沒有 MCP，AI 模型只會知道訓練內容，無法查看特定資源。有了 [GKE MCP 伺服器](#)，Gemini CLI 就能主動查詢 Google Cloud 專案的 API、檢查叢集狀態，並代表您執行指令。可做為模型推論引擎與實際 GKE API 之間的橋樑。

實驗室目標

完成本課程後，您將能夠：

1. **設定環境**：存取 Cloud Shell 並驗證 GKE MCP 擴充功能，允許 Gemini CLI 與 Google Cloud 資源互動。
 2. **基礎架構設計**：使用互動式提示，根據成本、管理負擔和工作負載需求，決定最佳叢集設定。
 3. **資源管理**：使用自然語言產生、稽核及部署 [Kubernetes 資訊清單 \(Deployment、Service 等\)](#)。
 4. **作業分析**：運用 AI 匯總記錄和事件的能力，找出部署失敗的根本原因，並建議具體的技術修正措施。
-

2. 專案設定

Gemini CLI 必須先與資源互動，因此請務必正確設定 Google Cloud 環境。這項設定可確保專案具備正確的權限，且所有必要的後端服務都已準備好接收 AI 代理程式的要求。

開啟 Cloud Shell

在本實驗室中，我們將使用 Google Cloud 提供的瀏覽器型終端機環境 **Cloud Shell**。我們使用 Cloud Shell，是因為它已預先設定所有需要的工具，包括 **Google Cloud CLI (gcloud)**、**kubectl** 和 Gemini CLI，可節省您在本機安裝這些工具的時間。

1. 前往 [Google Cloud 控制台](#)。
2. 查看控制台右上方的標題，然後點擊「啟用 Cloud Shell」按鈕 (看起來像終端機提示 `>_`)。
3. 瀏覽器視窗底部會開啟終端機工作階段。如果出現提示訊息，請點選「繼續」。

選取專案

在 Cloud Shell 終端機中，確認您正在正確的專案中作業。

1. 在控制台中選取現有專案，或專為本實驗建立新專案。
2. 記下您的**專案 ID**。如要在目前的殼層中設定專案，請執行：`gcloud config set project [YOUR_PROJECT_ID]`

啟用 API

新專案預設不會啟用 Kubernetes 和 AI 功能。啟用這些 API 會初始化處理容器管理、生成模型和集中式記錄的基礎 Google Cloud 服務。

👉 在 **Cloud Shell** 中執行下列指令，即可啟用這些 API。這項程序可能需要一分鐘才能完成。

〇〇〇〇

```
gcloud services enable \  
  container.googleapis.com \  
  generativelanguage.googleapis.com \  
  cloudresourcemanager.googleapis.com \  
  logging.googleapis.com
```

- **container.googleapis.com**:Google Kubernetes Engine API。您必須擁有這項權限，才能執行任何叢集層級的作業，包括建立、更新及刪除叢集。
 - **generativelanguage.googleapis.com**:這項 API 可讓 Gemini CLI 與 Gemini 大型語言模型通訊，以生成文字和進行推理。
 - **cloudresourcemanager.googleapis.com**:代理程式需要這項權限，才能檢查專案層級的中繼資料、驗證專案 ID，以及管理 IAM 權限。
 - **logging.googleapis.com**:這項服務對於疑難排解至關重要，因為當發生問題時，MCP 伺服器可藉此從容器擷取及分析記錄。
-

步驟 3 · 約 0 分鐘

3. 設定 Gemini CLI

Cloud Shell 預設包含 Gemini CLI，因此是這個工作流程的理想環境。首先，請將其設定為「代理程式」，具備管理 GKE 環境所需的授權和特定工具。這項設定步驟至關重要，因為它會在 AI 的邏輯與實際雲端基礎架構之間建立安全連線。

啟動 Gemini CLI

在 **Cloud Shell** 終端機中，建立新的工作目錄並執行 Gemini CLI。這會啟動工作階段，讓您與模型持續對話。與一次性指令不同，互動模式會保留內容視窗，記住您先前的指令和專案狀態。

👉 執行下列指令：

```
mkdir -p ~/gke-lab
cd ~/gke-lab
gemini
```



進入後，請測試工具的基本感知能力，確保工具能看到您的環境：

- 👉 提示：Which Google Cloud project is currently active in this shell?

系統可能會要求您確認執行 `gcloud` 指令，您可以接受要求。

如要隨時離開介面，請輸入 `/quit`。

注意：如果 Gemini 2.5 Pro 的用量達到上限，請開啟 Gemini with

```
gemini -m gemini-2.5-flash
```

或使用

```
/model
```

指令。

連結 GKE MCP 擴充功能

根據預設，Gemini CLI 是一般用途工具，不具備與叢集互動的特定知識。您必須安裝 [GKE MCP 擴充功能](#)。這個擴充功能會做為外掛程式，定義一組特定工具和函式 (例如「列出叢集」或「取得 Pod 記錄」)，模型需要執行工作時可以呼叫這些工具和函式。

👉 執行下列指令，安裝 GKE 擴充功能並重新開啟 Gemini CLI：

```
gemini extensions install https://github.com/GoogleCloudPlatform/gke-mcp.git  
gemini
```

如要確認是否已正確啟用，請重新進入 Gemini CLI 並輸入：

```
/extensions
```

4. 佈建基礎架構

傳統基礎架構佈建通常需要瀏覽複雜的文件，或編寫數百行的設定程式碼。使用代理程式時，您可以專注於描述需求，讓 AI 處理技術翻譯，轉換成正確的 API 呼叫。本節說明如何在規劃階段和實際建立 GKE 環境時使用代理程式。

技術規劃與比較

建立叢集前，請先選擇符合需求的架構。GKE 提供兩種主要模式：[標準](#)模式可讓您完全掌控基礎節點，[Autopilot](#) 模式則由 Google 管理節點，您只需根據 Pod 要求的資源付費。讓我們試試簡單的查詢，瞭解兩者之間的差異，並針對特定用途集思廣益，決定要使用哪一個。

- 👉💬 **提示：** `I need to run a standard 3-tier web application. Compare GKE Standard and GKE Autopilot. Focus on the operational effort for a small team and the cost structure for small workloads.`

請嘗試詢問其他基礎架構構想。如果您要部署 AI 推論工作負載、需要極大規模的資源，或是受到複雜的網路限制，該怎麼辦？嘗試使用其他提示。

執行叢集建立作業

比較完畢並做出選擇後，即可指示智慧助理建立叢集。代理程式會分析您的要求，並從 GKE MCP 伺服器呼叫 `create_cluster` 工具，根據這些要求部署可供正式環境使用的環境。

- 👉💬 **提示：** `Create a GKE Standard zonal cluster named 'gke-lab' in us-central1-a with 1 node with 4 CPUs. The cluster should have Workload Identity enabled.`

注意：佈建 GKE 叢集時，系統會設定控制層、虛擬私人網路和初始節點設定，通常需要 8 到 10 分鐘。請勿關閉 Gemini CLI 工作階段。

您可以詢問叢集狀態，這會再次利用 GKE MCP 伺服器傳回最新資訊。

- 👉💬 **提示：** `Is the new GKE cluster created and ready to use, yet?`
-

5. 部署與驗證

使用 AI 代理程式進行平台工程的主要優點，是能夠對設定執行「預檢」檢查和稽核。您可以使用代理程式驗證 YAML 在技術上是否正確，以及是否符合貴機構的安全性政策，不必部署資訊清單並等待失敗。

產生資訊清單

請代理建立部署資訊清單。由於代理程式瞭解 Kubernetes API 版本管理和結構定義，因此會產生格式正確的 YAML，並包含成功部署所需的所有欄位。

- 👉💬 提示：`Generate a Kubernetes YAML manifest for an Nginx web server. I need 3 replicas. Set a memory limit of 256Mi and a CPU limit of 500m. Also, include a Service of type LoadBalancer to make it accessible via the internet. Save the manifest as web-server.yaml`

技術驗證和安全稽核

手動建立 YAML 時，設定通常會以超出必要範圍的權限執行，或缺少基本的可靠性功能。您可以透過代理程式稽核剛建立的資訊清單，確保符合現代安全和復原標準。

- 👉💬 提示：`Review the Nginx manifest you just created. Does it include resource requests (not just limits)? Does it specify a non-root user for the container? Add a Pod Disruption Budget to ensure high availability during cluster maintenance. Make any necessary modifications to the file, and tell me what changes were made.`

部署作業執行

完成上一節的叢集佈建後，請告知 Gemini CLI 將設定套用至新叢集。代理程式會使用工具與 Kubernetes API 伺服器通訊，並建立所要求的資源。

- 👉💬 提示：`Deploy the audited Nginx manifest to the 'gke-lab' cluster. Use the kubectl command to do this.`

即時狀態檢查

不必執行多個 `kubectl get pods` 或 `kubectl describe` 指令，只要以自然語言詢問代理，就能取得部署進度的摘要。

- 👉💬 提示：`Are the Nginx pods running? Provide the external IP address assigned to the LoadBalancer once it is available.`

卡關了嗎？

如果 Nginx 服務似乎無法順利部署，請嘗試使用 Gemini CLI 排解問題。這項功能可協助你！

- 👉💬 提示：`The Nginx deployment doesn't start up as expected. Can you help troubleshoot?`
-

6. 維護與疑難排解

AI 輔助平台最有價值的優點之一，就是「第 2 天」作業功能。系統發生故障時，往往需要從成千上萬的記錄行中，找出重要的錯誤。搭配使用 Gemini CLI 和 MCP，即可讓代理程式彙整記錄、事件和狀態訊息，為您提供高階診斷結果和具體的解決途徑。

手動注入失敗

為測試代理程式的診斷能力，我們將刻意建立失敗狀態。在另一個終端機分頁中，執行這項指令，使用不存在的容器映像檔更新部署作業。這會模擬常見的人為錯誤：容器代碼中的錯字。

👉 在 Gemini CLI 外部執行下列指令：

```
kubectl set image deployment/nginx nginx=nginx:invalid-version-xyz123
```

注意：您的部署作業可能不會稱為「nginx」。您可以執行

```
kubectl get deployments
```

Kubernetes 會嘗試提取這個映像檔，但由於找不到標記而失敗，Pod 也會進入 `ImagePullBackOff` 狀態。

使用 Gemini CLI 進行分析

返回 Gemini CLI 工作階段。不必手動搜尋 [Cloud Logging](#) 控制台，只要請代理程式找出並說明錯誤即可。

- 👉 提示： `The Nginx deployment on my 'gke-lab' cluster has stopped working. Use your tools to inspect the cluster state, check the recent events, and explain exactly why the pods are failing to start.`

後續情形：Gemini CLI 會發現部署作業不正常，然後使用可用工具檢查失敗的 Pod。服務專員會找出提取錯誤，說明標記無效，並建議您還原為已知良好的映像檔。

維護與風險評估

平台維護作業包括提前因應升級和淘汰作業。您可以要求代理程式擔任 SRE，並評估叢集的健康狀態和使用壽命。

- 👉 提示： `Is my cluster 'gke-lab' running the latest version of GKE? Check for available upgrades and let me know if any of my current resources use deprecated APIs that would break during an upgrade.`

這可能會導致 Gemini 呼叫叢集狀態和建議工具等 GKE MCP 伺服器工具。

7. 結論

本實驗室示範了與雲端基礎架構互動的新方式。透過 Gemini CLI 和 MCP，將 AI 代理直接整合至終端機工作流程後，您就能從手動編寫指令，轉變為意圖導向的作業模式。平台團隊可透過這種方式擴展專業知識，因為智慧型介面會處理 Kubernetes 管理中重複且容易出錯的細節，而工程師則專注於高階架構和解決問題。

實驗室摘要

- **連線：**您已使用 Model Context Protocol 將 Gemini CLI 連線至 GKE API，讓 AI 模型直接瞭解專案狀態。
- **基礎架構：**您使用自然語言設計及佈建 GKE 叢集，不必記住複雜的 CLI 旗標。
- **開發：**您產生、稽核安全性並部署 Kubernetes 資源，過程中完全不需手動編輯 YAML，確保從一開始就遵循最佳做法。
- **營運：**您使用 AI 對故障的部署作業進行根本原因分析，讓 AI 摘要記錄和事件，大幅縮短平均復原時間。

清除所用資源

如要避免系統持續向您的 Google Cloud 帳戶收取本實驗室所建資源的費用，請指示代理程式刪除叢集。

注意：如果您打算將 GKE 叢集用於其他實驗室，請略過這個步驟。

- 🗑️ 提示：Delete the 'gke-lab' cluster and any associated resources.

後續步驟

建議延伸閱讀：

- [Gemini CLI 說明文件](#)：Gemini CLI 的官方說明文件。
 - [GKE 說明文件](#)：所有 GKE 說明文件的到達網頁。
 - [Google Cloud 平台工程](#)：說明如何在 Google Cloud 上進行平台工程。
 - [GKE 上的 AI 和機器學習](#)：說明如何在 GKE 上執行 AI/機器學習工作負載的文件。
 - [Google Cloud Architecture Center](#)：在 Google Cloud 上建構工作負載的指南和最佳做法。
-