

告別迴圈，高效處理百萬向量：運用 AlloyDB 大規模生成嵌入項目

來源：<https://codelabs.developers.google.com/embeddings-at-scale-with-alloydb?hl=zh-tw>

步驟數：8


在本程式碼研究室中，您將瞭解如何使用 AlloyDB AI 的批次處理功能，大規模生成向量嵌入。

目錄

1. [總覽](#)
2. [事前準備](#)
3. [資料庫設定](#)
4. [結構定義佈建](#)
5. [「單次」向量生成](#)
6. [彈性情境搜尋](#)
7. [清除所用資源](#)
8. [恭喜](#)

1. 總覽

在本程式碼研究室中，您將建構可擴充的知識庫搜尋應用程式。您不必使用 Python 指令和迴圈管理複雜的 ETL 管道來生成向量嵌入，而是使用 AlloyDB AI，透過單一 SQL 指令在資料庫中原生處理嵌入生成作業。



建構項目

高效能「可搜尋」知識庫資料庫應用程式。

課程內容

您將學習下列內容：

- 佈建 AlloyDB 叢集並啟用 AI 擴充功能。
- 使用 SQL 產生合成資料 (50,000 列以上)。
- 使用批次處理功能，為整個資料集回填向量嵌入。
- 設定即時增量觸發條件，自動嵌入新資料。
- 對「Flexing Context」執行混合搜尋 (向量 + SQL 篩選器)。

需求條件

- 瀏覽器，例如 [Chrome](#) 或 [Firefox](#)。
- 已啟用計費功能的 Google Cloud 專案。
- 對 SQL 有基本瞭解。

步驟 2 · 約 0 分鐘

2. 事前準備

從做中學 免付費

立即取得 Google Cloud 抵免額，並完成這個實驗室。無須提供信用卡或付款方式。

info

從做中學 免付費

立即取得 Google Cloud 抵免額，並完成這個實驗室。無須提供信用卡或付款方式。

啟用

建立專案

1. 在 [Google Cloud 控制台](#) 的專案選取器頁面中，選取或建立 Google Cloud [專案](#)。
2. 確認 Cloud 專案已啟用計費功能。瞭解如何[檢查專案是否已啟用計費功能](#)。
3. 您將使用 [Cloud Shell](#)，這是 Google Cloud 中執行的指令列環境。點選 Google Cloud 控制台頂端的「啟用 Cloud Shell」。



4. 連至 Cloud Shell 後，請使用下列指令確認驗證已完成，專案也已設為獲派的專案 ID：

〇〇〇〇

```
gcloud auth list
```

5. 在 Cloud Shell 中執行下列指令，確認 gcloud 指令已瞭解您的專案。

〇〇〇〇

```
gcloud config list project
```

6. 如果未設定專案，請使用下列指令來設定：

```
gcloud config set project <YOUR_PROJECT_ID>
```

7. 啟用必要的 API：按照[這個連結](#)啟用 API。

或者，您也可以使用 gcloud 指令執行這項操作。如要瞭解 gcloud 指令和用法，請參閱[說明文件](#)。

```
gcloud services enable \  
  alloydb.googleapis.com \  
  compute.googleapis.com \  
  cloudresourcemanager.googleapis.com \  
  servicenetworking.googleapis.com \  
  aiplatform.googleapis.com
```

常見錯誤與疑難排解

「幽靈專案」症候群	您執行了 <code>gcloud config set project</code> ，但實際上在控制台 UI 中查看的是其他專案。檢查左上方的下拉式選單中的專案 ID！
帳單 路障	您已啟用專案，但忘記帳單帳戶。AlloyDB 是高效能引擎，如果「油箱」(帳單) 空了，就無法啟動。
API 傳播 延遲	您點選了「啟用 API」，但指令列仍顯示 <code>Service Not Enabled</code> 。等待 60 秒。雲端需要一點時間喚醒神經元。
配額 Quags	如果您使用全新的試用帳戶，可能會達到 AlloyDB 執行個體的區域配額。如果 <code>us-central1</code> 失敗，請嘗試 <code>us-east1</code> 。
「隱藏」服務專員	有時系統不會自動將 <code>aiplatform.user</code> 角色授予 AlloyDB 服務代理。如果 SQL 查詢稍後無法與 Gemini 對話，通常就是這個原因。

3. 資料庫設定

在本實驗室中，我們會使用 AlloyDB 做為測試資料的資料庫。並使用「叢集」保存所有資源，例如資料庫和記錄檔。每個叢集都有一個「主要執行個體」，可做為資料的存取點。資料表會保存實際資料。

我們來建立 AlloyDB 叢集、執行個體和資料表，以便載入測試資料集。

1. 按一下按鈕，或將下方連結複製到已登入 Google Cloud 控制台使用者的瀏覽器。
2. 完成這個步驟後，存放區會複製到本機 Cloud Shell 編輯器，您就能從專案資料夾執行下列指令 (請務必確認您位於專案目錄中)：

```
sh run.sh
```

3. 現在請使用 UI (按一下終端機中的連結，或按一下終端機中的「preview on web」連結)。
4. 輸入專案 ID、叢集和執行個體名稱的詳細資料，即可開始使用。
5. 在記錄捲動時去買杯咖啡吧！如要瞭解系統在幕後如何執行這項操作，請參閱這篇文章。這個過程大約需要 10 到 15 分鐘。

重要事項：如要在本機或從任何位置進行測試，請前往 AlloyDB 執行個體，按一下「EDIT」，然後按一下「Enable Public IP」或「Public IP Connectivity」(不是輸出 IP)，並在「Authorized External Networks」中輸入「0.0.0.0/0」，以供開發用途。完成後，請移除並停用公開 IP 連線。


常見錯誤與疑難排解

「耐心」問題	資料庫叢集是龐大的基礎架構，如果因為「看起來卡住」而重新整理頁面或終止 Cloud Shell 工作階段，您可能會得到「虛擬」執行個體，這類執行個體已部分佈建，但必須手動介入才能刪除。
區域不符	如果您在 us-central1 中啟用 API，但嘗試在 asia-south1 中佈建叢集，可能會遇到配額問題或服務帳戶權限延遲。整個實驗室都使用同一個區域！
殭屍叢集	如果您先前使用過相同名稱的叢集，但未刪除，指令碼可能會顯示叢集名稱已存在。叢集名稱在專案內不得重複。
Cloud Shell 超時	如果咖啡休息時間為 30 分鐘，Cloud Shell 可能會進入休眠狀態，並中斷 sh run.sh 程序。請保持分頁啟用狀態！


步驟 4 · 約 0 分鐘

4. 結構定義佈建

本步驟將涵蓋下列內容：




AlloyDB 叢集和執行個體啟動後，請前往 AlloyDB Studio SQL 編輯器啟用 AI 擴充功能，並佈建結構定義。



您可能需要等待執行個體建立完成。完成後，請使用建立叢集時建立的憑證登入 AlloyDB。使用下列資料向 PostgreSQL 進行驗證：

- 使用者名稱：「`postgres`」
- 資料庫：「`postgres`」
- 密碼：「`alloydb`」(或您在建立時設定的密碼)

成功驗證 AlloyDB Studio 後，即可在編輯器中輸入 SQL 指令。如要新增多個編輯器視窗，請按一下最後一個視窗右側的加號。



您會在編輯器視窗中輸入 AlloyDB 指令，並視需要使用「執行」、「格式化」和「清除」選項。

啟用擴充功能

我們會使用 `pgvector` 和 `google_ml_integration` 擴充功能建構這個應用程式。[pgvector 擴充功能](#)可讓您儲存及搜尋向量嵌入。[google_ml_integration](#) 擴充功能提供多種函式，可存取 Vertex AI 預測端點，在 SQL 中取得預測結果。執行下列 DDL，[啟用](#)這些擴充功能：

```
CREATE EXTENSION IF NOT EXISTS google_ml_integration CASCADE;  
CREATE EXTENSION IF NOT EXISTS vector;
```

建立資料表

我們需要資料集來展示規模。我們不會匯入 CSV 檔案，而是使用 SQL 立即產生 50,000 列合成的「說明文章」。

您可以在 AlloyDB Studio 中使用下列 DDL 陳述式建立資料表：

```
-- 1. Create the table
CREATE TABLE help_articles (
  id SERIAL PRIMARY KEY,
  title TEXT,
  category TEXT,
  product_version TEXT,
  content_body TEXT,
  embedding vector(768) -- Dimension for text-embedding-005
);

-- 2. Generate 50,000 rows of synthetic data
INSERT INTO help_articles (title, category, product_version, content_body)
SELECT
  'Help Article ' || i,
  CASE
    WHEN i % 3 = 0 THEN 'Billing'
    WHEN i % 3 = 1 THEN 'Technical'
    ELSE 'General'
  END,
  CASE
    WHEN i % 2 = 0 THEN '2.0'
    ELSE '1.0'
  END,
  'This article covers common issues regarding ' ||
  CASE
    WHEN i % 3 = 0 THEN 'payment failures, invoice disputes, and credit card updates.'
    WHEN i % 3 = 1 THEN 'connection timeouts, latency issues, and API errors.'
    ELSE 'account profile settings, password resets, and user roles.'
  END
FROM generate_series(1, 50000) AS i;
```

`item_vector` 欄可儲存文字的向量值。

驗證資料：

```
SELECT count(*) FROM help_articles;
-- Output: 50000
```

啟用資料庫旗標

前往執行個體設定控制台，按一下「編輯主要」，然後前往「進階設定」，並點選「新增資料庫旗標」。

1. 確認 `google_ml_integration.enable_model_support` 旗標已設為「開啟」：

如果沒有，請在旗標下拉式選單中輸入，並設為「開啟」，然後更新執行個體。

2. 確認 `google_ml_integration.enable_faster_embedding_generation` 旗標已設為啟用：

如果沒有，請在旗標下拉式選單中輸入，並設為「開啟」，然後更新執行個體。

設定資料庫旗標的步驟：

1. 前往 Google Cloud 控制台的「叢集」頁面。

[前往「Clusters」\(叢集\) 頁面](#)

2. 按一下「資源名稱」欄中的叢集。
3. 在「總覽」頁面中，前往叢集中的「執行個體」，選取執行個體，然後按一下「編輯」。
4. 從執行個體新增、修改或刪除資料庫旗標：

新增旗標

1. 如要為執行個體新增資料庫旗標，請按一下「新增旗標」。
2. 從「New database flag」(新資料庫旗標) 清單中選取旗標。
3. 提供旗標值。
4. 按一下 [完成]。
5. 按一下「更新執行個體」。
6. 確認 **google_ml_integration** 擴充功能為 1.5.2 以上版本：

如要使用下列指令檢查擴充功能版本：

```
SELECT extversion FROM pg_extension WHERE extname = 'google_ml_integration';
```

如要將擴充功能更新至較高版本，請使用下列指令：

```
ALTER EXTENSION google_ml_integration UPDATE;
```

授予權限

1. 如要讓使用者管理自動產生嵌入內容，請授予 **google_ml.embed_gen_progress** 和 **google_ml.embed_gen_settings** 資料表的 INSERT、UPDATE 和 DELETE 權限：

```
GRANT INSERT, UPDATE, DELETE ON google_ml.embed_gen_progress TO postgres;
```

「postgres」是獲得權限的 **USER_NAME**。

2. 執行下列陳述式，授予「embedding」函式的執行權：

```
GRANT EXECUTE ON FUNCTION embedding TO postgres;
```

為 AlloyDB 服務帳戶授予 Vertex AI 使用者角色

在 **Google Cloud IAM 控制台** 中，將「Vertex AI 使用者」角色授予 AlloyDB 服務帳戶 (看起來像這樣：service-**<<PROJECT_NUMBER>>**@gcp-sa-alloydb.iam.gserviceaccount.com)。PROJECT_NUMBER 會顯示您的專案編號。

或者，您也可以從 Cloud Shell 終端機執行下列指令：

```
PROJECT_ID=$(gcloud config get-value project)

gcloud projects add-iam-policy-binding $PROJECT_ID \
  --member="serviceAccount:service-$(gcloud projects describe $PROJECT_ID --
format="value(projectNumber)")@gcp-sa-alloydb.iam.gserviceaccount.com" \
  --role="roles/aiplatform.user"
```

常見錯誤與疑難排解

「密碼失憶」迴圈	如果您使用「一鍵」設定，但忘記密碼，請前往控制台的「執行個體基本資訊」頁面，然後按一下「編輯」重設 <code>postgres</code> 密碼。
「找不到擴充功能」錯誤	如果 <code>CREATE EXTENSION</code> 失敗，通常是因為執行個體仍處於初始佈建的「維護」或「更新」狀態。檢查執行個體建立步驟是否完成，視需要等待幾秒鐘。

5. 「單次」向量生成

這是實驗室的核心。我們不會編寫 Python 迴圈來處理這 50,000 列，而是使用 `ai.initialize_embeddings` 函式。

這個單一指令會執行以下兩項作業：

1. 補充所有現有資料列。
2. 建立觸發條件，自動嵌入未來的資料列。

從 AlloyDB 查詢編輯器執行下列 SQL 陳述式

```
CALL ai.initialize_embeddings(  
  model_id => 'text-embedding-005',  
  table_name => 'help_articles',  
  content_column => 'content_body',  
  embedding_column => 'embedding',  
  incremental_refresh_mode => 'transactional'  
);
```

驗證嵌入

確認 `embedding` 欄位現在已填入：

```
SELECT id, left(content_body, 30), substring(embedding::text, 1, 30) as vector_partial  
FROM help_articles;
```

畫面會顯示類似以下的結果：

1 select * from help_articles

Results						Execution time: 11.4 ms		Export		
	id	title	category	product_version	content_body	embedding				
	501	Help...	General	1.0	This article c...	[-0.01130913,0.03717588,-0.018826906,0.028082764,0.02884				
	503	Help...	Technical	1.0	This article c...	[-0.01086893,0.03071511,-0.017373975,0.00106332,0.016466				
	001	Help...	Billing	1.0	This article c...	[-0.013845331,0.014893613,-0.036284603,0.014245588,0.014				
	002	Help...	Technical	2.0	This article c...	[-0.01086893,0.03071511,-0.017373975,0.00106332,0.016466				
	003	Help...	General	1.0	This article c...	[-0.01130913,0.03717588,-0.018826906,0.028082764,0.02884				
	004	Help...	Billing	2.0	This article c...	[-0.013845331,0.014893613,-0.036284603,0.014245588,0.014				

發生什麼事了？

1. 大規模回填：系統會自動掃描現有的 50,000 列，並透過 Vertex AI 生成嵌入項目。
2. 自動化：設定 `incremental_refresh_mode => 'transactional'` 後，AlloyDB 會自動設定內部觸發條件。插入 `help_articles` 的任何新資料列都會立即生成嵌入內容。
3. 您可以選擇設定 `incremental_refresh_mode => 'None'`，這樣您就只能取得陳述式來進行大量更新，並手動呼叫 `ai.refresh_embeddings()` 來更新所有資料列的嵌入。

您剛才只用 6 行 SQL 程式碼，就取代了 Kafka 佇列、Python 工作人員和遷移指令碼。如需所有屬性的詳細資料，請參閱 [官方說明文件](#)。

即時觸發測試

請確認「零迴圈」自動化功能是否適用於新資料。

1. 插入新資料列：

```
INSERT INTO help_articles (title, category, product_version, content_body)
VALUES ('New Scaling Guide', 'Technical', '2.0', 'How to scale AlloyDB to millions of transactions.');
```

2. 立即檢查：

```
SELECT embedding FROM help_articles WHERE title = 'New Scaling Guide';
```

結果：

您應該會看到系統立即生成向量，不必執行任何外部指令碼。

微調批次大小

目前 AlloyDB 預設的批量大小為 50。AlloyDB 預設設定已能提供絕佳效能，但使用者仍可自行調整，為獨特的模型和資料集設定最佳配置。

```
CALL ai.initialize_embeddings(
  model_id => 'text-embedding-005',
  table_name => 'help_articles',
  content_column => 'content_body',
  embedding_column => 'embedding',
  incremental_refresh_mode => 'transactional',
  batch_size => 20
);
```

不過，使用者必須注意配額限制，這可能會影響效能。如要查看建議的 AlloyDB 配額，請參閱[說明文件](#)的「事前準備」一節。

常見錯誤與疑難排解

IAM 傳播落差	您已執行 gcloud IAM 指令，但 SQL CALL 仍因權限錯誤而失敗。IAM 變更可能需要一段時間才會透過 Google 骨幹網路傳播。深呼吸。
向量維度不符	資料表 help_articles 的資料欄 content_body 已設為 VECTOR(768)。如果之後嘗試使用其他模型 (例如 1536 維度模型)，插入內容就會爆炸。請使用 text-embedding-005。

6. 彈性情境搜尋

現在執行**混合型搜尋**。我們結合語意理解 (向量) 和商業邏輯 (SQL 篩選條件)。

執行這項查詢，找出產品版本 2.0 的帳單問題：

```
SELECT
  title,
  left(content_body, 100) as content_snippet,
  1 - (embedding <=> embedding('text-embedding-005', 'Invoice did not go through'))::vector)
as relevance
FROM help_articles
WHERE category = 'Billing' -- Hard SQL Filter
      AND product_version = '2.0' -- Hard SQL Filter
ORDER BY relevance DESC
LIMIT 5;
```

這就是彈性背景資訊。搜尋功能會「彈性」解讀使用者意圖 (「帳單問題」)，同時遵守嚴格的業務限制 (2.0 版)。

1 SELECT

2 title,

3 left(content_body, 100) as content_snippet,

4 1 - (embedding <=> embedding('text-embedding-005', 'Invoice did not go through'))::vector) as relevance

Results

Execution time: 149.2 ms

Export

title	content_snippet	relevance	
Help Article 7506	This article covers common issues regarding payment failures, invoice disput...	0.681982344121198	▼
Help Article 10002	This article covers common issues regarding payment failures, invoice disput...	0.681982344121198	▼
Help Article 10008	This article covers common issues regarding payment failures, invoice disput...	0.681982344121198	▼
Help Article 12504	This article covers common issues regarding payment failures, invoice disput...	0.681982344121198	▼
Help Article 5004	This article covers common issues regarding payment failures, invoice disput...	0.681982344121198	▼

為何這項功能適合新創公司和遷移作業

- 1. 基礎架構債務為零：您並未啟動個別的向量資料庫 (Pinecone/Milvus)。您並未編寫獨立的 ETL 工作。一切都在 Postgres 中。
- 2. 即時更新：使用「交易」模式時，搜尋索引絕不會過時。資料一經提交，即可轉換為向量。
- 3. 擴充性：AlloyDB 建構在 Google 基礎架構上，與 Python 指令碼相比，這項功能可更快大量生成數百萬個向量。

常見錯誤與疑難排解

生產環境效能錯誤	問題：快速處理 50,000 列資料。如果類別篩選器不夠精確，100 萬列的查詢速度會非常緩慢。解決方法：新增向量索引：如要 正式運作 ，您必須建立索引：CREATE INDEX ON help_articles USING hnsw (embedding vector_cosine_ops); 驗證索引使用情形 ：執行 EXPLAIN ANALYZE SELECT ...，確保資料庫使用索引，而非進行循序掃描。
「模型不符」災難	問題：您在 CALL 程序中，使用 text-embedding-005 初始化資料欄。如果您在 SELECT 查詢函式 embedding('model-name', ...) 中誤用其他模型 (例如 text-embedding-004 或 OSS 模型)，維度可能會相符 (768)，但向量空間會完全不同。查詢會順利執行，但結果完全不相關 (關聯性分數為垃圾)。疑難排解：請確保 ai.initialize_embeddings 中的 model_id 與 SELECT 查詢中的 model_id 完全相符。

「無聲空白」結果 (過度篩選)	問題：混合型搜尋是「AND」運算。這需要語意比對和 SQL 比對。如果使用者搜尋「帳單說明」，但 <code>product_version</code> 欄有 <code>'2.0.1'</code> 而不是 <code>'2.0'</code>，即使向量比對為 99%，結果也會是零列。疑難排解： - 不要先執行向量排序，而是先執行查詢，看看 SQL 篩選器 (<code>WHERE category...</code>) 是否確實會傳回資料。 - 檢查是否區分大小寫 (<code>Billing</code> 與 <code>billing</code>)。
4. 權限/配額錯誤 (500 錯誤)	問題： <code>SELECT</code> 子句中的 <code>embedding()</code> 函式會即時呼叫 Vertex AI 網路。如果資料庫服務帳戶失去 Vertex AI 使用者 角色，或您達到 Vertex AI API 配額 (每分鐘查詢次數)，整個 SQL 查詢 就會失敗。疑難排解： - 檢查 AlloyDB 的 Cloud Logging。 - 確認 IAM 角色仍處於有效狀態。 - 如果需要高復原力，請在預存程序中將函式包裝在 <code>TRY/CATCH</code> 區塊中。
5. 空值嵌入	問題：如果在模型完全初始化「之前」插入資料，或背景工作站失敗，部分資料列的 <code>embedding</code> 欄可能會出現 <code>NULL</code>。 <code>NULL <=> Vector</code> 會傳回 <code>NULL</code>。這些資料列會從排序順序中消失。疑難排解： 執行 <code>SELECT count(*) FROM help_articles WHERE embedding IS NULL;</code>，確認涵蓋率為 100%。

步驟 7 · 約 0 分鐘

7. 清除所用資源

完成本實驗室後，別忘了刪除 AlloyDB 叢集和執行個體。

前往 <https://console.cloud.google.com/alloydb/clusters>。按一下要刪除的叢集旁的垂直省略號，然後按一下「刪除」。

這項作業應會清理叢集及其執行個體。

8. 恭喜

您已成功建構可擴充的知識庫搜尋應用程式。您不必使用 Python 指令碼和迴圈管理複雜的 ETL 管道來生成向量嵌入，而是使用 AlloyDB AI，透過單一 SQL 指令在資料庫中原生處理嵌入生成作業。

涵蓋內容

- 我們淘汰了用於資料處理的「Python For 迴圈」。
- 我們使用一個 SQL 指令產生了 50,000 個向量。
- 我們透過觸發條件自動生成未來的向量。
- 我們執行了混合型搜尋。

後續步驟

- 請使用自己的資料集試試看。
 - 請參閱 [AlloyDB AI 說明文件](#)。
 - 如要參加更多工作坊，請前往 [Code Vipassana](#) 網站。
-