

使用 BigQuery 從 Snowflake 至 Spanner 執行反向 ETL

來源：<https://codelabs.developers.google.com/snowflake-bigquery-spanner?hl=zh-tw>

步驟數：9

目錄

1. 使用 Google Cloud Storage 和 BigQuery，從 Snowflake 建構反向 ETL 管道至 Spanner
2. 設定、需求和限制
3. 建立 Google Cloud Storage 值區
4. 從 Snowflake 匯出至 GCS
5. 設定 BigQuery 外部資料表
6. 將資料從 BigQuery 匯入 Spanner：最後一個步驟
7. 驗證 Spanner 中的資料
8. 清除
9. 恭喜

1. 使用 Google Cloud Storage 和 BigQuery，從 Snowflake 建構反向 ETL 管道至 Spanner

簡介

在本程式碼研究室中，您將建構從 Snowflake 到 Spanner 的反向 ETL 管道。傳統上，ETL (擷取、轉換、載入) 管道會將資料從作業資料庫移至 Snowflake 等資料倉儲，以供分析。反向 ETL 管道則相反，會將經過處理的精選資料從資料倉儲移回營運系統，用於支援應用程式、提供使用者功能，或用於即時決策。

目標是將匯總資料集從 Snowflake Iceberg 資料表移至 Spanner。Spanner 是全球分散式關聯式資料庫，非常適合高可用性應用程式。

為此，我們使用 Google Cloud Storage (GCS) 和 BigQuery 做為中繼步驟。以下是資料流程的細目，以及此架構背後的理由：

1. 以 Iceberg 格式將 Snowflake 資料匯出至 Google Cloud Storage (GCS)：

- 第一步是以開放且定義完善的格式，將資料從 Snowflake 匯出。資料表會以 **Apache Iceberg** 格式匯出。這個程序會將基礎資料寫入一組 **Parquet** 檔案，並將資料表的中繼資料 (結構定義、分區、檔案位置) 寫入 **JSON** 和 **Avro** 檔案。在 GCS 中暫存這個完整的資料表結構，可讓資料可攜，且任何瞭解 Iceberg 格式的系統都能存取。

2. 將 GCS 中的 Iceberg 資料表轉換為 BigQuery BigLake 外部資料表：

- 您不必直接將資料從 GCS 載入 Spanner，而是使用 BigQuery 做為強大的中介服務。您將在 BigQuery 中建立 **BigLake** 外部資料表，直接指向 GCS 中的 Iceberg 中繼資料檔案。這種方法有幾個優點：
- **無資料重複**：BigQuery 會從中繼資料讀取資料表結構，並直接查詢 Parquet 資料檔案，不必擷取這些檔案，因此可大幅節省時間和儲存空間費用。
- **聯合查詢**：可讓您對 GCS 資料執行複雜的 SQL 查詢，就像查詢原生 BigQuery 資料表一樣。

3. BigQuery 至 Spanner：

- 最後一個步驟是將資料從 BigQuery 移至 Spanner。您將使用 BigQuery 的強大功能 (稱為「查詢」`EXPORT DATA`) 完成這項工作，也就是「反向 ETL」步驟。
- **運作準備**：Spanner 專為交易工作負載設計，可為應用程式提供同步一致性和高可用性。將資料移至 Spanner 後，需要低延遲點查的使用者導向應用程式、API 和其他作業系統，就能存取這些資料。
- **可擴充性**：這個模式可充分運用 BigQuery 的分析能力處理大型資料集，然後透過 Spanner 的全球可擴充基礎架構有效提供結果。

服務和術語

- **Snowflake** - 雲端資料平台，提供資料倉儲即服務。
- **Spanner** - 全代管的全球分散式關聯式資料庫。
- **Google Cloud Storage**：Google Cloud 的 Blob 儲存空間服務。
- **BigQuery** - 全代管的無伺服器資料倉儲，適用於資料分析。
- **Iceberg**：由 Apache 定義的開放式資料表格式，可針對常見的開放原始碼資料檔案格式提供抽象化功能。
- **Parquet**：Apache 的開放原始碼欄位式二進位資料檔案格式。

課程內容

- 如何將資料載入 Snowflake

- 如何建立 GCS 值區
 - 如何以 Iceberg 格式將 Snowflake 資料表匯出至 GCS
 - 如何設定 Spanner 執行個體
 - 如何將 BigQuery 中的 BigLake 外部資料表載入 Spanner
-

2. 設定、需求和限制

必要條件

- Snowflake 帳戶
- 如要從 BigQuery 匯出至 Spanner，必須使用 Google Cloud 帳戶，並具備 [Enterprise 級以上的預訂](#)。
- 透過網路瀏覽器存取 Google Cloud 控制台
- 用於執行 [Google Cloud CLI](#) 指令的終端機
- 如果 Google Cloud 機構已啟用 `iam.allowedPolicyMemberDomains` 政策，系統管理員可能需要授予例外狀況，允許來自外部網域的服務帳戶。我們會在後續步驟中說明相關內容 (如適用)。

限制

請務必留意這個管道可能出現的某些限制和資料類型不相容問題。

從 Snowflake 遷移至 Iceberg

Snowflake 和 Iceberg 的資料欄資料類型不同。如要瞭解如何在這兩種格式之間轉換，請參閱 [Snowflake 說明文件](#)。

從 Iceberg 遷移至 BigQuery

使用 BigQuery 查詢 Iceberg 資料表時，會有一些限制。如需完整清單，請參閱 [BigQuery 說明文件](#)。請注意，目前不支援 `BIGNUMERIC`、`INTERVAL`、`JSON`、`RANGE` 或 `GEOGRAPHY` 等型別。

BigQuery 至 Spanner

從 BigQuery 到 Spanner 的 `EXPORT DATA` 指令不支援所有 BigQuery 資料類型。匯出下列類型的資料表時會發生錯誤：

- `STRUCT`
- `GEOGRAPHY`
- `DATETIME`
- `RANGE`
- `TIME`

此外，如果 BigQuery 專案使用 `GoogleSQL` 方言，下列數值型別也不支援匯出至 Spanner：

- `BIGNUMERIC`

如需完整且最新的限制清單，請參閱官方文件：[匯出至 Spanner 的限制](#)。

Snowflake

在本程式碼研究室中，您可以使用現有的 Snowflake 帳戶，或設定[免費試用](#)帳戶。

Google Cloud Platform IAM 權限

Google 帳戶需要下列權限，才能執行本程式碼研究室中的所有步驟。

服務帳戶	
------	--

<code>iam.serviceAccountKeys.create</code>	允許建立服務帳戶。
Spanner	
<code>spanner.instances.create</code>	可建立新的 Spanner 執行個體。
<code>spanner.databases.create</code>	可執行 DDL 陳述式來建立
<code>spanner.databases.updateDdl</code>	可執行 DDL 陳述式，在資料庫中建立資料表。
Google Cloud Storage	
<code>storage.buckets.create</code>	可建立新的 GCS bucket，用來儲存匯出的 Parquet 檔案。
<code>storage.objects.create</code>	允許將匯出的 Parquet 檔案寫入 GCS 值區。
<code>storage.objects.get</code>	允許 BigQuery 從 GCS 儲存空間讀取 Parquet 檔案。
<code>storage.objects.list</code>	允許 BigQuery 列出 GCS bucket 中的 Parquet 檔案。
Dataflow	
<code>Dataflow.workitems.lease</code>	允許從 Dataflow 認領工作項目。
<code>Dataflow.workitems.sendMessage</code>	允許 Dataflow 工作站將訊息傳回 Dataflow 服務。
<code>Logging.logEntries.create</code>	允許 Dataflow 工作站將記錄項目寫入 Google Cloud Logging。

為方便起見，您可以使用具備這些權限的預先定義角色。

<code>roles/resourcemanager.projectIamAdmin</code>
<code>roles/iam.serviceAccountKeyAdmin</code>
<code>roles/spanner.instanceAdmin</code>
<code>roles/spanner.databaseAdmin</code>
<code>roles/storage.admin</code>

```
roles/dataflow.serviceAgent
```

```
roles/dataflow.worker
```

```
roles/dataflow.serviceAgent
```

設定可重複使用的屬性

本實驗室會重複使用幾個值。為簡化這項作業，我們會將這些值設為殼層變數，以供日後使用。

- GCP_REGION - GCP 資源所在的特定區域。如要查看區域清單，請按[這裡](#)。
- GCP_PROJECT - 要使用的 GCP 專案 ID。
- GCP_BUCKET_NAME：要建立的 GCS Bucket 名稱，以及儲存資料檔案的位置。

值區名稱在全域範圍內都不可重複。常見模式為：`[organization_name]-[project_id]-[environment]-[purpose]`。

```
export GCP_REGION = <GCP REGION HERE>
export GCP_PROJECT= <GCP PROJECT HERE>
export GCS_BUCKET_NAME = <GCS BUCKET NAME HERE>
export SPANNER_INSTANCE = <SPANNER INSTANCE ID HERE>
export SPANNER_DB = <SPANNER DATABASE ID HERE>
```

請注意，這些環境變數只會在執行變數的殼層執行個體中設定，如果您稍後在其他殼層執行個體中執行本實驗室的指令，則需要重新設定。

Google Cloud 專案

專案是 Google Cloud 的基本組織單位。如果管理員已提供可用的憑證，則可略過這個步驟。

您可以使用 CLI 建立專案，如下所示：

```
gcloud projects create $GCP_PROJECT
gcloud config set project $GCP_PROJECT
```

如要進一步瞭解如何建立及管理專案，請參閱[這篇文章](#)。

設定 Spanner

如要開始使用 Spanner，您需要佈建執行個體和資料庫。如要瞭解如何設定及建立 Spanner 執行個體，請參閱[這篇文章](#)。

建立執行個體

```
gcloud spanner instances create $SPANNER_INSTANCE \  
--config=regional-$GCP_REGION \  
--description="Codelabs Snowflake RETL" \  
--processing-units=100 \  
--edition=ENTERPRISE
```

建立資料庫

```
gcloud spanner databases create $SPANNER_DB \  
--instance=$SPANNER_INSTANCE
```

步驟 3 · 約 0 分鐘

3. 建立 Google Cloud Storage 值區

Google Cloud Storage (GCS) 會用於儲存 Snowflake 產生的 Parquet 資料檔案和 Iceberg 中繼資料。如要這麼做，請先建立新 bucket 做為檔案目的地。在本機電腦的「終端機」視窗中，按照下列步驟操作。

建立 bucket

使用下列指令在特定區域 (例如 us-central1) 建立 Storage 值區。

```
gcloud storage buckets create gs://$GCS_BUCKET_NAME --location=$GCP_REGION
```

確認已建立 bucket

該指令成功執行後，請列出所有 bucket，藉此檢查結果。新 bucket 應會顯示在結果清單中。值區參照通常會在值區名稱前面加上 `gs://` 前置字元。

```
gcloud storage ls | grep gs://$GCS_BUCKET_NAME
```

測試寫入權限

這個步驟可確保本機環境已正確通過驗證，並具備將檔案寫入新建立值區的必要權限。

```
echo "Hello, GCS" | gcloud storage cp - gs://$GCS_BUCKET_NAME/hello.txt
```

驗證上傳的檔案

列出值區中的物件。系統應會顯示剛上傳檔案的完整路徑。

```
gcloud storage ls gs://$GCS_BUCKET_NAME
```

您應該會看到以下的輸出內容：

```
gs://$GCS_BUCKET_NAME/hello.txt
```

如要查看 bucket 中物件的內容，可以使用 `gcloud storage cat`。

```
gcloud storage cat gs://$GCS_BUCKET_NAME/hello.txt
```

檔案內容應會顯示：

```
Hello, GCS
```

清理測試檔案

Cloud Storage bucket 現在已設定完成。現在可以刪除臨時測試檔案。

```
gcloud storage rm gs://$GCS_BUCKET_NAME/hello.txt
```

輸出內容應會確認刪除：

```
Removing gs://$GCS_BUCKET_NAME/hello.txt...  
/ [1 objects]  
Operation completed over 1 objects.
```

4. 從 Snowflake 匯出至 GCS

在本實驗室中，您將使用 **TPC-H 資料集**，這是決策支援系統的業界標準基準。這個結構定義會模擬真實的商業環境，包含顧客、訂單、供應商和零件，非常適合用來展示實際的數據分析和資料移動情境。所有 Snowflake 帳戶預設都會提供這個資料集。

您將建立新的匯總資料表，而不是使用原始的標準化 TPC-H 資料表。這個新資料表會彙整 `orders`、`customer` 和 `nation` 資料表中的資料，產生反正規化的全國銷售總額摘要檢視畫面。預先彙整資料是數據分析的常見做法，因為這樣可準備好資料，以用於特定用途。在本情境中，資料會用於作業應用程式。

允許 Snowflake 存取 Google Cloud Storage

如要允許 Snowflake 將資料寫入 GCS bucket，必須建立「外部磁碟區」和必要的「權限」。

- 外部磁碟區是 Snowflake 物件，可提供 GCS 值區中特定位置的安全連結。它本身不會儲存資料，而是保留 Snowflake 存取雲端儲存空間所需的設定。
- 為確保安全，雲端儲存空間值區預設為私密。建立外部磁碟區時，Snowflake 會產生專用的**服務帳戶**。這個服務帳戶必須具備讀取及寫入 bucket 的權限。

建立資料庫

- 在左側選單的「Horizon Catalog」下方，將游標懸停在「Catalog」上，然後點選「Database Explorer」。
- 前往「資料庫」頁面後，按一下右上方的「+ 資料庫」按鈕。
- 將新資料庫命名為 `codelabs_ret1_db`

建立工作表

如要對資料庫執行 SQL 指令，您需要使用工作表。

如要建立工作表，請按照下列步驟操作：

- 在左側選單的「處理資料」下方，將游標懸停在「專案」上，然後點選「工作區」。
- 在「我的工作區」側邊列下方，按一下「+ 新增」按鈕，然後選取「SQL 檔案」。

如要對 Snowflake 執行其他 SQL 指令，請替換這個檔案的內容。如要執行檔案中的段落部分，請將游標放在該段落上，然後按下鍵盤上的 Ctrl + Enter 鍵。

建立外部磁碟區

在 Snowflake 工作表執行下列指令，建立磁碟區。

請注意，Snowflake 會使用 `gcs://` 前置字串做為 Google Cloud Storage 路徑，而非 `gs://`。

由於下列 SQL 程式碼不會在設定環境變數的殼層執行個體中執行，請務必將 **GCS Bucket name** 的值替換為實際值

```
CREATE EXTERNAL VOLUME codelabs_ret1_ext_vol
STORAGE_LOCATIONS =
(
  (
    NAME = 'codelabs_ret1_ext_vol'
    STORAGE_PROVIDER = 'GCS'
    STORAGE_BASE_URL = 'gcs://<Your bucket name>/snowflake_extvol'
  )
);
```

取得 Snowflake 服務帳戶

DESC (說明) 新建立的外部磁碟區，取得 Snowflake 為該磁碟區產生的專屬服務帳戶。

```
DESC EXTERNAL VOLUME codelabs_ret1_ext_vol;
```

1. 在結果窗格中，尋找 json 屬性，找出包含以 `"NAME":"codelabs_ret1_ext_vol"` 開頭的 JSON 字串的 `property_value` 項目
2. 在 JSON 物件中找出 `STORAGE_GCP_SERVICE_ACCOUNT` 屬性，並複製其值 (看起來會像是電子郵件地址)。這是需要存取 GCS bucket 的服務帳戶 ID。
3. 將這個服務帳戶儲存至殼層執行個體中的環境變數，以供後續重複使用

```
export GCP_SERVICE_ACCOUNT=<Your service account>
```

注意：如果 Google Cloud 機構強制執行 `iam.allowedPolicyMemberDomains` 限制，安全管理員必須將這個服務帳戶的網域 (@ 符號後方的部分) 新增至允許清單。

將 GCS 權限授予 Snowflake

現在，必須授予 Snowflake 服務帳戶寫入 GCS bucket 的權限。

```
gcloud storage buckets add-iam-policy-binding gs://$GCS_BUCKET_NAME \
  --member="serviceAccount:$GCP_SERVICE_ACCOUNT" \
  --role="roles/storage.objectAdmin"

gcloud storage buckets add-iam-policy-binding gs://$GCS_BUCKET_NAME \
  --member="serviceAccount:$GCP_SERVICE_ACCOUNT" \
  --role="roles/storage.legacyBucketReader"
```

在 Snowflake 中驗證存取權

返回 Snowflake 工作表，執行下列指令，確認 Snowflake 現在可以順利連線至 GCS bucket。

```
SELECT SYSTEM$VERIFY_EXTERNAL_VOLUME('codelabs_ret1_ext_vol');
```

結果應為包含 `"success":true` 的 JSON 物件。

如要進一步瞭解 Snowflake 中的外部磁碟區，請參閱[官方說明文件](#)。

匯出範例訂單資料

現在您可以在 Snowflake 中建立 Iceberg 資料表。下列指令會指示 Snowflake 執行查詢，並以 Iceberg 格式將結果儲存在 GCS 中。資料檔案為 Parquet 格式，中繼資料為 Avro 和 JSON 格式，所有檔案都會儲存在 `codelabs_ret1_ext_vol` 外部磁碟區定義的位置。

建立資料庫

1. 在左側選單的「Horizon Catalog」下方，將游標懸停在「Catalog」上，然後點選「Database Explorer」。
2. 前往「資料庫」頁面後，按一下右上方的「+ 資料庫」按鈕。
3. 將新資料庫命名為 `codelabs_ret1_db`

```
USE DATABASE codelabs_ret1_db;

CREATE ICEBERG TABLE REGIONAL_SALES_ICEBERG (
  NATION_NAME STRING,
  MARKET_SEGMENT STRING,
  ORDER_YEAR INTEGER,
  ORDER_PRIORITY STRING,
  TOTAL_ORDER_COUNT INTEGER,
  TOTAL_REVENUE NUMBER(24,2),
  UNIQUE_CUSTOMER_COUNT INTEGER
)
EXTERNAL_VOLUME = 'codelabs_ret1_ext_vol'
CATALOG = 'SNOWFLAKE'
BASE_LOCATION = 'regional_sales_iceberg'
AS (
  SELECT
    n.n_name AS nation_name,
    c.c_mktsegment AS market_segment,
    YEAR(o.o_orderdate) AS order_year,
    o.o_orderpriority AS order_priority,
    COUNT(o.o_orderkey) AS total_order_count,
    ROUND(SUM(o.o_totalprice), 2) AS total_revenue,
    COUNT(DISTINCT c.c_custkey) AS unique_customer_count
  FROM SNOWFLAKE_SAMPLE_DATA.TPCH_SF1.orders AS o
  INNER JOIN SNOWFLAKE_SAMPLE_DATA.TPCH_SF1.customer AS c
    ON o.o_custkey = c.c_custkey
  INNER JOIN SNOWFLAKE_SAMPLE_DATA.TPCH_SF1.nation AS n
    ON c.c_nationkey = n.n_nationkey
  GROUP BY
    n.n_name,
    c.c_mktsegment,
    YEAR(o.o_orderdate),
    o.o_orderpriority
);
```

如要進一步瞭解如何使用 Snowflake 建立及管理 Iceberg 資料表，請參閱[官方說明文件](#)。

在 GCP 中驗證資料

現在請檢查 GCS bucket。您應該會看到 Snowflake 建立的檔案。這表示匯出作業已順利完成。**Iceberg** 中繼資料會位於 `metadata` 資料夾中，實際資料則會以 **Parquet** 檔案的形式位於 `data` 資料夾中。

```
gcloud storage ls "gs://$GCS_BUCKET_NAME/snowflake_extvol/**"
```

確切的檔案名稱會有所不同，但結構應如下所示：

```
gs://$GCS_BUCKET_NAME/snowflake_extvol/  
gs://$GCS_BUCKET_NAME/snowflake_extvol/regional_sales_iceberg.snvrAWuR/data/snow_cbsK  
IRmdDmo_wLg128fugxg_0_2_009.parquet  
...  
gs://$GCS_BUCKET_NAME/snowflake_extvol/regional_sales_iceberg.snvrAWuR/metadata/00001  
-62f831ff-6708-4494-94c5-c891b7ad447f.metadata.json  
...
```

資料現在已從 Snowflake 複製到 Google Cloud Storage，並採用 Iceberg 格式。

我們有了這份清單後，請將 `metadata.json` 檔案儲存至環境變數，稍後會用到。

```
export GCS_METADATA_JSON=$(gcloud storage ls "gs://$GCS_BUCKET_NAME/snowflake_extvol/**" |  
grep .metadata.json)
```

5. 設定 BigQuery 外部資料表

Iceberg 資料表現在位於 Google Cloud Storage 中，下一步是讓 BigQuery 能夠存取該資料表。方法是建立 **BigLake** 外部資料表。

[BigLake](#) 是一種儲存引擎，可讓您在 BigQuery 中建立資料表，直接從 Google Cloud Storage 等外部來源讀取資料。在本實驗室中，這項技術是 BigQuery 瞭解剛匯出的 Iceberg 資料表的關鍵，不必擷取資料。

如要讓這項功能正常運作，需要兩個元件：

1. **雲端資源連線**：這是 BigQuery 和 GCS 之間的安全連結。系統會使用特殊服務帳戶處理驗證，確保 BigQuery 具備從 GCS bucket 讀取檔案的必要權限。
2. **外部資料表定義**：這會告知 BigQuery 在 GCS 中尋找 Iceberg 資料表的中繼資料檔案，以及應如何解讀該檔案。

設定 Google Cloud Storage 連線

首先，系統會建立連線，讓 BigQuery 存取 GCS。這項指令會在 BigQuery 中建立連線資源。

```
bq mk \  
  --connection \  
  --project_id=$GCP_PROJECT \  
  --location=$GCP_REGION \  
  --connection_type=CLOUD_RESOURCE \  
  codelabs-retl-connection
```

成功訊息如下所示：

```
Connection 12345678.region.codelabs-retl-connection successfully created
```

如要進一步瞭解 BigQuery 中的 Cloud 資源連線，請參閱 [Google Cloud 說明文件](#)。

授權 BigQuery 連線讀取資料

新的 BigQuery 連線有自己的服務帳戶，需要具備從 Google Cloud Storage 值區讀取資料的權限。

1. 取得連線服務帳戶

首先，請從剛建立的連線取得服務帳戶 ID：

```
bq show \  
  --location $GCP_REGION \  
  --connection codelabs-retl-connection
```

結果會顯示相符連線的表格。

請將 `serviceAccountId` 設為環境變數，以供後續使用。

```
export GCP_BQ_SERVICE_ACCOUNT=<Your service account email>
```

2. 授予權限

執行下列指令，授權服務帳戶查看 GCS bucket 中的資料。

```
gcloud storage buckets add-iam-policy-binding \  
gs://$GCS_BUCKET_NAME \  
--member serviceAccount:$GCP_BQ_SERVICE_ACCOUNT \  
--role roles/storage.objectViewer
```

建立外部資料表

現在，請在 BigQuery 中建立 BigLake 外部資料表。這項指令不會移動任何資料。這項操作只會建立指向 GCS 中現有資料的指標，您需要 Snowflake 建立的其中一個 `.metadata.json` 檔案路徑。

在下列指令中，將 `external_table_definition` 值替換為 `metadata.json` 檔案的適當路徑。

請確認這個資料表與上一步的連線位於相同區域。

```
bq mk --dataset --location=$GCP_REGION codelabs_ret1  
  
bq mk \  
  --table \  
  --location=$GCP_REGION \  
  --  
  external_table_definition=ICEBERG=$GCS_METADATA_JSON@projects/$GCP_PROJECT/locations/$GCP_REGION/connections/codelabs-ret1-connection \  
  codelabs_ret1.regional_sales
```

在 BigQuery 中驗證資料

現在，您可以使用標準 SQL 查詢這個資料表，就像查詢任何其他 BigQuery 資料表一樣。BigQuery 會使用連線，即時從 GCS 讀取 Parquet 檔案。

```
bq query \  
  --location=$GCP_REGION \  
  --nouse_legacy_sql "SELECT * FROM \`$GCP_PROJECT.codelabs_ret1.regional_sales\` LIMIT 10;"
```


6. 將資料從 BigQuery 匯入 Spanner：最後一個步驟

管道的最後一個也是最重要的部分已完成：將資料從 BigLake 資料表移至 Spanner。這是「反向 ETL」步驟，資料在資料倉儲中經過處理和整理後，會載入營運系統供應應用程式使用。

Spanner 是全代管的全球分散式關聯式資料庫。Cloud Spanner 具有傳統關聯式資料庫的交易一致性，且能夠水平擴充 NoSQL 資料庫。因此非常適合建構可擴充的高可用性應用程式。

程序如下：

1. 在 Spanner 資料庫中建立符合資料結構的資料表結構定義。
2. 執行 BigQuery `EXPORT DATA` 查詢，將資料從 BigLake 資料表直接載入 Spanner 資料表。

建立 Spanner 資料表

從 BigQuery 移轉資料前，必須先在 Spanner 中建立具有相容結構定義的目的地資料表。

```
gcloud spanner databases ddl update $SPANNER_DB \  
  --instance=$SPANNER_INSTANCE \  
  --ddl="$(cat <<EOF  
CREATE TABLE regional_sales (  
  nation_name STRING(MAX),  
  market_segment STRING(MAX),  
  order_year INT64,  
  order_priority STRING(MAX),  
  total_order_count INT64,  
  total_revenue NUMERIC,  
  unique_customer_count INT64  
) PRIMARY KEY (nation_name, market_segment, order_year, order_priority);  
EOF  
)"
```

從 BigQuery 匯出資料

這是最後一個步驟。在 BigQuery BigLake 資料表中準備好來源資料，並在 Spanner 中建立目的地資料表後，實際的資料移動作業會出乎意料地簡單。系統會使用單一 BigQuery SQL 查詢：`EXPORT DATA`。

這項查詢專為這類情境設計。可有效率地將資料從 BigQuery 資料表 (包括 BigLake 資料表等外部資料表) 匯出至外部目的地。在本例中，目的地是 Spanner 資料表。

```
bq query --location=$GCP_REGION --use_legacy_sql=false <<EOF
EXPORT DATA OPTIONS (
  uri="https://spanner.googleapis.com/projects/${GCP_PROJECT}/instances/${SPANNER_INSTANCE}/databases/${SPANNER_DB}",
  format='CLOUD_SPANNER',
  spanner_options=""{
    "table": "regional_sales",
    "priority": "HIGH"
  }""
) AS
SELECT * FROM \`${PROJECT_ID}.codelabs_retl.regional_sales\`
EOF
```

查詢完成後，「結果」窗格應會顯示「更新完成」。

7. 驗證 Spanner 中的資料

恭喜！已成功建構並執行完整的 Reverse ETL 管道。最後一個步驟是確認資料是否已如預期匯入 Spanner。

```
gcloud spanner databases execute-sql \  
  --instance=$SPANNER_INSTANCE \  
  $SPANNER_DB \  
  --sql='SELECT * FROM regional_sales LIMIT 10'
```

匯入的範例資料會如要求顯示：

nation_name	market_segment	order_year	order_priority	total_order_count	total_revenue	unique_customer_count
ALGERIA	AUTOMOBILE	1992	1-URGENT	375	59232423.66	298
ALGERIA	AUTOMOBILE	1992	2-HIGH	328	47371891.08	269
ALGERIA	AUTOMOBILE	1992	3-MEDIUM	346	52823195.87	262
ALGERIA	AUTOMOBILE	1992	4-NOT SPECIFIED	365	52935998.34	288
ALGERIA	AUTOMOBILE	1992	5-LOW	380	54920263.68	293
ALGERIA	AUTOMOBILE	1993	1-URGENT	394	63145618.78	312
ALGERIA	AUTOMOBILE	1993	2-HIGH	340	50737488.4	277
ALGERIA	AUTOMOBILE	1993	3-MEDIUM	383	55871057.46	298
ALGERIA	AUTOMOBILE	1993	4-NOT SPECIFIED	365	56424662.05	291
ALGERIA	AUTOMOBILE	1993	5-LOW	363	54673249.06	283

分析和營運資料世界之間的鴻溝已成功彌平。

步驟 8 · 約 0 分鐘

8. 清除

清理 Spanner

刪除 Spanner 資料庫和執行個體

```
gcloud spanner instances delete $SPANNER_INSTANCE
```

清理 GCS

刪除為代管資料而建立的 GCS Bucket

```
gcloud storage rm --recursive gs://$GCS_BUCKET_NAME
```

清理 BigQuery

```
bq rm -r codelabs_ret1  
bq rm --connection --location=$GCP_REGION codelabs-ret1-connection
```

清理 Snowflake

捨棄資料庫

1. 在左側選單的「Horizon Catalog」下方，將游標懸停在「Catalog」上，然後點選「Database Explorer」。
2. 按一下 `CODELABS_RETL_DB` 資料庫右側的「...」，展開選項並選取「Drop」
3. 在彈出的確認對話方塊中，選取「Drop Database」

刪除活頁簿

4. 在左側選單的「處理資料」下方，將游標懸停在「專案」上，然後點選「工作區」
5. 在「我的工作區」側邊欄中，將滑鼠游標懸停在您用於本實驗室的不同工作區檔案上，顯示「...」其他選項，然後點選該選項
6. 選取「刪除」，然後在彈出的確認對話方塊中再次選取「刪除」。
7. 針對您為本實驗室建立的所有 SQL 工作區檔案執行這項操作。

刪除外部磁碟區

8. 在左側選單的「Horizon Catalog」下方，將游標懸停在「Catalog」上，然後點選「External Data」
9. 按一下 `CODELABS_RETL_EXT_VOL` 右側的

⋮

，選取「卸除外部磁碟區」，然後再次點選確認對話方塊中的「卸除外部磁碟區」

步驟 9 · 約 0 分鐘

9. 恭喜

恭喜您完成本程式碼研究室。

涵蓋內容

- 如何將資料載入 Snowflake
 - 如何建立 GCS 值區
 - 如何以 CSV 格式將 Snowflake 資料表匯出至 GCS
 - 如何設定 Spanner 執行個體
 - 如何使用 Dataflow 將 CSV 資料表載入 Spanner
-