

如何在 Cloud Run 工作上執行批次推論

來源：<https://codelabs.developers.google.com/codelabs/cloud-run/how-to-batch-inference-cloud-run-jobs?hl=zh-tw>

步驟數：7

瞭解如何執行批次干擾 Cloud Run 工作

目錄

1. [簡介](#)
2. [事前準備](#)
3. [設定和需求](#)
4. [建立 Cloud Run 工作](#)
5. [部署及執行工作](#)
6. [恭喜！](#)
7. [清除所用資源](#)

步驟 1 · 約 0 分鐘

1. 簡介

總覽

在本程式碼實驗室中，您將使用 Cloud Run 工作，透過 Cloud Run Jobs GPU 支援的 [Meta 的 Llama 3.2-1b LLM](#) 和 [vLLM](#) 執行批次推論。您將使用 [Cloud Run 磁碟區掛接](#)，直接將結果寫入 Cloud Storage。

課程內容

- 如何使用 Cloud Run Jobs GPU 執行批次推論
 - 如何使用 Cloud Run 磁碟區掛接將資料寫入 Cloud Storage
-

步驟 2 · 約 0 分鐘

2. 事前準備

啟用 API

開始使用本程式碼研究室前，請先執行下列指令，啟用下列 API：

```
gcloud services enable run.googleapis.com \  
  cloudbuild.googleapis.com \  
  secretmanager.googleapis.com \  
  artifactregistry.googleapis.com
```

GPU 配額

[申請提高支援區域的配額](#)。配額為 `nvidia_l4_gpu_allocation_no_zonal_redundancy`，位於 Cloud Run Admin API 下方。

注意：如果您使用新專案，啟用 API 後，可能需要幾分鐘，配額才會顯示在這個頁面。

Hugging Face

本程式碼研究室使用 [Hugging Face](#) 上代管的模型。如要取得這個模型，請申請具備「讀取」權限的 [Hugging Face 使用者存取權杖](#)。稍後會將此值做為 `YOUR_HF_TOKEN` 的參照。

您也必須同意使用條款才能使用模型：<https://huggingface.co/meta-llama/Llama-3.2-1B>

3. 設定和需求

本節包含下列資源的設定說明：

- IAM 服務帳戶和相關聯的 IAM 權限。
- [Secret Manager Secret](#)，用於儲存 Hugging Face 權杖。
- 用於儲存推論結果的 Cloud Storage bucket。

如要設定必要資源，請按照下列步驟操作：

1. 為本程式碼研究室設定環境變數：



```
export PROJECT_ID=<your_project_id>
export REGION=<your_region>
export HF_TOKEN=<YOUR_HF_TOKEN>

export SERVICE_ACCOUNT=inference-service-account
export SERVICE_ACCOUNT_EMAIL=${SERVICE_ACCOUNT}@${PROJECT_ID}.iam.gserviceaccount.com
export SECRET_ID=hugging-face-token
export BUCKET_NAME=inference-codelab-${PROJECT_ID}
```

2. 執行下列指令來建立服務帳戶：

```
gcloud iam service-accounts create ${SERVICE_ACCOUNT} \
  --display-name="Service account for batch inference codelab"
```

3. 使用 Secret Manager 儲存 Hugging Face 存取權杖：

```
gcloud secrets create $SECRET_ID \
  --replication-policy="automatic"

printf $HF_TOKEN | gcloud secrets versions add $SECRET_ID --data-file=-
```

4. 將 Secret Manager 密鑰存取者角色授予服務帳戶：

```
gcloud secrets add-iam-policy-binding $SECRET_ID \
  --member serviceAccount:${SERVICE_ACCOUNT_EMAIL} \
  --role='roles/secretmanager.secretAccessor'
```

5. 建立 bucket 來代管微調模型：

```
gcloud storage buckets create -l europe-west4 gs://${BUCKET_NAME}
```

6. 授予服務帳戶 bucket 存取權：

```
gcloud storage buckets add-iam-policy-binding gs://$BUCKET_NAME \
  --member=serviceAccount:$SERVICE_ACCOUNT_EMAIL \
  --role=roles/storage.objectAdmin
```

7. 建立 Artifact Registry 存放區，用於儲存容器映像檔。如果您先前已在專案中使用 Cloud Run 來源部署，請略過這個步驟。

```
gcloud artifacts repositories create cloud-run-source-deploy \
  --repository-format=docker \
  --location=$REGION \
  --project=$PROJECT_ID
```

4. 建立 Cloud Run 工作

在本節中，您將建立執行下列操作的程式碼：

- 從 Hugging Face 匯入 Llama 模型
- 對模型執行批次推論。這項工作會使用單一 L4 GPU 執行此程序。
- 將結果寫入本機磁碟。這會透過磁碟區掛接寫入 Cloud Storage。

如要建立 Cloud Run 工作和 Dockerfile，請按照下列步驟操作：

1. 建立目錄來存放微調工作程式碼：

```
mkdir codelab-inference-job
cd codelab-inference-job
```

2. 建立名為 `main.py` 的檔案

```
# SPDX-License-Identifier: Apache-2.0
from vllm import LLM, SamplingParams

# Sample prompts.
prompts = [
    "Cloud Run is",
    "The future of AI is",
    "The capital of Germany is",
    "python as a programming language is",
]

# Create a sampling params object.
sampling_params = SamplingParams(temperature=0.8, top_p=0.95)

# Create an LLM.
llm = LLM(model="meta-llama/Llama-3.2-1B")
# Generate texts from the prompts. The output is a list of RequestOutput objects
# that contain the prompt, generated text, and other information.
outputs = llm.generate(prompts, sampling_params)

# Save the outputs to disk
with open("/results/output.txt", "w") as f:
    for output in outputs:
        prompt = output.prompt
        generated_text = output.outputs[0].text
        f.write(f"Prompt: {prompt!r}, Generated text: {generated_text!r}\n")

print(f"Wrote {len(outputs)} to disk.")
```

3. 建立 `Dockerfile`：

```
FROM python:3.12
ADD main.py .
RUN python -m pip install --upgrade pip setuptools
RUN pip install vllm
CMD ["python", "./main.py"]
```

5. 部署及執行工作

在這個步驟中，您將使用 Cloud Run 來源部署建立 Cloud Run 工作，然後執行該工作。這個步驟也包含 Cloud Run 磁碟區掛接旗標，可儲存結果。

1. 建立 Cloud Run 工作：

```
gcloud run jobs deploy inference-job \
  --region $REGION \
  --source . \
  --gpu=1 \
  --set-secrets HF_TOKEN=${SECRET_ID}:latest \
  --add-volume name=results,type=cloud-storage,bucket=${BUCKET_NAME} \
  --add-volume-mount volume=results,mount-path=/results \
  --service-account $SERVICE_ACCOUNT_EMAIL
```

這個指令會從來源建構映像檔，並部署工作。這項作業需要一段時間才能完成。

2. 執行工作：

```
gcloud run jobs execute inference-job --region $REGION --async
```

這項工作需要幾分鐘才能完成。您可以透過上一個指令輸出內容中提供的連結，查看狀態。

確認成功

如要確認工作是否順利執行，請查看工作記錄，如上一個指令的輸出內容所示。

在 Cloud Storage bucket 中查看結果：

在控制台中：

1. 前往 [Cloud Storage](#)。
2. 選取以 `inference-codelab` 開頭的 bucket。
3. 選取「`output.txt`」。
4. 按一下「已驗證網址」，即可在瀏覽器中查看內容。

檔案內容應為四個提示及其輸出內容。

步驟 6 · 約 0 分鐘

6. 恭喜！

恭喜您完成本程式碼研究室！

建議參閱 [Cloud Run](#) 說明文件。

涵蓋內容

- 如何使用 Cloud Run Jobs GPU 執行批次推論
 - 如何使用 Cloud Run 磁碟區掛接將資料寫入 Cloud Storage
-

步驟 7 · 約 0 分鐘

7. 清除所用資源

如要刪除 Cloud Run 工作，請前往 Cloud Run Cloud 控制台 (<https://console.cloud.google.com/run>)，然後刪除 `inference-job` 工作。

如要刪除整個專案，請前往「管理資源」，選取您在步驟 2 中建立的專案，然後選擇「刪除」。刪除專案後，您必須在 Cloud SDK 中變更專案。如要查看所有可用專案的清單，請執行 `gcloud projects list`。
