

如何在 Cloud Run 部署 Generative UI 網站

來源：<https://codelabs.developers.google.com/codelabs/cloud-run/how-to-deploy-generative-ui-website?hl=zh-tw>

步驟數：11

瞭解如何在 Cloud Run 上建構及部署生成式 UI 網站，並透過 IAP 保護網站安全。

目錄

1. [1. 簡介](#)
2. [2. 專案設定](#)
3. [3. 開啟 Cloud Shell 編輯器](#)
4. [4. 啟用 API](#)
5. [5. 準備 Node.js 專案](#)
6. [6. 建立應用程式程式碼](#)
7. [7. 建立服務帳戶](#)
8. [8. 部署至 Cloud Run](#)
9. [9. 設定 IAP 存取權](#)
10. [10. 測試應用程式](#)
11. [11. 結論](#)

1. 簡介

總覽

在本實驗室中，您將建構及部署網站，其內容是由 Google 的 Gemini 大型語言模型即時生成。這個網站會是簡單的「選擇你的冒險」風格導覽，方便探索主題，每次點選都會根據你的選擇產生新網頁和新連結。您將使用 Node.js 和 Fastify 建構這項服務，並使用 Vertex AI SDK 呼叫 Gemini，然後在 Cloud Run 上以安全且可供實際使用的服務形式部署，並使用 Identity-Aware Proxy (IAP) 保護服務。

學習內容

- 建立使用 Vertex AI 的 Node.js Fastify 應用程式。
- 從原始碼將應用程式部署至 Cloud Run，不必使用 Dockerfile。
- 使用 Identity-Aware Proxy (IAP) 保護 Cloud Run 端點。

課程內容

- 瞭解如何使用 Node.js 適用的 Vertex AI SDK 生成內容。
 - 如何將 Node.js 應用程式部署至 Cloud Run。
 - 如何使用 IAP 保護 Cloud Run 應用程式。
-

2. 專案設定

1. 如果沒有 Google 帳戶，請先[建立帳戶](#)。
 - 請改用個人帳戶，而非公司或學校帳戶。公司和學校帳戶可能設有限制，導致您無法啟用本實驗室所需的 API。
 2. 登入 [Google Cloud 控制台](#)。
 3. 在 Cloud 控制台中[啟用帳單](#)。
 - 完成本實驗室的 Cloud 資源費用應不到 \$1 美元。
 - 您可以按照本實驗室結尾的步驟刪除資源，以免產生後續費用。
 - 新使用者可獲得價值 [\\$300 美元的免費試用期](#)。
 4. [建立新專案](#)，或選擇重複使用現有專案。
 - 如果看到專案配額相關錯誤，請重複使用現有專案，或刪除現有專案來建立新專案。
-

步驟 3 · 約 0 分鐘

3. 開啟 Cloud Shell 編輯器

1. 按一下這個連結，直接前往 [Cloud Shell 編輯器](#)
2. 如果系統在今天任何時間提示您授權，請點選「授權」繼續操作。

Authorize Cloud Shell

gcloud is requesting your credentials to make a GCP API call.


Click to authorize this and future calls that require your credentials.

REJECT

AUTHORIZE

3. 如果畫面底部未顯示終端機，請開啟終端機：

- 按一下「查看」
- 按一下「終端機」



4. 在終端機中，使用下列指令設定專案：

- 格式：

```
gcloud config set project [PROJECT_ID]
```


- 範例：

```
gcloud config set project lab-project-id-example
```

◦ 如果忘記專案 ID，請按照下列步驟操作：

- 您可以使用下列指令列出所有專案 ID：

```
gcloud projects list | awk '/PROJECT_ID/{print $2}'
```



5. 您應會看到下列訊息：

```
Updated property [core/project].
```

如果看到 `WARNING` 並收到 `Do you want to continue (Y/n)?` 提示，可能是專案 ID 輸入有誤。按下 `n` 和 `Enter`，然後再次嘗試執行 `gcloud config set project` 指令。

6. 設定 `GOOGLE_CLOUD_PROJECT` 環境變數

```
export GOOGLE_CLOUD_PROJECT=$(gcloud config get-value project)
```

步驟 4 · 約 0 分鐘

4. 啟用 API

在終端機中啟用 API：

```
gcloud services enable \  
  run.googleapis.com \  
  aiplatform.googleapis.com \  
  cloudresourcemanager.googleapis.com \  
  iap.googleapis.com
```

如果系統提示您授權，請點選「授權」繼續操作。

Authorize Cloud Shell

gcloud is requesting your credentials to make a GCP API call.

Click to authorize this and future calls that require your credentials.

REJECT

AUTHORIZE

這個指令可能需要幾分鐘才能完成，但最終應該會產生類似以下的成功訊息：

```
Operation "operations/acf.p2-73d90d00-47ee-447a-b600" finished successfully.
```

步驟 5 · 約 0 分鐘

5. 準備 Node.js 專案

1. 建立名為 `gen-ui-on-cloudrun` 的資料夾，用來儲存部署作業的原始碼：

```
mkdir gen-ui-on-cloudrun && cd gen-ui-on-cloudrun
```

2. 初始化 Node.js 專案：

```
npm init -y
```

3. 執行下列指令，將專案設定為使用 ES 模組，並定義啟動指令碼：

```
npm pkg set type="module"
```

4. 安裝網路伺服器的 `fastify` 和 Vertex AI SDK 的 `@google/genai`：

```
npm install fastify @google/genai
```

步驟 6 · 約 0 分鐘

6. 建立應用程式程式碼

1. 建立及開啟新的 `index.ts` 檔案，做為應用程式原始碼：

```
cloudshell edit ~/gen-ui-on-cloudrun/index.ts
```

`cloudshell edit` 指令會在終端機上方的編輯器中開啟 `index.ts` 檔案。

2. 在 `index.ts` 檔案中新增下列生成式 UI 伺服器原始碼：

```

import fastifyLib from 'fastify';
import { GoogleGenAI } from '@google/genai';

const fastify = fastifyLib({ logger: true });

const ai = new GoogleGenAI({
  vertexai: true,
  project: process.env.GOOGLE_CLOUD_PROJECT,
  location: process.env.GOOGLE_CLOUD_LOCATION || 'europe-west4',
});

const SYSTEM_INSTRUCTION = `The user should have submitted an html page and the id of the
element just clicked.
Given the next page description, create a new webpage with a link back to "Start Over"
(the / route), a brief overview of the topic, and a list of clickable link elements
related to the page.
When an element is clicked, the webpage should link to the base route / with the
nextPageDescription as a query string parameter.
All information needed to generate the next page should be included in the
nextPageDescription without additional context.
Each nextPageDescription should be less than 1500 characters.

Example:
If the current HTML page is for a small pet store, it might include a link to an "About"
page.
The href for the about page link should be /?
nextPageDescription=about%20page%20for%20small%20pet%20store%20website

All responses should be valid HTML without markdown backticks.`;

interface QueryParams {
  nextPageDescription?: string;
}

fastify.get<{ Querystring: QueryParams }>('/', async (request, reply) => {
  const {
    nextPageDescription = 'A web page with interesting fun facts where I can select a
fact to learn more about that topic.'
  } = request.query;

  try {
    const response = await ai.models.generateContent({
      model: 'gemini-2.5-flash',
      contents: nextPageDescription,
      config: {
        systemInstruction: SYSTEM_INSTRUCTION,
        temperature: 0.9,
      }
    });

    reply.type('text/html; charset=utf-8').send(response.text);
  } catch (error: any) {

```

```
        request.log.error(error);
        reply.status(500).send('An error occurred calling the AI.');
```

```
    }
  });

const start = async () => {
  try {
    await fastify.listen({ port: Number(process.env.PORT) || 8080, host: '0.0.0.0'
  });
  } catch (err) {
    fastify.log.error(err);
    process.exit(1);
  }
};

start();
```

這段程式碼會設定網路伺服器，在根路徑 (/) 上監聽 HTTP GET 要求。收到要求時，程式碼會透過 Vertex AI，使用 `nextPageDescription` 查詢參數 (或預設值) 做為 Gemini 2.5 Flash 模型的提示。 `SYSTEM_INSTRUCTION` 會指示模型傳回含有連結的 HTML 網頁，每個連結都包含 `nextPageDescription`，用於產生後續網頁。

步驟 7 · 約 0 分鐘

7. 建立服務帳戶

您需要 Cloud Run 服務的服務帳戶，才能透過 Vertex AI API 進行驗證。

1. 建立名為 `gen-navigator-sa` 的服務帳戶：

```
gcloud iam service-accounts create gen-navigator-sa --display-name="Generative Navigator Service Account"
```

2. 將使用 Vertex AI 的權限授予服務帳戶：

```
gcloud projects add-iam-policy-binding $GOOGLE_CLOUD_PROJECT \
  --member="serviceAccount:gen-navigator-sa@$GOOGLE_CLOUD_PROJECT.iam.gserviceaccount.com" \
  --role="roles/aiplatform.user"
```

8. 部署至 Cloud Run

現在，您可以直接從原始碼將應用程式部署至 Cloud Run，不必使用 Dockerfile。

1. 執行 `gcloud` 指令來部署應用程式：

```
cd ~/gen-ui-on-cloudrun
gcloud beta run deploy generative-web-navigator \
  --source . \
  --no-build \
  --base-image=nodejs24 \
  --command="node" \
  --args="index.ts" \
  --region=europe-west4 \
  --no-allow-unauthenticated \
  --iap \
  --service-account="gen-navigator-sa@$GOOGLE_CLOUD_PROJECT.iam.gserviceaccount.com" \
  --set-env-vars
GOOGLE_CLOUD_PROJECT="$GOOGLE_CLOUD_PROJECT",GOOGLE_CLOUD_LOCATION="europe-west4"
```

我們在此使用幾個重要標記：

- `--source . --no-build --base-image=nodejs24`：這會告知 Cloud Run 從目前目錄部署原始碼、略過建構階段，並使用預先建構的 Node.js 24 基礎映像檔執行應用程式。
- `--no-allow-unauthenticated`：確保只有通過驗證的使用者可以存取服務。
- `--iap`：這會啟用 Identity-Aware Proxy (IAP)，管理應用程式的存取權。IAP 可根據使用者身分和情境控管存取權，而不僅限於 IP 位址。

2. 幾分鐘後，您會看到類似下列的訊息：

```
Service [generative-web-navigator] revision [generative-web-navigator-12345-abc]
has been deployed and is serving 100 percent of traffic.
```

您已部署應用程式，但仍須設定 IAP，允許存取應用程式。

9. 設定 IAP 存取權

在 Cloud Run 上啟用 IAP 後，IAP 會攔截所有要求，並要求使用者先通過驗證及授權，才能存取您的服務。如要使用這項功能，請授予以下兩項權限：

- 允許 IAP 服務本身叫用 Cloud Run 服務。
- 允許自己 (或其他使用者/群組) 透過 IAP 存取應用程式。

1. 取得專案編號，這是識別 IAP 服務代理程式的必要資訊：

```
export PROJECT_NUMBER=$(gcloud projects describe $GOOGLE_CLOUD_PROJECT --  
format="value(projectNumber)")
```

2. 在 Cloud Run 服務中，為 IAP 服務代理程式授予 `roles/run.invoker` 角色。這樣一來，IAP 就能在驗證及授權使用者後，叫用您的服務。

```
gcloud run services add-iam-policy-binding generative-web-navigator \  
  --region=europe-west4 \  
  --member="serviceAccount:service-$PROJECT_NUMBER@gcp-sa-iap.iam.gserviceaccount.com" \  
  --role="roles/run.invoker"
```

3. 將 `roles/iap.httpsResourceAccessor` 角色授予使用者帳戶。您就能存取受 IAP 保護的 HTTPS 資源。

```
gcloud beta iap web add-iam-policy-binding \  
  --resource-type=cloud-run \  
  --region=europe-west4 \  
  --service=generative-web-navigator \  
  --member="user:$(gcloud config get-value account)" \  
  --role="roles/iap.httpsResourceAccessor"
```

步驟 10 · 約 0 分鐘

10. 測試應用程式

1. 取得已部署服務的網址：

```
gcloud run services describe generative-web-navigator --format='value(status.url)' --  
region=europe-west4
```

2. 複製網址並在網路瀏覽器中開啟。由於這項服務受到 IAP 保護，如果尚未登入，系統會提示您登入 Google 帳戶。驗證完成後，您應該會看到第一個自動產生的頁面。
3. 按一下任一連結即可前往新頁面，系統會根據您點選的連結，透過 AI 生成新頁面！

你做到了！您已成功將生成式 UI 網站部署至 Cloud Run，並使用 IAP 保護網站安全。

11. 結論

恭喜！您已成功使用 Cloud Run、Vertex AI 和 IAP，部署及保護生成式 UI 網站。

(選用) 清理

如要清理您建立的項目，可以刪除雲端專案，以免產生額外費用。

不使用服務時，Cloud Run 不會收費，但您可能仍須支付已建立建構構件的儲存費用。刪除雲端專案後，系統就會停止對專案使用的所有資源收取費用。

如要刪除專案，請按照下列步驟操作：

```
gcloud projects delete $GOOGLE_CLOUD_PROJECT
```

您也可以從 Cloud Shell 磁碟刪除不必要的資源。您可以：

1. 刪除 Codelab 專案目錄：

```
rm -rf ~/gen-ui-on-cloudrun
```

2. 警告！這項操作無法復原，如要刪除 Cloud Shell 中的所有內容來釋出空間，可以[刪除整個主目錄](#)。請務必將要保留的內容另存他處。

```
sudo rm -rf $HOME
```
