

使用 CSV 從 Databricks 至 Spanner 執行反向 ETL

來源：<https://codelabs.developers.google.com/databricks-csv-spanner?hl=zh-tw>

步驟數：7

目錄

1. [1. 使用 GCS 和 Dataflow，從 Databricks 建構反向 ETL 管道至 Spanner](#)
2. [2. 設定、需求和限制](#)
3. [3. 建立 Google Cloud Storage bucket](#)
4. [4. 從 Databricks 匯出至 GCS](#)
5. [5. 使用 Dataflow 將資料載入 Spanner](#)
6. [6. 清除](#)
7. [7. 恭喜](#)

1. 使用 GCS 和 Dataflow，從 Databricks 建構反向 ETL 管道至 Spanner

簡介

在本程式碼研究室中，您將使用儲存在 Google Cloud Storage 中的 CSV 檔案，從 Databricks 建構至 Spanner 的反向 ETL 管道。傳統上，ETL (擷取、轉換、載入) 管道會將作業資料庫的資料移至 Databricks 等資料倉儲，以供分析。反向 ETL 管道則相反，會將經過處理的精選資料從資料倉儲移回營運系統，用於支援應用程式、提供使用者功能，或用於即時決策。

目標是將範例資料集從 Databricks 資料表移至 Spanner。Spanner 是全球分散式關聯式資料庫，非常適合高可用性應用程式。

為此，我們將 Google Cloud Storage (GCS) 和 Dataflow 做為中繼步驟。以下是資料流程的細目，以及此架構背後的理由：

1. 以 CSV 格式將 Databricks 資料匯出至 Google Cloud Storage (GCS)：

- 第一步是以開放的通用格式從 Databricks 匯出資料。匯出為 CSV 檔案是建立可攜式資料檔案的常見方法，簡單又直接。這些檔案會暫存在 GCS 中，這個服務提供可擴充且持久耐用的物件儲存解決方案。

2. 從 GCS 匯入至 Spanner (透過 Dataflow)：

- 我們使用全代管資料處理服務 Google Dataflow，而非編寫自訂指令碼來從 GCS 讀取資料並寫入 Spanner。Dataflow 提供專為這類工作預先建構的範本。使用「GCS Text to Cloud Spanner」範本，即可平行匯入大量資料，無須撰寫任何資料處理程式碼，大幅節省開發時間。

課程內容

- 如何將資料載入 Databricks
 - 如何建立 GCS 值區
 - 如何以 CSV 格式將 Databricks 資料表匯出至 GCS
 - 如何設定 Spanner 執行個體
 - 如何使用 Dataflow 將 CSV 資料表載入 Spanner
-

2. 設定、需求和限制

必要條件

- 具備建立叢集和安裝程式庫權限的 Databricks 帳戶。免費試用帳戶不適用於本實驗室。
- 已啟用 Spanner、Cloud Storage 和 Dataflow API 的 Google Cloud 帳戶。
- 透過網路瀏覽器存取 Google Cloud 控制台。
- 已安裝 Google Cloud CLI 的終端機。
- 如果 Google Cloud 機構已啟用 `iam.allowedPolicyMemberDomains` 政策，系統管理員可能需要授予例外狀況，允許來自外部網域的服務帳戶。我們會在後續步驟中說明相關內容 (如適用)。

Google Cloud Platform IAM 權限

Google 帳戶需要下列權限，才能執行本程式碼研究室中的所有步驟。

服務帳戶	
<code>iam.serviceAccountKeys.create</code>	允許建立服務帳戶。
Spanner	
<code>spanner.instances.create</code>	可建立新的 Spanner 執行個體。
<code>spanner.databases.create</code>	可執行 DDL 陳述式來建立
<code>spanner.databases.updateDdl</code>	可執行 DDL 陳述式，在資料庫中建立資料表。
Google Cloud Storage	
<code>storage.buckets.create</code>	可建立新的 GCS bucket，用來儲存匯出的 Parquet 檔案。
<code>storage.objects.create</code>	允許將匯出的 Parquet 檔案寫入 GCS 值區。
<code>storage.objects.get</code>	允許 BigQuery 從 GCS 儲存空間讀取 Parquet 檔案。
<code>storage.objects.list</code>	允許 BigQuery 列出 GCS bucket 中的 Parquet 檔案。
Dataflow	
<code>Dataflow.workitems.lease</code>	允許從 Dataflow 認領工作項目。

<code>Dataflow.workitems.sendMessage</code>	允許 Dataflow 工作站將訊息傳回 Dataflow 服務。
<code>Logging.logEntries.create</code>	允許 Dataflow 工作站將記錄項目寫入 Google Cloud Logging。

為方便起見，您可以使用具備這些權限的預先定義角色。

<code>roles/resourcemanager.projectIamAdmin</code>
<code>roles/iam.serviceAccountKeyAdmin</code>
<code>roles/spanner.instanceAdmin</code>
<code>roles/spanner.databaseAdmin</code>
<code>roles/storage.admin</code>
<code>roles/dataflow.serviceAgent</code>
<code>roles/dataflow.worker</code>
<code>roles/dataflow.serviceAgent</code>

限制

在系統之間移動資料時，請務必注意資料類型差異。

- **Databricks 轉為 CSV**：匯出時，Databricks 資料類型會轉換為標準文字表示法。
- **CSV 檔案匯入 Spanner**：匯入時，請務必確認目標 Spanner 資料型別與 CSV 檔案中的字串表示法相容。本實驗室將逐步說明常見的型別對應。

設定可重複使用的屬性

本實驗室會重複使用幾個值。為簡化這項作業，我們會將這些值設為殼層變數，以供日後使用。

- GCP_REGION - GCP 資源所在的特定區域。如要查看區域清單，請按[這裡](#)。
- GCP_PROJECT - 要使用的 GCP 專案 ID。
- GCP_BUCKET_NAME：要建立的 GCS Bucket 名稱，以及儲存資料檔案的位置。

值區名稱在全域範圍內都不可重複。常見模式為：`[organization_name]-[project_id]-[environment]-[purpose]`。

```
export GCP_REGION = <GCP REGION HERE>
export GCP_PROJECT= <GCP PROJECT HERE>
export GCS_BUCKET_NAME = <GCS BUCKET NAME HERE>
export SPANNER_INSTANCE = <SPANNER INSTANCE ID HERE>
export SPANNER_DB = <SPANNER DATABASE ID HERE>
```

請注意，這些環境變數只會在執行變數的殼層執行個體中設定，如果您稍後在其他殼層執行個體中執行本實驗室的指令，則需要重新設定。

Databricks

在本實驗室中，您將使用 GCP 代管的 Databricks 帳戶，在 GCS 中定義外部資料位置。

如果 Databricks 執行個體位於其他雲端服務供應商，資料必須先暫存在該雲端服務供應商的儲存空間解決方案中，然後再分別移至 GCS。

Google Cloud

本實驗室需要 Google Cloud 專案。

Google Cloud 專案

專案是 Google Cloud 的基本組織單位。如果管理員已提供可用的憑證，則可略過這個步驟。

您可以使用 CLI 建立專案，如下所示：

```
gcloud projects create $GCP_PROJECT
gcloud config set project $GCP_PROJECT
```

如要進一步瞭解如何建立及管理專案，請參閱[這篇文章](#)。

設定 Spanner

如要開始使用 Spanner，您需要佈建執行個體和資料庫。如要瞭解如何設定及建立 Spanner 執行個體，請參閱[這篇文章](#)。

建立執行個體

```
gcloud spanner instances create $SPANNER_INSTANCE \
--config=regional-$GCP_REGION \
--description="Codelabs Snowflake RETL" \
--processing-units=100 \
--edition=ENTERPRISE
```

建立資料庫

```
gcloud spanner databases create $SPANNER_DB \  
--instance=$SPANNER_INSTANCE
```

步驟 3 · 約 0 分鐘

3. 建立 Google Cloud Storage bucket

系統會使用 Google Cloud Storage (GCS) 暫時儲存 Snowflake 產生的 CSV 資料檔案，然後再匯入 Spanner。

建立 bucket

使用下列指令在特定區域中建立儲存空間 bucket。

```
gcloud storage buckets create gs://$GCS_BUCKET_NAME --location=$GCP_REGION
```

確認已建立 bucket

該指令成功執行後，請列出所有 bucket，藉此檢查結果。新 bucket 應會顯示在結果清單中。值區參照通常會在值區名稱前面加上 `gs://` 前置字元。

```
gcloud storage ls | grep gs://$GCS_BUCKET_NAME
```

測試寫入權限

這個步驟可確保本機環境已正確通過驗證，並具備將檔案寫入新建立值區的必要權限。

```
echo "Hello, GCS" | gcloud storage cp - gs://$GCS_BUCKET_NAME/hello.txt
```

驗證上傳的檔案

列出值區中的物件。系統應會顯示剛上傳檔案的完整路徑。

```
gcloud storage ls gs://$GCS_BUCKET_NAME
```

您應該會看到以下的輸出內容：

```
gs://$GCS_BUCKET_NAME/hello.txt
```

如要查看 bucket 中物件的內容，可以使用 `gcloud storage cat`。

```
gcloud storage cat gs://$GCS_BUCKET_NAME/hello.txt
```

檔案內容應會顯示：

```
Hello, GCS
```

清理測試檔案

Cloud Storage bucket 現在已設定完成。現在可以刪除臨時測試檔案。


```
gcloud storage rm gs://$GCS_BUCKET_NAME/hello.txt
```

輸出內容應會確認刪除：

```
Removing gs://$GCS_BUCKET_NAME/hello.txt...  
/ [1 objects]  
Operation completed over 1 objects.
```

步驟 4 · 約 0 分鐘

4. 從 Databricks 匯出至 GCS

現在，系統會設定 Databricks 環境，安全地連線至 GCS 並匯出資料。

建立憑證

1. 在左側選單中，按一下「目錄」。
2. 如果目錄頁面頂端顯示「外部資料」，請按一下該選項。否則，請依序點選「連線」下拉式選單和「憑證」。
3. 如果尚未切換至「憑證」分頁，請切換至該分頁。
4. 按一下「建立憑證」。
5. 選取「憑證類型」的 `GCP Service Account`。
6. 輸入 `codelabs-retl-credentials` 做為憑證名稱。
7. 按一下「Create」(建立)。
8. 從對話方塊複製服務帳戶電子郵件地址，然後按一下「完成」。

將這個服務帳戶設為殼層執行個體中的環境變數，以供重複使用：

```
export GCP_SERVICE_ACCOUNT=<Your service account>
```

授予 Databricks GCS 權限

現在，必須授予 Snowflake 服務帳戶寫入 GCS bucket 的權限。

```
gcloud storage buckets add-iam-policy-binding gs://$GCS_BUCKET_NAME \
  --member="serviceAccount:$GCP_SERVICE_ACCOUNT" \
  --role="roles/storage.objectAdmin"

gcloud storage buckets add-iam-policy-binding gs://$GCS_BUCKET_NAME \
  --member="serviceAccount:$GCP_SERVICE_ACCOUNT" \
  --role="roles/storage.legacyBucketReader"
```

建立外部位置

6. 使用頁面頂端的階層連結，返回「憑證」頁面。
7. 切換至「外部位置」分頁。
8. 按一下「建立外部位置」。
9. 將「External Location Name」(外部位置名稱) 設為 `codelabs-retl-gcs`。
10. 將「儲存空間類型」保留為 `GCP`。
11. 將 bucket 路徑設為 `URL`。
12. 將「Storage Credential」(儲存空間憑證) 設為 `codelabs-retl-credentials`。
13. 按一下「Create」(建立)。
14. 確認後。按一下「Create」(建立)。

如果確認畫面顯示「驗證失敗」 `File Events Resource Provision`，請按一下「強制建立」，因為這不會影響本程式碼研究室。

建立目錄和結構定義

1. 在左側選單中，按一下「目錄」。
2. 依序點選「建立」和「建立目錄」
3. 將「目錄名稱」設為 `retl_tpch_project`
4. 將「Type」設為 `standard`
5. 選取「`codelabs-retl-gcs`」做為外部位置
6. 按一下「Create」(建立)
7. 按一下「目錄」清單中的 `retl_tpch_project`
8. 按一下「建立結構定義」
9. 將「結構定義名稱」設為 `tpch_data`
10. 選取「儲存空間位置」，然後選擇 `codelabs-retl-gcs`
11. 按一下「Create」(建立)

將資料匯出為 CSV 檔案

現在可以匯出資料了。我們會使用 TPC-H 範例資料集定義新資料表，並以 CSV 格式儲存在外部。

首先，請將範例資料複製到工作區的新資料表。如要這麼做，必須從查詢執行 SQL 程式碼。

1. 在左側側邊選單的「SQL」下方，按一下「查詢」
2. 按一下「建立查詢」按鈕
3. 在「執行」按鈕旁，將「工作區」設為 `retl_tpch_project`

由於下列程式碼不會在殼層中執行，且殼層中先前已為 GCS bucket 名稱定義環境變數，請務必將 `Your bucket name` 值替換為您自己的 bucket 名稱。

```
CREATE TABLE retl_tpch_project.tpch_data.regional_sales_csv
USING CSV
LOCATION 'gs://<Your bucket name>/regional_sales_csv'
OPTIONS (
  header "false",
  delimiter ",",
)
AS
SELECT
  n.n_name AS nation_name,
  c.c_mktsegment AS market_segment,
  YEAR(o.o_orderdate) AS order_year,
  o.o_orderpriority AS order_priority,
  COUNT(o.o_orderkey) AS total_order_count,
  ROUND(SUM(o.o_totalprice), 2) AS total_revenue,
  COUNT(DISTINCT c.c_custkey) AS unique_customer_count
FROM samples.tpch.orders AS o
INNER JOIN samples.tpch.customer AS c
  ON o.o_custkey = c.c_custkey
INNER JOIN samples.tpch.nation AS n
  ON c.c_nationkey = n.n_nationkey
GROUP BY 1, 2, 3, 4;
```

驗證 GCS 中的資料

檢查 GCS bucket，查看 Databricks 建立的檔案。

```
gcloud storage ls gs://$GCS_BUCKET_NAME/regional_sales_csv/
```

您應該會看到一或多個 `.csv` 檔案，以及 `_SUCCESS` 和記錄檔。

步驟 5 · 約 0 分鐘

5. 使用 Dataflow 將資料載入 Spanner

系統會使用 Google 提供的 Dataflow 範本，將 CSV 資料從 GCS 匯入 Spanner。

建立 Spanner 資料表

首先，請在 Spanner 中建立目的地資料表。結構定義必須與 CSV 檔案中的資料相容。

```
gcloud spanner databases ddl update $SPANNER_DB \  
  --instance=$SPANNER_INSTANCE \  
  --ddl="$(cat <<EOF  
CREATE TABLE regional_sales (  
  nation_name STRING(MAX),  
  market_segment STRING(MAX),  
  order_year INT64,  
  order_priority STRING(MAX),  
  total_order_count INT64,  
  total_revenue NUMERIC,  
  unique_customer_count INT64  
) PRIMARY KEY (nation_name, market_segment, order_year, order_priority);  
EOF  
)"
```

建立 Dataflow 資訊清單

Dataflow 範本需要「資訊清單」檔案。這個 JSON 檔案會告知範本來源資料檔案的位置，以及要將檔案載入哪個 Spanner 資料表。

定義並上傳新的 regional_sales_manifest.json 至 GCS bucket：

```
cat <<EOF | gcloud storage cp - gs://$GCS_BUCKET_NAME/regional_sales_manifest.json  
{  
  "tables": [  
    {  
      "table_name": "regional_sales",  
      "file_patterns": [  
        "gs://$GCS_BUCKET_NAME/regional_sales_csv/*.csv"  
      ]  
    }  
  ]  
}  
EOF
```

啟用 Dataflow API

使用 Dataflow 前，請先啟用這項服務。如要這麼做，請使用

```
gcloud services enable dataflow.googleapis.com --project=$GCP_PROJECT
```

建立及執行 Dataflow 工作

匯入工作現在可以執行。這個指令會使用 `GCS_Text_to_Cloud_Spanner` 範本啟動 Dataflow 工作。

這項指令很長，而且有多個參數。以下是細目：

- `--gcs-location`：GCS 上預先建構的範本路徑。
- `--region`：Dataflow 工作執行的區域。
- `--parameters`：範本專屬的鍵/值組合清單：
- `instanceId`、`databaseId`：目標 Spanner 執行個體和資料庫。
- `importManifest`：剛建立的資訊清單檔案的 GCS 路徑。

```
gcloud dataflow jobs run spanner-import-from-gcs \
  --gcs-location=gs://dataflow-templates/latest/GCS_Text_to_Cloud_Spanner \
  --region=$GCP_REGION \
  --staging-location=gs://$GCS_BUCKET_NAME/staging \
  --parameters \
instanceId=$SPANNER_INSTANCE,\
databaseId=$SPANNER_DB,\
importManifest=gs://$GCS_BUCKET_NAME/regional_sales_manifest.json,escape='\'
```

您可以使用下列指令檢查 Dataflow 工作的狀態

```
gcloud dataflow jobs list \
  --filter="name:spanner-import-from-gcs" \
  --region="$GCP_REGION" \
  --sort-by="~creationTime" \
  --limit=1
```

這項工作大約 5 分鐘就能完成。

驗證 Spanner 中的資料

Dataflow 工作完成後，請確認資料已載入 Spanner。

首先，請檢查列數，應為 4375

```
gcloud spanner databases execute-sql $SPANNER_DB \
  --instance=$SPANNER_INSTANCE \
  --sql='SELECT COUNT(*) FROM regional_sales;'
```

接著，查詢幾列資料來檢查資料。

```
gcloud spanner databases execute-sql $SPANNER_DB \
  --instance=$SPANNER_INSTANCE \
  --sql='SELECT * FROM regional_sales LIMIT 5'
```

您應該會看到從 Databricks 資料表匯入的資料。

步驟 6 · 約 0 分鐘

6. 清除

清理 Spanner

刪除 Spanner 資料庫和執行個體

```
gcloud spanner instances delete $SPANNER_INSTANCE
```

清理 GCS


刪除為代管資料而建立的 GCS Bucket

```
gcloud storage rm --recursive gs://$GCS_BUCKET_NAME
```


清理 Databricks

刪除目錄/結構定義/資料表

1. 登入 Databricks 執行個體
2. 按一下左側選單中的



3. 從目錄清單中選取先前建立的 `retl_tpch_project`



4. 在「結構定義」清單中，選取已建立的 `tpch_data`
5. 從表格清單中選取先前建立的 `regional_sales_csv`
6. 按一下



展開表格選項，然後選取「刪除」

7. 在確認對話方塊中按一下「刪除」，即可刪除表格
8. 刪除資料表後，系統會將您帶回結構定義頁面
9. 按一下



展開結構定義選項，然後選取「刪除」

10. 在確認對話方塊中按一下「刪除」，即可刪除結構定義
11. 刪除架構後，系統會將你帶回目錄頁面
12. 如果存在 `default` 架構，請再次按照步驟 4 到 11 刪除。
13. 在目錄頁面中，按一下



展開目錄選項，然後選取「刪除」。

14. 在確認對話方塊中按一下「刪除」，即可刪除目錄

刪除外部資料位置 / 憑證

15. 在「目錄」畫面中，按一下

External Data >

16. 如果沒有看到 `External Data` 選項，請改為在 `Connect` 下拉式選單中尋找 `External Location`。

17. 按一下先前建立的 `retl-gcs-location` 外部資料位置

18. 在外部地點頁面中，按一下



展開地點選項，然後選取 `Delete`。

19. 在確認對話方塊中按一下「刪除」，即可刪除外部位置

20. 按一下

Credentials ⓘ

21. 按一下先前建立的 `retl-gcs-credential`

22. 在憑證頁面中，按一下



展開憑證選項，然後選取 `Delete`。

23. 在確認對話方塊中按一下「刪除」，即可刪除憑證。

步驟 7 · 約 0 分鐘

7. 恭喜

恭喜您完成本程式碼研究室。

涵蓋內容

- 如何將資料載入 Databricks
 - 如何建立 GCS 值區
 - 如何以 CSV 格式將 Databricks 資料表匯出至 GCS
 - 如何設定 Spanner 執行個體
 - 如何使用 Dataflow 將 CSV 資料表載入 Spanner
-