

在 Cloud AI Platform 建構、訓練及部署 XGBoost 模型

來源：<https://codelabs.developers.google.com/codelabs/xgb-caip-e2e?hl=zh-tw>

步驟數：8

在這個研究室中，您將逐步瞭解 GCP 上完整的機器學習工作流程：從 BigQuery 擷取資料、在 Cloud AI 平台 Notebooks 執行個體中建構 XGBoost 模型，然後將模型部署至 AI 平台。

目錄

1. [總覽](#)
2. [設定環境](#)
3. [探索 BigQuery 資料集](#)
4. [準備訓練資料](#)
5. [XGBoost 快速入門](#)
6. [建構、訓練及評估 XGBoost 模型](#)
7. [將模型部署至 Cloud AI Platform](#)
8. [清除所用資源](#)

步驟 1 · 約 1 分鐘

1. 總覽

在本實驗室中，您將逐步瞭解 GCP 上的完整機器學習工作流程。您將在 Cloud AI Platform Notebooks 環境中，從 BigQuery 公開資料集擷取資料、建構及訓練 XGBoost 模型，然後將模型部署到 AI Platform 進行預測。

課程內容

內容如下：

- 在 AI Platform Notebooks 中擷取及分析 BigQuery 資料集
- 建構 XGBoost 模型
- 將 XGBoost 模型部署至 AI 平台 並取得預測結果

在 Google Cloud 上執行這個實驗室的總費用約為 **\$1 美元**。


步驟 2 · 約 10 分鐘

2. 設定環境

您必須擁有已啟用計費功能的 Google Cloud Platform 專案，才能執行這項程式碼研究室。如要建立專案，請按照[這裡](#)的操作說明進行。

步驟 1：啟用 Cloud AI Platform Models API

前往 Cloud 控制台的 [AI Platform Models 區段](#)，如果尚未啟用，請點選「啟用」。




步驟 2：啟用 Compute Engine API

前往「Compute Engine」，然後選取「啟用」（如果尚未啟用）。您需要這項資訊才能建立筆記本執行個體。

步驟 3：建立 AI Platform Notebooks 執行個體

前往 Cloud Console 的 [AI Platform Notebooks 專區](#)，然後點選「建立執行個體」。然後選取最新的 **Python** 執行個體類型：




使用預設選項，然後按一下「建立」。建立執行個體後，請選取「Open JupyterLab」：

步驟 4：安裝 XGBoost


開啟 JupyterLab 執行個體後，您需要新增 XGBoost 套件。

如要這麼做，請從啟動器選取「終端機」：


Notebook



Console



Other



然後執行下列指令，安裝 AI Platform 支援的最新版 XGBoost：

```
pip3 install xgboost==0.82
```

完成後，請從啟動器開啟 Python 3 Notebook 執行個體。您可以在筆記本中開始使用！

步驟 5：匯入 Python 套件

在本程式碼研究室的其餘部分，請從 Jupyter 筆記本執行所有程式碼片段。

在筆記本的第一個儲存格中，新增下列匯入內容並執行儲存格。如要執行，請按下頂端選單中的向右箭頭按鈕，或按下 Command-Enter 鍵：

```
import pandas as pd
import xgboost as xgb
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.utils import shuffle
from google.cloud import bigquery
```

步驟 3 · 約 5 分鐘

3. 探索 BigQuery 資料集

BigQuery 已公開提供[許多資料集](#)，供您探索。在本實驗室中，我們將使用[出生率資料集](#)。這項資料包含美國近 40 年的每筆出生記錄，包括嬰兒的出生體重，以及嬰兒父母的人口統計資料。我們會使用部分特徵來預測嬰兒的出生體重。

步驟 1：將 BigQuery 資料下載至筆記本

我們會使用 BigQuery 的 Python 用戶端程式庫，將資料下載至 Pandas DataFrame。原始資料集為 21 GB，包含 1.23 億列。為簡化流程，我們只會使用資料集中的 10,000 個資料列。

使用下列程式碼建構查詢，並預覽產生的 DataFrame。這裡我們從原始資料集取得 4 項特徵，以及嬰兒體重 (模型將預測的項目)。資料集可追溯至多年前，但我們只會使用 2000 年後的資料：

```
query=" """
SELECT
  weight_pounds,
  is_male,
  mother_age,
  plurality,
  gestation_weeks
FROM
  publicdata.samples.natality
WHERE year > 2000
LIMIT 10000
"""

df = bigquery.Client().query(query).to_dataframe()
df.head()
```

如要取得資料集中數值特徵的摘要，請執行下列指令：

```
df.describe()
```

這會顯示數值資料欄的平均值、標準差、最小值和其他指標。最後，我們來取得布林值資料欄的資料，指出嬰兒的性別。我們可以使用 Pandas 的 `value_counts` 方法執行這項操作：

```
df['is_male'].value_counts()
```

資料集似乎已根據性別平均分配 (50/50)。

步驟 4 · 約 5 分鐘

4. 準備訓練資料

在本節中，我們會將資料分成訓練集和測試集，準備用於訓練模型。

步驟 1：擷取標籤欄

首先，從資料集中捨棄含有空值的資料列，然後隨機排序資料：

```
df = df.dropna()
df = shuffle(df, random_state=2)
```

接著，將標籤欄位擷取至個別變數，並建立只含特徵的 DataFrame：

```
labels = df['weight_pounds']
data = df.drop(columns=['weight_pounds'])
```

現在，如果您執行 `data.head()` 預覽資料集，應該會看到我們將用於訓練的四項特徵。

步驟 2：將類別特徵轉換為整數

由於 XGBoost 需要所有資料都是數字，因此我們需要變更 `is_male` 資料欄中資料的表示方式，目前是 True / False 字串。只要變更該資料欄的類型，即可達成這個目的：

```
data['is_male'] = data['is_male'].astype(int)
```

步驟 3：將資料分成訓練集和測試集

我們會使用筆記本開頭匯入的 Scikit Learn `train_test_split` 公用程式，將資料分割為訓練和測試集：


```
x,y = data,labels
x_train,x_test,y_train,y_test = train_test_split(x,y)
```

現在可以建構及訓練模型了！

5. XGBoost 快速入門

XGBoost 是一種機器學習框架，可使用**決策樹**和**梯度提升**來建構預測模型。這項技術會根據樹狀結構中不同葉節點的相關分數，將多個決策樹集合在一起。

下圖是簡化的視覺化呈現方式，說明模型如何評估使用者是否會喜歡特定電腦遊戲 (取自 [XGBoost 文件](#))：



為什麼要使用 **XGBoost** 建立這個模型？傳統類神經網路在圖像和文字等非結構化資料方面表現最佳，而決策樹在結構化資料方面通常表現極佳，例如我們將在本程式碼研究室中使用的房貸資料集。

步驟 6 · 約 5 分鐘

6. 建構、訓練及評估 XGBoost 模型

步驟 1：定義及訓練 XGBoost 模型

在 XGBoost 中建立模型非常簡單。我們將使用 `XGBRegressor` 類別建立模型，只需要為特定工作傳遞正確的 `objective` 參數即可。由於我們要預測數值 (嬰兒體重)，因此使用迴歸模型。如果我們改為將資料分塊，判斷嬰兒體重是否超過 6 磅，則會使用分類模型。

在本例中，我們會使用 `reg:squarederror` 做為模型的目標。

下列程式碼會建立 XGBoost 模型：

```
model = xgb.XGBRegressor(  
    objective='reg:linear'  
)
```

您只需呼叫 `fit()` 方法，並傳遞訓練資料和標籤，即可使用一行程式碼訓練模型。

```
model.fit(x_train, y_train)
```

步驟 2：根據測試資料評估模型

現在可以使用訓練好的模型，透過 `predict()` 函式對測試資料產生預測結果：

```
y_pred = model.predict(x_test)
```

讓我們看看模型在測試集前 20 個值中的表現。以下我們會顯示每個測試範例的預測嬰兒體重和實際嬰兒體重：

```
for i in range(20):  
    print('Predicted weight: ', y_pred[i])  
    print('Actual weight: ', y_test.iloc[i])  
    print()
```

步驟 3：儲存模型

如要部署模型，請執行下列程式碼，將模型儲存至本機檔案：

```
model.save_model('model.bst')
```

步驟 7 · 約 12 分鐘

7. 將模型部署至 Cloud AI Platform

我們已在本機運作模型，但如果能從任何位置 (不只是這個筆記本！) 預測模型，那就太好了。在這個步驟中，我們會將其部署至雲端。

步驟 1：為模型建立 Cloud Storage bucket

首先，請定義一些環境變數，我們會在程式碼研究室的其餘部分使用這些變數。請在下方填入 Google Cloud 雲端專案名稱、要建立的 Cloud Storage 值區名稱 (必須是全域不重複的名稱)，以及模型第一個版本的版本名稱：

```
# Update these to your own GCP project, model, and version names
GCP_PROJECT = 'your-gcp-project'
MODEL_BUCKET = 'gs://storage_bucket_name'
VERSION_NAME = 'v1'
MODEL_NAME = 'baby_weight'
```

現在我們準備建立儲存值區，以儲存 XGBoost 模型檔案。部署時，我們會將 Cloud AI Platform 指向這個檔案。

在筆記本中執行下列 `gsutil` 指令，建立 bucket：

```
!gsutil mb $MODEL_BUCKET
```

步驟 2：將模型檔案複製到 Cloud Storage

接著，我們會將 XGBoost 儲存的模型檔案複製到 Cloud Storage。執行下列 `gsutil` 指令：

```
!gsutil cp ./model.bst $MODEL_BUCKET
```

前往 Cloud 控制台中的儲存空間瀏覽器，確認檔案已複製完成：

[Buckets](#) / mortgage_model_bucket

☐	Name	Size	Type	Storage class	Last modified	Public access	Encryption
☐	model.bst	48.63 KB	application/octet-stream	Multi-Regional	7/23/19, 5:18:57 PM UTC-7	Not public	Google-managed key

步驟 3：建立及部署模型

下列 `ai-platform gcloud` 指令會在專案中建立新模型。我們將這個帳戶稱為「`xgb_mortgage`」：

```
!gcloud ai-platform models create $MODEL_NAME
```

現在可以部署模型了。我們可以使用下列 `gcloud` 指令執行這項操作：

```
!gcloud ai-platform versions create $VERSION_NAME \
--model=$MODEL_NAME \
--framework='XGBOOST' \
--runtime-version=1.15 \
--origin=$MODEL_BUCKET \
--python-version=3.7 \
--project=$GCP_PROJECT
```

執行這項作業時，請檢查 AI Platform 控制台的[模型部分](#)。您應該會看到新版本正在部署：

Name

baby_weight

Default version

-

Region

us-central1

VERSIONS

EVALUATION

BETA

Filter by prefix...

?

☐	☒	Name	Create time	Last used	Evaluation	Labels
☐	☒	v1	Feb 3, 2020, 3:53:32 PM		N/A	

部署作業完成後，載入旋轉圖示會變成綠色勾號。部署作業應會在 **2 到 3 分鐘**內完成。

步驟 4：測試已部署的模型

如要確認已部署的模型是否正常運作，請使用 `gcloud` 進行預測測試。首先，請儲存 JSON 檔案，其中包含測試集中的兩個範例：

```
%%writefile predictions.json
[0.0, 33.0, 1.0, 27.0]
[1.0, 26.0, 1.0, 40.0]
```

將下列 `gcloud` 指令的輸出內容儲存至變數並列印，藉此測試模型：


```
prediction = !gcloud ai-platform predict --model=$MODEL_NAME --json-
instances=predictions.json --version=$VERSION_NAME
print(prediction.s)
```

輸出內容應會顯示模型的預測結果。這兩個範例的實際嬰兒體重分別為 1.9 磅和 8.1 磅。

步驟 8 · 約 2 分鐘

8. 清除所用資源

如要繼續使用這部筆電，建議在不使用時關機。在 Cloud 控制台的 Notebooks 使用者介面中，選取筆記本，然後選取「停止」：



如要刪除在本實驗室中建立的所有資源，請直接刪除筆記本執行個體，而不是停止執行個體。

使用 Cloud 控制台的導覽選單瀏覽至「儲存空間」，然後刪除您建立的兩個 bucket，以儲存模型資產。