

使用 Keras 和 TensorFlow Lite 實現裝置端大型語言模型

來源：<https://codelabs.developers.google.com/kerasnlp-tflite?hl=zh-tw>

步驟數：7

瞭解如何使用 KerasNLP 載入預先訓練的大型語言模型，並透過 TensorFlow Lite 將模型最佳化並部署至 Android

目錄

1. [1. 事前準備](#)
2. [2. 做好準備](#)
3. [3. 執行範例應用程式](#)
4. [4. 準備在裝置端部署 LLM](#)
5. [5. 完成 Android 應用程式](#)
6. [6. 負責任的 AI 技術注意事項](#)
7. [7. 結論](#)


1. 事前準備

本程式碼研究室使用 TensorFlow Lite 程式庫。建議所有新程式碼都使用 [Google AI Edge LiteRT 程式庫](#) 工具。

大型語言模型 (LLM) 是近期最令人期待的機器學習突破。可用於生成文字、翻譯語言，以及提供實用解答。Google [LaMDA](#) 和 [PaLM](#) 等大型語言模型 (LLM) 會以大量文字資料訓練，學習字詞和片語之間的統計模式和關係。這項技術可生成類似人類撰寫的文字，並準確翻譯語言。

LLM 儲存空間非常龐大，執行時通常會消耗大量運算效能，因此通常會部署在雲端，且由於行動裝置的運算效能有限，因此對裝置端機器學習 (ODML) 來說相當具有挑戰性。不過，您可以在現代 Android 裝置上執行較小規模的 LLM (例如 GPT-2)，並獲得令人驚豔的結果。

以下是 Google Pixel 7 Pro 執行 15 億參數的 [Google PaLM 模型](#) 版本示範，未加快播放速度。



在本程式碼研究室中，您將學習相關技術和工具，使用下列項目建構 LLM 輔助應用程式 (以 GPT-2 做為範例模型)：

- KerasNLP 載入經預訓練的 LLM
- 使用 KerasNLP 微調 LLM
- TensorFlow Lite，用於在 Android 上轉換、最佳化及部署大型語言模型

必要條件

- 具備 Keras 和 TensorFlow Lite 的中階知識
- 具備 Android 開發的基本知識

課程內容

- 如何使用 KerasNLP 載入經預訓練的 LLM 並進行微調
- 如何量化 LLM 並轉換為 TensorFlow Lite
- 如何對轉換後的 TensorFlow Lite 模型執行推論


軟硬體需求

- 存取 [Colab](#)
 - 最新版 [Android Studio](#)
 - 搭載 4G 以上 RAM 的新式 Android 裝置
-

2. 做好準備

如要下載本程式碼研究室的程式碼，請按照下列步驟操作：

1. 前往本程式碼研究室的 [GitHub 存放區](#)。
2. 依序點選「Code」>「Download zip」，下載這個程式碼研究室的所有程式碼。



3. 將下載的 ZIP 檔案解壓縮，解壓縮後會產生 `examples` 根資料夾，內含所有需要的資源。

步驟 3 · 約 3 分鐘

3. 執行範例應用程式

1. 將 `examples/lite/examples/generative_ai/android` 資料夾匯入 Android Studio。
2. 啟動 [Android Emulator](#)，然後按一下導覽選單中的「執行」




。

執行並探索應用程式

Android 裝置上應會啟動應用程式。這款應用程式名為「自動完成」。使用者介面相當簡單：在文字方塊中輸入一些種子字詞，然後輕觸「生成」，應用程式就會對 LLM 執行推論，並根據您的輸入內容生成額外文字。

目前，如果您在輸入一些字詞後輕觸「生成」，不會有任何反應。這是因為目前還沒有執行 LLM。



步驟 4 · 約 45 分鐘

4. 準備在裝置端部署 LLM

- 開啟 [Colab](#)，然後執行筆記本 (位於 [TensorFlow Codelabs GitHub 存放區](#))。
-


步驟 5 · 約 5 分鐘

5. 完成 Android 應用程式

現在您已將 GPT-2 模型轉換為 TensorFlow Lite，最後可以將其部署至應用程式。

執行應用程式

1. 將上一個步驟下載的 `autocomplete.tflite` 模型檔案拖曳至 Android Studio 的 `app/src/main/assets/` 資料夾。



2. 按一下導覽選單中的「執行」



，然後等待應用程式載入。

3. 在文字欄位中輸入一些種子字詞，然後輕觸「生成」。



I'm enjoying a little bit of a break. The show's the perfect place to get a little extra time. The show starts off with a bit of a break, and the show's the perfect place to go. It's like a little bit

New suggestion

✓ Accept

Apply context window

20 words

Powered by KerasNLP and TensorFlow Lite

注意：請務必在 RAM 超過 4 GB 的新式 Android 裝置上執行應用程式。在記憶體不足的裝置上執行應用程式時，應用程式可能會當機。

6. 負責任的 AI 技術注意事項

如原始 [OpenAI GPT-2 公告](#) 所述，GPT-2 模型有 [顯著的注意事項和限制](#)。事實上，目前 LLM 普遍存在一些眾所周知的問題，例如幻覺、產生冒犯內容、公平性和偏誤；這是因為這些模型是根據真實世界的資料訓練而成，因此會反映現實世界的問題。

本程式碼研究室僅用於示範如何使用 TensorFlow 工具，建立由 LLM 驅動的應用程式。本程式碼研究室產生的模型僅供教育用途，不適用於正式環境。

如要在實際工作環境中使用 LLM，必須慎選訓練資料集，並採取全面的安全防護措施。如要進一步瞭解 LLM 領域的負責任 AI 技術，請務必觀看 2023 年 Google I/O 大會的 [安全且負責任的生成式語言模型開發技術研討會](#)，並參閱 [負責任的 AI 技術工具包](#)。

步驟 7 · 約 1 分鐘

7. 結論

恭喜！您已建構應用程式，可完全在裝置上執行預先訓練的大型語言模型，根據使用者輸入內容生成連貫的文字！

瞭解詳情

- [KerasNLP 首頁](#)
 - [TensorFlow Lite 首頁](#)
 - [TensorFlow Lite 範例](#)
-