

運用 Google Dataproc 建立 Spark 機器學習模型

來源：<https://codelabs.developers.google.com/dataproc-spark-ml?hl=zh-tw>

步驟數：5

在本程式碼研究室中，您會將 Spark 機器學習工作提交至 Google 的 Dataproc 服務。

目錄

1. [簡介](#)
2. [啟用 API](#)
3. [建立及連線至 Vertex AI Workbench 執行個體](#)
4. [從筆記本使用 Spark ML 建構模型](#)
5. [清除所用資源](#)

1. 簡介

Apache Spark 的核心元件之一是 [Spark ML](#)，這個程式庫可建構以 Apache Spark 引擎為基礎的機器學習模型和管線。網站提供下列工具：

- 機器學習演算法：常見的學習演算法，例如分類、迴歸、分群和協同過濾
- 特徵化：特徵擷取、轉換、降維和選取
- 管道：建構、評估及調整機器學習管道的工具
- 持續性：儲存及載入演算法、模型和管道
- 公用程式：線性代數、統計資料、資料處理等。

在本程式碼研究室中，您將瞭解如何使用筆記本建立 Spark 機器學習模型。

步驟 2 · 約 2 分鐘

2. 啟用 API

在本程式碼研究室中，您必須啟用下列 API：

- [BigQuery](#)
- [Dataproc](#)
- [Vertex AI](#)
- [筆記本](#)

按一下這個[連結](#)，在專案中啟用這些 API。系統提示時，請確認 API 將在正確的專案中啟用。

3. 建立及連線至 Vertex AI Workbench 執行個體

在本節中，您將建立 Vertex AI Workbench 執行個體。然後連線至該執行個體、複製 GitHub 存放區，並執行筆記本。

如要建立 Vertex AI Workbench 執行個體，請按照[操作說明](#)或以下步驟進行。

1. 前往 [Managed Notebooks 控制台頁面](#)。
2. 按一下「新增筆記本」。
3. 提供名稱並選擇[區域](#)，例如「us-central1 (Iowa)」(us-central1 (愛荷華州))。理想情況下，這應與您在 Codelab 中稍早選取的區域相符，但並非必要。
4. 在「權限」下方，選取「僅限單一使用者」。
5. 開啟「進階設定」下拉式選單。
6. 在「安全性」下方，選取「啟用 nbconvert」和「啟用終端機」。
7. 按一下 [建立]。

執行個體應會在五分鐘內完成佈建。執行個體準備就緒後，**筆記本名稱**旁會顯示綠色勾號。

執行個體就緒後，按一下「OPEN JUPYTERLAB」。在系統提示時進行驗證，並啟用所有權限。

步驟 4 · 約 20 分鐘

4. 從筆記本使用 Spark ML 建構模型

JupyterLab 執行個體載入後，您會進入「啟動器」分頁。在這個分頁中，按一下「Other」(其他) 下方的「Terminal」(終端機)，開啟新的終端機。

在終端機中，複製 [Vertex AI 範例](#) 存放區。



```
git clone https://github.com/GoogleCloudPlatform/vertex-ai-samples.git
```

在「File Browser」(檔案瀏覽器) 分頁中，前往 **vertex-ai-samples/notebooks/official/workbench/spark**。按兩下開啟筆記本 **spark_ml.ipynb**。系統提示選取核心時，請選取「Python (local)」。

逐步執行筆記本中的每個儲存格，並按照儲存格中的操作說明操作。

5. 清除所用資源

完成本程式碼研究室後，為避免系統向您的 GCP 帳戶收取不必要的費用，請按照下列步驟操作：

1. 刪除 Workbench 執行個體。在[控制台](#)中，勾選執行個體旁邊的方塊，然後按一下「DELETE」(刪除)。

如果您專為本程式碼研究室建立了專案，也可以選擇刪除該專案：

1. 前往 GCP 主控台的「Projects」(專案) 頁面。
2. 在專案清單中，選取要刪除的專案，然後按一下「刪除」。
3. 在方塊中輸入專案 ID，然後按一下「關閉」刪除專案。

警告：刪除專案會出現以下結果：

- **專案中的所有內容都會遭到刪除。**如果您之前使用現有的專案來進行本教學課程，當您刪除該專案時，也會一併刪除您在該專案中完成的所有其他工作。
- **自訂專案 ID 不復存在。**您建立這個專案時，可能已建立日後使用的自訂專案 ID。如要保留使用該專案 ID 的網址 (例如 `appspot.com` 網址)，請刪除在該專案中選取的資源，而不是刪除整個專案。