

在 Cloud Run 使用 PaLM API 的即時通訊應用程式

來源：<https://codelabs.developers.google.com/llm-chat-app-flask?hl=zh-tw>

步驟數：8

使用 Python Flask 架構和 Vertex AI PaLM API 模型開發聊天應用程式。

目錄

1. [簡介](#)
2. [需求條件](#)
3. [事前準備](#)
4. [設定環境](#)
5. [建構 Docker 映像檔](#)
6. [部署應用程式](#)
7. [清除所用資源](#)
8. [恭喜](#)

步驟 1 · 約 0 分鐘

1. 簡介

本程式碼實驗室會說明如何建構及部署 AI 即時通訊應用程式，並以 Google Cloud 的 Cloud Run 服務形式部署至網頁應用程式。使用者可透過這個即時通訊應用程式，使用 PaLM for Chat Bison 模型 ([text-chat](#)) 查詢並取得回覆。

建構項目

您將建立

- Google Cloud 中用於執行應用程式的環境
 - 應用程式的 Docker 映像檔
 - 執行應用程式的 Cloud Run 服務
-

步驟 2 · 約 0 分鐘

2. 需求條件

- [Chrome](#) 或 [Firefox](#) 瀏覽器
 - 已啟用計費功能的 Google Cloud 雲端專案
-

3. 事前準備

1. 在 [Google Cloud 控制台](#) 的專案選取器頁面中，選取或建立 Google Cloud [專案](#)
2. 確保您的 Google Cloud 雲端專案有啟用計費服務。瞭解如何[檢查專案是否已啟用計費功能](#)
3. 按照[這裡](#)的說明，從 Google Cloud 控制台啟用 Cloud Shell
4. 如果未設定專案，請使用下列指令來設定：

```
gcloud config set project <YOUR_PROJECT_ID>
```

5. 在 Cloud Shell 中設定下列環境變數：

□□□

```
export GCP_PROJECT=<YOUR_PROJECT_ID>
export GCP_REGION=us-central1
```

6. 在 Cloud Shell 終端機執行下列指令，啟用必要的 Google Cloud API：

□□□

```
gcloud services enable cloudbuild.googleapis.com cloudfunctions.googleapis.com
run.googleapis.com logging.googleapis.com storage-component.googleapis.com
aiplatform.googleapis.com
```

4. 設定環境

1. 如要將程式碼範例複製到專案，請在 Cloud Shell 中複製存放區：



```
git clone https://github.com/rominirani/genai-apptemplates-googlecloud
```

2. 這個指令會將存放區內容複製到 genai-templates-googlecloud 資料夾。
3. 在 Cloud Shell 終端機執行下列指令，前往我們感興趣的專案資料夾：

```
cd genai-apptemplates-googlecloud/chat-flask-cloudrun
```

4. 為 Vertex AI 初始化設定下列環境變數：

GCP_PROJECT：您的 Google Cloud 專案 ID。例如：my_project。

GCP_REGION：要部署 Cloud Function 的區域。例如：us-central1。

```
export GCP_PROJECT='YOUR_PROJECT'  
export GCP_REGION='us-central1'
```

5. 建構 Docker 映像檔

如要建構應用程式的 Docker 映像檔，並推送至 Artifact Registry，請按照下列步驟操作：

1. 為 Artifact Registry 存放區設定環境變數。名稱只能由小寫英文字母、數字和連字號組成，且開頭須為英文字母，結尾須為英文字母或數字。例如：my-chat-app-repo。

```
export AR_REPO='my-chat-app-repo'
```

2. 為服務名稱設定環境變數。例如：chat-flask-app。

```
export SERVICE_NAME='chat-flask-app'
```

3. 以 Docker 格式建立存放區。

```
gcloud artifacts repositories create "$AR_REPO" --location="$GCP_REGION" --repository-format=Docker
```

4. 設定 Docker 驗證。

```
gcloud auth configure-docker "$GCP_REGION-docker.pkg.dev"
```

5. 建構映像檔。

```
gcloud builds submit --tag "$GCP_REGION-docker.pkg.dev/$GCP_PROJECT/$AR_REPO/$SERVICE_NAME"
```

5. 前往 Artifact Registry 頁面，確認映像檔已推送至 Artifact Registry。在這個頁面中找出您建立的存放區。
-

步驟 6 · 約 0 分鐘


6. 部署應用程式

1. 將應用程式部署為 Cloud Run 上的服務。

```
gcloud run deploy "$SERVICE_NAME" \  
--port=8080 \  
--image="$GCP_REGION-docker.pkg.dev/$GCP_PROJECT/$AR_REPO/$SERVICE_NAME" \  
--allow-unauthenticated \  
--region=$GCP_REGION \  
--platform=managed \  
--project=$GCP_PROJECT \  
--set-env-vars=GCP_PROJECT=$GCP_PROJECT,GCP_REGION=$GCP_REGION
```


這個步驟可能需要幾秒鐘才能完成。

2. 點選服務網址，啟動即時通訊應用程式。



```
CLOUD SHELL  
Terminal (web-risk6) x +  
  
--allow-unauthenticated \  
--region=$GCP_REGION \  
--platform=managed \  
--project=$GCP_PROJECT \  
--set-env-vars=GCP_PROJECT=$GCP_PROJECT,GCP_REGION=$GCP_REGION  
Deploying container to Cloud Run service [chat-flask-app] in project [web-risk6] region [us-central1]  
OK Deploying new service... Done.  
OK Creating Revision...  
OK Routing traffic...  
OK Setting IAM Policy...  
Done.  
Service [chat-flask-app] revision [chat-flask-app-(7zd)] has been deployed and is serving 100 percent of traffic.  
Service URL: https://chat-flask-app-uc.a.run.app
```

即時通訊應用程式會在新分頁中開啟，如下列螢幕截圖所示：



7. 清除所用資源

如要避免系統向您的 Google Cloud 帳戶收取本文章所用資源的費用，請按照下列步驟操作：

1. 在 Google Cloud 控制台中前往「管理資源」頁面。
 2. 在專案清單中選取要刪除的專案，然後按一下「刪除」。
 3. 在對話方塊中輸入專案 ID，然後按一下「Shut down」(關機) 即可刪除專案。
 4. 如要保留專案，請略過上述步驟，然後前往 Cloud Run 刪除 Cloud Run 服務。在服務清單中，勾選要刪除的服務，然後按一下「刪除」。
-

步驟 8 · 約 0 分鐘

8. 恭喜

恭喜！您已成功在 Google Cloud 中，以 Cloud Run 服務的形式，為網頁應用程式建構及部署 AI 即時通訊應用程式。使用者可以在這個即時通訊應用程式中輸入查詢，應用程式會叫用 Vertex AI 聊天模型並提供回覆。
