

透過 Vertex AI 取得預先訓練的 TensorFlow 圖像模型預測結果

來源：<https://codelabs.developers.google.com/vertex-image-deploy?hl=zh-tw>

步驟數：9

目錄

1. [總覽](#)
2. [Vertex AI 簡介](#)
3. [用途總覽](#)
4. [設定環境](#)
5. [註冊模型](#)
6. [部署模型](#)
7. [取得預測結果](#)
8. [\[選用\] 使用 TF Serving 最佳化預測](#)
9. [清除所用資源](#)

步驟 1 · 約 1 分鐘

1. 總覽

在本實驗室中，您將使用 [Vertex AI](#)，從預先訓練的圖像分類模型取得預測結果。

課程內容

內容如下：


- 將 TensorFlow 模型匯入 Vertex AI Model Registry
- 取得線上預測
- 更新 TensorFlow Serving 函式

在 Google Cloud 上執行這個實驗室的總費用約為 **\$1 美元**。

2. Vertex AI 簡介

本實驗室使用 Google Cloud 最新推出的 AI 產品服務。Vertex AI 整合了 Google Cloud 機器學習服務，提供流暢的開發體驗。以 AutoML 訓練的模型和自訂模型，先前需透過不同的服務存取。這項新服務將兩者併至單一 API，並加入其他新產品。您也可以將現有專案遷移至 Vertex AI。

Vertex AI 包含許多不同的產品，可支援端對端機器學習工作流程。本實驗室將著重於下列產品：**Predictions**和**Workbench**



步驟 3 · 約 0 分鐘

3. 用途總覽

在本實驗室中，您將瞭解如何從 [TensorFlow Hub](#) 取得預先訓練的模型，並部署至 Vertex AI。TensorFlow Hub 是已訓練模型的存放區，適用於各種問題領域，例如嵌入、文字生成、語音轉文字、影像分割等。

本實驗室使用的範例是以 [ImageNet 資料集預先訓練的 MobileNet V1 圖片分類模型](#)。只要運用 TensorFlow Hub 或其他類似的深度學習存放區提供的現成模型，您就能為多項預測工作部署高品質的機器學習模型，不必擔心模型訓練問題。

步驟 4 · 約 10 分鐘

4. 設定環境

您必須擁有已啟用計費功能的 Google Cloud Platform 專案，才能執行這項程式碼研究室。如要建立專案，請按照[這裡的說明](#)操作。

步驟 1：啟用 Compute Engine API

前往「Compute Engine」，然後選取「啟用」（如果尚未啟用）。


步驟 2：啟用 Vertex AI API

前往 [Cloud 控制台](#) 的 [Vertex AI 專區](#)，然後點選「啟用 Vertex AI API」。

Get started with Vertex AI

Vertex AI empowers machine learning developers, data scientists, and data engineers to take their projects from ideation to deployment, quickly and cost-effectively. [Learn more](#)

ENABLE VERTEX AI API



Region
us-central1 (Iowa)

Prepare your training data

Collect and prepare your data, then import it into a dataset to train a model

+ CREATE DATASET

Train your model

Train a best-in-class machine learning model with your dataset. Use Google's AutoML, or bring your own code.

+ TRAIN NEW MODEL


Get predictions

After you train a model, you can use it to get predictions, either online as an endpoint or through batch requests

+ CREATE BATCH PREDICTION

步驟 3：建立 Vertex AI Workbench 執行個體

在 Cloud 控制台的「Vertex AI」部分中，按一下「Workbench」：



如果尚未啟用 Notebooks API，請先啟用。



Notebooks API

Google Enterprise API

Notebooks API is used to manage notebook resources in Google Cloud.

ENABLE

TRY THIS API [↗](#)

OVERVIEW

PRICING

DOCUMENTATION

Overview

Notebooks API is used to manage notebook resources in Google Cloud.

Additional details

Type: [SaaS & APIs](#)

Last updated: 15/09/2021

Category: [Google Enterprise APIs](#)

Service name: notebooks.googleapis.com

啟用後，按一下「MANAGED NOTEBOOKS」(代管型筆記本)：

Managed notebooks

[+ NEW NOTEBOOK](#)

[REFRESH](#)

[▶ START](#)

[■ STOP](#)

[⏻ RESET](#)

[🗑 DELETE](#)

[MANAGED NOTEBOOKS](#) [PREVIEW](#)

USER-MANAGED NOTEBOOKS

EXECUTIONS [PREVIEW](#)

SCHEDULES [PREVIEW](#)

Managed notebooks provide JupyterLab services and flexible computing resources integrated with Google Cloud services. [Learn more](#)

然後選取「新增記事本」。

[+ NEW NOTEBOOK](#)

[REFRESH](#)

[▶ START](#)

[MANAGED NOTEBOOKS](#) [PREVIEW](#)

USER-MANAGED NOTEBOOKS

Notebooks service has been moved under the Vertex AI Workbench

為筆記本命名，然後在「權限」下方選取「服務帳戶」

← Create a managed notebook

Notebook name *

my-notebook

63 character limit with lowercase letters, digits or '-' only. Must start with a letter. Cannot end with a '-'.

Region

us-central1 (Iowa)



Permission

JupyterLab access modes determine who can use a notebook instance and which credentials are used to call Google APIs. **This cannot be changed once the notebook is created.**

☒ Service account

Service account mode allows anyone who is granted the `iam.serviceAccounts.actAs` permission on the specified service account to access the JupyterLab UI. [Learn more](#)

☐ Single user only

Single-user-only mode restricts access to the user specified below. [Learn more](#)

☒ Use Compute Engine default service account

選取「進階設定」。

在「安全性」下方，選取「啟用終端機」(如果尚未啟用)。

Security

☒ Enable nbconvert

☒ Enable file downloading from Notebook UI

☒ Enable terminal

其他進階設定可以保留原樣。

接著點選「建立」。執行個體會在幾分鐘內佈建完畢。

建立執行個體後，請選取「OPEN JUPYTERLAB」。

☐	☒	my-notebook	OPEN JUPYTERLAB
--------------------------	-------------------------------------	-------------	-----------------

步驟 5 · 約 10 分鐘

5. 註冊模型

步驟 1：將模型上傳至 Cloud Storage

按一下[這個連結](#)，前往 TensorFlow Hub 頁面，查看以 ImageNet 資料集訓練的 MobileNet V1 模型。

選取 下載，即可下載儲存的模型構件。

Model formats

TF	.JS (v1, default)	.JS (v3, default)
TF2.0 Saved Model (v5) Usage data: 32 Downloads V5 Fine tuneable: Yes License: Apache-2.0 Format: TF2.0 Saved Model Imagenet (ILSVRC-2012-CLS) classification with MobileNet V1 (depth multiplier 0.50). ..et_v1_050_128/classification/5 Copy URL Download 4.81MB		

在 Google Cloud 控制台的 Cloud Storage 專區中，選取「CREATE」(建立)

Cloud Storage	Buckets	CREATE	REFRESH
Buckets	Filter Filter buckets		
Monitoring	☐ Name ↑	Created	

為 bucket 命名，並選取 us-central1 做為區域。然後按一下「建立」。



Create a Bucket



Name your bucket

Name: image-codelab-bucket

Choose where to store your data

This permanent choice defines the geographic placement of your data and affects cost, performance and availability. [Learn more](#)

Location type



Multi-region

Highest availability across largest area



Dual-region

High availability and low latency across 2 regions



Region

Lowest latency within a single region

us-central1 (Iowa)



CONTINUE

將下載的 TensorFlow Hub 模型上傳至值區。請務必先解壓縮檔案。

←

Bucket details

REFRESH

image-codelab-bucket

Location

Storage class

Public access

Protection

us-central1 (Iowa)

Standard

Not public

None

OBJECTS

CONFIGURATION

PERMISSION

PROTECTION

LIFECYCLE

Buckets > image-codelab-bucket

UPLOAD FILES

UPLOAD FOLDER

CREATE FOLDER

MANAGE HOLDS

DOWNLOAD

DELETE

Filter by name prefix only

Filter Filter objects and folders

☐	Name	Size	Type	Created ?	Storage class	Last modified	Public access ?	Version
☐	 imagenet_mobilenet_v1_050_128_classificat...	—	Folder	—	—	—	—	—

您的儲存空間應如下所示：

```
imagenet_mobilenet_v1_050_128_classification_5/  
  saved_model.pb  
  variables/  
    variables.data-00000-of-00001  
    variables.index
```

步驟 2：將模型匯入登錄檔

前往 Cloud 控制台的 Vertex AI 模型登錄專區。



Google Cloud



Vertex AI



Dashboard



Datasets



Feature Store



Labelling tasks



Workbench



Pipelines



Training



Experiments



Model registry



Endpoints



Batch predictions



Metadata



Matching engine

選取「匯入」 **IMPORT**

選取「匯入為新模型」，然後為模型命名。

Import model

- 1 Name and region
- 2 Model settings
- 3 Explainability (optional)

IMPORT

CANCEL

You can import model artifacts that have been trained outside of Google Cloud. Once your model has been imported, you can serve it for online or batch predictions and compare it against your other Cloud AI models. [More info](#)

☒ Import as new model

Creates a new model group and assigns the imported model as version 1

☐ Import as new version

Imports the model as a version of an existing model

Name *
imagenet_model

Description

Region

us-central1 (Iowa)

▼ ADVANCED OPTIONS

CONTINUE

在「模型設定」下方，指定最新的預建 TensorFlow 容器。然後選取 Cloud Storage 中儲存模型構件的路徑。

- ☒ Import model artifacts into a new pre-built container
View the list of [supported runtimes](#) including TensorFlow, scikit-learn and XGBoost versions
- ☐ Import an existing custom container
Build a custom Docker container. Must be stored in [Container Registry](#) or [Artifact Registry](#)

Pre-built container settings

In order to run in a pre-built container, your code needs to be in Python 3.7

Model framework *

TensorFlow



Model framework version *

2.8



Accelerator type *

None



Model artifact location (Cloud storage path) *



gs:// image-codelab-bucket/imagenet_mobilenet_v1_050_128_classi

BROWSE

Path to the Cloud Storage directory where the exported model file is stored (not the path to the model file itself). The model name must be one of: saved_model.pb, model.pkl, model.joblib or model.bst, depending on which library you used.

您可以略過「可解釋性」部分。

然後選取「匯入」 **IMPORT**

匯入完成後，模型就會顯示在模型登錄中

Models

 CREATE  IMPORT

Models are built from your data sets or unmanaged data sources. There are many different types of machine learning models available on Vertex AI, depending on your use case and level of experience with machine learning. [Learn more](#)

Region

us-central1 (Iowa)  

 Filter Enter a property name

Name	Deployment status	Description	Default version	Type	Source
imagnet_model	—	—	1	 Imported	Custom training

6. 部署模型

在「模型登錄」中，選取模型右側的三點圖示，然後按一下「Deploy to endpoint」(部署至端點)。

Models

+

CREATE

↓

IMPORT

REFRESH

LEARN

Models are built from your data sets or unmanaged data sources. There are many different types of machine learning models available on Vertex AI, depending on your use case and level of experience with machine learning. [Learn more](#)

Region

us-central1 (Iowa)

Filter

Enter a property name

?

⋮

Edit labels

Edit name and description

Delete model

Deploy to endpoint

在「定義端點」下方，選取「建立新端點」，然後為端點命名。

在「模型設定」下方，將「運算節點數上限」設為 1，機型設為 `n1-standard-2`，其餘設定維持不變。然後點按「部署」。

Deploy to endpoint

✓ Define your endpoint

2 Model settings

3 Model monitoring

DEPLOY

CANCEL

Choose how compute resources will serve prediction traffic to your model

- Autoscaling:** If you set a minimum and maximum, compute nodes will scale to meet traffic demand within those boundaries
- No scaling:** If you only set a minimum, then that number of compute nodes will always run regardless of traffic demand (the maximum will be set to minimum)

Once scaling settings are set, they can't be changed unless you redeploy the model. [Pricing guide](#)

Minimum number of compute nodes *

1

Default is 1. If set to 1 or more, then compute resources will continuously run even without traffic demand. This can increase cost but avoid dropped requests due to node initialisation.

Maximum number of compute nodes (optional)

1

Enter a number equal to or greater than the minimum nodes. Can reduce costs but may cause reliability issues for high traffic.

✓ ADVANCED SCALING OPTIONS

Machine type *

n1-standard-2, 2 vCPUs, 7.5 GiB memory

Service account

A service account determines what Google Cloud resources your service code can access. By default, a Google-managed service account is used with permissions

部署作業大約需要十分鐘。

部署完成後，部署狀態會變更為「已在 Vertex AI 上部署」。

Models

[+ CREATE](#)

[IMPORT](#)



Models are built from your data sets or unmanaged data sources. There are many different types of machine learning models available on Vertex AI, depending on your use case and level of experience with machine learning. [Learn more](#)

Region

us-central1 (Iowa)




Filter Enter a property name

Name	Deployment status	Description	Default version	Type	Source	Updated
imagnet_model	Deployed on Vertex AI	—	1	Imported	Custom training	26 Aug 2022, 13:49:21

7. 取得預測結果

開啟您在設定步驟中建立的 Workbench 筆記本。從啟動器建立新的 TensorFlow 2 筆記本。



執行下列儲存格，匯入必要的程式庫

```
from google.cloud import aiplatform

import tensorflow as tf
import numpy as np
from PIL import Image
```

從 TensorFlow Hub 下載的 MobileNet 模型是透過 ImageNet 資料集訓練的。MobileNet 模型的輸出內容是數字，對應至 ImageNet 資料集中的類別標籤。如要將該數字轉換為字串標籤，請下載圖片標籤。

```
# Download image labels

labels_path =
tf.keras.utils.get_file('ImageNetLabels.txt', 'https://storage.googleapis.com/download.tensorflow.org/data/ImageNetLabels.txt')
imagenet_labels = np.array(open(labels_path).read().splitlines())
```

如要存取端點，您必須定義端點資源。請務必替換 `{PROJECT_NUMBER}` 和 `{ENDPOINT_ID}`。

```
PROJECT_NUMBER = "{PROJECT_NUMBER}"
ENDPOINT_ID = "{ENDPOINT_ID}"

endpoint = aiplatform.Endpoint(
    endpoint_name=f"projects/{PROJECT_NUMBER}/locations/us-central1/endpoints/{ENDPOINT_ID}")
```

您可以在控制台首頁找到專案編號。



Welcome

You're working in [cloudadvocacyorg.joonix.net](#) > [nikita-demos](#)

Project number:

Project ID: nikita-demos

[Dashboard](#)

[Recommendations](#)

以及 Vertex AI 「端點」 部分中的端點 ID。

Endpoints

[+ CREATE ENDPOINT](#)

Endpoints are machine learning models made available for online prediction requests. Endpoints are useful for timely predictions from many users (for example, in response to an application request). You can also request batch predictions if you don't need immediate results.

To create an endpoint, you need at least one machine-learning model. [Learn more](#)

Region

us-central1 (Iowa)

Filter Enter a property name

☐	Name	ID	Status	Models	Region	Monitoring	M
☐	my-endpoint	2464726837473837056	Active	1	us-central1	Disabled	-

接著，您會測試端點。

首先，請下載下列圖片，然後上傳至執行個體。



使用 PIL 開啟圖片。然後調整大小並縮放 255。請注意，模型預期的圖片大小可在模型的 TensorFlow Hub 頁面找到。

```
IMAGE_PATH = "test-image.jpg"
IMAGE_SIZE = (128, 128)

im = Image.open(IMAGE_PATH)
im = im.resize(IMAGE_SIZE)
im = np.array(im)/255.0
```

接著，將 NumPy 資料轉換為清單，以便在 HTTP 要求的本文中傳送。

```
x_test = im.astype(np.float32).tolist()
```

最後，對端點發出預測呼叫，然後查閱對應的字串標籤。

```
# make prediction request
result = endpoint.predict(instances=[x_test]).predictions

# post process result
predicted_class = tf.math.argmax(result[0], axis=-1)
string_label = imagenet_labels[predicted_class]

print(f"label ID: {predicted_class}")
print(f"string label: {string_label}")
```

步驟 8 · 約 0 分鐘

8. [選用] 使用 TF Serving 最佳化預測

如要查看更貼近現實的範例，您可能需要直接將圖片傳送至端點，而不是先載入 NumPy。這種做法效率較高，但您必須修改 TensorFlow 模型的服務函式。這項修改作業是為了將輸入內容轉換為模型預期的格式。

步驟 1：修改服務函式

開啟新的 TensorFlow 筆記本，然後匯入必要程式庫。

```
from google.cloud import aiplatform

import tensorflow as tf
```

這次您不會下載儲存的模型構件，而是使用 `hub.KerasLayer` 將模型載入 TensorFlow，這會將 TensorFlow SavedModel 包裝為 Keras 層。如要建立模型，您可以搭配使用 Keras Sequential API 和下載的 TF Hub 模型 (做為層)，並指定模型的輸入形狀。

```
tfhub_model = tf.keras.Sequential(

    [hub.KerasLayer("https://tfhub.dev/google/imagenet/mobilenet_v1_050_128/classification/5")]

)
tfhub_model.build([None, 128, 128, 3])
```

定義您先前建立的 bucket 的 URI。

```
BUCKET_URI = "gs://{YOUR_BUCKET}"
MODEL_DIR = BUCKET_URI + "/bytes_model"
```

當您將要求傳送至線上預測伺服器時，HTTP 伺服器會收到該要求。HTTP 伺服器會從 HTTP 要求內容主體中擷取預測要求。擷取的預測要求會轉送至服務函式。如果是 Vertex AI 預建預測容器，要求內容會以 `tf.string` 形式傳遞至服務函式。

如要將圖片傳遞至預測服務，您需要將壓縮的圖片位元組編碼為 Base64，這樣在透過網路傳輸二進位資料時，內容就不會遭到修改。

由於已部署的模型預期輸入資料為原始 (未壓縮) 位元組，因此您需要確保 base64 編碼資料會轉換回原始位元組 (例如 JPEG)，然後經過預先處理，符合模型輸入需求，再做為輸入內容傳遞至已部署的模型。

如要解決這個問題，請定義服務函式 (`serving_fn`)，並將其附加至模型做為前處理步驟。您會新增 `@tf.function` 裝飾器，以便將服務函式融合至基礎模型 (而非 CPU 上的上游)。

如果您不熟悉 TensorFlow 中的具體函式或 `tf.function`，請別擔心。下列程式碼片段是樣板，您應該可以將其用於其他 TensorFlow 圖片分類模型。

```

CONCRETE_INPUT = "numpy_inputs"

def _preprocess(bytes_input):
    decoded = tf.io.decode_jpeg(bytes_input, channels=3)
    decoded = tf.image.convert_image_dtype(decoded, tf.float32)
    resized = tf.image.resize(decoded, size=(128, 128))
    return resized

@tf.function(input_signature=[tf.TensorSpec([None], tf.string)])
def preprocess_fn(bytes_inputs):
    decoded_images = tf.map_fn(
        _preprocess, bytes_inputs, dtype=tf.float32, back_prop=False
    )
    return {
        CONCRETE_INPUT: decoded_images
    } # User needs to make sure the key matches model's input

@tf.function(input_signature=[tf.TensorSpec([None], tf.string)])
def serving_fn(bytes_inputs):
    images = preprocess_fn(bytes_inputs)
    prob = m_call(**images)
    return prob

m_call = tf.function(tfhub_model.call).get_concrete_function(
    [tf.TensorSpec(shape=[None, 128, 128, 3], dtype=tf.float32, name=CONCRETE_INPUT)]
)

tf.saved_model.save(tfhub_model, MODEL_DIR, signatures={"serving_default": serving_fn})

```

以 HTTP 要求封包形式傳送預測資料時，圖片資料會經過 base64 編碼，但 TensorFlow 模型會採用 NumPy 輸入。服務函式會將 base64 轉換為 NumPy 陣列。

提出預測要求時，您需要將要求路徑導向服務函式，而非模型，因此您有知情必要知道服務函式的輸入層名稱。我們可以從服務函式簽章取得這個名稱。

```

loaded = tf.saved_model.load(MODEL_DIR)

serving_input = list(
    loaded.signatures["serving_default"].structured_input_signature[1].keys()
)[0]
print("Serving function input name:", serving_input)

```

步驟 2：匯入登錄檔並部署

在先前的章節中，您已瞭解如何透過 UI 將模型匯入 Vertex AI Model Registry。本節將說明如何使用 SDK 進行替代操作。請注意，您還是可以改用這裡的 UI。


```

model = aiplatform.Model.upload(
    display_name="optimized-model",
    artifact_uri=MODEL_DIR,
    serving_container_image_uri="us-docker.pkg.dev/vertex-ai/prediction/tf2-cpu.2-8:latest",
)

print(model)

```

您也可以使用 SDK 部署模型，而非 UI。

```

endpoint = model.deploy(
    deployed_model_display_name='my-bytes-endpoint',
    traffic_split={"0": 100},
    machine_type="n1-standard-4",
    accelerator_count=0,
    min_replica_count=1,
    max_replica_count=1,
)

```

步驟 3：測試模型

現在可以測試端點。由於我們修改了服務函式，這次您可以直接在要求中傳送圖片 (採用 Base64 編碼)，不必先將圖片載入 NumPy。這樣一來，您就能傳送較大的圖片，不會達到 Vertex AI Predictions 的大小限制。

再次下載圖片標籤

```

import numpy as np
labels_path =
tf.keras.utils.get_file('ImageNetLabels.txt', 'https://storage.googleapis.com/download.tensorf
low.org/data/ImageNetLabels.txt')
imagenet_labels = np.array(open(labels_path).read().splitlines())

```

將圖片進行 Base64 編碼。

```

import base64

with open("test-image.jpg", "rb") as f:
    data = f.read()
b64str = base64.b64encode(data).decode("utf-8")

```

進行預測呼叫，指定服務函式的輸入層名稱，也就是我們稍早定義的 `serving_input` 變數。

```
instances = [{serving_input: {"b64": b64str}}]

# Make request
result = endpoint.predict(instances=instances).predictions

# Convert image class to string label
predicted_class = tf.math.argmax(result[0], axis=-1)
string_label = imagenet_labels[predicted_class]

print(f"label ID: {predicted_class}")
print(f"string label: {string_label}")
```

🎉 恭喜！🎉

您已瞭解如何使用 Vertex AI 執行下列作業：


- 代管及部署預先訓練模型

如要進一步瞭解 Vertex 的其他部分，請參閱[說明文件](#)。

步驟 9 · 約 1 分鐘

9. 清除所用資源

由於 Vertex AI Workbench 代管筆記本具有閒置關機功能，因此我們不必擔心執行個體關機問題。如要手動關閉執行個體，請按一下控制台 Vertex AI Workbench 專區的「停止」按鈕。如要徹底刪除筆記本，請按一下「刪除」按鈕。



如要刪除 Storage Bucket，請使用 Cloud 控制台中的導覽選單瀏覽至 Storage，選取 bucket，然後按一下「Delete」：

