

運用 Vertex AI 和 BigQuery 機器學習預測時間序列

來源：<https://codelabs.developers.google.com/codelabs/time-series-forecasting-with-cloud-ai-platform?hl=zh-tw>

步驟數：9

在本研究室中，您將瞭解如何使用 Vertex AI 解決時間序列問題，內容涵蓋筆記本、訓練、預測和 BigQuery ML。

目錄

1. [1. 總覽](#)
2. [2. 時間序列預測簡介](#)
3. [3. 設定 Notebook 環境](#)
4. [4. 探索資料並以圖表呈現](#)
5. [5. 使用 BigQuery 時間序列預測建立模型](#)
6. [6. 建立自訂預測模型](#)
7. [7. 在雲端中訓練及預測](#)
8. [8. 挑戰](#)
9. [9. 清除所用資源](#)

步驟 1 · 約 1 分鐘

1. 總覽

在本實驗室中，您將瞭解如何使用 TensorFlow 建構時間序列預測模型，然後瞭解如何使用 [Vertex AI](#) 部署這些模型。

課程內容

內容如下：


- 轉換資料，以使用於機器學習模型
 - 以圖表呈現及探索資料
 - 使用 BigQuery ML 建立時間序列預測模型
 - 使用 LSTM 和 CNN 架構，透過 TensorFlow 建構時間序列預測模型
-

2. 時間序列預測簡介

本程式碼實驗室的重點是說明如何使用 Google Cloud Platform 套用時間序列預測技術。這不是一般的時間序列預測課程，但簡要介紹相關概念或許對使用者有幫助。

時間序列資料

首先，什麼是時間序列？這類資料集會定期記錄資料。時間序列資料集包含時間和至少一個依時間而定的變數。




元件

時間序列可分解為下列元件：

- **趨勢**：以可合理預測的模式上升或下降
- **季節性**：在特定時間範圍內重複，例如一天、一週、一個月、一季等。
- **隨機**：剩餘波動


季節性可能有多個層面。舉例來說，客服中心可能會發現，通話量在每週的特定幾天和特定月份會出現規律變化。除了時間以外，其他變數或許也能解釋殘差。




平穩性

為獲得最佳預測結果，時間序列資料應為**平穩**資料，也就是平均值和變異數等統計屬性會隨時間保持不變。您可以對原始資料套用差分和去趨勢等技術，讓資料更平穩。

舉例來說，下方的二氧化碳濃度圖表顯示每年重複的模式，且呈現上升趨勢。([來源](#))



移除線性趨勢後，資料現在具有恆定的平均值，因此更適合用於預測。



使用時間序列資料進行機器學習

如要在機器學習問題中使用時間序列資料，必須先轉換資料，才能使用先前的值預測後續值。下表顯示如何建立延遲變數，協助預測目標。

Original Data	
Date	Value
Jan/2000	11
Feb/2000	12
Mar/2000	13
Apr/2000	14
May/2000	15
Jun/2000	16
Jul/2000	16
Aug/2000	15
Sep/2000	14
Oct/2000	13
Nov/2000	12
Dec/2000	11



LAGGED VARIABLES (FEATURES)			TARGET
Date	t-2	t-1	Actual
Jan/2000			11
Feb/2000		11	12
Mar/2000	11	12	13
Apr/2000	12	13	14
May/2000	13	14	15
Jun/2000	14	15	16
Jul/2000	15	16	16
Aug/2000	16	16	15
Sep/2000	16	15	14
Oct/2000	15	14	13
Nov/2000	14	13	12
Dec/2000	13	12	11

瞭解一些基本概念後，我們就來探索資料並進行預測吧！


步驟 3 · 約 5 分鐘

3. 設定 Notebook 環境

簡要介紹完資料後，現在來設定模型開發環境。


步驟 1：啟用 API

BigQuery 連接器使用 BigQuery Storage API。在控制台中搜尋 **BigQuery Storage API**，如果目前已停用，請啟用該 API。



步驟 2：建立 Vertex AI Workbench 筆記本

前往 Cloud Console 的 [Vertex AI Workbench 區段](#)，然後按一下「New Notebook」(新增筆記本)。然後選取最新版的 **TensorFlow 企業版 2.x** 筆記本類型，且「不加入任何 GPU」：



使用預設選項，然後按一下「建立」。建立執行個體後，請選取「Open JupyterLab」：

☐	☒	tensorflow-20200225-175616	OPEN JUPYTERLAB	us-west1-b	TensorFlow:2.0	4 vCPUs, 15 GB RAM	None	Compute Engine default service account
--------------------------	-------------------------------------	----------------------------	---------------------------------	------------	----------------	--------------------	------	--

接著，從 JupyterLab 建立 **Python 3** 筆記本：



Notebook



Python 3



Python 2



Console



Python 3



Python 2



Other



Terminal



Text File



Markdown File



Tensorboard



Contextual Help

步驟 3：下載實驗室教材

在 JupyterLab 介面中建立新的終端機視窗：依序點選「File」>「New」>「Terminal」。

然後使用下列指令複製來源資料：

```
git clone https://github.com/GoogleCloudPlatform/training-data-analyst
```

步驟 4 · 約 15 分鐘

4. 探索資料並以圖表呈現

本節內容：

- 建立查詢，將資料分組為時間序列
- 填入缺少的值
- 以視覺化方式呈現資料
- 將時間序列分解為趨勢和季節性成分

步驟 1


在 Vertex AI Workbench 中，前往 `training-data-analyst/courses/ai-for-time-series/notebooks` 並開啟 `01-explore.ipynb`。

步驟 2

清除筆記本中的所有儲存格 (依序點選「Edit」>「Clear All Outputs」)，在其中一個前幾個儲存格中變更區域、專案和 bucket 設定，然後逐一執行儲存格。

步驟 3

在本節中，您已匯入資料，並以視覺化方式呈現各種維度。現在您已對資料有更清楚的瞭解，可以準備使用這些資料進行機器學習建模。



步驟 5 · 約 15 分鐘

5. 使用 BigQuery 時間序列預測建立模型

本節內容：

- 將時間序列輸入資料匯入 BigQuery 資料表
- 使用 BigQuery ML 語法建立時間序列模型
- 瞭解如何評估模型參數和準確率
- 使用模型進行預測

步驟 1


我們將使用剛才探索的 CSV 檔案中的原始資料，建立 BigQuery 資料表。首先，請從筆記本環境下載 CSV 檔。

在 `training-data-analyst/courses/ai-for-time-series/notebooks/data` 目錄中，在 `cta_ridership.csv` 上按一下滑鼠右鍵，然後下載至本機環境。


步驟 2

接著，我們會將這項資料上傳至 BigQuery 資料表。

在控制台中前往 BigQuery (搜尋或使用這個[連結](#))：




您可以將資料表新增至新資料集或現有資料集，這類資料集會將相關資料表分組。如果尚未建立資料集，可以按一下左下角的專案，然後選取右下角的「建立資料集」。



選擇名稱 (例如 `demo`)，接受預設值，然後繼續。

選取該資料集後，選取右下角的「建立資料表」，即可建立新資料表。



選取下列任一資料表建立選項：

- 建立資料表來源：上傳
- 選取檔案：cta_ridership.csv
- 資料表名稱：cta_ridership
- 結構定義：勾選方塊，自動偵測「結構定義和輸入參數」

Create table

Source

Create table from: Select file: File format:

Destination

☒ Search for a project ☐ Enter a project name

Project name: Dataset name: Table type:

Table name:

Schema

Auto detect ☒ Schema and input parameters

步驟 3

現在要建立模型了！[BigQuery ML](#) 提供類似 SQL 的簡單語法，可讓您建立各種模型類型。

在查詢編輯器中，貼上/輸入這項查詢，並視需要將兩處的「demo」換成資料集名稱：

```
CREATE OR REPLACE MODEL
  `demo.cta_ridership_model` OPTIONS(MODEL_TYPE='ARIMA',
    TIME_SERIES_TIMESTAMP_COL='service_date',
    TIME_SERIES_DATA_COL='total_rides',
    HOLIDAY_REGION='us') AS
SELECT
  service_date, total_rides
FROM
  `demo.cta_ridership`
```

讓我們瞭解語法的重要元素：

步驟 5

現在，我們可以使用 `ML.FORECAST` 函式預測結果了！

貼上/輸入下列內容 (視需要取代 `demo`)：

```
SELECT
  *
FROM
  ML.FORECAST(MODEL `demo.cta_ridership_model`,
    STRUCT(7 AS horizon))
```

這項查詢只會使用我們的模型預測 7 天後的結果！我們可以看到下方傳回的七個資料列。預測結果也會包含信賴區間 (預設為 0.95，但可在查詢中設定)。

Row	forecast_timestamp	forecast_value	standard_error	confidence_level	prediction_interval_lower_bound	prediction_interval_upper_bound	confidence_interval_lower_bound	confidence_interval_upper_bound
1	2020-01-01 00:00:00 UTC	662436.4424369269	46059.49014554253	0.95	572322.980240453	752549.9046334007	572322.980240453	752549.9046334007
2	2020-01-02 00:00:00 UTC	1029641.4669424891	46276.328347693256	0.95	939103.76989082	1120179.1639941582	939103.76989082	1120179.1639941582
3	2020-01-03 00:00:00 UTC	1201660.2034356925	47233.43871922012	0.95	1109249.9600529654	1294070.4468184195	1109249.9600529654	1294070.4468184195
4	2020-01-04 00:00:00 UTC	651095.9776391207	48157.99332862347	0.95	556876.8819095747	745315.0733686666	556876.8819095747	745315.0733686666
5	2020-01-05 00:00:00 UTC	467394.91846646497	48621.50963880497	0.95	372268.97250121285	562520.8644317171	372268.97250121285	562520.8644317171
6	2020-01-06 00:00:00 UTC	1158999.319539823	48869.23710364581	0.95	1063388.705171438	1254609.9339082083	1063388.705171438	1254609.9339082083
7	2020-01-07 00:00:00 UTC	1127789.5651062205	49011.66149084522	0.95	1031900.3033930386	1223678.8268194026	1031900.3033930386	1223678.8268194026

做得好！我們只用了幾項 BQML 查詢，就建立了一個時間序列模型。

6. 建立自訂預測模型

本節內容：

- 從資料中移除離群值
- 執行多步驟預測
- 在時間序列模型中加入其他特徵
- 瞭解時間序列預測的類神經網路架構：LSTM 和 CNN
- 瞭解統計模型，包括 Holt-Winters 指數平滑法
- 集成模型

步驟 1

在 Vertex AI Workbench 中，前往 `training-data-analyst/courses/ai-for-time-series/notebooks` 並開啟 `02-model.ipynb`。

步驟 2

清除筆記本中的所有儲存格 (依序點選「Edit」>「Clear All Outputs」)，在其中一個前幾個儲存格中變更區域、專案和 bucket 設定，然後逐一執行儲存格。

步驟 3

在筆記本中，您已探索多種模型架構：LSTM、CNN 和統計模型。您可以查看每個模型在測試資料上的效能：


```
[21]: # Predict the results, and then reverse the transformation that scaled all values to a mean of 0 and std. dev. of 1
preds = model.predict(X_test)
y_pred_lstm = inverse_scale(preds)

# Evaluate the overall results and for each time step
evaluate(y_pred_lstm)

# The plot will show the R^2 value (0 lowest -> 1 highest) and the MAE (mean absolute error) for the entire prediction window.
# It will also show individual plots for 1 day out, 2 days out, etc. comparing the actual vs the predicted value.

=== t+(1-7) ===
R^2: 0.792
MAPE: 0.096
MAE: 83489.282

=== t+1 ===
R^2: 0.846
MAPE: 0.081
MAE: 69439.243
```



7. 在雲端中訓練及預測

本節內容：

- 準備要用於雲端訓練的資料和模型
- 使用 AI Platform Training 訓練模型並監控工作進度
- 使用 AI Platform Prediction 透過模型進行預測

步驟 1

在 Vertex AI Workbench 中，前往 `training-data-analyst/courses/ai-for-time-series/notebooks` 並開啟 `03-cloud-training.ipynb`。

步驟 2

清除筆記本中的所有儲存格 (依序點選「Edit」>「Clear All Outputs」)，在其中一個前幾個儲存格中變更區域、專案和 bucket 設定，然後逐一執行儲存格。

步驟 3

在上一節中，我們在 Workbench 筆記本中訓練模型並進行預測。在本節中，我們示範如何從筆記本使用 [Vertex AI Python SDK](#)，透過 Vertex AI 服務進行訓練和部署。

```
[*]: # Create and run the training job

job = aiplatform.CustomTrainingJob(
    display_name=JOB_NAME,
    script_path=f"{TRAINER_DIR}/task.py",
    container_uri=TRAIN_IMAGE,
    model_serving_container_image_uri=DEPLOY_IMAGE,
)

model = job.run(
    model_display_name=MODEL_DISPLAY_NAME,
    args=CMDARGS,
)
```

8. 挑戰

在本節中，您將嘗試將所學概念套用至新的資料集！

我們不會提供詳細說明，只會給予一些提示 (如有需要！)。

目標是預測紐約市的 311 服務要求。這類非緊急要求包括噪音投訴、路燈問題等。

步驟 1

首先，請瞭解資料集。

首先，請存取「[City of New York 311 Service Requests](#)」資料集。

如要進一步瞭解資料，請試用資料集說明中列出的幾個查詢範例：

- 在 311 服務要求中，與冰淇淋車有關的要求有多少個？
- 哪些天接到與派對有關的 311 服務要求最多？

在 BigQuery UI 中選取「建立查詢」，即可查看如何存取資料集。請注意，選取陳述式是從 `bigquery-public-data.new_york_311.311_service_requests` 查詢。

步驟 2

我們已準備好開始。在本節中，請修改「Explore and Visualize」筆記本，以便使用這項資料。

提示

- 複製 `01-explore.ipynb` 筆記本，然後從副本開始作業。
- 如要探索資料，請嘗試以下查詢：

```
from google.cloud import bigquery as bq

sql = """
SELECT * FROM `bigquery-public-data.new_york_311.311_service_requests` LIMIT 5
"""

client = bq.Client(project=PROJECT)
df = client.query(sql).to_dataframe()

df.head()
```

- 如要按月取得事件計數，請使用這項查詢：

```
SELECT
  COUNT(unique_key) as y,
  DATE_TRUNC(DATE(created_date), month) as ds
FROM `bigquery-public-data.new_york_311.311_service_requests`
GROUP by ds ORDER BY ds asc
```

- 更新常數部分中的資料欄變數。在上述查詢中，目標資料欄為 **y**，日期資料欄為 **ds**。沒有其他功能。
- 請考慮變更匯出資料的檔案名稱，以供下一個實驗室使用。

- 使用下列方式匯出資料：`df.to_csv(YOUR-EXPORT-FILENAME, index=False)`

步驟 3

現在，我們來使用每月資料建立時間序列模型。

提示：

- 複製 `02-model.ipynb` 筆記本，然後從副本開始作業。
 - 更新資料集參數：
 - 更新 `target_col` 和 `ts_col` 參數，使其與新資料集相符。
 - 更新模型參數：
 - 頻率為每月 (月份開始的代碼為「MS」)
 - 輸入步驟：12 (回溯期為 12 個月)
 - 輸出步驟：3 (預測未來 3 個月)
 - 季節：12 (季節性為 12 個月)
 - 如果您在先前的筆記本中變更了輸入檔案名稱，請一併變更。
 - 如果您在月中執行查詢，最後一個月的每月總計金額會遠低於預期。因此，為了本實驗室的目的，請使用 `df = df[:-1]` 從資料集中移除最後一個月。
 - 資料中似乎沒有明顯的離群值，因此請略過或註解掉這些儲存格。
 - 調整這個新模型的 LSTM 單位、CNN 篩選器和核心大小。
-

9. 清除所用資源

如要繼續使用這部筆電，建議在不使用時關機。在 Cloud 控制台的 Workbench 使用者介面中，選取筆記本，然後選取「停止」：

Notebook instances BETA

NEW INSTANCE

REFRESH

START

STOP

RESET

DELETE

Filter table

Instance name

Region

Environment

Machine type

GPUs

Permission

Labels

tensorflow-20191028-092711

OPEN JUPYTERLAB

us-west1-b

TensorFlow:1.15

4 vCPUs, 15 GB RAM

None

Service account

No labels

如要刪除在本實驗室中建立的所有資源，請**刪除**工作台筆記本，而非停止執行。

使用 Cloud 控制台的導覽選單，瀏覽至「儲存空間」，然後刪除您建立的兩個 bucket，以儲存模型資產 (警告：只有在您專為本實驗室建立新 bucket 時，才執行這項操作)。