

在 PSC 端點上部署 Model Garden

來源：<https://codelabs.developers.google.com/gemini-psc-endpoint?hl=zh-tw>

步驟數：10

在本教學課程中，您將瞭解如何部署 Gemini 模型，並透過 Private Service Connect 連線至該模型。

目錄

1. [1. 簡介](#)
2. [2. 事前準備](#)
3. [3. 部署模型](#)
4. [4. 消費者設定](#)
5. [5. 啟用 IAP](#)
6. [6. 建立消費者 VM 執行個體](#)
7. [7. Private Service Connect 端點](#)
8. [8. 從消費者 VM 進行測試](#)
9. [9. 清理](#)
10. [10. 恭喜](#)

步驟 1 · 約 0 分鐘

在 PSC 端點部署 Model Garden

程式碼研究室簡介


subject上次更新時間：3月 27, 2026

account_circle作者：Mohamed Barkhad, Deepak Michael

1. 簡介

運用 Private Service Connect，為從 Vertex AI Model Garden 部署的模型建立安全私人的存取權。這個方法不會公開端點，而是將模型部署至只能在虛擬私有雲 (VPC) 內存取的私人 Vertex AI 端點。

Private Service Connect 會在虛擬私有雲中建立具有內部 IP 位址的端點，直接連線至 Google 管理的 Vertex AI 服務，該服務會代管您的模型。這項功能可讓虛擬私有雲和地端部署環境中的應用程式 (透過 Cloud VPN 或 Interconnect) 使用私人 IP 傳送推論要求。所有網路流量都會留在 Google 的網路中，因此可提高安全性、減少延遲，並完全隔離模型的服務端點與公開網際網路。



建構項目

在本教學課程中，您將從 Model Garden 下載 Gemma 3，並以私人端點的形式，透過 Private Service Connect 存取 Vertex AI Online Inference 中代管的 Gemma 3。端對端設定包括：

1. Model Garden 模型：從 Vertex AI Model Garden 選取 Gemma 3，並部署至 Private Service Connect 端點。
2. Private Service Connect：您會在虛擬私有雲 (VPC) 中設定用戶端端點，其中包含您網路中的內部 IP 位址。
3. 安全連線至 Vertex AI：PSC 端點會以 Vertex AI 為私人模型部署自動產生的服務附件為目標。這會建立私人連線，確保虛擬私有雲和提供模型端點之間的流量不會經過公用網際網路。
4. 虛擬私有雲中的用戶端設定：您會在虛擬私有雲中設定用戶端 (例如 Compute Engine VM)，使用 PSC 端點的內部 IP 位址，將推論要求傳送至已部署的模型。

完成後，您將擁有可正常運作的範例，以私密方式提供 Model Garden 模型，且只能從指定虛擬私有雲網路內存取。

課程內容

在本教學課程中，您將瞭解如何從 Vertex AI Model Garden 部署模型，並使用 Private Service Connect (PSC)，從虛擬私有雲 (VPC) 安全地存取模型。透過這種方式，虛擬私有雲 (消費者) 中的應用程式就能以私密方式連線至 Vertex AI 模型端點 (生產端服務)，不必經過公開網際網路。

具體來說，您將學到：

1. 瞭解 Vertex AI 的 PSC：瞭解 PSC 如何建立私密且安全的消費者與供應商連線。您的 VPC 可以使用內部 IP 位址存取已部署的 Model Garden 模型。
2. 使用私密存取權部署模型：瞭解如何為 Model Garden 模型設定 Vertex AI 端點，以使用 PSC，將其設為私密端點。

3. 服務附件的角色：將模型部署至私有 Vertex AI 端點時，Google Cloud 會在 Google 管理的租戶專案中自動建立服務附件。這項服務連結會向消費者網路公開提供模型服務。
4. 在虛擬私有雲中建立 PSC 端點：
 - 如何從已部署的 Vertex AI 端點詳細資料取得專屬服務附件 URI。
 - 如何在虛擬私有雲中選定子網路內預留內部 IP 位址。
 - 如何在虛擬私有雲中建立轉送規則，做為 PSC 端點，並以 Vertex AI 服務連結為目標。這個端點可透過保留的內部 IP 存取模型。
5. 建立私人連線：虛擬私有雲中的 PSC 端點如何連線至服務附件，安全地將您的網路橋接至 Vertex AI 服務。
6. 私下傳送推論要求：如何從虛擬私有雲內的資源 (例如 Compute Engine VM) 將預測要求傳送至 PSC 端點的內部 IP 位址。
7. 驗證：測試並確認您可以透過私有連線，從虛擬私有雲成功將推論要求傳送至已部署的 Model Garden 模型。

完成這項操作後，您就能從 Model Garden 代管模型，且只能透過私人網路基礎架構存取。

軟硬體需求

Google Cloud 專案

IAM 權限

- [AI Platform 管理員](#) (roles/ml.Admin)
 - [Compute 網路管理員](#) (roles/compute.networkAdmin)
 - [Compute 執行個體管理員](#) (roles/compute.instanceAdmin)
 - [Compute 安全管理員](#) (roles/compute.securityAdmin)
 - [DNS 管理員](#) (roles/dns.admin)
 - [受 IAP 保護的通道使用者](#) (roles/iap.tunnelResourceAccessor)
 - [記錄管理員](#) (roles/logging.admin)
 - [Notebooks 管理員](#) (roles/notebooks.admin)
 - [專案 IAM 管理員](#) (roles/resourcemanager.projectIamAdmin)
 - [服務帳戶管理員](#) (roles/iam.serviceAccountAdmin)
 - [服務使用情形管理員](#) (roles/serviceusage.serviceUsageAdmin)
-

步驟 2 · 約 2 分鐘

2. 事前準備

更新專案以支援教學課程

本教學課程會使用 `$variables`，協助您在 Cloud Shell 中實作 gcloud 設定。

在 Cloud Shell 中執行下列操作：

□□□

```
gcloud config list project
gcloud config set project [YOUR-PROJECT-ID]
projectid=[YOUR-PROJECT-ID]
echo $projectid
```

啟用 API

在 Cloud Shell 中執行下列操作：


```
gcloud services enable "compute.googleapis.com"
gcloud services enable "aiplatform.googleapis.com"
gcloud services enable "serviceusage.googleapis.com"
```

步驟 3 · 約 30 分鐘

3. 部署模型

請按照下列步驟，從 Model Garden 部署模型：


在 Google Cloud 控制台中，前往 [Model Garden](#)，然後搜尋並選取 **Gemma 3**



按一下「部署選項」，然後選取「Vertex AI」

Gemma 3

Lightweight, state-of-the-art open models from Google, built from the same research and technology used to create the Gemini models



在「Deploy on Vertex AI」窗格中，選取「Advanced」。系統會根據可用容量預先填入區域和機器規格。您可以變更這些值，但本程式碼研究室是為 us-central1 量身打造。

Deploy on Vertex AI

Vertex AI will deploy the model to a managed endpoint that you can access to make online or batch inferences through the Cloud console or the Vertex AI API. [Learn more](#) [See pricing](#)

Resource ID
gemma-3-12b-it

Model name *
gemma-3-12b-it-1759002549946

Endpoint name *
gemma-3-12b-it-mg-one-click-deploy

Deployment settings * [?](#)

☐ Basic

☒ Advanced

Region *
us-central1 (Iowa)

Machine spec *
vLLM 128K context (1 NVIDIA_H100_80GB; a3-highgpu-1g)

Deployment policy

Default is Vertex AI's compute resources ([manage project quota](#)). Alternatively, you can deploy to a [previous reservation](#).

在「Deploy on Vertex AI」窗格中，確認「Endpoint Access」已設為「Private Service Connect」，然後選取專案。

Availability policies

VM provisioning model
Standard


Choose 'Spot' to get a discounted, pre-emptible VM. Otherwise, stick to 'Standard'. [Learn more](#)

Endpoint access
Private (Private Service Connect)

Default is 'Public (dedicated endpoint)'. [How to choose an endpoint type](#). Choose 'Private' to forward your requests privately to Vertex AI using [Private Service Connect](#)

Project IDs
test4-473419 [Select project IDs](#)

其他選項均保留預設值，然後選取底部的「Deploy」（部署），並查看通知中的部署狀態。



在 Model Garden 中，選取提供 Gemma 3 模型和端點的區域 (us-central1)。模型部署作業大約需要 5 分鐘。

Google Cloud test4 Search (/) for resources, docs, products and more Search

Region us-central1 (Iowa)

View and manage all the deployments and model instances that have been created in this Cloud project from Model Garden

My endpoints [View all](#)

Filter Enter a property name

Name	ID	Status	Monitoring	Last updated ↓	API
gemma-3-12b-it-mg-one-click-deploy	2133539641536544768	Creating endpoint	—	27 Sept 2025, 16:02:07	—

My models [Evaluate](#)

Filter Enter a property name

Name	Default version	Deployment status	Description	Type	Source	Updated ↓	Labels
gemma-3-12b-it-1759002549946	1	—	—	Imported	Model garden	27 Sept 2025, 15:59:36	—

My gen AI-provisioned throughput orders [View all](#)

完成後，端點會在 30 分鐘內轉換為「有效」

My endpoints [View all](#)

Filter Enter a property name

Name	ID	Status	Monitoring	Last updated ↓	API
gemma-3-12b-it-mg-one-click-deploy	2133539641536544768	Active	Disabled	27 Sept 2025, 16:02:07	—

My models [Evaluate](#)

選取端點，取得並記下端點 ID。

← gemma-3-12b-it-mg-one-click-deploy [Edit settings](#)

Details

Endpoint ID	2133539641536544768
Region	us-central1
Network	
Logs	View logs
Model monitoring	Disabled

開啟 Cloud Shell 並執行下列操作，取得 Private Service Connect 服務連結 URI。部署 PSC 取用端點時，取用端會使用這個 URI 字串。

在 Cloud Shell 中更新端點 ID，然後發出下列指令。

```
gcloud ai endpoints describe [Endpoint ID] --region=us-central1 | grep -i serviceAttachment:
```

範例如下：

```
user@cloudshell:~$ gcloud ai endpoints describe 2124795225560842240 --region=us-central1 |  
grep -i serviceAttachment:  
  
Using endpoint [https://us-central1-aiplatform.googleapis.com/]  
serviceAttachment: projects/o9457b320a852208e-tp/regions/us-  
central1/serviceAttachments/gkedpm-52065579567eaf39bfe24f25f7981d
```

將 serviceAttachment 後的內容複製到名為「Service_attachment」的變數中，稍後建立 PSC 連線時會用到。

```
user@cloudshell:~$ Service_attachment=projects/o9457b320a852208e-tp/regions/us-  
central1/serviceAttachments/gkedpm-52065579567eaf39bfe24f25f7981d
```


步驟 4 · 約 10 分鐘

4. 消費者設定

建立消費者虛擬私有雲

在 Cloud Shell 中執行下列操作：

```
gcloud compute networks create consumer-vpc --project=$projectid --subnet-mode=custom
```

建立消費者 VM 子網路

在 Cloud Shell 中執行下列操作：

```
gcloud compute networks subnets create consumer-vm-subnet --project=$projectid --  
range=192.168.1.0/24 --network=consumer-vpc --region=us-central1 --enable-private-ip-google-  
access
```

建立 PSC 端點子網路

```
gcloud compute networks subnets create pscendpoint-subnet --project=$projectid --  
range=10.10.10.0/28 --network=consumer-vpc --region=us-central1
```

步驟 5 · 約 5 分鐘

5. 啟用 IAP

如要允許 IAP 連線至您的 VM 執行個體，請根據以下條件建立防火牆規則：

- 套用至所有您希望能透過 IAP 存取的 VM 執行個體。
- 允許來自 IP 範圍 35.235.240.0/20 的輸入流量。這個範圍包含 IAP 用於 TCP 轉送的所有 IP 位址。

在 Cloud Shell 中，建立 IAP 防火牆規則。

```
gcloud compute firewall-rules create ssh-iap-consumer \  
  --network consumer-vpc \  
  --allow tcp:22 \  
  --source-ranges=35.235.240.0/20
```

步驟 6 · 約 0 分鐘

6. 建立消費者 VM 執行個體

在 Cloud Shell 中，建立取用者 VM 執行個體 consumer-vm。

```
gcloud compute instances create consumer-vm \  
  --project=$projectid \  
  --machine-type=e2-micro \  
  --image-family debian-11 \  
  --no-address \  
  --shielded-secure-boot \  
  --image-project debian-cloud \  
  --zone us-central1-a \  
  --subnet=consumer-vm-subnet
```

7. Private Service Connect 端點

消費者會在虛擬私有雲中，使用內部 IP 位址建立消費者端點 (轉送規則)。這個 PSC 端點的目標是供應商的服務連結。消費者虛擬私有雲或混合式網路中的用戶端可以將流量傳送至這個內部 IP 位址，以連線至生產者的服務。

為消費者端點保留 IP 位址。

在 Cloud Shell 中建立轉送規則。

```
gcloud compute addresses create psc-address \
  --project=$projectid \
  --region=us-central1 \
  --subnet=pscendpoint-subnet \
  --addresses=10.10.10.6
```

確認 IP 位址已保留

在 Cloud Shell 中，列出保留的 IP 位址。

```
gcloud compute addresses list
```

您應該會看到預留的 10.10.10.6 IP 位址。

```
mbarkhad@cloudshell:~ (test4-473419)$ gcloud compute addresses list
NAME: psc-address
ADDRESS/RANGE: 10.10.10.6
TYPE: INTERNAL
PURPOSE: GCE_ENDPOINT
NETWORK:
REGION: us-central1
SUBNET: pscendpoint
STATUS: RESERVED
mbarkhad@cloudshell:~ (test4-473419)$
```

指定您在上一個步驟「部署模型」一節中擷取的服務連結 URI (target-service-attachment)，建立消費者端點。

在 Cloud Shell 中，說明網路附件。

```
gcloud compute forwarding-rules create psc-consumer-ep \
  --network=consumer-vpc \
  --address=psc-address \
  --region=us-central1 \
  --target-service-attachment=$Service_attachment \
  --project=$projectid
```

確認服務連結接受端點

```
gcloud compute forwarding-rules describe psc-consumer-ep \
  --project=$projectid \
  --region=us-central1 \
```

在回應中，確認 pscConnectionStatus 欄位顯示「ACCEPTED」狀態


```
IPAddress: 10.10.10.6
allowPscGlobalAccess: false
creationTimestamp: '2025-10-04T11:24:26.471-07:00'
fingerprint: 4FocUBv3IoM=
id: '7496966126619646133'
kind: compute#forwardingRule
labelFingerprint: 42WmSpB8rSM=
name: psc-consumer-ep
network: https://www.googleapis.com/compute/v1/projects/test3-473819/global/networks/consumer-vpc
networkTier: PREMIUM
pscConnectionId: '100888073281866246'
pscConnectionStatus: ACCEPTED
region: https://www.googleapis.com/compute/v1/projects/test3-473819/regions/us-central1
selfLink: https://www.googleapis.com/compute/v1/projects/test3-473819/regions/us-central1/forwardingRules/psc-consumer-ep
selfLinkWithId: https://www.googleapis.com/compute/v1/projects/test3-473819/regions/us-central1/forwardingRules/7496966126619646133
serviceDirectoryRegistrations:
- namespace: goog-psc-default
target: https://www.googleapis.com/compute/v1/projects/h1974ddc2a0e214fd-tp/regions/us-central1/serviceAttachments/gkedpm-bd66703eb24f4e33d638d85962d828
```

步驟 8 · 約 10 分鐘

8. 從消費者 VM 進行測試

在 Cloud Shell 中執行下列步驟，授予 Consumer VM 存取 Vertex Model Garden API 的權限

透過 SSH 連線至 Consumer VM



使用應用程式預設憑證重新驗證，並指定 Vertex AI 範圍。

```
gcloud auth application-default login
--scopes=https://www.googleapis.com/auth/cloud-platform
```

使用下表產生 CURL 指令，並根據環境調整

屬性	值
通訊協定	HTTP
位置	us-central1
線上預測端點	2133539641536544768
專案 ID	test4-473419
型號	gemma-3-12b-it
Private Service Connect 端點 IP	10.10.10.6
訊息	[{"role": "user", "content": "What weighs more 1 pound of feathers or rocks?"}]

根據環境詳細資料更新並執行 curl 指令：

```
curl -k -v -X POST -H "Authorization: Bearer $(gcloud auth application-default print-access-token)" -H "Content-Type: application/json" http://[PSC-IP]/v1/projects/[Project-ID]/locations/us-central1/endpoints/[Predictions Endpoint]/chat/completions -d '{"model": "google/gemma-3-12b-it", "messages": [{"role": "user", "content": "What weighs more 1 pound of feathers or rocks?"}] }'
```

範例：

```
curl -k -v -X POST -H "Authorization: Bearer $(gcloud auth application-default print-access-token)" -H "Content-Type: application/json" http://10.10.10.6/v1/projects/test4-473419/locations/us-central1/endpoints/2133539641536544768/chat/completions -d '{"model": "google/gemma-3-12b-it", "messages": [{"role": "user", "content": "What weighs more 1 pound of feathers or rocks?"}] }'
```

最終結果 - 成功！

您應該會在輸出內容底部看到 Gemma 3 的預測結果，這表示您已透過 PSC 端點私下存取 API 端點

```
Connection #0 to host 10.10.10.6 left intact
{"id":"chatcmpl-9e941821-65b3-44e4-876c-37d81baf62e0","object":"chat.completion","created":1759009221,"model":"google/gemma-3-12b-it","choices":[{"index":0,"message":{"role":"assistant","reasoning_content":null,"content":"This is a classic trick question! They weigh the same. One pound is one pound, regardless of the material. 😊\n\n\n\n"},"tool_calls":[]},"logprobs":null,"finish_reason":"stop","stop_reason":106}],"usage":{"prompt_tokens":20,"total_tokens":46,"completion_tokens":26,"prompt_tokens_details":null},"prompt_logprobs":null}
```

步驟 9 · 約 10 分鐘

9. 清理

在 Cloud Shell 中刪除教學課程元件。

```
gcloud ai endpoints undeploy-model ENDPOINT_ID --deployed-model-id=DEPLOYED_MODEL_ID --
region=us-central1 --quiet

gcloud ai endpoints delete $ENDPOINT_ID --project=$projectid --region=us-central1 --quiet

gcloud ai models delete $MODEL_ID --project=$projectid --region=us-central1 --quiet

gcloud compute instances delete consumer-vm --zone=us-central1-a --quiet

gcloud compute forwarding-rules delete psc-consumer-ep --region=us-central1 --
project=$projectid --quiet

gcloud compute addresses delete psc-address --region=us-central1 --project=$projectid --quiet

gcloud compute networks subnets delete pscendpoint-subnet consumer-vm-subnet --region=us-
central1 --quiet

gcloud compute firewall-rules delete ssh-iap-consumer --project=$projectid

gcloud compute networks delete consumer-vpc --project=$projectid --quiet

gcloud projects delete $projectid --quiet
```

10. 恭喜

恭喜！您已成功設定並驗證，透過 Private Service Connect 端點私密存取 Vertex AI Prediction 上代管的 Gemma 3 API。

您已建立消費者基礎架構，包括預留內部 IP 位址，以及在虛擬私有雲中設定 Private Service Connect 端點 (轉送規則)。這個端點會以與已部署的 Gemma 3 模型相關聯的服務附件為目標，安全地連線至 Vertex AI 服務。完成這項設定後，虛擬私有雲或連線網路中的應用程式就能使用內部 IP 位址，以私密且安全的方式與 Gemma 3 API 互動，不必透過公開網際網路傳輸流量。

延伸閱讀和影片

- [Private Service Connect 總覽](#)

參考文件

- [透過私人端點存取線上預測](#)
 - [使用 Model Garden 中的模型](#)
-