

開始使用 Spanner 向量搜尋

來源：<https://codelabs.developers.google.com/spanner-getting-started-vector-search?hl=zh-tw>

步驟數：9

在本程式碼實驗室中，您將建立 Spanner 例項，並使用 Spanner 內建的向量搜尋功能，以及與 Vertex AI 模型整合，對向量嵌入執行相似度搜尋。

目錄

1. [1. 簡介](#)
2. [2. 設定和需求](#)
3. [3. 建立 Spanner 執行個體和資料庫](#)
4. [4. 載入 Cymbal 結構定義和資料](#)
5. [5. 使用嵌入](#)
6. [6. 使用大型語言模型](#)
7. [7. 擴充向量搜尋功能](#)
8. [8. 清除 \(選用\)](#)
9. [9. 恭喜！](#)

1. 簡介


Spanner 是全代管、可水平擴充的全球分散式資料庫服務，非常適合關聯式和非關聯式作業工作負載。

Spanner 內建向量搜尋支援功能，可讓您執行相似度或語意搜尋，並在生成式 AI 應用程式中大規模實作檢索增強生成 (RAG)，方法是運用**精確的 K 近鄰 (KNN)** 或**近似近鄰 (ANN)** 功能。

與作業資料上的任何其他查詢一樣，Spanner 的向量搜尋查詢會在交易提交後，立即傳回最新的即時資料。

在本實驗室中，您將逐步設定基本功能，以便運用 Spanner 執行向量搜尋，並使用 SQL 從 Vertex AI 的 Model Garden 存取嵌入和 LLM 模型。

架構如下所示：



注意：本實驗室著重於圖表的右側部分，因此您只會部署 Spanner 執行個體和 Vertex AI 整合。

有了這項基礎知識，您將瞭解如何建立以 **ScaNN 演算法** 為基礎的向量索引，以及在語意工作負載需要擴充時，如何使用 APPROX 距離函式。

建構項目

本實驗室的學習內容包括：

- 可建立 Spanner 執行個體
- 設定 Spanner 的資料庫結構定義，與 Vertex AI 中的嵌入和 LLM 模型整合
- 載入零售資料集
- 對資料集發出問題相似度搜尋查詢
- 向 LLM 模型提供脈絡資訊，生成特定產品的建議。
- 修改結構定義並建立向量索引。
- 變更查詢，以運用新建立的向量索引。

課程內容

- 如何設定 Spanner 執行個體
- 如何與 Vertex AI 整合
- 如何使用 Spanner 執行向量搜尋，在零售資料集中找出相似項目
- 如何準備資料庫，使用 ANN 搜尋擴充向量搜尋工作負載。

軟硬體需求

- 已連結至帳單帳戶的 Google Cloud 專案。
 - 網路瀏覽器，例如 [Chrome](#) 或 [Firefox](#)。
-


步驟 2 · 約 15 分鐘

2. 設定和需求

建立專案

如果您沒有 Google 帳戶 (Gmail 或 Google 應用程式)，請先[建立帳戶](#)。登入 Google Cloud Platform 主控台 (console.cloud.google.com)，然後建立新專案。


如果您已有專案，請按一下主控台左上方的專案選取下拉式選單：



然後在隨即顯示的對話方塊中，按一下「NEW PROJECT」(新專案) 按鈕，建立新專案：



如果您還沒有專案，應該會看到如下對話方塊，請建立第一個專案：



後續的專案建立對話方塊會顯示，讓您輸入新專案的詳細資料：

New Project

Project name ?

spanner-1on1-codelab

Your project ID will be spanner-1on1-codelab ? [Edit](#)

Billing account ?

Choose account

Create

Cancel

請記住專案 ID，所有 Google Cloud 專案的專案 ID 都是不重複的名稱 (上述名稱已遭占用，因此不適用於您，抱歉！)。本程式碼研究室稍後會將其稱為 PROJECT_ID。

接下來，如果尚未啟用，請在開發人員控制台中[啟用帳單](#)，以便使用 Google Cloud 資源，並[啟用 Spanner API](#)。

Billing

This project has no billing account

This project is not linked to a billing account

[Link a billing account](#)

or

[Manage billing accounts](#)

完成本程式碼研究室的費用不應超過數美元，但如果您決定使用更多資源，或是將資源繼續執行 (請參閱本文件結尾的「清除」一節)，則可能會增加費用。Google Cloud Spanner 定價說明文件請參閱[這裡](#)。

Google Cloud Platform 新使用者享有價值 **\$300 美元的免費試用期**，因此本程式碼研究室應完全免費。

設定 Google Cloud Shell


雖然可以透過筆電遠端操作 Google Cloud 和 Spanner，但在本程式碼研究室中，我們將使用 [Google Cloud Shell](#)，這是在雲端執行的指令列環境。

這部以 Debian 為基礎的虛擬機器，搭載各種您需要的開發工具，並提供永久的 5GB 主目錄，而且可在 Google Cloud 運作，大幅提升網路效能並強化驗證功能。也就是說，您只需要瀏覽器 (Chromebook 也可以) 就能完成本程式碼研究室。

1. 如要從 Cloud 控制台啟用 Cloud Shell，只要按一下「啟用 Cloud Shell」圖示



即可 (佈建並連線至環境的作業需要一些時間才能完成)。



連至 Cloud Shell 後，您應該會看到驗證已完成，專案也已設為獲派的 PROJECT_ID。

```
gcloud auth list
```

指令輸出

```
Credentialed accounts:  
- <myaccount>@<mydomain>.com (active)
```

注意：Cloud Shell 已預先安裝 gcloud 指令列工具。詳情請參閱 [gcloud 指令列工具總覽](#)。

```
gcloud config list project
```

指令輸出

```
[core]  
project = <PROJECT_ID>
```

如果專案未設定，請發出下列指令：

```
gcloud config set project <PROJECT_ID>
```

在尋找「PROJECT_ID」嗎？請檢查您在設定步驟中使用的 ID，或在 Cloud 控制台資訊主頁中尋找：

 Google Cloud Platform 

DASHBOARD

ACTIVITY

RECOMMENDATIONS

 **Project info** 

Project name

my-project

Project ID

coral-bucksaw-280805

Project number

58646390136

[ADD PEOPLE TO THIS PROJECT](#)

[→ Go to project settings](#)

Cloud Shell 也會預設設定部分環境變數，這些變數在您執行後續指令時可能很有用。

```
echo $GOOGLE_CLOUD_PROJECT
```

指令輸出

```
<PROJECT_ID>
```

注意：


1. 在自己的機器上執行 gcloud 時，各工作階段都會保留這些設定。但在 Cloud Shell 中，每次啟動新工作階段或重新連線時，都必須重新設定。
2. 專案名稱、專案 ID 和專案編號可能是三個不同的字串，且用於不同指令，如下列工作階段所示。

啟用 Spanner API 和 Vertex AI API



```
gcloud services enable spanner.googleapis.com
gcloud services enable aiplatform.googleapis.com
```

檢查 IAM 政策：

如要在 Spanner 執行個體中啟用向量搜尋功能，您只需要在 IAM 政策中，將 `service-<PROJECT_NUMBER>@gcp-spanner.iam.gserviceaccount.com` 授予 *Cloud Spanner API 服務代理* 即可。按一下左上角的三條線圖示，如下所示：



您會在該處看到 IAM 政策：



您可以在「權限」下檢查 IAM 設定，如下所示。

☒ Include Google-provided role grants [?](#)

View by principals

View by roles

+ Grant access

- Remove access

Filter

Enter property name or value

?

|||

☐ Type	Principal ↑	Name	Role	Security insights ?
☐	service-624081414247@gcp-sa-spanner.iam.gserviceaccount.com	Cloud Spanner Production Service Account ?	Cloud Spanner API Service Agent	

如果沒有 `Cloud Spanner API Service Agent`，請使用下列指令授予權限。如需更多操作說明，請參閱[這篇文章](#)。

```
$ gcloud beta services identity create --service=spanner.googleapis.com --project=  
<PROJECT_ID>  
$ gcloud projects add-iam-policy-binding <PROJECT_NUMBER> --member=serviceAccount:service-  
<PROJECT_NUMBER>@gcp-sa-spanner.iam.gserviceaccount.com --role=roles/spanner.serviceAgent --  
condition=None
```

注意：如需更多操作說明，請參閱[這篇文章](#)和 <https://cloud.google.com/spanner/docs/ml-tutorial>。

摘要

在本步驟中，您已設定專案 (如果沒有的話)、啟動 Cloud Shell，並啟用必要的 API。

下一步

接著，您將設定 Spanner 執行個體和資料庫。

步驟 3 · 約 5 分鐘

3. 建立 Spanner 執行個體和資料庫

建立 Spanner 執行個體

在本步驟中，我們要為程式碼研究室設定 Spanner 執行個體。如要這麼做，請開啟 Cloud Shell 並執行下列指令：

```
export SPANNER_INSTANCE_ID=retail-demo
gcloud spanner instances create $SPANNER_INSTANCE_ID \
--edition=ENTERPRISE \
--config=regional-us-central1 \
--description="spanner AI retail demo" \
--nodes=1
```

最低版本應為 `ENTERPRISE`。 `STANDARD` 版本不具備向量搜尋功能。

注意：建立執行個體需要一點時間。

注意：這項指令會使用 `regional-us-central1` 做為區域。您可以根據 [Spanner 適用的區域設定](#)，選取與 [VertexAI 端點所在區域](#)相符的區域。

指令輸出：

```
$ Creating instance...done.
```

建立資料庫

執行個體啟動後，您就可以建立資料庫。Spanner 允許單一執行個體有多個資料庫。

您可以在資料庫中定義結構定義。您也可以控管資料庫的存取權、設定自訂加密、設定最佳化工具，以及設定保留期限。

如要建立資料庫，請再次使用 gcloud 指令列工具：

```
export SPANNER_DATABASE=cymbal-bikes
gcloud spanner databases create $SPANNER_DATABASE \
--instance=$SPANNER_INSTANCE_ID
```

指令輸出：

```
$ Creating database...done.
```

摘要

您已在這個步驟中建立 Spanner 執行個體和資料庫。

下一步


接著，您將設定 Spanner 結構定義和資料。

步驟 4 · 約 5 分鐘

4. 載入 Cymbal 結構定義和資料

建立 Cymbal 結構定義

如要設定結構定義，請前往 Spanner Studio：



附註：按一下 `retail-demo` Spanner 執行個體，然後按一下 `cymbal-bikes` 資料庫，即可找到 Spanner Studio。

這個結構定義分為兩部分。首先，請新增 `products` 表格。複製這段陳述並貼到空白分頁中。

在結構定義部分，複製下列 DDL 並貼到方塊中：

```
CREATE TABLE products(  
  categoryId INT64 NOT NULL,  
  productId INT64 NOT NULL,  
  productName STRING(MAX) NOT NULL,  
  productDescription STRING(MAX) NOT NULL,  
  productDescriptionEmbedding ARRAY<FLOAT32>,  
  createTime TIMESTAMP NOT NULL  
OPTIONS (  
  allow_commit_timestamp = TRUE),  
  inventoryCount INT64 NOT NULL,  
  priceInCents INT64,  
  PRIMARY KEY(categoryId, productId);
```

接著按一下 `run` 按鈕，等待幾秒鐘，系統就會建立結構定義。

接著，您會建立這兩個模型，並將其設定為 Vertex AI 模型端點。

第一個模型是 Embedding 模型，用於從文字生成嵌入；第二個是 LLM 模型，用於根據 Spanner 中的資料生成回覆。

將下列結構定義貼到 Spanner Studio 的新分頁中：

警告：請將這兩項陳述式中的 `<PROJECT_ID>` 變更為您在程式碼研究室一開始建立的專案 ID。

注意：

1. 下方的結構定義使用 `us-central1` VertexAI 端點。如果您在建立執行個體時選擇了其他 Spanner 區域，請在 `EmbeddingsModel` 和 `LLMModel` 定義中變更此設定。
2. 本程式碼研究室中使用的 Vertex AI 模型可能已淘汰。如要進一步瞭解模型版本和生命週期，以及如何使用穩定模型，請參閱[這篇文章](#)。

```
CREATE OR REPLACE MODEL EmbeddingsModel
  INPUT(content STRING(MAX)) OUTPUT(embeddings STRUCT<values ARRAY<FLOAT32>>) REMOTE
  OPTIONS (
    endpoint = '//aiplatform.googleapis.com/projects/<PROJECT_ID>/locations/us-
central1/publishers/google/models/text-embedding-004');

CREATE OR REPLACE MODEL LLMModel
  INPUT(prompt STRING(MAX)) OUTPUT(content STRING(MAX)) REMOTE
  OPTIONS (
    endpoint = '//aiplatform.googleapis.com/projects/<PROJECT_ID>/locations/us-
central1/publishers/google/models/gemini-2.0-flash-001',
    default_batch_size = 1);
```

然後按一下 `run` 按鈕，等待幾秒鐘，模型就會建立完成。

Spanner Studio 左窗格應會顯示下列資料表和模型：

Explorer			
▼	Default		⋮
▼	 Tables 1		⋮
	▶ products		⋮
	 Change streams 0		⋮
	 Views 0		⋮
	▶  Roles 3		⋮
▼	 Models 2		⋮
	EmbeddingsModel		⋮
	LLMModel		⋮

載入資料

現在，您要將一些產品插入資料庫。在 Spanner Studio 中開啟新分頁，然後複製並貼上下列插入陳述式：


```
INSERT INTO products (categoryId, productId, productName, productDescription, createTime,
inventoryCount, priceInCents)
VALUES (1, 1, "Cymbal Helios Helmet", "Safety meets style with the Cymbal children's bike
helmet. Its lightweight design, superior ventilation, and adjustable fit ensure comfort and
protection on every ride. Stay bright and keep your child safe under the sun with Cymbal
Helios!", PENDING_COMMIT_TIMESTAMP(), 100, 10999),
(1, 2, "Cymbal Sprout", "Let their cycling journey begin with the Cymbal Sprout, the ideal
balance bike for beginning riders ages 2-4 years. Its lightweight frame, low seat height, and
puncture-proof tires promote stability and confidence as little ones learn to balance and
steer. Watch them sprout into cycling enthusiasts with Cymbal Sprout!",
PENDING_COMMIT_TIMESTAMP(), 10, 13999),
(1, 3, "Cymbal Spark Jr.", "Light, vibrant, and ready for adventure, the Spark Jr. is the
perfect first bike for young riders (ages 5-8). Its sturdy frame, easy-to-use brakes, and
puncture-resistant tires inspire confidence and endless playtime. Let the spark of cycling
ignite with Cymbal!", PENDING_COMMIT_TIMESTAMP(), 34, 13900),
(1, 4, "Cymbal Summit", "Conquering trails is a breeze with the Summit mountain bike. Its
lightweight aluminum frame, responsive suspension, and powerful disc brakes provide
exceptional control and comfort for experienced bikers navigating rocky climbs or shredding
downhill. Reach new heights with Cymbal Summit!", PENDING_COMMIT_TIMESTAMP(), 0, 79999),
(1, 5, "Cymbal Breeze", "Cruise in style and embrace effortless pedaling with the Breeze
electric bike. Its whisper-quiet motor and long-lasting battery let you conquer hills and
distances with ease. Enjoy scenic rides, commutes, or errands with a boost of confidence from
Cymbal Breeze!", PENDING_COMMIT_TIMESTAMP(), 72, 129999),
(1, 6, "Cymbal Trailblazer Backpack", "Carry all your essentials in style with the
Trailblazer backpack. Its water-resistant material, multiple compartments, and comfortable
straps keep your gear organized and accessible, allowing you to focus on the adventure. Blaze
new trails with Cymbal Trailblazer!", PENDING_COMMIT_TIMESTAMP(), 24, 7999),
(1, 7, "Cymbal Phoenix Lights", "See and be seen with the Phoenix bike lights. Powerful LEDs
and multiple light modes ensure superior visibility, enhancing your safety and enjoyment
during day or night rides. Light up your journey with Cymbal Phoenix!",
PENDING_COMMIT_TIMESTAMP(), 87, 3999),
(1, 8, "Cymbal Windstar Pump", "Flat tires are no match for the Windstar pump. Its compact
design, lightweight construction, and high-pressure capacity make inflating tires quick and
effortless. Get back on the road in no time with Cymbal Windstar!",
PENDING_COMMIT_TIMESTAMP(), 36, 24999),
(1, 9, "Cymbal Odyssey Multi-Tool", "Be prepared for anything with the Odyssey multi-tool. This
handy gadget features essential tools like screwdrivers, hex wrenches, and tire levers,
keeping you ready for minor repairs and adjustments on the go. Conquer your journey with
Cymbal Odyssey!", PENDING_COMMIT_TIMESTAMP(), 52, 999),
(1, 10, "Cymbal Nomad Water Bottle", "Stay hydrated on every ride with the Nomad water bottle.
Its sleek design, BPA-free construction, and secure lock lid make it the perfect companion
for staying refreshed and motivated throughout your adventures. Hydrate and explore with
Cymbal Nomad!", PENDING_COMMIT_TIMESTAMP(), 42, 1299);
```

按一下 `run` 按鈕即可插入資料。

摘要

在這個步驟中，您已建立結構定義，並將一些基本資料載入 `cymbal-bikes` 資料庫。

下一步

接著，您會與 Embedding 模型整合，為產品說明生成嵌入項目，並將文字搜尋要求轉換為嵌入項目，以搜尋相關產品。

步驟 5 · 約 10 分鐘

5. 使用嵌入

生成產品說明的向量嵌入

如要對產品執行相似度搜尋，請先為產品說明產生嵌入。

有了在結構定義中建立的 `EmbeddingsModel`，這就是簡單的 `UPDATE` DML 陳述式。

```
UPDATE products p1
SET
  productDescriptionEmbedding = (
    SELECT embeddings.values
    FROM
      ML.PREDICT(
        MODEL EmbeddingsModel,
        (SELECT productDescription AS content))
  )
WHERE categoryId = 1;
```

按一下 `run` 按鈕，更新產品說明。

注意：對於效能較為敏感的工作負載，建議在唯讀交易中使用 `ML.PREDICT` 生成嵌入，然後使用讀寫交易將嵌入寫入 `Spanner`。

如果遇到任何錯誤，請嘗試使用 `gcloud` 指令在終端機中執行 SQL 指令，以取得更詳細的錯誤訊息，例如：

```
gcloud spanner databases execute-sql <YOUR_DATA_BASE> --instance=<YOUR_INSTANCE> --sql
'UPDATE products p1
SET
  productDescriptionEmbedding = (
    SELECT embeddings.values
    FROM
      ML.PREDICT(
        MODEL EmbeddingsModel,
        (SELECT productDescription AS content FROM products p2 WHERE p2.productId =
p1.productId))
  )
WHERE categoryId = 1;'
```

使用向量搜尋

在本範例中，您會透過 SQL 查詢提供自然語言搜尋要求。這項查詢會將搜尋要求轉換為嵌入，然後根據上一步驟中產生的產品說明儲存嵌入，搜尋類似結果。

```
-- Use Spanner's vector search, and integration with embedding and LLM models to
-- return items that are semantically relevant and available in inventory based on
-- real-time data.

SELECT
  productName,
  productDescription,
  inventoryCount,
  COSINE_DISTANCE(
    productDescriptionEmbedding,
    (
      SELECT embeddings.values
      FROM
        ML.PREDICT(
          MODEL EmbeddingsModel,
          (SELECT "I'd like to buy a starter bike for my 3 year old child" AS content))
    )) AS distance
FROM products
WHERE inventoryCount > 0
ORDER BY distance
LIMIT 5;
```

按一下 **run** 按鈕即可尋找類似產品。結果應如下所示：

The screenshot shows the Google Cloud Spanner Studio interface. The top bar includes the Google Cloud logo, a dropdown menu, and a search bar. The main area is divided into three sections: Explorer, Editor, and Results.

Explorer: Shows a tree view of the database structure, including tables, views, roles, and models. The 'LLMModel' is highlighted.

Editor: Contains the SQL query being executed. The query is as follows:

```
-- Use Spanner's vector search, and integration with embedding and LLM models to
-- return items that are semantically relevant and available in inventory based on
-- real-time data.

SELECT productId, productName, productDescription, inventoryCount, COSINE_DISTANCE(
  productDescriptionEmbedding,
  ( SELECT embeddings.values
    FROM ML.PREDICT(
      MODEL EmbeddingsModel,
      (SELECT "I'd like to buy a starter bike for my 3 year old child" as content)
    )
  ) as distance
FROM products
WHERE inventoryCount > 0
ORDER BY distance
LIMIT 5;
```

Results: The query has been executed successfully, returning 5 rows of data. The results are displayed in a table with the following columns: productId, productName, productDescription, inventoryCount, and distance.

productId	productName	productDescription	inventoryCount	distance
2	Cymbal Sprout	Let their cycling journey begin with the Cymbal Sprout, the ideal balance bike for beginning riders ages 2-4 years. Its lightweight frame, low seat height, and puncture-proof tires promote stability and confidence as little ones learn to balance and steer. Watch them sprout into cycling enthusiasts with Cymbal Sprout!	10	0.21625804022114337
3	Cymbal Spark Jr.	Light, vibrant, and ready for adventure, the Spark Jr. is the perfect first bike for young riders (ages 5-8). Its sturdy frame, easy-to-use brakes, and puncture-resistant tires inspire confidence and endless playtime. Let the spark of cycling ignite with Cymbal!	34	0.2653910293192284
1	Cymbal Helios Helmet	Safety meets style with the Cymbal children's bike helmet. Its lightweight design, superior ventilation, and adjustable fit ensure comfort and protection on every ride. Stay bright and keep your child safe under the sun with Cymbal Helios!	100	0.34851557182277637
5	Cymbal Breeze	Cruise in style and embrace effortless pedaling with the Breeze electric bike. Its whisper-quiet motor and...	72	0.3736301608159621

請注意，查詢中使用了其他篩選條件，例如只對有現貨的產品感興趣 (`inventoryCount > 0`)。

摘要

在這個步驟中，您使用 SQL 建立產品說明嵌入和搜尋要求嵌入，並運用 Spanner 與 Vertex AI 中模型的整合功能。您也執行了向量搜尋，找出符合搜尋要求的相似產品。

後續步驟

接著，我們將使用搜尋結果，讓 LLM 為每項產品生成自訂回覆。

6. 使用大型語言模型

Spanner 可輕鬆與 Vertex AI 提供的 LLM 模型整合。開發人員可直接使用 SQL 與 LLM 互動，不必讓應用程式執行邏輯。

舉例來說，我們有來自使用者 "I'd like to buy a starter bike for my 3 year old child". 的先前 SQL 查詢結果

開發人員想針對每個結果提供回覆，說明產品是否適合使用者，並使用下列提示：

```
"Answer with 'Yes' or 'No' and explain why: Is this a good fit for me? I'd like to buy a starter bike for my 3 year old child"
```

您可以使用的查詢如下：

```
-- Use an LLM to analyze this list and provide a recommendation on whether each
-- product is a good fit for the user. We use the vector search and real time
-- inventory data to first filter the products to reduce the size of the prompt to
-- the LLM.
SELECT productName, productDescription, inventoryCount, content AS LLMResponse
FROM
  ML.PREDICT(
    MODEL LLModel,
    (
      SELECT
        FORMAT(
          ""Answer with Yes or No and explain why: Is this a good fit for me?
            I would like to buy a starter bike for my 3 year old child \n Product Name:
%s\nProduct Description: %s"", productName,productDescription) AS prompt,
          -- Pass through columns.
          inventoryCount,
          productName,
          productDescription,
        FROM products
        WHERE inventoryCount > 0
        ORDER BY
          COSINE_DISTANCE(
            productDescriptionEmbedding,
            (
              SELECT embeddings.values
              FROM
                ML.PREDICT(
                  MODEL EmbeddingsModel,
                  (SELECT "I'd like to buy a starter bike for my 3 year old child" AS content))
            ))
          LIMIT 5
    ));
```

注意：我們將上一個步驟的相同查詢提供給 LLM 模型，以生成我們希望獲得回覆的產品清單。

按一下 `run` 按鈕發出查詢。結果應如下所示：

Google Cloud

demo

vertexai

Search

GOOGLE STANDARD SQL DATABASE

bike-store: Spanner Studio

OPEN IN DATAPLEX

LEARN

Explorer

Default

Tables 1

products

Change streams 0

Views 0

Roles 3

Models 2

EmbeddingsModel

LLMModel

INFORMATION_SCHEMA

SPANNER_SYS

Editor 1

Editor 2

Editor 3

Editor 4

Valid

1 -- Use an LLM to analyze this list and provide a recommendation on whether each

2 -- product is a good fit for the user. We use the vector search and real time

3 -- inventory data to first filter the products to reduce the size of the prompt to

4 -- the LLM.

5

6 SELECT productName, productDescription, inventoryCount, content

7 FROM ML.PREDICT(

8 MODEL LLMModel

9

RESULTS

EXPLANATION

All results

SELECT productName, productDescription, inventoryCount, content FROM ML.PREDICT(MODEL LLMModel, (SELECT inventoryCount, prod...

Statement completed (964.12 ms elapsed)

productName	productDescription	inventoryCount	content
Cymbal Sprout	Let their cycling journey begin with the Cymbal Sprout, the ideal balance bike for beginning riders ages 2-4 years. Its lightweight frame, low seat height, and puncture-proof tires promote stability and confidence as little ones learn to balance and steer. Watch them sprout into cycling enthusiasts with Cymbal Sprout!	10	Yes. The product is a balance bike for beginning riders ages 2-4 years. My child is 3 years old. So the product is a good fit for me.
Cymbal Spark Jr.	Light, vibrant, and ready for adventure, the Spark Jr. is the perfect first bike for young riders (ages 5-8). Its sturdy frame, easy-to-use brakes, and puncture-resistant tires inspire confidence and endless playtime. Let the spark of cycling ignite with Cymbal!	34	No. The product is not a good fit for you because it is designed for children ages 5-8, and your child is 3 years old.
Cymbal Helios Helmet	Safety meets style with the Cymbal children's bike helmet. Its lightweight design, superior ventilation, and adjustable fit ensure comfort and protection on every ride. Stay bright and keep your child safe under the sun with Cymbal Helios!	100	No, this is not a good fit for you. The product is a helmet, not a bike.
Cymbal Breeze	Cruise in style and embrace effortless pedaling with the Breeze electric bike. Its whisper-quiet motor and long-lasting battery let you conquer hills and distances with ease. Enjoy scenic rides, commutes, or errands with a boost of confidence from Cymbal Breeze!	72	No, this is not a good fit for you. The Cymbal Breeze is an electric bike, not a starter bike for a 3 year old child.

第一個產品的產品說明中指出適合 2 到 4 歲的年齡層，因此適合 3 歲兒童。其他產品不太適合。

摘要

在本步驟中，您使用 LLM 生成使用者提示的基本回覆。

後續步驟

接著，我們來瞭解如何使用 ANN 擴充向量搜尋。

7. 擴充向量搜尋功能

先前的向量搜尋範例採用的是精確的 KNN 向量搜尋。如果您可以查詢 Spanner 資料的特定子集，這項功能就非常實用。這類查詢稱為「高度可分割」。

如果工作負載無法高度分割，且資料量龐大，建議使用 ANN 向量搜尋，並採用 [ScaNN 演算法](#)，提升查閱效能。

如要在 Spanner 中執行這項操作，您需要完成下列兩件事：

- 建立向量索引
- 修改查詢，使用 **APPROX** 距離函式。

建立向量索引

如要在這個資料集上建立向量索引，首先需要修改 `productDescriptionEmbeddings` 資料欄，定義每個向量的長度。如要將向量長度新增至資料欄，必須捨棄原始資料欄並重新建立。

```
ALTER TABLE products DROP COLUMN productDescriptionEmbedding;

ALTER TABLE products
ADD COLUMN productDescriptionEmbedding ARRAY<FLOAT32>(vector_length => 768);
```

接著，從先前執行的 `Generate Vector embedding` 步驟再次建立嵌入。

```
UPDATE products p1
SET
  productDescriptionEmbedding = (
    SELECT embeddings.values
    FROM
      ML.PREDICT(
        MODEL EmbeddingsModel,
        (SELECT productDescription AS content FROM products p2 WHERE p2.productId =
p1.productId))
  )
WHERE categoryId = 1;
```

注意：在正式環境中，您會想要新增具有新定義的資料欄，並複製嵌入內容。然後修改應用程式，改用新資料欄，再捨棄舊資料欄。

建立資料欄後，請建立索引：

```
CREATE VECTOR INDEX ProductDescriptionEmbeddingIndex
ON products(productDescriptionEmbedding)
WHERE productDescriptionEmbedding IS NOT NULL
OPTIONS (
  distance_type = 'COSINE'
);
```


注意：建立向量索引大約需要 30 分鐘。你可以去喝杯咖啡或茶，完成後再回來。

如有興趣，請參閱 <https://cloud.google.com/spanner/docs/backfill-embeddings> 的 PDML。單一 DML 陳述式是交易，受限於 8 萬個變異的限制，因此您無法一次更新太多資料列。PDML 會有效率地將資料分批處理。

使用新索引

如果要使用新的向量索引，您必須稍微修改先前的嵌入查詢。

原始查詢如下：

```
SELECT
  productName,
  productDescription,
  inventoryCount,
  COSINE_DISTANCE(
    productDescriptionEmbedding,
    (
      SELECT embeddings.values
      FROM
        ML.PREDICT(
          MODEL EmbeddingsModel,
          (SELECT "I'd like to buy a starter bike for my 3 year old child" AS content))
    ) AS distance
  FROM products
  WHERE inventoryCount > 0
  ORDER BY distance
  LIMIT 5;
```

您必須進行下列變更：

- 為新的向量索引使用索引提示：`@{force_index=ProductDescriptionEmbeddingIndex}`
- 將 `COSINE_DISTANCE` 函式呼叫變更為 `APPROX_COSINE_DISTANCE`。請注意，下方最終查詢中的 *JSON* 選項也必須提供。
- 從 `ML.PREDICT` 函式分別生成嵌入。
- 將嵌入內容的結果複製到最終查詢。

生成及使用嵌入項目：

```
-- Generate the prompt embeddings
SELECT embeddings.values
FROM ML.PREDICT(
  MODEL EmbeddingsModel,
  (SELECT "I'd like to buy a starter bike for my 3 year old child" as content)
);
```

醒目顯示並複製查詢結果。

摘要

在這個步驟中，您已轉換結構定義來建立向量索引。然後，您重新編寫嵌入查詢，使用向量索引執行 ANN 搜尋。隨著資料量增加，向量搜尋工作負載也會隨之擴大，因此這個步驟非常重要。

後續步驟

接著，該來清理了！

8. 清除 (選用)

如要清理，只要刪除我們在程式碼研究室中建立的 'retail-demo' 執行個體即可。

All instances > INSTANCE retail-demo: Overview

EDIT INSTANCE

DELETE INSTANCE

Overview

Name	spanner AI retail demo
ID	retail-demo
Configuration	us-central1 (Iowa)
Scaling mode	Manual allocation

Summary

Statistics are updated every 3–5 minutes, which may cause some delay in actual data.

Compute capacity ?

1000 PUs (1 node)

CPU utilisation (high)

1.30%

Operations

Read: -/s

Write: -/s

Databases

CREATE DATABASE

Filter Filter databases

☐	Name ↑	Dialect ?	CPU utilisation	Size	Version retention period ?
☐	cymbal-bikes	Google Standard SQL	1.30%	0 B	1 hour

步驟 9 · 約 2 分鐘

9. 恭喜！

恭喜！您已成功使用 Spanner 內建的向量搜尋功能執行相似度搜尋。此外，您也瞭解到使用嵌入和 LLM 模型有多麼容易，可以直接使用 SQL 提供生成式 AI 功能。

最後，您也瞭解如何使用 [ScaNN 演算法](#) 執行 ANN 搜尋，以擴充向量搜尋工作負載。

後續步驟

如要進一步瞭解 Spanner 的 K 近鄰 (KNN) 向量搜尋功能，請參閱：<https://cloud.google.com/spanner/docs/find-k-nearest-neighbors>

如要進一步瞭解 Spanner 的近似最鄰近 (ANN 向量搜尋) 功能，請參閱：<https://cloud.google.com/spanner/docs/find-approximate-nearest-neighbors>

如要進一步瞭解如何使用 Spanner 的 Vertex AI 整合功能，透過 SQL 執行線上預測，請參閱：<https://cloud.google.com/spanner/docs/ml>
