

使用 CSV 檔案從 Snowflake 至 Spanner 執行反向 ETL

來源：<https://codelabs.developers.google.com/snowflake-csv-spanner?hl=zh-tw>

步驟數：8

目錄

1. [1. 使用 Google Cloud Storage 和 Dataflow，從 Snowflake 建構反向 ETL 管道至 Spanner](#)
2. [2. 設定、需求和限制](#)
3. [3. 設定 Spanner](#)
4. [4. 建立 Google Cloud Storage 值區](#)
5. [5. 從 Snowflake 匯出至 GCS](#)
6. [6. 使用 Dataflow 將資料載入 Spanner](#)
7. [7. 清除](#)
8. [8. 恭喜](#)

1. 使用 Google Cloud Storage 和 Dataflow，從 Snowflake 建構反向 ETL 管道至 Spanner

簡介

在本實驗室中，您將建構 **Reverse ETL** pipeline。傳統上，ETL (擷取、轉換、載入) 管道會將資料從作業資料庫移至 Snowflake 等資料倉儲，以供分析。反向 ETL 管道則相反，會將經過處理的精選資料從資料倉儲移回營運系統，用於支援應用程式、提供使用者功能，或用於即時決策。

目標是將範例資料集從 Snowflake 資料表移至 Spanner。Spanner 是全球分散式關聯式資料庫，非常適合高可用性應用程式。

為此，我們將 Google Cloud Storage (GCS) 和 Dataflow 做為中繼步驟。以下將詳細說明流程，以及採用此架構的原因：

1. 以 CSV 格式將 Snowflake 資料匯出至 Google Cloud Storage (GCS)：

- 第一步是以開放的通用格式從 Snowflake 匯出資料。匯出為 CSV 檔案是建立可攜式資料檔案的常見方法，簡單又直接。我們會在 GCS 中暫存這些檔案，GCS 提供可擴充且持久耐用的物件儲存空間解決方案。

2. 從 GCS 匯入至 Spanner (透過 Dataflow)：

- 我們使用全代管資料處理服務 Google Dataflow，而非編寫自訂指令碼來從 GCS 讀取資料並寫入 Spanner。Dataflow 提供專為這類工作預先建構的範本。使用「GCS Text to Cloud Spanner」範本，即可平行匯入大量資料，無須撰寫任何資料處理程式碼，大幅節省開發時間。

課程內容

- 如何將資料載入 Snowflake
 - 如何建立 GCS 值區
 - 如何以 CSV 格式將 Snowflake 資料表匯出至 GCS
 - 如何設定 Spanner 執行個體
 - 如何使用 Dataflow 將 CSV 資料表載入 Spanner
-

2. 設定、需求和限制

必要條件

- Snowflake 帳戶。
- 已啟用 Spanner、Cloud Storage 和 Dataflow API 的 Google Cloud 帳戶。
- 透過網路瀏覽器存取 Google Cloud 控制台。
- 已安裝 [Google Cloud CLI](#) 的終端機。
- 如果 Google Cloud 機構已啟用 `iam.allowedPolicyMemberDomains` 政策，系統管理員可能需要授予例外狀況，允許來自外部網域的服務帳戶。我們會在後續步驟中說明相關內容 (如適用)。

Google Cloud Platform IAM 權限

Google 帳戶需要下列權限，才能執行本程式碼研究室中的所有步驟。

服務帳戶	
<code>iam.serviceAccountKeys.create</code>	允許建立服務帳戶。
Spanner	
<code>spanner.instances.create</code>	可建立新的 Spanner 執行個體。
<code>spanner.databases.create</code>	可執行 DDL 陳述式來建立
<code>spanner.databases.updateDdl</code>	可執行 DDL 陳述式，在資料庫中建立資料表。
Google Cloud Storage	
<code>storage.buckets.create</code>	可建立新的 GCS bucket，用來儲存匯出的 Parquet 檔案。
<code>storage.objects.create</code>	允許將匯出的 Parquet 檔案寫入 GCS 值區。
<code>storage.objects.get</code>	允許 BigQuery 從 GCS 儲存空間讀取 Parquet 檔案。
<code>storage.objects.list</code>	允許 BigQuery 列出 GCS bucket 中的 Parquet 檔案。
Dataflow	
<code>Dataflow.workitems.lease</code>	允許從 Dataflow 認領工作項目。

<code>Dataflow.workitems.sendMessage</code>	允許 Dataflow 工作站將訊息傳回 Dataflow 服務。
<code>Logging.logEntries.create</code>	允許 Dataflow 工作站將記錄項目寫入 Google Cloud Logging。

為方便起見，您可以使用具備這些權限的預先定義角色。

<code>roles/resourcemanager.projectIamAdmin</code>
<code>roles/iam.serviceAccountKeyAdmin</code>
<code>roles/spanner.instanceAdmin</code>
<code>roles/spanner.databaseAdmin</code>
<code>roles/storage.admin</code>
<code>roles/dataflow.serviceAgent</code>
<code>roles/dataflow.worker</code>
<code>roles/dataflow.serviceAgent</code>

限制

在系統間移動資料時，請務必注意資料類型差異。

- **Snowflake 轉為 CSV**：匯出時，Snowflake 資料類型會轉換為標準文字表示法。
- **CSV 檔案匯入 Spanner**：匯入時，請務必確認目標 Spanner 資料型別與 CSV 檔案中的字串表示法相容。本實驗室將逐步說明常見的型別對應。

設定可重複使用的屬性

本實驗室會重複使用幾個值。為簡化這項作業，我們會將這些值設為殼層變數，以供日後使用。

- GCP_REGION - GCP 資源所在的特定區域。如要查看區域清單，請按[這裡](#)。
- GCP_PROJECT - 要使用的 GCP 專案 ID。
- GCP_BUCKET_NAME：要建立的 GCS Bucket 名稱，以及儲存資料檔案的位置。

值區名稱在全域範圍內都不可重複。常見模式為：`[organization_name]-[project_id]-[environment]-[purpose]`。

- SPANNER_INSTANCE - 要指派給 Spanner 執行個體的名稱

- SPANNER_DB - 要指派給 Spanner 執行個體內資料庫的名稱

```
export GCP_REGION = <GCP REGION HERE>
export GCP_PROJECT= <GCP PROJECT HERE>
export GCS_BUCKET_NAME = <GCS BUCKET NAME HERE>
export SPANNER_INSTANCE = <SPANNER INSTANCE ID HERE>
export SPANNER_DB = <SPANNER DATABASE ID HERE>
```

請注意，這些環境變數只會在執行變數的殼層執行個體中設定，如果您稍後在其他殼層執行個體中執行本實驗室的指令，則需要重新設定。

Google Cloud

本實驗室需要 Google Cloud 專案。

Google Cloud 專案

專案是 Google Cloud 的基本組織單位。如果管理員已提供可用的憑證，則可略過這個步驟。

您可以使用 CLI 建立專案，如下所示：

```
gcloud projects create $GCP_PROJECT
gcloud config set project $GCP_PROJECT
```

如要進一步瞭解如何建立及管理專案，請參閱[這篇文章](#)。

步驟 3 · 約 0 分鐘

3. 設定 Spanner

如要開始使用 Spanner，您需要佈建執行個體和資料庫。如要瞭解如何設定及建立 Spanner 執行個體，請參閱[這篇文章](#)。

建立執行個體

```
gcloud spanner instances create $SPANNER_INSTANCE \  
--config=regional-$GCP_REGION \  
--description="Codelabs Snowflake RETL" \  
--processing-units=100 \  
--edition=ENTERPRISE
```

建立資料庫

```
gcloud spanner databases create $SPANNER_DB \  
--instance=$SPANNER_INSTANCE
```

步驟 4 · 約 0 分鐘

4. 建立 Google Cloud Storage 值區

系統會使用 Google Cloud Storage (GCS) 暫時儲存 Snowflake 產生的 CSV 資料檔案，然後再匯入 Spanner。

建立 bucket

使用下列指令在特定區域 (例如 us-central1) 建立 Storage 值區。

```
gcloud storage buckets create gs://$GCS_BUCKET_NAME --location=$GCP_REGION
```

確認已建立 bucket

該指令成功執行後，請列出所有 bucket，藉此檢查結果。新 bucket 應會顯示在結果清單中。值區參照通常會在值區名稱前面加上 `gs://` 前置字元。

```
gcloud storage ls | grep gs://$GCS_BUCKET_NAME
```

測試寫入權限

這個步驟可確保本機環境已正確通過驗證，並具備將檔案寫入新建立值區的必要權限。

```
echo "Hello, GCS" | gcloud storage cp - gs://$GCS_BUCKET_NAME/hello.txt
```

驗證上傳的檔案

列出值區中的物件。系統應會顯示剛上傳檔案的完整路徑。

```
gcloud storage ls gs://$GCS_BUCKET_NAME
```

您應該會看到以下的輸出內容：

```
gs://$GCS_BUCKET_NAME/hello.txt
```

如要查看 bucket 中物件的內容，可以使用 `gcloud storage cat`。

```
gcloud storage cat gs://$GCS_BUCKET_NAME/hello.txt
```

檔案內容應會顯示：

```
Hello, GCS
```

清理測試檔案

Cloud Storage bucket 現在已設定完成。現在可以刪除臨時測試檔案。


```
gcloud storage rm gs://$GCS_BUCKET_NAME/hello.txt
```

輸出內容應會確認刪除：

```
Removing gs://$GCS_BUCKET_NAME/hello.txt...  
/ [1 objects]  
Operation completed over 1 objects.
```

步驟 5 · 約 0 分鐘

5. 從 Snowflake 匯出至 GCS

在本實驗室中，我們將使用 **TPC-H 資料集**，這是決策支援系統的業界標準基準。所有 Snowflake 帳戶預設都會提供這個資料集。

準備 Snowflake 中的資料

登入 Snowflake 帳戶，然後建立新的工作表。

由於權限限制，您無法直接從 Snowflake 提供的共用位置匯出 TPC-H 範例資料。首先，必須將 **ORDERS** 資料表複製到另一個資料庫和結構定義。

建立資料庫

1. 在左側選單的「Horizon Catalog」下方，將游標懸停在「Catalog」上，然後點選「Database Explorer」。
2. 前往「資料庫」頁面後，按一下右上方的「+ 資料庫」按鈕。
3. 將新資料庫命名為 `codelabs_ret1_db`

建立工作表

如要對資料庫執行 SQL 指令，您需要使用工作表。

如要建立工作表，請按照下列步驟操作：

1. 在左側選單的「處理資料」下方，將游標懸停在「專案」上，然後點選「工作區」。
2. 在「我的工作區」側邊列下方，按一下「+ 新增」按鈕，然後選取「SQL 檔案」。

如要對 Snowflake 執行其他 SQL 指令，請替換這個檔案的內容。如要執行檔案中的段落部分，請將游標放在該段落上，然後按下鍵盤上的 Ctrl + Enter 鍵。

```

USE DATABASE codelabs_retl_db;

CREATE SCHEMA codelabs_retl_export;

CREATE TABLE codelabs_retl_export.regional_sales_csv AS
SELECT
    n.n_name AS nation_name,
    c.c_mktsegment AS market_segment,
    YEAR(o.o_orderdate) AS order_year,
    o.o_orderpriority AS order_priority,
    COUNT(o.o_orderkey) AS total_order_count,
    ROUND(SUM(o.o_totalprice), 2) AS total_revenue,
    COUNT(DISTINCT c.c_custkey) AS unique_customer_count
FROM SNOWFLAKE_SAMPLE_DATA.TPCH_SF1.orders AS o
INNER JOIN SNOWFLAKE_SAMPLE_DATA.TPCH_SF1.customer AS c
    ON o.o_custkey = c.c_custkey
INNER JOIN SNOWFLAKE_SAMPLE_DATA.TPCH_SF1.nation AS n
    ON c.c_nationkey = n.n_nationkey
GROUP BY
    n.n_name,
    c.c_mktsegment,
    YEAR(o.o_orderdate),
    o.o_orderpriority;

SELECT COUNT(*) FROM regional_sales_csv;

```

輸出結果應顯示已複製 4375 個資料列。

設定 Snowflake 以存取 GCS

如要允許 Snowflake 將資料寫入 GCS 值區，必須建立 **Storage Integration** 和 **Stage**。

- **儲存空間整合**：Snowflake 物件，用於儲存外部雲端儲存空間產生的服務帳戶和驗證資訊。
- **Stage**：具名物件，使用儲存空間整合功能處理驗證，並參照特定 bucket 和路徑。方便您為資料載入和卸載作業命名位置。

首先，請建立 Storage 整合。

由於下列 SQL 程式碼不會在設定環境變數的殼層執行個體中執行，請務必將 **GCS Bucket name** 的值替換為實際值

```

CREATE OR REPLACE STORAGE INTEGRATION gcs_int
    TYPE = EXTERNAL_STAGE
    STORAGE_PROVIDER = 'GCS'
    ENABLED = TRUE
    -- Grant Snowflake permission to write to a specific path in your bucket.
    STORAGE_ALLOWED_LOCATIONS = ('gcs://<Your bucket name>/sample_orders');

```

接著，請說明整合項目，取得 Snowflake 為該項目建立的服務帳戶。

```
DESC STORAGE INTEGRATION gcs_int;
```

在結果中，複製 `STORAGE_GCP_SERVICE_ACCOUNT` 的值。看起來會像是電子郵件地址。

將這個服務帳戶儲存至殼層執行個體中的環境變數，以供後續重複使用

```
export GCP_SERVICE_ACCOUNT=<Your service account>
```

注意：如果 Google Cloud 機構強制執行 `iam.allowedPolicyMemberDomains` 限制，安全管理員必須將這個服務帳戶的網域 (@ 符號後方的部分) 新增至允許清單。

將 GCS 權限授予 Snowflake

現在，必須授予 Snowflake 服務帳戶寫入 GCS bucket 的權限。

```
gcloud storage buckets add-iam-policy-binding gs://$GCS_BUCKET_NAME \
  --member="serviceAccount:$GCP_SERVICE_ACCOUNT" \
  --role="roles/storage.objectAdmin"

gcloud storage buckets add-iam-policy-binding gs://$GCS_BUCKET_NAME \
  --member="serviceAccount:$GCP_SERVICE_ACCOUNT" \
  --role="roles/storage.legacyBucketReader"
```

建立階段並匯出資料

權限設定完成後，請返回 Snowflake 工作表。建立使用整合功能的 Stage，然後使用 `COPY INTO` 指令將 `SAMPLE_ORDERS` 資料表資料匯出至該 Stage。

由於下列 SQL 程式碼不會在設定環境變數的殼層執行個體中執行，請務必在出現 **GCS Bucket name** 的位置替換值。

```
CREATE OR REPLACE STAGE retl_gcs_stage
  URL = 'gs://<Your bucket name>/regional_sales_csv'
  STORAGE_INTEGRATION = gcs_int
  -- Define the output file format
  FILE_FORMAT = (TYPE = 'CSV');

COPY INTO @retl_gcs_stage/regional_sales_csv
FROM (SELECT * FROM codelabs_retel_export.regional_sales_csv)
FILE_FORMAT = (TYPE = CSV, COMPRESSION = NONE);
```

在「結果」窗格中，應該會顯示 `rows_unloaded`，值為 `1500000`。

驗證 GCS 中的資料

檢查 GCS bucket，查看 Snowflake 建立的檔案。這表示匯出作業已順利完成。

```
gcloud storage ls gs://$GCS_BUCKET_NAME/regional_sales_csv/
```

您應該會看到一或多個編號的 CSV 檔案。

```
gs://your-bucket-name/regional_sales_csv/regional_sales_csv_0_0_0.csv  
...
```

步驟 6 · 約 0 分鐘

6. 使用 Dataflow 將資料載入 Spanner

資料現在位於 GCS 中，接下來將使用 **Dataflow** 匯入 Spanner。Dataflow 是 Google Cloud 的全代管服務，可用於串流和批次資料處理。系統會使用預先建構的 Google 範本，專門用於將 GCS 中的文字檔匯入 Spanner。

建立 Spanner 資料表

首先，請在 Spanner 中建立目的地資料表。結構定義必須與 CSV 檔案中的資料相容。

```
gcloud spanner databases ddl update $SPANNER_DB \  
  --instance=$SPANNER_INSTANCE \  
  --ddl="$(cat <<EOF  
CREATE TABLE regional_sales (  
  nation_name STRING(MAX),  
  market_segment STRING(MAX),  
  order_year INT64,  
  order_priority STRING(MAX),  
  total_order_count INT64,  
  total_revenue NUMERIC,  
  unique_customer_count INT64  
) PRIMARY KEY (nation_name, market_segment, order_year, order_priority);  
EOF  
)"
```

建立 Dataflow 資訊清單

Dataflow 範本需要「資訊清單」檔案。這個 JSON 檔案會告知範本來源資料檔案的位置，以及要將檔案載入哪個 Spanner 資料表。

定義並上傳新的 regional_sales_manifest.json 至 GCS bucket：

```
cat <<EOF | gcloud storage cp - gs://$GCS_BUCKET_NAME/regional_sales_manifest.json  
{  
  "tables": [  
    {  
      "table_name": "regional_sales",  
      "file_patterns": [  
        "gs://$GCS_BUCKET_NAME/regional_sales_csv/*.csv"  
      ]  
    }  
  ]  
}  
EOF
```

啟用 Dataflow API

使用 Dataflow 前，請先啟用這項服務。如要這麼做，請使用

```
gcloud services enable dataflow.googleapis.com --project=$GCP_PROJECT
```

建立及執行 Dataflow 工作

匯入工作現在可以執行。這個指令會使用 `GCS_Text_to_Cloud_Spanner` 範本啟動 Dataflow 工作。

這項指令很長，而且有多個參數。以下是細目：

<code>-gcs-location</code>	GCS 中預先建立的範本路徑。
<code>-region</code>	Dataflow 工作執行的區域。
<code>-parameters</code>	
<code>instanceId</code> 、 <code>databaseId</code>	目標 Spanner 執行個體和資料庫。
<code>importManifest</code>	剛建立的資訊清單檔案 GCS 路徑。

```
gcloud dataflow jobs run spanner-import-from-gcs \
  --gcs-location=gs://dataflow-templates/latest/GCS_Text_to_Cloud_Spanner \
  --region=$GCP_REGION \
  --staging-location=gs://$GCS_BUCKET_NAME/staging \
  --parameters \
instanceId=$SPANNER_INSTANCE,\
databaseId=$SPANNER_DB,\
importManifest=gs://$GCS_BUCKET_NAME/regional_sales_manifest.json,escape='\'
```

您可以使用下列指令檢查 Dataflow 工作的狀態

```
gcloud dataflow jobs list \
  --filter="name:spanner-import-from-gcs" \
  --region="$GCP_REGION" \
  --sort-by="~creationTime" \
  --limit=1
```

這項工作大約 5 分鐘就能完成。

驗證 Spanner 中的資料

Dataflow 工作完成後，請確認資料已載入 Spanner。

首先，請檢查列數。應為 4375

```
gcloud spanner databases execute-sql $SPANNER_DB \
  --instance=$SPANNER_INSTANCE \
  --sql='SELECT COUNT(*) FROM regional_sales;'
```

接著，查詢幾列資料來檢查資料。

```
gcloud spanner databases execute-sql $SPANNER_DB \  
--instance=$SPANNER_INSTANCE \  
--sql='SELECT * FROM regional_sales LIMIT 5'
```

您應該會看到從 Snowflake 資料表匯入的資料。

步驟 7 · 約 0 分鐘

7. 清除

清理 Spanner

刪除 Spanner 資料庫和執行個體

```
gcloud spanner instances delete $SPANNER_INSTANCE
```

清理 GCS

刪除為代管資料而建立的 GCS Bucket

```
gcloud storage rm --recursive gs://$GCS_BUCKET_NAME
```

清理 Snowflake

捨棄資料庫

1. 在左側選單的「Horizon Catalog」下方，將游標懸停在「Catalog」上，然後點選「Database Explorer」
2. 按一下 `CODELABS_RETL_DB` 資料庫右側的「...」，展開選項並選取「Drop」
3. 在彈出的確認對話方塊中，選取「Drop Database」

刪除活頁簿

4. 在左側選單的「處理資料」下方，將游標懸停在「專案」上，然後點選「工作區」
 5. 在「我的工作區」側邊欄中，將滑鼠游標懸停在您用於本實驗室的不同工作區檔案上，顯示「...」其他選項，然後點選該選項
 6. 選取「刪除」，然後在彈出的確認對話方塊中再次選取「刪除」。
 7. 針對您為本實驗室建立的所有 SQL 工作區檔案執行這項操作。
-

步驟 8 · 約 0 分鐘

8. 恭喜

恭喜您完成本程式碼研究室。

涵蓋內容

- 如何將資料載入 Snowflake
 - 如何建立 GCS 值區
 - 如何以 CSV 格式將 Snowflake 資料表匯出至 GCS
 - 如何設定 Spanner 執行個體
 - 如何使用 Dataflow 將 CSV 資料表載入 Spanner
-