

如何在 Cloud Run GPU 執行 Transformers.js

來源：<https://codelabs.developers.google.com/codelabs/how-to-use-transformers-js-cloud-run-gpu?hl=zh-tw>

步驟數：7

瞭解如何在 Cloud Run GPU 上執行穩定的擴散作業

目錄

1. [簡介](#)
2. [啟用 API 並設定環境變數](#)
3. [建立 Transformers.js 應用程式](#)
4. [建構及部署 Cloud Run 服務](#)
5. [測試服務](#)
6. [恭喜！](#)
7. [清除所用資源](#)

步驟 1 · 約 0 分鐘

1. 簡介

總覽

Cloud Run 最近新增了 GPU 支援功能。目前僅開放公開測試，且須先加入候補名單。如有興趣試用這項功能，請[填寫這份表單](#)，加入等候名單。Cloud Run 是 Google Cloud 的容器平台，可讓您輕鬆在容器中執行程式碼，不必管理叢集。

我們目前提供的 GPU 是 Nvidia L4 GPU，具有 24 GB 的 vRAM。每個 Cloud Run 執行個體都有一個 GPU，且 Cloud Run 自動調整資源配置功能仍適用。包括最多擴充至 5 個執行個體 (可申請提高配額)，以及在沒有任何要求時縮減至零個執行個體。

Transformers.js 的設計與 Hugging Face 的 transformers Python 程式庫功能相同，因此您可以使用非常類似的 API 執行相同的預先訓練模型。詳情請參閱 [Transformers.js 網站](#)。

在本程式碼研究室中，您將建立應用程式並部署至 Cloud Run，該應用程式會使用 Transformers.js 和 GPU。

課程內容

- 如何在 Cloud Run 上使用 GPU 執行 Transformers.js 應用程式
-

步驟 2 · 約 0 分鐘

2. 啟用 API 並設定環境變數

開始進行本程式碼研究室之前，請先啟用數個 API。本程式碼研究室需要使用下列 API。執行下列指令即可啟用這些 API：

```
gcloud services enable run.googleapis.com \  
storage.googleapis.com \  
cloudbuild.googleapis.com \
```

接著，您可以設定本程式碼研究室全程都會用到的環境變數。

```
PROJECT_ID=<YOUR_PROJECT_ID>  
  
AR_REPO_NAME=repo  
REGION=us-central1
```

步驟 3 · 約 0 分鐘

3. 建立 Transformers.js 應用程式

首先，請建立原始碼的目錄，然後 cd 到該目錄。



```
mkdir transformers-js-codelab && cd $_
```

建立 `package.json` 檔案。



```
{
  "name": "huggingface",
  "version": "1.0.0",
  "main": "index.js",
  "type": "module",
  "scripts": {
    "test": "echo \"Error: no test specified\" && exit 1"
  },
  "keywords": [],
  "author": "",
  "license": "ISC",
  "description": "",
  "dependencies": {
    "@huggingface/transformers": "^3.0.0-alpha.8",
    "@xenova/transformers": "^2.17.2",
    "express": "^4.17.1"
  }
}
```

建立名為 `index.js` 的檔案

```

import { pipeline } from "@xenova/transformers";

import express from 'express';

// make sure the text-generation pipeline is created first
// before anyone can access the routes
const generator = await pipeline('text-generation', 'Xenova/llama2.c-stories15M', {
  device: 'cuda',
  dtype: 'fp32',
});

// now create the app and routes
const app = express();

app.get('/', async (req, res) => {
  const text = 'A long time ago in a galaxy far far away,';
  const output = await generator(text, { max_new_tokens: 50 });
  res.send(output);
});

const port = parseInt(process.env.PORT) || 8080;
app.listen(port, () => {
  console.log(`transformers-js app: listening on port ${port}`);
});

```

建立 `Dockerfile` 。`Dockerfile` 會安裝 `Transformers.js` 所需的額外 `NVIDIA` 驅動程式

```

FROM node:20
WORKDIR /usr/src/app

RUN apt-get update && \
  apt-get install software-properties-common -y && \
  wget https://developer.download.nvidia.com/compute/cuda/repos/debian12/x86_64/cuda-
keyring_1.1-1_all.deb && \
  dpkg -i cuda-keyring_1.1-1_all.deb && \
  add-apt-repository contrib && \
  apt-get update && \
  apt-get -y install cuda-toolkit-12-6 && \
  apt-get -y install cudnn-cuda-12

EXPOSE 8080
COPY package.json .

RUN npm install

COPY index.js .
ENTRYPOINT ["node", "index.js"]

```

步驟 4 · 約 0 分鐘

4. 建構及部署 Cloud Run 服務

在 Artifact Registry 中建立存放區。

```
gcloud artifacts repositories create $AR_REPO_NAME \  
  --repository-format docker \  
  --location us-central1
```

將程式碼提交至 Cloud Build。

```
IMAGE=us-central1-docker.pkg.dev/$PROJECT_ID/$AR_REPO_NAME/gpu-transformers-js  
gcloud builds submit --tag $IMAGE
```

接著，部署至 Cloud Run

```
gcloud beta run deploy transformers-js-codelab \  
  --image=$IMAGE \  
  --cpu 8 --memory 32Gi \  
  --gpu=1 --no-cpu-throttling --gpu-type nvidia-l4 \  
  --allow-unauthenticated \  
  --region us-central1 \  
  --project=$PROJECT_ID \  
  --max-instances 1
```

步驟 5 · 約 0 分鐘

5. 測試服務

如要測試服務，請執行下列指令：

```
SERVICE_URL=$(gcloud run services describe transformers-js-codelab --region $REGION -  
-format 'value(status.url)')  
  
curl $SERVICE_URL
```

您會看到類似下列的內容：

```
[{"generated_text": "A long time ago in a galaxy far far away, there was a beautiful garden.  
Every day, the little girl would go to the garden and look at the flowers. She loved the  
garden so much that she would come back every day to visit it.\nOne day, the little girl was  
walking through"}]
```

步驟 6 · 約 0 分鐘

6. 恭喜！

恭喜您完成本程式碼研究室！

建議您參閱 [Cloud Run GPU](#) 說明文件。

涵蓋內容

- 如何在 Cloud Run 上使用 GPU 執行 Transformers.js 應用程式
-

7. 清除所用資源

為避免產生意外費用 (例如，如果 Cloud Run 服務的叫用次數超過免費層級的每月 Cloud Run 叫用配額)，您可以刪除 Cloud Run 或在步驟 2 中建立的專案。

如要刪除 Cloud Run 服務，請前往 Cloud Run Cloud 控制台 (<https://console.cloud.google.com/run>)，然後刪除 `transformers-js-codelab` 服務。

如要刪除整個專案，請前往 <https://console.cloud.google.com/cloud-resource-manager>，選取您在步驟 2 中建立的專案，然後選擇「刪除」。刪除專案後，您必須在 Cloud SDK 中變更專案。如要查看所有可用專案的清單，請執行 `gcloud projects list`。
