

使用 BQ 從 Databricks 至 Spanner 執行反向 ETL

來源：<https://codelabs.developers.google.com/databricks-bigquery-spanner?hl=zh-tw>

步驟數：10

目錄

1. 使用 Google Cloud Storage 和 BigQuery，從 Databricks 建構反向 ETL 管道至 Spanner
2. 設定、需求和限制
3. 設定 Google Cloud Storage (GCS)
4. 設定 Databricks
5. 設定服務帳戶權限
6. 設定 BigQuery 和 BigLake
7. 載入至 Spanner
8. 驗證 Spanner 中的資料
9. 清除
10. 恭喜

1. 使用 Google Cloud Storage 和 BigQuery，從 Databricks 建構反向 ETL 管道至 Spanner

簡介

在本程式碼研究室中，您將建構從 Databricks 到 Spanner 的**反向 ETL** 管道。傳統上，標準 ETL (擷取、轉換、載入) 管道會將作業資料庫中的資料移至 Databricks 等資料倉儲，以供分析。反向 ETL 管道則會反向操作，將經過處理的精選資料從資料倉儲移回營運資料庫，例如 Spanner (全球分散式關聯式資料庫，非常適合高可用性應用程式)，以便為應用程式提供支援、提供使用者介面功能，或用於即時決策。

目標是將匯總資料集從 Databricks Iceberg 資料表移至 Spanner 資料表。

為此，我們使用 Google Cloud Storage (GCS) 和 BigQuery 做為中繼步驟。以下是資料流程的細目，以及此架構背後的理由：



1. 以 Iceberg 格式將 Databricks 匯出至 Google Cloud Storage (GCS)：

- 第一步是以開放且定義完善的格式，從 Databricks 匯出資料。資料表會以 **Apache Iceberg** 格式匯出。這個程序會將基礎資料寫入一組 **Parquet** 檔案，並將資料表的中繼資料 (結構定義、分區、檔案位置) 寫入 **JSON** 和 **Avro** 檔案。在 GCS 中暫存這個完整的資料表結構，可讓資料可攜，且任何瞭解 Iceberg 格式的系統都能存取。

2. 將 GCS Iceberg 資料表轉換為 BigQuery BigLake 外部資料表：

- 您不必直接將資料從 GCS 載入 Spanner，而是使用 BigQuery 做為強大的中介服務。BigQuery 中會建立 **BigLake** 外部資料表，直接指向 GCS 中的 Iceberg 中繼資料檔案。這種方法有幾個優點：
- **無資料重複**：BigQuery 會從中繼資料讀取資料表結構，並直接查詢 Parquet 資料檔案，不必擷取這些檔案，因此可大幅節省時間和儲存空間費用。
- **聯合查詢**：可讓您對 GCS 資料執行複雜的 SQL 查詢，就像查詢原生 BigQuery 資料表一樣。

3. 將 BigLake 外部資料表反向 ETL 匯入 Spanner：

- 最後一個步驟是將資料從 BigQuery 移至 Spanner。這項作業是透過 BigQuery 的強大功能 (稱為「查詢」) 達成，也就是「反向 ETL」步驟。 `EXPORT DATA`
- **運作準備**：Spanner 專為交易工作負載設計，可為應用程式提供同步一致性和高可用性。將資料移至 Spanner 後，需要低延遲點查的使用者導向應用程式、API 和其他作業系統，就能存取這些資料。
- **可擴充性**：這個模式可充分運用 BigQuery 的分析能力處理大型資料集，然後透過 Spanner 的全球可擴充基礎架構有效提供結果。

服務和術語

- **DataBricks** - 以 Apache Spark 為基礎建構的雲端資料平台。
- **Spanner**：Google 全代管的全球分散式關聯式資料庫。
- **Google Cloud Storage**：Google Cloud 提供的 Blob 儲存空間。
- **BigQuery**：無伺服器資料倉儲，可進行數據分析，並由 Google 全代管。
- **Iceberg**：由 Apache 定義的開放式資料表格式，可針對常見的開放原始碼資料檔案格式提供抽象化功能。
- **Parquet**：Apache 的開放原始碼欄位式二進位資料檔案格式。

課程內容

- 如何將資料載入 Databricks 做為 Iceberg 資料表
 - 如何建立 GCS 值區
 - 如何以 Iceberg 格式將 Databricks 資料表匯出至 GCS
 - 如何從 GCS 中的 Iceberg 資料表，在 BigQuery 中建立 BigLake 外部資料表
 - 如何設定 Spanner 執行個體
 - 如何將 BigQuery 中的 BigLake 外部資料表載入 Spanner
-

2. 設定、需求和限制

必要條件

- Databricks 帳戶 (建議使用 GCP 上的帳戶)
- 如要從 BigQuery 匯出至 Spanner，必須使用 Google Cloud 帳戶，並具備 [Enterprise 級以上的預訂](#)。
- 透過網路瀏覽器存取 Google Cloud 控制台
- 用於執行 [Google Cloud CLI](#) 指令的終端機

如果 Google Cloud 機構已啟用 `iam.allowedPolicyMemberDomains` 政策，系統管理員可能需要授予例外狀況，允許來自外部網域的服務帳戶。我們會在後續步驟中說明相關內容 (如適用)。

需求條件

- 已啟用計費功能的 Google Cloud 專案。
- 網路瀏覽器，例如 [Chrome](#)
- Databricks 帳戶 (本實驗室假設工作區是託管在 GCP 中)
- BigQuery 執行個體必須是 Enterprise 版或更高版本，才能使用 EXPORT DATA 功能。
- 如果 Google Cloud 機構已啟用 `iam.allowedPolicyMemberDomains` 政策，系統管理員可能需要授予例外狀況，允許來自外部網域的服務帳戶。我們會在後續步驟中說明相關內容 (如適用)。

Google Cloud Platform IAM 權限

Google 帳戶需要下列權限，才能執行本程式碼研究室中的所有步驟。

服務帳戶	
<code>iam.serviceAccountKeys.create</code>	允許建立服務帳戶。
Spanner	
<code>spanner.instances.create</code>	可建立新的 Spanner 執行個體。
<code>spanner.databases.create</code>	可執行 DDL 陳述式來建立
<code>spanner.databases.updateDdl</code>	可執行 DDL 陳述式，在資料庫中建立資料表。
Google Cloud Storage	
<code>storage.buckets.create</code>	可建立新的 GCS bucket，用來儲存匯出的 Parquet 檔案。
<code>storage.objects.create</code>	允許將匯出的 Parquet 檔案寫入 GCS 值區。

<code>storage.objects.get</code>	允許 BigQuery 從 GCS 儲存空間讀取 Parquet 檔案。
<code>storage.objects.list</code>	允許 BigQuery 列出 GCS bucket 中的 Parquet 檔案。
Dataflow	
<code>Dataflow.workitems.lease</code>	允許從 Dataflow 認領工作項目。
<code>Dataflow.workitems.sendMessage</code>	允許 Dataflow 工作站將訊息傳回 Dataflow 服務。
<code>Logging.logEntries.create</code>	允許 Dataflow 工作站將記錄項目寫入 Google Cloud Logging。

為方便起見，您可以使用具備這些權限的預先定義角色。

<code>roles/resourcemanager.projectIamAdmin</code>
<code>roles/iam.serviceAccountKeyAdmin</code>
<code>roles/spanner.instanceAdmin</code>
<code>roles/spanner.databaseAdmin</code>
<code>roles/storage.admin</code>
<code>roles/dataflow.serviceAgent</code>
<code>roles/dataflow.worker</code>
<code>roles/dataflow.serviceAgent</code>

Google Cloud 專案

專案是 Google Cloud 的基本組織單位。如果管理員已提供可用的憑證，則可略過這個步驟。

您可以使用 CLI 建立專案，如下所示：

```
gcloud projects create <your-project-name>
```

如要進一步瞭解如何建立及管理專案，請參閱[這篇文章](#)。

限制

請務必留意這個管道可能出現的某些限制和資料類型不相容問題。

從 Databricks Iceberg 遷移至 BigQuery

使用 BigQuery 查詢 Databricks 管理的 Iceberg 資料表 (透過 UniForm) 時，請注意下列事項：

- **結構定義演進**：UniForm 可將 Delta Lake 結構定義變更轉換為 Iceberg，但複雜的變更可能無法如預期傳播。舉例來說，在 Delta Lake 中重新命名資料欄不會轉換為 Iceberg，因為 Iceberg 會將其視為 `drop` 和 `add`。請務必徹底測試結構定義異動。
- **時空旅行**：BigQuery 無法使用 Delta Lake 的時空旅行功能。系統只會查詢 Iceberg 資料表的最新快照。
- **不支援的 Delta Lake 功能**：Delta Lake 的刪除向量和欄對應 (採用 `id` 模式) 等功能與 Iceberg 的 UniForm 不相容。本實驗室使用 `name` 模式進行資料欄對應，此模式受到支援。

BigQuery 至 Spanner

從 BigQuery 到 Spanner 的 `EXPORT DATA` 指令不支援所有 BigQuery 資料類型。匯出下列類型的資料表時會發生錯誤：

- `STRUCT`
- `GEOGRAPHY`
- `DATETIME`
- `RANGE`
- `TIME`

此外，如果 BigQuery 專案使用 `GoogleSQL` 方言，下列數值型別也不支援匯出至 Spanner：

- `BIGNUMERIC`

如需完整且最新的限制清單，請參閱官方文件：[匯出至 Spanner 的限制](#)。

疑難排解與常見錯誤

- 如果不是在 GCP Databricks 執行個體上，可能無法在 GCS 中定義**外部資料位置**。在這種情況下，檔案必須先暫存在 Databricks 工作區的雲端供應商儲存解決方案中，然後再個別遷移至 GCS。
 - 這麼做時，由於資訊會包含暫存檔案的硬式編碼路徑，因此需要調整中繼資料。
-

步驟 3 · 約 0 分鐘


3. 設定 Google Cloud Storage (GCS)

Google Cloud Storage (GCS) 會用於儲存 Databricks 產生的 Parquet 資料檔案。如要這麼做，請先建立新 bucket，做為檔案目的地。

Google Cloud Storage

建立新 bucket

1. 前往雲端控制台中的 [Google Cloud Storage](#) 頁面。
2. 在左側面板中選取「儲存區」：




3. 按一下「建立」按鈕：



4. 填寫 bucket 詳細資料：

請注意，GCS Bucket 名稱在全域範圍內不得重複，因此您需要使用其他 Bucket 名稱。

- 選擇要使用的 bucket 名稱。在本實驗室中，將使用 `codelabs_ret1_databricks` 這個名稱
 - 選取要儲存 bucket 的區域，或使用預設值。
 - 繼續使用 **儲存空間級別** 做為 `standard`
 - 保留「控制存取權」的預設值
 - 保留保護物件資料的預設值
5. 完成後，請按一下 `Create` 按鈕。系統可能會顯示提示，要求您確認要禁止公開存取。請確認。
 6. 恭喜，您已成功建立新的值區！系統會重新導向至 bucket 頁面。
- 將新值區名稱複製到任一處，以便稍後使用。



為後續步驟做好準備

請務必記下下列詳細資料，因為後續步驟會用到：

1. Google 專案 ID
2. Google Storage bucket 名稱

4. 設定 Databricks

TPC-H 資料

在本實驗室中，我們將使用 **TPC-H 資料集**，這是決策支援系統的業界標準基準。這個結構定義會模擬真實的商業環境，包含顧客、訂單、供應商和零件，非常適合用來展示實際的數據分析和資料移動情境。

系統會建立新的匯總資料表，而非使用原始的標準化 TPC-H 資料表。這個新資料表會彙整 `orders`、`customer` 和 `nation` 資料表中的資料，產生反正規化的區域銷售摘要檢視畫面。預先彙整資料是數據分析的常見做法，因為這樣可準備好資料，以用於特定用途。在本情境中，資料會用於作業應用程式。

匯總資料表的最終結構定義如下：

Col	類型
nation_name	字串
market_segment	字串
order_year	int
order_priority	字串
total_order_count	bigint
total_revenue	decimal(29,2)
unique_customer_count	bigint

透過 Delta Lake Universal Format (UniForm) 支援 Iceberg

在本實驗室中，Databricks 內的資料表將是 **Delta Lake** 資料表。不過，為了讓 BigQuery 等外部系統可讀取，系統會啟用名為「通用格式 (UniForm)」的強大功能。

UniForm 會自動產生 **Iceberg** 中繼資料，以及資料表單一共用副本的 Delta Lake 中繼資料。這項功能兼具兩者的優點：

- 在 **Databricks** 中：可享有 Delta Lake 的所有效能和管理優勢。
- Databricks** 以外：任何與 Iceberg 相容的查詢引擎 (例如 BigQuery) 都能讀取資料表，就像讀取原生 Iceberg 資料表一樣。

這樣一來，就不必維護資料副本或執行手動轉換工作。建立資料表時，只要設定特定資料表屬性，即可啟用 UniForm。

Databricks 目錄

Databricks 目錄是 **Unity Catalog** (Databricks 的統一治理解決方案) 中的頂層資料容器。Unity Catalog 提供集中管理資料資產、控管存取權及追蹤沿襲的方式，對於妥善管理的資料平台至關重要。

這項服務會使用三層命名空間來整理資料：`catalog.schema.table`。

- **目錄**：最高層級，用於依環境、業務單位或專案分組資料。
- **結構定義 (或資料庫)**：目錄中資料表、檢視區塊和函式的邏輯分組。
- **資料表**：包含資料的物件。

建立匯總 TPC-H 資料表前，必須先設定專屬的目錄和結構定義來存放該資料表。確保專案井然有序，並與工作區中的其他資料隔離。

建立新的目錄和結構定義

在 Databricks Unity Catalog 中，目錄是資料資產的最高層級組織，可做為安全容器，跨越多個 Databricks 工作區。您可以根據業務部門、專案或環境整理及隔離資料，並清楚定義權限和存取控管機制。


在目錄中，結構定義 (也稱為資料庫) 會進一步整理資料表、檢視區塊和函式。這種階層式結構可精細控管相關資料物件，並進行邏輯分組。在本實驗室中，我們將建立專屬的目錄和結構定義來存放 TPC-H 資料，確保適當的隔離和管理。

建立目錄

1. 前往



2. 按一下「+」，然後從下拉式選單中選取「建立目錄」



3. 系統會建立新的「標準」目錄，並採用下列設定：

- **目錄名稱**： `retl_tpch_project`
- **儲存位置**：如果工作區已設定儲存位置，請使用預設位置，否則請建立新的儲存位置。

Create a new catalog

×

A catalog is the first layer of Unity Catalog's three-level namespace and is used to organize your data assets. [Learn more](#)

Catalog name*

retl_tpch_project

Type*

Standard

Storage location

Cloud storage location used for managed tables and volumes in this catalog. If not specified, it defaults to the metastore root location.

Select external location

sub/path

[Create a new external location](#)

Cancel

Create

建立結構定義

1. 前往

 Catalog

2. 從左側面板選取新建立的目錄

>  system

>  retl_tpch_project

▼ Delta Shares Received

3. 按一下

Create schema

4. 系統會以「結構定義名稱」做為 `tpch_data` 建立新結構定義

Create a new schema

×

A schema is the second layer of Unity Catalog's three-level namespace and organizes tables and views. [Learn more](#)

Schema name*

tpch_data

Storage location

Cloud storage location used for managed tables and volumes in this catalog. If not specified, it defaults to the metastore root location.

Select external location

sub/path

[Create a new external location](#)

Comment

Cancel

Create

設定外部資料

如要將資料從 Databricks 匯出至 Google Cloud Storage (GCS)，必須在 Databricks 中設定外部資料憑證。這樣 Databricks 就能安全地存取 GCS bucket 並寫入資料。

如「需求條件和限制」一節所述，如果不是在 GCP 代管的 Databricks 工作區，資料必須先暫存在其他位置，然後再分別移至 GCS。

1. 在「目錄」畫面上，按一下

External Data >

- 如果沒有看到 `External Data` 選項，請改為在 `Connect` 下拉式選單中尋找 `External Locations`。

2. 按一下

Credentials ⓘ

3. 在新對話方塊視窗中，設定憑證的必要值：

- 憑證類型：`GCP Service Account`
- 憑證名稱：`retl-gcs-credential`

Create a new credential

×

A storage credential represents an authentication and authorization mechanism for accessing data stored on your cloud tenant. [Learn more](#)

Credential Type*

GCP Service Account

Credential name*

retl-gcs-credential

Comment

> Advanced Options

Cancel

Create

4. 按一下「Create」(建立)
5. 接著點選「外部位置」分頁標籤。
6. 按一下「建立營業地點」。
7. 在新對話方塊視窗中，設定外部位置的必要值：

- 外部位置名稱：`retl-gcs-location`
- 「Storage type」(儲存空間類型)：`GCP`
- 網址：GCS bucket 的網址，格式為 `gs://YOUR_BUCKET_NAME`
- 儲存空間憑證：選取剛建立的 `retl-gcs-credential`。

Create a new external location

An external location allows you to access your data stored in cloud storage (e.g. GCS). You will need the cloud storage path and a paired credential (e.g. IAM role) which gives access to that path [Learn more](#)

External location name*

retl-gcs-location

Storage type*

GCP

URL* ⓘ

Enter the bucket path that you want to use as the external location

gs://codelabs_retl_databricks/

Storage credential* [Learn more](#)

Provide a storage credential capable of accessing the URL

retl-gcs-credential (Service Account)

Email: db-uc-credential-06dq9aeflo-qt@uc-uscentral1.iam.gserviceaccount.com

Comment

> Advanced Options

8. 選取「storage credential」(儲存空間憑證) 後，系統會自動填入「Service account」(服務帳戶) 電子郵件地址，請記下這個地址，下一個步驟會用到。

注意：如果 Google Cloud 機構強制執行 `iam.allowedPolicyMemberDomains` 限制，安全管理員必須將這個服務帳戶的網域 (@ 符號後方的部分) 新增至允許清單。


9. 按一下「Create」(建立)
-

5. 設定服務帳戶權限

服務帳戶是特殊的帳戶類型，應用程式或服務可透過這種帳戶，對 Google Cloud 資源發出授權 API 呼叫。

現在，您必須為 GCS 中新 bucket 建立的服務帳戶新增權限。

1. 在 GCS bucket 頁面中，選取「權限」分頁標籤。



2. 在主體頁面中，點選「授予存取權」
3. 在從右側滑出的「授予存取權」面板中，將「服務帳戶 ID」輸入「新增主體」欄位。
4. 在「指派角色」下方，新增 `Storage Object Admin` 和 `Storage Legacy Bucket Reader`。這些角色可讓服務帳戶讀取、寫入及列出儲存空間 bucket 中的物件。

載入 TPC-H 資料

現在已建立 Catalog 和 Schema，可以從 Databricks 內部儲存的現有 `samples.tpch` 資料表載入 TPC-H 資料，並在新的 Schema 中操作成新資料表。

建立支援 Iceberg 的資料表

Iceberg 與 UniForm 的相容性


在幕後，Databricks 會在內部將這個資料表管理為 Delta Lake 資料表，在 Databricks 生態系統中提供 Delta 效能最佳化和治理功能的所有優點。不過，啟用 **UniForm** (通用格式的簡稱) 後，Databricks 會收到特殊指令：每次更新資料表時，Databricks 除了 Delta Lake 中繼資料外，還會自動生成並維護對應的 Iceberg 中繼資料。

也就是說，現在有兩組不同的中繼資料，用來描述同一組共用的資料檔案 (Parquet 檔案)。

- **Databricks**：使用 `_delta_log` 讀取資料表。
- **外部讀取器 (例如 BigQuery)**：這類讀取器會使用 Iceberg 中繼資料檔案 (`.metadata.json`) 瞭解資料表的結構定義、分區和檔案位置。

因此產生的資料表完全相容於任何可辨識 Iceberg 的工具，且相容性一目瞭然。不會重複資料，也不需要手動轉換或同步處理。這個單一可靠來源可供 Databricks 的分析世界，以及支援開放 Iceberg 標準的更廣泛工具生態系統無縫存取。

1. 依序按一下「新增」和「查詢」。



2. 在查詢頁面的文字欄位中，執行下列 SQL 指令：

設定 `LOCATION` 時，請務必將 `<Your bucket name>` 的值替換為您在上一步中建立的實際 bucket 名稱。

```
CREATE TABLE retl_tpch_project.tpch_data.regional_sales_iceberg
USING DELTA
LOCATION 'gs://<Your bucket name>/regional_sales_iceberg'
TBLPROPERTIES (
  'delta.columnMapping.mode' = 'name',
  'delta.enableIcebergCompatV2' = 'true',
  'delta.universalFormat.enabledFormats' = 'iceberg'
)
AS

SELECT
  n.n_name AS nation_name,
  c.c_mktsegment AS market_segment,
  YEAR(o.o_orderdate) AS order_year,
  o.o_orderpriority AS order_priority,
  COUNT(o.o_orderkey) AS total_order_count,
  ROUND(SUM(o.o_totalprice), 2) AS total_revenue,
  COUNT(DISTINCT c.c_custkey) AS unique_customer_count
FROM samples.tpch.orders AS o
INNER JOIN samples.tpch.customer AS c
  ON o.o_custkey = c.c_custkey
INNER JOIN samples.tpch.nation AS n
  ON c.c_nationkey = n.n_nationkey
GROUP BY
  n.n_name,
  c.c_mktsegment,
  YEAR(o.o_orderdate),
  o.o_orderpriority;

OPTIMIZE retl_tpch_project.tpch_data.regional_sales_iceberg;

DESCRIBE EXTENDED retl_tpch_project.tpch_data.regional_sales_iceberg;
```

注意：

- **使用 Delta** - 指定我們使用的是 Delta Lake 資料表。只有 Databricks 中的 Delta Lake 資料表可以儲存為外部資料表。
- **位置**：指定資料表的儲存位置 (如為外部資料表)。
- **TableProperties** - `delta.universalFormat.enabledFormats = 'iceberg'` 會在 Delta Lake 檔案旁建立相容的 Iceberg 中繼資料。
- **最佳化**：強制觸發 UniForm 中繼資料生成作業，因為這項作業通常會以非同步方式進行。

3. 查詢輸出內容應會顯示新建立資料表的詳細資料

步驟 6 · 約 0 分鐘

6. 設定 BigQuery 和 BigLake

Iceberg 資料表現在位於 Google Cloud Storage 中，下一步是讓 BigQuery 能夠存取該資料表。方法是建立 **BigLake** 外部資料表。

BigLake 是一種儲存引擎，可讓您在 BigQuery 中建立資料表，直接從 Google Cloud Storage 等外部來源讀取資料。在本實驗室中，這項技術是 BigQuery 瞭解剛匯出的 Iceberg 資料表的關鍵，不必擷取資料。

如要讓這項功能正常運作，需要兩個元件：


1. **雲端資源連線**：這是 BigQuery 和 GCS 之間的安全連結。系統會使用特殊服務帳戶處理驗證，確保 BigQuery 具備從 GCS bucket 讀取檔案的必要權限。
2. **外部資料表定義**：這會告知 BigQuery 在 GCS 中尋找 Iceberg 資料表的中繼資料檔案，以及應如何解讀該檔案。

建立 Cloud 資源連結

首先，系統會建立連線，讓 BigQuery 存取 GCS。

如要進一步瞭解如何建立 Cloud 資源連線，請參閱[這篇文章](#)。

1. 前往 [BigQuery](#)
 2. 按一下「探索」下方的「連線」
- 如果沒有看到「Explorer」平面，請按一下



3. 在「連線」頁面中，按一下

Create connection

4. 在「連線類型」中選擇 `Vertex AI remote models, remote functions, BigLake and Spanner (Cloud Resource)`
5. 將連線 ID 設為 `databricks_retl`，然後建立連線

External data source

Connection type
Vertex AI remote models, remote functions, BigLake and Spanner (Cloud... ▼

Connection ID *
databricks_retl

Location type ?
☐ Region
Specify a region to colocate your datasets with other Google Cloud services.
☒ Multi-region
Allow BigQuery to select a region within a group to achieve higher quota limits.

Multi-region *
US (multiple regions in United States) ▼

Friendly name

Description

Create connection

請確認連線是在與資料集相同的區域中建立

6. 現在應該會在新建連線的「連線」表格中看到項目。按一下該項目即可查看連線詳細資料。

Connection ID	Friendly name	Location
➔ [REDACTED]		us-central1
➔ databricks_retl		us
➔ [REDACTED]		us

7. 在連線詳細資料頁面中，記下「服務帳戶 ID」，稍後會用到。

databricks_retl


Connection info

Connection ID	projects/improvingvancouver/locations/us/connections/databricks_retl
Friendly name	
Created	Dec 29, 2025, 12:14:05 PM UTC-8
Last modified	Dec 29, 2025, 12:14:05 PM UTC-8
Data location	us
Description	
Connection type	Vertex AI remote models, remote functions, BigLake and Spanner (Cloud Resource)
Service account id	bqcx-246523842825-va63@gcp-sa-bigquery-condel.iam.gserviceaccount.com

授予連線服務帳戶存取權

1. 前往「IAM 與管理」

2. 點選「授予存取權」



3. 在「新增主體」欄位，輸入上述建立的連線資源服務帳戶 ID。

4. 選取「角色」的 `Storage Object User`，然後點選


Save

。

建立連線並授予服務帳戶必要權限後，現在可以建立 BigLake 外部資料表。首先，您需要在 BigQuery 中建立資料集，做為新資料表的容器。接著，系統會建立資料表本身，並將其指向 GCS bucket 中的 Iceberg 中繼資料檔案。

1. 前往 [BigQuery](#)

2. 在「Explorer」面板中，點選專案 ID，然後點選三點圖示並選取「建立資料集」。



3. 資料集名稱為 `databricks_retl`。其他選項保留預設值，然後按一下「建立資料集」按鈕。

Create dataset

Project ID *
[Redacted] [Change](#)

Dataset ID *

Letters, numbers, and underscores allowed


Data location ▼ ?

Tags ▼

Advanced options ▼

[Create dataset](#) [Cancel](#)

4. 現在，請在「Explorer」面板中找出新的 `databricks_ret1` 資料集。點選旁邊的三點圖示，然後選取「建立資料表」。



- 填寫下列資料表建立設定：
 - 使用下列資料建立資料表：`Google Cloud Storage`
 - 從 **GCS bucket** 選取檔案或使用 **URI 模式**：瀏覽至 GCS Bucket，然後找出 Databricks 匯出作業期間產生的**中繼資料 JSON 檔案**。路徑應如下所示：`regional_sales/metadata/v1.metadata.json`。
 - 檔案格式：`Iceberg`
 - 表格：`regional_sales`
 - 資料表類型：`External table`
 - 「連線 ID」：選取先前建立的 `databricks_ret1` 連線。
 - 其餘值保留預設值，然後點選「建立資料表」。
- 建立完成後，新的 `regional_sales` 資料表應會顯示在 `databricks_ret1` 資料集下方。現在，您可以使用標準 SQL 查詢這個資料表，就像查詢任何其他 BigQuery 資料表一樣。

Overview	Details
Tables	Models
	Routines
Filter	Enter property name or value
Table ID	Type
regional_sales	Table

7. 載入至 Spanner

管道的最後一個也是最重要的部分已完成：將資料從 BigLake 外部資料表移至 Spanner。這是「反向 ETL」步驟，資料在資料倉儲中經過處理和整理後，會載入營運系統供應用程式使用。

Spanner 是全代管的全球分散式關聯式資料庫。Cloud Spanner 具有傳統關聯式資料庫的交易一致性，且能夠水平擴充 NoSQL 資料庫。因此非常適合建構可擴充的高可用性應用程式。

程序如下：

- 1. 建立 Spanner 執行個體，這是資源的實體分配。
- 2. 在該執行個體中建立資料庫。
- 3. 在資料庫中定義與 `regional_sales` 資料結構相符的資料表結構定義。
- 4. 執行 BigQuery `EXPORT DATA` 查詢，將資料從 BigLake 資料表直接載入 Spanner 資料表。

建立 Spanner 執行個體、資料庫和資料表

- 1. 前往 [Spanner](#)
- 2. 按一下

 [Create instance](#)

。如有現有執行個體，請隨意使用。視需要設定執行個體需求。本實驗室使用下列項目：

版本	Enterprise
執行個體名稱	databricks-retl
區域設定	你選擇的區域
運算單元	處理單元 (PU)
手動分配	100

- 3. 建立完成後，請前往 Spanner 執行個體頁面，然後選取

 [Create database](#)

。如有現成資料庫，歡迎直接使用。

- 在本實驗室中，您將使用下列項目建立資料庫：
 - 名稱：`databricks-retl`
 - 資料庫方言：`Google Standard SQL`
- 4. 建立資料庫後，請從 Spanner 執行個體頁面選取資料庫，然後進入 Spanner 資料庫頁面。
 - 5. 在 Spanner 資料庫頁面中，按一下


 [Write DDL](#)

6. 在新查詢頁面中，系統會建立要匯入 Spanner 的資料表定義。如要執行這項操作，請執行下列 SQL 查詢。

```
CREATE TABLE regional_sales (  
  nation_name STRING(MAX),  
  market_segment STRING(MAX),  
  order_year INT64,  
  order_priority STRING(MAX),  
  total_order_count INT64,  
  total_revenue NUMERIC,  
  unique_customer_count INT64  
) PRIMARY KEY (nation_name, market_segment, order_year, order_priority);
```

上述 SQL 是以 Google 標準 SQL 建立。請根據資料庫設定的方言視需要變更

7. SQL 指令執行完畢後，BigQuery 即可對 Spanner 資料表執行反向 ETL 作業。在 Spanner 資料庫的左側面板中，您會看到資料表列出，藉此確認資料表已建立。



使用 `EXPORT DATA` 對 Spanner 執行反向 ETL

這是最後一個步驟。在 BigQuery BigLake 資料表中準備好來源資料，並在 Spanner 中建立目的地資料表後，實際的資料移動作業會出乎意料地簡單。系統會使用單一 BigQuery SQL 查詢：`EXPORT DATA`。

這項查詢專為這類情境設計。可有效率地將資料從 BigQuery 資料表 (包括 BigLake 資料表等外部資料表) 匯出至外部目的地。在本例中，目的地是 Spanner 資料表。如要進一步瞭解匯出功能，請參閱[這篇文章](#)

如要進一步瞭解如何設定 BigQuery 到 Spanner 的反向 ETL，請參閱[這篇文章](#)

如要使用匯出功能，BigQuery 執行個體必須至少為 Enterprise 版

1. 前往 [BigQuery](#)

2. 開啟新的查詢編輯器分頁。

3. 在「查詢」頁面中，輸入下列 SQL。請記得將 **** uri **** 中的專案 ID 和資料表路徑替換為正確的專案 ID。

```
EXPORT DATA OPTIONS(  
  
uri='https://spanner.googleapis.com/projects/YOUR_PROJECT_ID/instances/databricks-  
retl/databases/databricks-retl',  
  format='CLOUD_SPANNER',  
  spanner_options=""{  
    "table": "regional_sales",  
    "priority": "MEDIUM"  
  }""  
) AS  
  
SELECT * FROM `YOUR_PROJECT_ID.databricks_retl.regional_sales`;
```

4. 指令完成後，資料就會成功匯出至 Spanner！

8. 驗證 Spanner 中的資料

恭喜！您已成功建構及執行完整的反向 ETL 管道，將資料從 Databricks 資料倉儲移至營運 Spanner 資料庫。

最後一個步驟是確認資料是否已如預期匯入 Spanner。

1. 前往 [Spanner](#)。
2. 前往 `databricks-retl` 執行個體，然後前往 `databricks-retl` 資料庫。
3. 在資料表清單中，按一下 `regional_sales` 資料表。
4. 在資料表的左側導覽選單中，按一下「資料」分頁標籤。

Spanner

Table

Schema

Indexes

Data

All instances > Instance databricks-retl: Overview > Google Standard SQL Database databricks-retl: Overview > Table regional_sales: Schema

Schema

Name

regional_sales

Schema updates

No recent updates

Primary Key(s): nation_name (asc), market_segment (asc), order_year (asc), order_priority (asc)

	Column	Type	Nullable	Order	Watched by
	nation_name	STRING(MAX)	Yes	asc	
	market_segment	STRING(MAX)	Yes	asc	
	order_year	INT64	Yes	asc	
	order_priority	STRING(MAX)	Yes	asc	
	total_order_count	INT64	Yes	—	
	total_revenue	NUMERIC	Yes	—	
	unique_customer_count	INT64	Yes	—	

Show equivalent DDL

5. 原本來自 Databricks 的匯總銷售資料現在應該已載入，並可在 Spanner 資料表中使用。這些資料現在位於作業系統中，可供即時應用程式使用、用於資訊主頁，或透過 API 查詢。

All instances > Instance databricks-retl: Overview > Google Standard SQL Database databricks-retl: Overview > Table regional_sales: Data

Data

Insert

Edit

Delete

Filter

Filter data

	nation_name	market_segment	order_year	order_priority	total_order_count	total_revenue	unique_customer_count
	ALGERIA	AUTOMOBILE	1992	1-URGENT	1860	280055751.22	1437
	ALGERIA	AUTOMOBILE	1992	2-HIGH	1780	271562816.54	1415
	ALGERIA	AUTOMOBILE	1992	3-MEDIUM	1796	271939193.68	1403
	ALGERIA	AUTOMOBILE	1992	4-NOT SPECIFIED	1764	263214640.65	1381
	ALGERIA	AUTOMOBILE	1992	5-LOW	1748	264860382.86	1361
	ALGERIA	AUTOMOBILE	1993	1-URGENT	1762	267663645.09	1402
	ALGERIA	AUTOMOBILE	1993	2-HIGH	1789	274859054.46	1430
	ALGERIA	AUTOMOBILE	1993	3-MEDIUM	1753	262963791.71	1383
	ALGERIA	AUTOMOBILE	1993	4-NOT SPECIFIED	1797	267417733.4	1380
	ALGERIA	AUTOMOBILE	1993	5-LOW	1795	269971770.64	1405
	ALGERIA	AUTOMOBILE	1994	1-URGENT	1831	279987288.81	1415
	ALGERIA	AUTOMOBILE	1994	2-HIGH	1801	268164106.37	1394
	ALGERIA	AUTOMOBILE	1994	3-MEDIUM	1788	264860382.86	1361

分析和營運資料世界之間的鴻溝已成功彌平。

步驟 9 · 約 0 分鐘

9. 清除

完成本實驗室後，請移除所有新增的資料表和儲存的資料。

清理 Spanner 資料表

1. 前往 [Spanner](#)
2. 從名為「`databricks-retl`」的清單中，點選用於本實驗室的執行個體。

☐	Name ↑	ID	Edition	Configuration
☐	<u>databricks-retl</u>	databricks-retl	Standard	us-west1 (Oregon)

3. 在執行個體頁面中，按一下

 Delete instance

。

4. 在彈出的確認對話方塊中輸入 `databricks-retl`，然後按一下

Delete

清理 GCS

1. 前往 [GCS](#)
2. 選取左側選單中的

 Buckets

3. 選取 `code-labs_retl_databricks` bucket

	Name ↑
☒	<u>code-labs_retl_databricks</u>

4. 選取後，按一下頂端橫幅顯示的

 Delete

按鈕

	1 bucket selected	 Delete	 Permissions	 Tags	 Labels
---	-------------------	--	---	--	--

5. 在彈出的確認對話方塊中輸入 `DELETE`，然後按一下

Delete

清理 Databricks

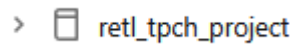
刪除目錄/結構定義/資料表

1. 登入 Databricks 執行個體


2. 按一下左側選單中的




3. 從目錄清單中選取先前建立的



4. 在「結構定義」清單中，選取已建立的



5. 從表格清單中選取先前建立的



6. 按一下



展開表格選項，然後選取 `Delete`

7. 在確認對話方塊中按一下

Delete

即可刪除表格

8. 刪除資料表後，系統會將您帶回結構定義頁面

9. 按一下



展開結構定義選項，然後選取 `Delete`

10. 在確認對話方塊中按一下

Delete

，刪除結構定義

11. 刪除架構後，系統會將你帶回目錄頁面

12. 如果存在 `default` 架構，請再次按照步驟 4 到 11 刪除。

13. 在目錄頁面中，按一下



展開目錄選項，然後選取 `Delete`


14. 在確認對話方塊中按一下

Delete

，即可刪除目錄

刪除外部資料位置 / 憑證

15. 在「目錄」畫面中，按一下



16. 如果沒有看到 External Data 選項，請改為在 Connect 下拉式選單中尋找 External Location 。

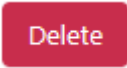
17. 按一下先前建立的 retl-gcs-location 外部資料位置

18. 在外部地點頁面中，按一下



展開地點選項，然後選取 Delete 。

19. 在確認對話方塊中按一下



，刪除外部位置

20. 按一下



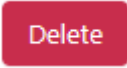
21. 按一下先前建立的 retl-gcs-credential

22. 在憑證頁面中，按一下




展開憑證選項，然後選取 Delete 。

23. 在確認對話方塊中按一下



，即可刪除憑證。



步驟 10 · 約 0 分鐘

10. 恭喜

恭喜您完成本程式碼研究室。

涵蓋內容

- 如何將資料載入 Databricks 做為 Iceberg 資料表
 - 如何建立 GCS 值區
 - 如何以 Iceberg 格式將 Databricks 資料表匯出至 GCS
 - 如何從 GCS 中的 Iceberg 資料表，在 BigQuery 中建立 BigLake 外部資料表
 - 如何設定 Spanner 執行個體
 - 如何將 BigQuery 中的 BigLake 外部資料表載入 Spanner
-