

從原型設計到正式環境：透過自訂訓練模型取得預測結果

來源：<https://codelabs.developers.google.com/vertex-p2p-predictions?hl=zh-tw>

步驟數：7

目錄

1. [總覽](#)
2. [Vertex AI 簡介](#)
3. [設定環境](#)
4. [將模型上傳至登錄檔](#)
5. [將模型部署至端點](#)
6. [取得預測結果](#)
7. [清除所用資源](#)

步驟 1 · 約 1 分鐘

1. 總覽

在本實驗室中，您將使用 [Vertex AI](#)，從自訂訓練模型取得線上和批次預測結果。

本實驗室是「從原型設計到投入正式環境」系列影片的一部分。請務必先完成[上一個實驗室](#)，再進行這個實驗室。如要瞭解詳情，請觀看隨附影片：



。

課程內容

內容如下：


- 將模型上傳至 Vertex AI Model Registry
- 將模型部署至端點
- 使用 UI 和 SDK 取得線上和批次預測結果

在 Google Cloud 上執行這個實驗室的總費用約為 **\$1 美元**。

2. Vertex AI 簡介

本實驗室使用 Google Cloud 最新推出的 AI 產品服務。Vertex AI 整合了 Google Cloud 機器學習服務，提供流暢的開發體驗。以 AutoML 訓練的模型和自訂模型，先前需透過不同的服務存取。這項新服務將兩者併至單一 API，並加入其他新產品。您也可以將現有專案遷移至 Vertex AI。

Vertex AI 包含許多不同的產品，可支援端對端機器學習工作流程。本實驗室將著重於下列產品：**Predictions**和**Workbench**



步驟 3 · 約 10 分鐘

3. 設定環境

完成「[使用 Vertex AI 訓練自訂模型](#)」實驗室中的步驟，設定環境。

4. 將模型上傳至登錄檔

如要使用模型取得預測結果，必須先將模型上傳至 [Vertex AI Model Registry](#)。這個存放區可讓您管理機器學習模型的生命週期。

設定自訂訓練工作時，您可以上傳模型，如下所示。

Train new model

- ✓ Training method
- ✓ Model details
- ✓ Training container
- ✓ Hyperparameters (optional)
- ✓ Compute and pricing
- 6 Prediction container (optional)**

START TRAINING **CANCEL**

You can associate your custom-trained model with a container in order to serve prediction requests using Vertex AI. [Learn more about getting predictions.](#)

- ☐ No prediction container
You can always import your model artifact later to serve prediction requests
- ☒ **Pre-built container**
View the list of [supported runtimes](#) including TensorFlow, scikit-learn and PyTorch versions
- ☐ Custom container
Build a custom Docker container. Must be stored in [Container Registry or Artifact Registry](#)

Pre-built container settings

Vertex AI provides Docker container images for serving predictions. To use a pre-built container, your trained model code must be in Python 3.7. [Learn more about pre-built containers](#)

In order to run in a pre-built container, your code needs to be in Python 3.7

或者，只要將儲存的模型構件存放在 Cloud Storage bucket 中，您也可以在訓練工作完成後匯入模型。本實驗室將使用這個選項。

前往控制台的「模型」專區。



Vertex AI



Dashboard



Datasets



Features



Labelling tasks



Workbench



Pipelines



Training



Experiments



Models



Endpoints



Batch predictions



Metadata



Matching engine

選取「匯入」IMPORT

Models



CREATE



IMPORT

Models are built from your data sets or unmanaged data sources. You can create different types of machine learning models available on Vertex AI, depending on your use case and level of experience with machine learning. [Learn more](#)

選取「匯入為新模型」，然後為模型命名

You can import model artifacts that have been trained outside of Google Cloud. Once your model has been imported, you can serve it for online or batch predictions and compare it against your other Cloud AI models. [More info](#)



Import as new model

Creates a new model group and assigns the imported model as version 1



Import as new version

Imports the model as a version of an existing model

在「模型設定」下方，使用預建容器匯入模型，並使用 TensorFlow 2.8。如需預先建構的預測容器完整清單，請參閱[這篇文章](#)。

然後提供雲端儲存空間值區的路徑，您已在自訂訓練工作中將模型構件儲存至該值區。畫面應如下所

示：`gs://{PROJECT_ID}-bucket/model_output`

我們將略過「可解釋性」一節，但如要進一步瞭解 Vertex Explainable AI，請參閱[說明文件](#)。

模型匯入後，您會在登錄中看到該模型。

Models

+

CREATE

↓

IMPORT

Models are built from your data sets or unmanaged data sources. There are many different types of machine learning models available on Vertex AI, depending on your use case and level of experience with machine learning. [Learn more](#)

Region

us-central1 (Iowa)

▼

?

≡ Filter

Enter a property name

Name	Deployment status	Description	Default version	Type	Source
flower-model	—	—	1	👤 Imported	Custom training

請注意，如要透過 SDK (而非 UI) 執行這項操作，可以從 Workbench 筆記本執行下列指令來上傳模型。

```
from google.cloud import aiplatform

my_model = aiplatform.Model.upload(display_name='flower-model',
                                   artifact_uri='gs://{PROJECT_ID}-bucket/model_output',
                                   serving_container_image_uri='us-docker.pkg.dev/vertex-ai/prediction/tf2-cpu.2-8:latest')
```

5. 將模型部署至端點

我們可以在 Vertex AI 中執行兩種預測工作：批次和線上。


批次預測為非同步要求。如果您不需要立即取得回覆，並想透過單一要求處理累積的資料，就適合選用這個模式。

另一方面，如要從傳遞至模型的資料即時取得低延遲預測結果，則應使用線上預測。

模型現在位於登錄檔中，我們可以將其用於批次預測。

但如要進行線上預測，我們必須將模型部署至端點。這會將儲存的模型構件與實體資源建立關聯，以提供低延遲的預測結果。

如要部署至端點，請選取模型最右側的三點圖示，然後選取「Deploy to endpoint」(部署至端點)。



為端點命名，然後其餘設定保留原狀，並點選「繼續」

Deploy to endpoint

1 Define your endpoint

2 Model settings

3 Model monitoring

DEPLOY

CANCEL

☒ Create new endpoint ☐ Add to existing endpoint

Endpoint name *

my-endpoint



Location

Region

us-central1 (Iowa)



Access

Determines how your endpoint can be accessed. By default, endpoints are available for prediction serving through a REST API. Endpoint access can't be changed after the endpoint is created.

☒ Standard

Makes the endpoint available for prediction serving through a REST API. AutoML and custom-trained models can be added to standard endpoints.

☐ Private

Create a private connection to this endpoint using a VPC network and [private services access](#). Only custom-trained and tabular models can be added to private endpoints. [Learn more](#)

ADVANCED OPTIONS

CONTINUE

端點支援自動調度資源，也就是說，您可以設定下限和上限，運算節點就會在這些界線內調度資源，以滿足流量需求。

由於本實驗室僅供示範，我們不會將這個端點用於高流量，因此您可以將「運算節點數量上限」設為 1，並選取 n1-standard-4 做為「機型」。

Once scaling settings are set, they can't be changed unless you redeploy the model. [Pricing guide](#)

Minimum number of compute nodes *

1

Default is 1. If set to 1 or more, then compute resources will continuously run even without traffic demand. This can increase cost but avoid dropped requests due to node initialisation.

Maximum number of compute nodes (optional)

1

Enter a number equal to or greater than the minimum nodes. Can reduce costs but may cause reliability issues for high traffic.

✓ ADVANCED SCALING OPTIONS

Machine type *

n1-standard-4, 4 vCPUs, 15 GiB memory



Service account



A service account determines what Google Cloud resources your service code can access. By default, a Google-managed service account is used with permissions appropriate for most models. You can also use a user-managed service account to customise permissions. [Learn more.](#)

我們會略過模型監控，但如要進一步瞭解這項功能，請[參閱說明文件](#)。

然後按一下「DEPLOY」。

部署作業需要幾分鐘，完成後，模型部署狀態會變更為「已部署至 Vertex AI」。

如要透過 SDK 部署模型，請執行下列指令。

```
my_model = aiplatform.Model("projects/{PROJECT_NUMBER}/locations/us-  
central1/models/{MODEL_ID}")  
  
endpoint = my_model.deploy(  
    deployed_model_display_name='my-endpoint',  
    traffic_split={"0": 100},  
    machine_type="n1-standard-4",  
    accelerator_count=0,  
    min_replica_count=1,  
    max_replica_count=1,  
)
```

步驟 6 · 約 0 分鐘


6. 取得預測結果

線上預測

將模型部署至端點後，您就能像使用任何其他 REST 端點一樣使用模型，也就是說，您可以從 Cloud 函式、聊天機器人、網頁應用程式等呼叫模型。

為方便示範，我們將從 Workbench 呼叫這個端點。

返回您在上一個實驗室中建立的筆記本。從啟動器建立新的 TensorFlow 2 筆記本。




匯入 Vertex AI Python SDK、numpy 和 PIL

```
from google.cloud import aiplatform

import numpy as np
from PIL import Image
```

下載下方的圖片，然後上傳至 Workbench 執行個體。我們將在這張蒲公英圖片上測試模型。



首先，請定義端點。請替換下方的 {PROJECT_NUMBER} 和 {ENDPOINT_ID} 。

```
endpoint = aiplatform.Endpoint(  
    endpoint_name="projects/{PROJECT_NUMBER}/locations/us-central1/endpoints/{ENDPOINT_ID}" )
```

您可以在 Cloud 控制台的「端點」部分找到 endpoint_id 。

Vertex AI

Dashboard

Datasets

Features

Labelling tasks

Workbench

Pipelines

Training

Experiments

Models

Endpoints

Endpoints

+ CREATE ENDPOINT

Endpoints are machine learning models made available for online prediction r
Endpoints are useful for timely predictions from many users (for example, in r
an application request). You can also request batch predictions if you don't ne
immediate results.

To create an endpoint, you need at least one machine-learning model.[Learn m](#)


Region
us-central1 (Iowa)

Filter

Enter a property name

☐	Name	ID	Status
☐	flower-model-endpoint	6180882625310228480	Active
☐	flower-model-endpoint	5637072970305241088	Active
☐	weeds-model-	5276433156394713088	Ready

您可以在控制台首頁找到專案編號。請注意，這與專案 ID 不同。



以下程式碼會使用 PIL 開啟圖片並調整大小。

```
IMAGE_PATH = "test-image.jpg"
im = Image.open(IMAGE_PATH)
```

接著，將 NumPy 資料轉換為 float32 型別，並轉換為清單。我們轉換為清單，是因為 NumPy 資料無法進行 JSON 序列化，因此無法在要求主體中傳送。

```
x_test = np.asarray(im).astype(np.float32).tolist()
```

最後，呼叫 `endpoint.predict`。

```
endpoint.predict(instances=x_test).predictions
```

您會得到模型的輸出結果，也就是含有 5 個單位的 Softmax 層。如要編寫自訂邏輯來傳回字串標籤，而非索引，可以使用 [自訂預測處理常式](#)。

批次預測

您可以透過不同方式 [設定批次預測資料格式](#)。為求簡單，我們會將 NumPy 資料傾印至 JSON 檔案，並將該檔案儲存至 Cloud Storage。

```
with open('test-data.json', 'w') as fp:
    json.dump(x_test, fp)

!gsutil cp test-data.json gs://{YOUR_BUCKET}
```

接著定義模型。這與定義端點類似，但您需要提供 `MODEL_ID`，而不是 `ENDPOINT_ID`。

```
my_model=aiplatform.Model("projects/{PROJECT_NUMBER}/locations/us-central1/models/{MODEL_ID}")
```


如要查看模型 ID，請在控制台的「模型」部分選取模型名稱和版本，然後選取「版本詳細資料」。

Vertex AI

Dashboard

Datasets

Features

Labelling tasks

Workbench

Pipelines

Training

Experiments

Models

Endpoints

flower-model > Version 1

EXPORT

DEPLOY AND TEST

BATCH PREDICT

VERSION DETAILS

This model was imported on 28 Jun 2022, 18:52:03.

Model ID	7176780675331129344
Created	28 Jun 2022, 18:52:03
Region	us-central1
Encryption type	Google-managed key
Dataset	No managed dataset
Objective	Custom
Source	Custom training
Container image	us-docker.pkg.dev/vertex-ai/prediction/tf2-cpu.2-8:latest

最後，使用 SDK 呼叫批次預測工作，傳遞儲存 JSON 檔案的 Cloud Storage 路徑，並提供儲存預測結果的 Cloud Storage 位置。

```
batch_prediction_job = my_model.batch_predict(
    job_display_name='flower_batch_predict',
    gcs_source='gs://{YOUR_BUCKET}/test-data.json',
    gcs_destination_prefix='gs://{YOUR_BUCKET}/prediction-results',
    machine_type='n1-standard-4',)
```

您可以在主控台的「批次預測」專區追蹤工作進度。請注意，為單一圖片執行批次預測工作效率不彰。

Features

Labelling tasks

Workbench

Pipelines

Training

Experiments

Models

Endpoints

Batch predictions

Metadata

specified location. Use batch prediction when you don't require an immediate response and want to process accumulated data with a single request.[Learn more](#)

Region
us-central1 (Iowa)

Filter

Enter a property name

Name	Status	Model	Objective
flower_batch_predict	✓ Finished	flowers (Version 1)	Custom

後續步驟

在本例中，我們在發出預測呼叫前，先將測試圖片轉換為 NumPy。在更實際的應用情境中，您可能想直接傳送圖片，而不必先載入 NumPy。如要這麼做，您需要調整 TensorFlow 服務函式，解碼圖片位元組。這需要多花一點時間，但對於大型圖片和應用程式建構來說，效率會高出許多。如需範例，請參閱[這個筆記本](#)。

🎉 恭喜！ 🎉

您已瞭解如何使用 Vertex AI 執行下列作業：

- 將模型上傳至 Vertex AI Model Registry
- 取得批次和線上預測結果

如要進一步瞭解 Vertex 的其他部分，請參閱[說明文件](#)。

步驟 7 · 約 1 分鐘

7. 清除所用資源

如果沒有使用模型的打算，建議從端點取消部署模型。您也可以完全刪除端點。如有需要，您隨時可以將模型重新部署至端點。

Region
us-central1

Logs
[View logs](#)

Model Monitoring
Disabled

☐	Model	Status	Most recent alerts	Monitoring	Traffic split	Compute nodes	Type	Created	
☐	flowers (Version 1)	Ready	—	Disabled	100%	Auto (1 minimum, 1 maximum)	Custom trained	29 Jun 2022,	

[DEPLOY ANOTHER MODEL](#)

Undeploy model from endpoint

Workbench 管理的筆記本會在閒置 180 分鐘後自動逾時，因此您不必擔心執行個體會關閉。如要手動關閉執行個體，請按一下控制台 Vertex AI Workbench 專區的「停止」按鈕。如要徹底刪除筆記本，請按一下「刪除」按鈕。

Managed notebooks

[+ NEW NOTEBOOK](#)

[REFRESH](#)

[▶ START](#)

[■ STOP](#)

[⏻ RESET](#)

[🗑 DELETE](#)

[MANAGED NOTEBOOKS](#) [PREVIEW](#)

[USER-MANAGED NOTEBOOKS](#)

[EXECUTIONS](#) [PREVIEW](#)

[SCHEDULES](#) [PREVIEW](#)

[SCHEDULED RUNS](#)

如要刪除 Storage Bucket，請使用 Cloud 控制台中的導覽選單瀏覽至 Storage，選取 bucket，然後按一下「Delete」：

Storage browser

[+ CREATE BUCKET](#)

[🗑 DELETE](#)

[REFRESH](#)

Filter buckets

	Name	Created
☒	bucket_of_fun	Sep 16, 2020, 11:16:30 AM