

運用 BigQuery SQL 和 Vertex AI 取得生成式洞察資料

來源：<https://codelabs.developers.google.com/generative-insights-sqlonly?hl=zh-tw>

步驟數：12

使用 BigQuery SQL 查詢和 Vertex AI PaLM API，建構電影成功評分預測和處方藥應用程式。

目錄

1. [1. 簡介](#)
2. [2. 需求條件](#)
3. [3. 正在準備資料](#)
4. [4. 資料到機器學習](#)
5. [5. 使用模型預測電影評分](#)
6. [6. 提供給生成式 AI 的資料](#)
7. [7. 建立外部連線](#)
8. [8. 建立遠端機器學習模型](#)
9. [9. 使用機器學習模型生成文字](#)
10. [10. 將查詢結果攤平](#)
11. [11. 清除所用資源](#)
12. [12. 恭喜](#)

步驟 1 · 約 0 分鐘

1. 簡介

在本程式碼實驗室中，我們將使用 BigQuery SQL 查詢和 Vertex AI PaLM API，建構電影成功率預測與建議應用程式。用於執行文字生成的模型為 [text-bison](#)，並以 BigQuery 中的遠端函式形式代管。

使用的服務包括：

1. BigQuery ML
2. Vertex AI PaLM API
3. Cloud Shell

建構項目

您將建立

- 包含模型的 BigQuery 資料集
 - BigQuery ML 模型，根據電影的 GENRE 和 RUNTIME 屬性預測電影的成功分數
 - BigQuery 模型，將 Vertex AI PaLM API 做為遠端函式代管
 - 外部連線，用於建立 BigQuery 和 Vertex AI 之間的連線
-

步驟 2 · 約 0 分鐘


2. 需求條件

- [Chrome](#) 或 [Firefox](#) 瀏覽器
- 已啟用計費功能的 Google Cloud 雲端專案

事前準備

1. 在 [Google Cloud 控制台](#) 的專案選取器頁面中，選取或建立 Google Cloud [專案](#)
2. 確認 Cloud 專案已啟用計費功能。瞭解如何[檢查專案是否已啟用計費功能](#)
3. 確認所有必要 API (BigQuery API、Vertex AI API、BigQuery Connection API) 均已[啟用](#)
4. 您將使用 [Cloud Shell](#)，這是 Google Cloud 中執行的指令列環境，已預先載入 **bq**。如需 gcloud 指令和用法，請參閱 [說明文件](#)

在 Cloud 控制台，按一下右上角的「啟用 Cloud Shell」：



如果未設定專案，請使用下列指令來設定：

〇〇〇〇

```
gcloud config set project <YOUR_PROJECT_ID>
```

5. 在瀏覽器中輸入下列網址，直接前往 [BigQuery](#) 控制台：<https://console.cloud.google.com/bigquery>
-

3. 正在準備資料

在本例中，我們將使用從 [movielens](#) 來源衍生的電影資料集。

1. 建立資料集：

[BigQuery 資料集](#) 是資料表的集合，資料集中的所有資料表都儲存在同一個資料位置。您也可以附加自訂存取權控管，限制資料集及其資料表的存取權。

在 Cloud Shell 中，使用 `bq mk` 指令建立名為「movie_insights」的資料集

```
bq mk --location=us-central1 movie_insights
```

2. 將原始碼檔案複製到 Cloud Shell 電腦：

```
git clone https://github.com/AbiramiSukumaran/movie_score_genai_insights
```

3. 前往 Cloud Shell 機器中建立的新專案目錄：

```
cd movie_score_genai_insights
```

4. 使用 `bq load` 指令將 CSV 檔案載入 BigQuery 資料表 (請注意，您也可以直接從 BigQuery UI 上傳)：

```
bq load --source_format=CSV --skip_leading_rows=1 movie_insights.movie_score \  
./movies_data.csv \  
Id:numeric,name:string,rating:string,genre:string,year:numeric,released:string,score:string,d  
irector:string,writer:string,star:string,country:string,budget:numeric,company:string,runtime  
:numeric,data_cat:string
```

5. 您可以查詢樣本，檢查資料集是否已建立 movie_score 資料表和資料：

```
bq query --use_legacy_sql=false \  
SELECT name, rating, genre, runtime FROM movie_insights.movie_score limit 3;
```

步驟 4 · 約 0 分鐘

4. 資料到機器學習

我們來建立分類模型，根據 GENRE 和 RUNTIME 屬性預測電影的成功率。我們會使用 [CREATE MODEL](#) 陳述式搭配「LOGISTIC_REG」選項，建立及訓練邏輯迴歸模型。

在 BigQuery 控制台的「SQL Workspace」查詢編輯器部分，執行下列查詢：

```
CREATE OR REPLACE MODEL
  `movie_insights.model_rating_by_runtime_genre`
OPTIONS
  ( model_type='LOGISTIC_REG',
    auto_class_weights=TRUE,
    data_split_method='NO_SPLIT',
    model_registry='vertex_ai',
    vertex_ai_model_version_aliases=['logistic_reg', 'experimental'],
    input_label_cols=['score']
  ) AS
SELECT name, genre, runtime, score
FROM
  movie_insights.movie_score
WHERE
  data_cat = 'TRAIN';
```

查詢詳細資料：

1. CREATE MODEL 陳述式會使用 SELECT 陳述式中的訓練資料訓練模型。
2. OPTIONS 子句會指定模型類型和訓練選項。這裡的 LOGISTIC_REG 選項會指定邏輯迴歸模型類型。您不需要指定二元邏輯迴歸模型或多元類別邏輯迴歸模型；BigQuery ML 可根據標籤資料欄中不重複值的數量，判斷要使用何者來進行訓練。
3. data_split_method='NO_SPLIT' 會強制 BigQuery ML 根據查詢條件 (data_cat = 'TRAIN') 訓練資料，此外，建議您在此選項中使用「AUTO_SPLIT」，讓框架 (或本例中的服務) 隨機分割訓練/測試資料。
4. input_label_cols 選項會指定 SELECT 陳述式中的哪個資料欄要當做標籤資料欄。這裡的標籤資料欄為「score」，因此模型將根據每個資料列中呈現的其他值，學習「score」的 10 個值中哪一個最有可能。
5. 「auto_class_weights=TRUE」選項會平衡訓練資料中類別標籤的權重。預設情況下，訓練資料並未加權。如果訓練資料中的標籤不平衡，則模型學習到的權重可能不均，導致最熱門的標籤類別預測比例過高。
6. SELECT 陳述式會查詢我們載入 CSV 資料的資料表。WHERE 子句會篩選輸入資料表中的資料列，以便在這個步驟中只選取 TRAIN 資料集。
7. 下列建構函式為選用，因此 BigQuery ML 可以明確將其註冊至 Vertex AI Model Registry。如要進一步瞭解這項功能，請參閱這篇[網誌](#)。model_registry='vertex_ai', vertex_ai_model_version_aliases=['logistic_reg', 'experimental']

建立完成後，BigQuery SQL 工作區的「SCHEMA」部分會顯示以下內容：

model_rating_by_runtime_genre			
DETAILS	TRAINING	EVALUATION	SCHEMA
Labels			
Filter Enter property name or value			
Field name	Type	Mode	Description
predicted_score	STRING	NULLABLE	
Features			
Filter Enter property name or value			
Field name	Type	Mode	Description
name	STRING	NULLABLE	
genre	STRING	NULLABLE	
runtime	NUMERIC	NULLABLE	

建立模型後，請使用 `ML.EVALUATE` 函式評估模型效能。ML.EVALUATE 函式會根據實際資料來評估預測值。

您也可以在「模型」頁面中查看模型的評估指標：

model_rating_by_runtime_genre			
DETAILS	TRAINING	EVALUATION	SCHEMA
Aggregate metrics ⓘ			
Threshold ⓘ	0.0000		
Precision ⓘ	0.9748		
Recall ⓘ	0.9895		
Accuracy ⓘ	0.9864		
F1 score ⓘ	0.9820		
Log loss ⓘ	0.0758		
ROC AUC ⓘ	0.9943		

主要指標一覽：

精確度：實際正確的正面識別比例是多少？精確度 = 真陽性 / (真陽性 + 偽陽性) 召回率 - 實際正類中，有多少比例正確識別？召回率 = 真陽性 / (真陽性 + 偽陰性) 準確率 - 用於評估分類模型的指標，是模型實際預測正確的比例。準確率 = 正確預測數 / 預測總數

5. 使用模型預測電影評分

預測時間到啦！以下查詢會預測資料集中歸類為「TEST」資料的每部電影分數。

在 BigQuery 控制台的「SQL Workspace」查詢編輯器部分，執行下列查詢：

```
SELECT
  *
FROM
  ML.PREDICT (MODEL movie_insights.model_rating_by_runtime_genre,
    (
      SELECT
        *
      FROM
        movie_insights.movie_score
      WHERE
        data_cat= 'TEST'
    )
  );
```

結果如下所示：

Row	predicted_score	predicted_score_prob...label	predict... prob	Id	name	rating
1	6	6	0.395299032363...	7640	El Coyote	R
		7	0.228922125525...			
		5	0.140799898225...			
		4	0.061646326487...			
		8	0.060654464528...			
		3	0.040029967018...			
		2	0.037857531899...			
		9	0.034790653949...			
2	6	6	0.341537481297...	7658	Black Wall Street Burning	R
		7	0.286722477138...			
		5	0.131730196838...			

模型結果會顯示電影的預測分數，範圍為 1 到 10 分 (分類)。您可能想知道為何每部電影都有好幾列預測結果。這是因為模型已傳回可能的預測標籤，以及每個標籤的出現機率 (依遞減順序排列)。

分析預測結果和模型：

您可以透過預測執行兩項出色的分析步驟，瞭解結果：

- 1. 如要瞭解模型產生這些預測結果的原因，可以使用 [ML.EXPLAIN_PREDICT](#) 函式。
- 2. 如要瞭解哪些特徵最能決定一般收入水平，可以使用 [ML.GLOBAL_EXPLAIN](#) 函式。

如要詳細瞭解這些步驟，請參閱[說明文件](#)。

6. 提供給生成式 AI 的資料

讓我們透過生成式 AI，使用 Vertex AI 的 text-bison (最新) 模型，僅透過 SQL 查詢，向 LLM (大型語言模型) 詢問影響電影評分高於 5 分的因素摘要，藉此提供電影資料集的洞察資料。

1. 我們建立的 movie_score 資料表也會是這個步驟的輸入內容。
 2. 系統會建立外部連線，在 BigQuery ML 和 Vertex 服務之間建立存取權。
 3. BigQuery GENERATE_TEXT 建構函式會用於從 Vertex AI 遠端叫用 PaLM API。
-

7. 建立外部連線

如果尚未啟用 BQ Connection API，請啟用並記下連線設定詳細資料中的服務帳戶 ID：

1. 在 BigQuery Explorer 窗格 (位於 BigQuery 控制台左側) 中，按一下「+新增」按鈕，然後在列出的熱門來源中，按一下「連線至外部資料來源」
2. 選取「BigLake and remote functions」(BigLake 和遠端函式) 做為連線類型，提供「Region」(區域) 做為位置類型，並提供「us-central1 (Iowa)」(us-central1 (愛荷華州)) 做為值，以及「bq_llm_connection」做為連線 ID

External data source

Connection type

BigLake and remote functions (cloud resource)

Connection ID *

bq_llm_connection

Location type ?

☒ Region

Specify a region to colocate your datasets with other Google Cloud services.

☐ Multi-region

Allow BigQuery to select a region within a group to achieve higher quota limits.

Region *

us-central1 (Iowa)

Friendly name

Description

CREATE CONNECTION

CANCEL

3. 連線建立完畢後，請記下連線設定詳細資料中產生的服務帳戶

授予權限

在這個步驟中，我們會將存取 Vertex AI 服務的權限授予服務帳戶：

開啟 IAM，將您在建立外部連線後複製的服務帳戶新增為主體，然後選取「Vertex AI 使用者」角色

Principal ?

bqcx-273845608377-onsu@gcp-sa-bigquery-
condel.iam.gserviceaccount.com

Project

Abi's

Assign Roles

Roles are composed of sets of permissions and determine what the principal can do with this resource. [Learn more](#)

Role

Vertex AI user

Grants access to use all resources in Vertex AI

IAM condition (optional) ?

+ ADD IAM CONDITION

+ ADD ANOTHER ROLE

步驟 8 · 約 0 分鐘

8. 建立遠端機器學習模型

建立遠端模型，代表代管的 Vertex AI 大型語言模型：

```
CREATE OR REPLACE MODEL
  movie_insights.llm_model REMOTE
WITH CONNECTION `us-central1.bq_llm_connection` OPTIONS (remote_service_type =
  'CLOUD_AI_LARGE_LANGUAGE_MODEL_V1');
```

這會在資料集 `movie_insights` 中建立名為 **llm_model** 的模型，並將 Vertex AI 的 `CLOUD_AI_LARGE_LANGUAGE_MODEL_V1` API 做為遠端函式。這項作業需要幾秒鐘才能完成。

9. 使用機器學習模型生成文字

模型建立完成後，即可用來生成、摘要或分類文字。

```
SELECT
  ml_generate_text_result['predictions'][0]['content'] AS generated_text,
  ml_generate_text_result['predictions'][0]['safetyAttributes']
    AS safety_attributes,
  * EXCEPT (ml_generate_text_result)
FROM
  ML.GENERATE_TEXT(
    MODEL `movie_insights.llm_model`,
    (
      SELECT
        CONCAT('FROM THE FOLLOWING TEXT ABOUT MOVIES, WHAT DO YOU THINK ARE THE FACTORS
INFLUENCING A MOVIE SCORE TO BE GREATER THAN 5?: ', movie_data) AS prompt
      FROM (
        SELECT
          REPLACE(String_Agg( CONCAT('A movie named ',name, ' from the country ', country, '
with a censor rating of ',rating, ' and a budget of ', budget, ' produced by ', company, '
with a runtime of about ', runtime, ' and in the genre ', genre, ' starring ', star, ' has
had a success score of ', score, '' ) ), ',', '. ') AS movie_data
        FROM (
          SELECT
            *
          FROM
            `movie_insights.movie_score`
          WHERE
            CAST(SCORE AS INT64) > 5
          LIMIT
            50) ) AS MOVIES
      ),
    STRUCT(
      0.2 AS temperature,
      100 AS max_output_tokens));
```

****說明：**

****ml_generate_text_result**** 是文字生成模型的回應，採用 JSON 格式，包含內容和安全性屬性：a. Content 代表產生的文字結果 b. 安全屬性代表內建內容篩選器，可調整門檻，並在 Vertex AI Palm API 中啟用，避免大型語言模型產生任何非預期或無法預測的回覆。如果回覆違反安全門檻，系統就會封鎖該回覆。

ML.GENERATE_TEXT 是您在 BigQuery 中使用的建構函式，可存取 Vertex AI LLM 來執行文字生成工作

CONCAT 會附加 PROMPT 陳述式和資料庫記錄

movie_insights 是資料集名稱，**movie_score** 則是含有資料的資料表名稱，我們會在提示設計中使用這些資料

溫度參數是提示詞參數，可控制回覆的隨機程度，越低越能確保回覆內容與提示詞相關

Max_output_tokens 是指回覆中的字數

查詢回應如下所示：

Row	generated_text	safety_attributes	ml_generate_text_status	prompt
1	" Based on the given information, the following factors seem to influence a movie score to be greater than 5:\n\n- **Genre**: All	{"blocked":false,"categories":["...]		FROM THE FOLLOWING TEXT ABOUT MOVIES, WHAT DO YOU THINK ARE THE FACTORS INFLUENCING A MOVIE

如您所見，回應是巢狀結構，且未經格式化。

10. 將查詢結果攤平

讓我們將結果攤平，這樣就不必在查詢中明確解碼 JSON：

```
SELECT
  *
FROM
  ML.GENERATE_TEXT( MODEL movie_insights.llm_model,
    (
      SELECT
        CONCAT('FROM THE FOLLOWING TEXT ABOUT MOVIES, WHAT DO YOU THINK ARE THE FACTORS
INFLUENCING A MOVIE SCORE TO BE GREATER THAN 5?: ', movie_data) AS prompt
      FROM (
        SELECT
          REPLACE(String_Agg( CONCAT('A movie named ',name, ' from the country ', country, '
with a censor rating of ',rating, ' and a budget of ', budget, ' produced by ', company, '
with a runtime of about ', runtime, ' and in the genre ', genre, ' starring ', star, ' has
had a success score of ', score, ' ') ), ',','.' ) AS movie_data
        FROM (
          SELECT
            *
          FROM
            `movie_insights.movie_score`
          WHERE
            CAST(SCORE AS INT64) > 5
          LIMIT
            50 ) AS MOVIES),
      STRUCT( 0.2 AS temperature,
        100 AS max_output_tokens,
        TRUE AS flatten_json_output));
```

****說明：**

Flatten_json_output** 代表布林值，如果設為 true，系統會傳回從 JSON 回應中擷取的扁平易懂文字。

查詢回應如下所示：

1	ml_generate_text_llm_result	ml_generate_text_rai_result	rr
	Based on the given information, the following factors seem to influence a movie score to be greater than 5: - **Genre**: All the movies with a success score greater than 5 belong to the crime genre. - **Censor Rating**: All the movies with a success score greater than 5 have a censor rating of R, which suggests that they may contain mature content.		
2	- **Budget**: Most of the movies with a success score greater than 5 have a relatively high budget		
2			

11. 清除所用資源

如要避免系統向您的 Google Cloud 帳戶收取本文所用資源的費用，請前往 Vertex AI 端點頁面，刪除您在機器學習步驟中建立的 Vertex AI 端點。

步驟 12 · 約 0 分鐘

12. 恭喜

恭喜！您已成功建立 BQML 模型，並僅使用 SQL 查詢，透過 Vertex AI API 對電影資料集執行 LLM 基礎分析。如要進一步瞭解可用模型，請參閱 [Vertex AI LLM 產品說明文件](#)。
