

透過 BigQuery Studio 筆記本，運用 Apache Spark 執行無伺服器資料轉換

來源：<https://codelabs.developers.google.com/devsite/codelabs/serverless-data-transformation-spark-bigquery-studio?hl=zh-tw>

步驟數：12

在本程式碼研究室中，您將瞭解如何運用無伺服器 Spark 功能，在 BigQuery Studio Notebook 的統一介面中，對 BigQuery 資料執行資料轉換和分析。使用 BigQuery Studio 筆記本，您就能輕鬆編寫及建構 Spark 應用程式，不必安裝 Spark，也不必設定運算叢集

目錄

1. [簡介](#)
2. [基本設定和需求](#)
3. [事前準備](#)
4. [讀取公開資料集](#)
5. [依裝置瀏覽器匯總資料 \(基本指標\)](#)
6. [分析流量來源並計算收益](#)
7. [地理區域分析](#)
8. [以時間為準的分析](#)
9. [將結果寫入 BigQuery 資料表](#)
10. [協調 BigQuery Studio 筆記本程式碼 \(選用\)](#)
11. [清除](#)
12. [恭喜](#)


1. 簡介

在本程式碼實驗室中，您將瞭解如何在 BigQuery Studio 的熟悉介面中，運用 Apache Spark 的強大功能轉換資料。您將從 BigQuery 讀取資料、使用 PySpark 執行資料清理及轉換，然後將結果寫回新的 BigQuery 資料表，所有作業都可在單一筆記本中完成。

在本程式碼研究室中，您將逐步完成下列步驟：

1. 準備 Google Cloud 專案，並啟用所有必要 API
2. 建立臨時資料夾的 GCS bucket
3. 匯入執行 Apache Spark 時所需的程式庫
4. 使用 BigQuery 連接器初始化 Spark 工作階段
5. 從 BigQuery 公開資料集讀取 Google Analytics 範例資料
6. 依裝置瀏覽器匯總資料轉換資料 (基本指標)
7. 使用流量來源分析和收益計算功能轉換資料
8. 使用地理分析功能轉換資料
9. 將轉換後的資料寫入 BigQuery 資料表

架構總覽



必要條件

- 已啟用計費功能的 Google Cloud Platform (GCP) 專案。
- 在 GCP 專案中啟用 BigQuery API 和 BigQuery Connection API。
- 具備 SQL 和 Python 的基本知識。

課程內容

- 如何使用 BigQuery Studio 筆記本中的 Apache Spark 擷取資料
- 如何使用 BigQuery Studio 筆記本中的 Apache Spark 轉換或匯總資料
- 如何在 BigQuery Studio 筆記本中使用 Apache Spark 轉換或彙整資料後寫入資料


軟硬體需求

- Chrome 網路瀏覽器
 - Gmail 帳戶
 - 已啟用計費功能的 Cloud 專案
-

2. 基本設定和需求

自修實驗室環境設定

1. 登入 [Google Cloud 控制台](#)，然後建立新專案或重複使用現有專案。如果沒有 Gmail 或 Google Workspace 帳戶，請先[建立帳戶](#)。



The screenshot shows the Google Cloud 'Select a project' dialog. At the top, there's a search bar with the text 'Search projects and folders'. To the right of the search bar is a 'NEW PROJECT' button. Below the search bar, the 'Project name' field is filled with 'My Project 13475'. The 'Project ID' field is highlighted with a blue box and contains the text 'inbound-analogy-389614'. Below the 'Project ID' field, there's a note: 'it cannot be changed later. EDIT'. The 'Location' field is empty, and there's a 'BROWSE' button next to it. At the bottom, there's a 'Parent organization or folder' field. The 'CREATE' button is highlighted with a blue box.

- 專案名稱是專案參與者的顯示名稱。這是 Google API 未使用的字元字串。你隨時可以更新。
- 專案 ID 在所有 Google Cloud 專案中不得重複，且設定後即無法變更。Cloud 控制台會自動產生專屬字串，通常您不需要在意該字串為何。在大多數程式碼研究室中，您需要參照專案 ID (通常標示為 `PROJECT_ID`)。如果您不喜歡產生的 ID，可以產生另一個隨機 ID。你也可以嘗試使用自己的名稱，看看是否可用。完成這個步驟後就無法變更，且專案期間會維持不變。
- 請注意，有些 API 會使用第三個值，也就是專案編號。如要進一步瞭解這三種值，請參閱[說明文件](#)。

注意：專案 ID 在全域中是唯一的，選定後就無法再供他人使用。您是該 ID 的唯一使用者。即使專案已刪除，ID 也無法再次使用

注意：如果您使用 Gmail 帳戶，可以將預設位置設為「沒有機構」。如果你使用 Google Workspace 帳戶，請選擇適合貴機構的位置。

2. 接著，您需要在 Cloud 控制台中[啟用帳單](#)，才能使用 Cloud 資源/API。完成這個程式碼研究室的費用不高，甚至可能完全免費。如要關閉資源，避免在本教學課程結束後繼續產生費用，請刪除您建立的資源或專案。Google Cloud 新使用者可參加[價值\\$300 美元的免費試用計畫](#)。
-

步驟 3 · 約 5 分鐘

3. 事前準備

啟用 API

使用 BigQuery Studio 筆記本前，請務必啟用下列 API：

- Compute Engine API
- Dataform API
- Vertex AI API

如要手動啟用，請前往 BigQuery。在編輯器窗格的分頁列中，按一下「+」符號旁的箭頭下拉式選單，將指標懸停在「筆記本」上，然後選取「BigQuery 範本」、「空白筆記本」或「Spark 範本」。

Introducing BigQuery Studio notebooks

BigQuery Studio notebooks are a collaborative, managed notebook environment that allow you execute Python code directly within BigQuery Studio. They are built on Colab Enterprise. To use BigQuery Studio notebooks in your Google Cloud projects you must enable an API. [Learn more](#)

Enable APIs



在「啟用核心功能 API」視窗中，按一下「BigQuery Unified API」中的「啟用」

1 Core feature APIs

i BigQuery Unified API contains a list of APIs needed to edit and save code, use version history, share with IAM for saved queries, Python notebooks, Data canvas, and more. [Learn more](#)

[BigQuery Unified API](#) ?

⊖ Not enabled [Enable](#)

View and enable individual APIs ^

Required APIs

[Dataform API](#) ?

✓ Enabled [Enable](#)

[Vertex AI API](#) ?

⊖ Not enabled [Enable](#)

[Compute Engine API](#) ?

⊖ Not enabled [Enable](#)

Optional APIs ▼

[Next](#)

2 Permissions (optional)

Assign new IAM roles to principals below

3 Additional APIs (optional)


Close

完成後，請啟用並按一下「關閉」。詳情請參閱「[啟用 BigQuery Studio 進行資產管理](#)」一文。

4. 讀取公開資料集

首先，我們會建立暫時使用的 GCS 儲存空間，以便在 BigQuery Studio 筆記本中執行 Spark。

1. 在 Google Cloud 控制台中，前往 BigQuery
2. 在編輯器窗格的分頁列中，按一下「+」符號旁的箭頭下拉式選單，將指標懸停在「筆記本」上，然後選取「空白筆記本」。



3. 按一下程式碼儲存格，然後輸入下列 CLI 指令碼來建立 GCS bucket，接著按一下「執行儲存格」按鈕或按下 *Shift + Enter* 鍵

```
!gsutil mb -p <your_project_id> -c STANDARD -l US gs://ioxiid2025-<your_project_id>
```

根據您在建立 Google Cloud 專案時選取的項目，更新 `<your_project_id>` 的值。將 `<your_project_id>` 的值更新為您的專案 ID，以建立 GCS 的專屬 bucket 名稱。然後點選「執行儲存格」按鈕或按下 *Shift + Enter* 鍵，執行程式碼儲存格

接著，我們會啟動 Spark 工作階段。在本程式碼實驗室中，我們會使用 `SparkSession` 程式庫，但您也可以使用 `DataprocSession`，在 BigQuery Studio 筆記本中運用 Dataproc 功能執行 Spark

1. 按一下程式碼儲存格，然後輸入下列 CLI 指令碼，初始化 Spark 工作階段。按一下「Run cell」(執行儲存格) 按鈕，或按下 *Shift + Enter* 鍵。

```
# Import required libraries
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, sum, count, countDistinct, when, expr, date_format
from pyspark.sql.types import DecimalType

# Initialize Spark session with BigQuery connector
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, sum, count, countDistinct, when, expr, date_format
from pyspark.sql.types import DecimalType

# Initialize Spark session with BigQuery connector
spark = SparkSession.builder \
    .appName("Google Analytics ETL with Apache Spark") \
    .config("spark.jars.packages", "com.google.cloud.spark:spark-bigquery-with- \
dependencies_2.12:0.32.0") \
    .getOrCreate()

spark
```

預期輸出內容：

```
SparkSession - in-memory
SparkContext
Spark UI
Version
v3.5.4
Master
local[*]
AppName
Google Analytics ETL with Apache Spark
```

2. 點選程式碼儲存格，然後輸入下列 CLI 指令碼，設定 GCP 專案和 GCS 暫時值區。

```
# Set GCP project and temporary bucket
project_id = "your-gcp-project-id" # Replace with your GCP project ID
bucket = "your-gcs-bucket" # Replace with your GCS bucket for temporary files
spark.conf.set("temporaryGcsBucket", bucket)
```

Google Analytics 範例資料庫

[Google Analytics 範例資料庫](#)是透過 [Google Cloud 的公開資料集計畫](#)在 BigQuery 上提供。這個資料集提供 12 個月 (2016 年 8 月至 2017 年 8 月) 的 BigQuery 資料，內含來自 [Google 商品網路商店](#) (銷售 Google 品牌商品的真實電子商務商店) 的 Google Analytics 360 資料 (已模糊處理)。如此一來，您就能輕鬆分析業務資料，並瞭解使用 BigQuery 分析 Analytics 360 資料對自己有何益處。[進一步瞭解資料](#)

這些資料是電子商務網站將看到的典型資料，包括以下資訊：

- 流量來源資料：與網站訪客來源相關的資訊，包括自然流量、付費搜尋流量和多媒體廣告流量的資料
- 內容資料：與使用者在網站上的行為相關的資訊，例如訪客瀏覽的網頁網址、訪客與內容互動的方式等。
- 交易資料：在 Google 商品網路商店網站交易的相關資訊。

執行下列程式碼，在 Apache Spark 中顯示前 5 筆資料範例

```
# EXTRACT: Read data from BigQuery
print("Extracting data from BigQuery...")
ga_df = spark.read.format("bigquery") \
    .option("table", "bigquery-public-data.google_analytics_sample.ga_sessions_20170801") \
    .load()

# Show schema sample data
print("Sample data:")
ga_df.show(5, truncate=False)
```

預期的輸出內容：

Sample data:

visitorId	visitNumber	visitId	visitStartTime	date	totals
trafficSource					
device					
geoNetwork					
customDimensions		hits			
fullVisitorId	userId	clientId	channelGrouping	socialEngagementType	

```

-----+-----+-----+-----+-----+
-----+-----+
|NULL      |1          |1501591568|1501591568    |20170801|{1, 1, 1, NULL, 1, NULL,
NULL, 1, NULL, NULL, NULL, NULL, 1}   |{NULL, (not set), (direct), (none), NULL,
NULL, {NULL, NULL, NULL, NULL, NULL, NULL, not available in demo dataset, NULL, NULL,
NULL, NULL, NULL}}, NULL, NULL}      |{Chrome, not available in
demo dataset, not available in demo dataset, Windows, not available in demo dataset,
false, not available in demo dataset, not available in demo dataset, not available in
demo dataset, not available in demo dataset, not available in demo dataset, not
available in demo dataset, NULL, not available in demo dataset, not available in demo
dataset, not available in demo dataset, desktop} |{Europe, Southern Europe, Greece,
not available in demo dataset, not available in demo dataset, not available in demo
dataset, not available in demo dataset, tellas.gr, not available in demo dataset, not
available in demo dataset, not available in demo dataset}      |[]
|[1, 0, 5, 46, NULL, true, true, true, https://www.google.gr/,
{/google+redesign/bags/google+zipper+front+sports+bag.axd,
shop.googlemerchandisestore.com, Page Unavailable, NULL, NULL, /google+redesign/,
/bags/, /google+zipper+front+sports+bag.axd, }, NULL, NULL, NULL, {NULL, NULL, NULL,
NULL, NULL, NULL, NULL, NULL,
shop.googlemerchandisestore.com/google+redesign/bags/google+zipper+front+sports+bag.a
xd,
shop.googlemerchandisestore.com/google+redesign/bags/google+zipper+front+sports+bag.a
xd,
shop.googlemerchandisestore.com/google+redesign/bags/google+zipper+front+sports+bag.a
xd, 0}, {NULL, true, NULL, NULL}, NULL, [], [], NULL, NULL, {0, 1, NULL}, [], NULL,
[], [], [], PAGE, {NULL, NULL, NULL, NULL, (not set), NULL, No, : }, NULL, NULL,
{(not set), Bags, (not set), (not set), (not set), (entrance), (entrance),
(entrance), (entrance), (entrance), NULL, 1, NULL, NULL, NULL}, web, []}]
|3418334011779872055|NULL |NULL |Organic Search |Not Socially Engaged|
|NULL      |2          |1501589647|1501589647    |20170801|{1, 1, 1, NULL, 1, NULL,
NULL, NULL, NULL, NULL, NULL, NULL, 1}|{/analytics/web/, (not set),
analytics.google.com, referral, NULL, NULL, {NULL, NULL, NULL, NULL, NULL, NULL, not
available in demo dataset, NULL, NULL, NULL, NULL, NULL}, NULL, NULL}|{Chrome, not
available in demo dataset, not available in demo dataset, Windows, not available in
demo dataset, false, not available in demo dataset, not available in demo dataset,
not available in demo dataset, not available in demo dataset, not available in demo
dataset, not available in demo dataset, NULL, not available in demo dataset, not
available in demo dataset, not available in demo dataset, desktop} |{Asia, Southern
Asia, India, Maharashtra, (not set), Mumbai, not available in demo dataset,
unknown.unknown, not available in demo dataset, not available in demo dataset, not
available in demo dataset}
|[4, APAC]      |[1, 0, 5, 14, NULL, true, true, true,

```

https://analytics.google.com/analytics/web/, {/google+redesign/shop+by+brand/youtube, shop.googlemerchandisestore.com, Page Unavailable, NULL, NULL, /google+redesign/, /shop+by+brand/, /youtube, }, NULL, NULL, NULL, {NULL, NULL, NULL, NULL, NULL, NULL, NULL, NULL, shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, 0}, {NULL, true, NULL, NULL}, NULL, [], [], NULL, NULL, {0, 1, NULL}, [], NULL, [], [], [], PAGE, {NULL, NULL, NULL, NULL, (not set), NULL, No, : }, NULL, NULL, {(not set), Brands, (not set), (not set), (not set), (entrance), (entrance), (entrance), (entrance), (entrance), NULL, 1, NULL, NULL, NULL}, web, []}]

2474397855041322408	NULL	NULL	Referral	Not Socially Engaged
NULL	1	1501616621	1501616621	20170801 {1, 1, 1, NULL, 1, NULL, NULL, 1, NULL, NULL, NULL, NULL, 1}

{/analytics/web/, (not set), analytics.google.com, referral, NULL, NULL, {NULL, NULL, NULL, NULL, NULL, NULL, not available in demo dataset, NULL, NULL, NULL, NULL, NULL}, NULL, NULL}|{Chrome, not available in demo dataset, not available in demo dataset, Windows, not available in demo dataset, false, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, desktop}|{Europe, Northern Europe, United Kingdom, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, as9105.com, not available in demo dataset, not available in demo dataset, not available in demo dataset}|[{4, EMEA}]|[{1, 0, 12, 43, NULL, true, true, true, https://analytics.google.com/analytics/web/?utm_source=demoaccount&utm_medium=demoaccount&utm_campaign=demoaccount, {/google+redesign/shop+by+brand/youtube, shop.googlemerchandisestore.com, Page Unavailable, NULL, NULL, /google+redesign/, /shop+by+brand/, /youtube, }, NULL, NULL, NULL, {NULL, NULL, NULL, NULL, NULL, NULL, NULL, NULL, shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, 0}, {NULL, true, NULL, NULL}, NULL, [], [], NULL, NULL, {0, 1, NULL}, [], NULL, [], [], [], PAGE, {NULL, NULL, NULL, NULL, (not set), NULL, No, : }, NULL, NULL, {(not set), Brands, (not set), (not set), (not set), (entrance), (entrance), (entrance), (entrance), (entrance), NULL, 1, NULL, NULL, NULL}, web, []}]

5870462820713110108	NULL	NULL	Referral	Not Socially Engaged
NULL	1	1501601200	1501601200	20170801 {1, 1, 1, NULL, 1, NULL, NULL, 1, NULL, NULL, NULL, NULL, 1}

{/analytics/web/, (not set), analytics.google.com, referral, NULL, NULL, {NULL, NULL, NULL, NULL, NULL, NULL, not available in demo dataset, NULL, NULL, NULL, NULL, NULL}, NULL, NULL}|{Firefox, not available in demo dataset, not available in demo dataset, Windows, not available in demo dataset, false, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, not available in demo dataset, desktop}|{Americas, Northern America, United States, Texas, Dallas-Ft. Worth TX, Dallas, not available in demo dataset, h5colo.com, not available in demo dataset, not available in demo

```
dataset, not available in demo dataset}
|[{4, North America}]|[{1, 0, 8, 26, NULL, true, true, true,
https://analytics.google.com/analytics/web/, {google+redesign/shop+by+brand/youtube,
shop.googlemerchandisestore.com, Page Unavailable, NULL, NULL, /google+redesign/,
/shop+by+brand/, /youtube, }, NULL, NULL, NULL, {NULL, NULL, NULL, NULL, NULL, NULL,
NULL, NULL, shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube,
shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube,
shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, 0}, {NULL,
true, NULL, NULL}, NULL, [], [], NULL, NULL, {0, 1, NULL}, [], NULL, [], [], [],
PAGE, {NULL, NULL, NULL, NULL, (not set), NULL, No, : }, NULL, NULL, {(not set),
Brands, (not set), (not set), (not set), (entrance), (entrance), (entrance)},
(entrance), (entrance), NULL, 1, NULL, NULL, NULL}, web, []]}
|9397809171349480379|NULL |NULL |Referral |Not Socially Engaged|
|NULL |1 |1501615525|1501615525 |20170801|{1, 1, 1, NULL, 1, NULL,
NULL, 1, NULL, NULL, NULL, NULL, 1} |{/analytics/web/, (not set),
adwords.google.com, referral, NULL, NULL, {NULL, NULL, NULL, NULL, NULL, NULL, not
available in demo dataset, NULL, NULL, NULL, NULL, NULL}, NULL, NULL} |{Chrome, not
available in demo dataset, not available in demo dataset, Windows, not available in
demo dataset, false, not available in demo dataset, not available in demo dataset,
not available in demo dataset, not available in demo dataset, not available in demo
dataset, not available in demo dataset, NULL, not available in demo dataset, not
available in demo dataset, not available in demo dataset, desktop} |{Americas,
Northern America, United States, not available in demo dataset, not available in demo
dataset, not available in demo dataset, not available in demo dataset, (not set), not
available in demo dataset, not available in demo dataset, not available in demo
dataset}|[4, North America]|[1, 0, 12, 25, NULL, true, true, true,
https://adwords.google.com/analytics/web/?__o=cues&authuser=0,
/googletagmanager/js/gtm.js?gtag=js&id=G-ANALYTICS, shop.googlemerchandisestore.com, Page
Unavailable, NULL, NULL, /googletagmanager/js/gtm.js?gtag=js&id=G-ANALYTICS, /shop+by+brand/, /youtube, }, NULL, NULL,
NULL, {NULL, NULL, NULL, NULL, NULL, NULL, NULL, NULL, NULL,
shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube,
shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube,
shop.googlemerchandisestore.com/google+redesign/shop+by+brand/youtube, 0}, {NULL,
true, NULL, NULL}, NULL, [], [], NULL, NULL, {0, 1, NULL}, [], NULL, [], [], [],
PAGE, {NULL, NULL, NULL, NULL, (not set), NULL, No, : }, NULL, NULL, {(not set),
Brands, (not set), (not set), (not set), (entrance), (entrance), (entrance),
(entrance), (entrance), NULL, 1, NULL, NULL, NULL}, web, []]}
|6089902943184578335|NULL |NULL |Referral |Not Socially Engaged|
```

[illegible]

only showing top 5 rows

5. 依裝置瀏覽器匯總資料 (基本指標)

這段程式碼會依裝置瀏覽器匯總 Google Analytics 資料，計算各種指標 (例如工作階段總數、造訪次數、點擊次數、網頁瀏覽次數、跳出次數、網站停留時間、不重複訪客和每次造訪的平均時間)，然後重新命名資料欄並排序結果。

```
print("Transformation 1: Aggregating by device browser...")
device_agg = ga_df.groupBy("device.browser") \
    .agg(
        count("*").alias("total_sessions"),
        sum("totals.visits").alias("total_visits"),
        sum("totals.hits").alias("total_hits"),
        sum("totals.pageviews").alias("total_pageviews"),
        sum("totals.bounces").alias("total_bounces"),
        sum("totals.timeOnSite").alias("total_time_on_site"),
        countDistinct("fullVisitorId").alias("unique_visitors"),
        (sum("totals.timeOnSite")/sum("totals.visits")).alias("avg_time_per_visit")
    ) \
    .withColumnRenamed("browser", "device_browser") \
    .orderBy("total_sessions", ascending=False)

# Show sample transformed data
print("\nDevice Aggregation Sample:")
device_agg.show(5)
```

預期的輸出內容：

Transformation 1: Aggregating by device browser...

Device Aggregation Sample:

device_browser	total_sessions	total_visits	total_hits	total_pageviews	total_bounces	total_time_on_site
unique_visitors	avg_time_per_visit					
Chrome	1900	1900	10896	8956	870	354691
Safari	397	397	1260	1137	218	43150
Firefox	101	101	390	343	59	10659
Internet Explorer	54	54	107	102	36	5589
Edge	23	23	63	55	12	2623

only showing top 5 rows

6. 分析流量來源並計算收益

這段程式碼會依流量來源和媒介分析 Google Analytics 資料，計算工作階段數、交易次數、總收益、單次工作階段收益和不重複訪客等指標，然後重新命名資料欄，並依總收益排序結果。

```
print("Transformation 2: Analyzing traffic sources...")
traffic_source_agg = ga_df.groupBy("trafficSource.source", "trafficSource.medium") \
    .agg(
        count("*").alias("session_count"),
        sum(when(col("totals.transactions").isNotNull(),
1).otherwise(0)).alias("transactions"),
        sum("totals.totalTransactionRevenue").cast(DecimalType(20,2)).alias("total_revenue"),

        (sum("totals.totalTransactionRevenue")/count("*")).cast(DecimalType(10,2)).alias("revenue_per_session"),
        countDistinct("fullVisitorId").alias("unique_visitors")
    ) \
    .withColumnRenamed("source", "traffic_source") \
    .withColumnRenamed("medium", "traffic_medium") \
    .orderBy("total_revenue", ascending=False)

print("\nTraffic Source Aggregation Sample:")
traffic_source_agg.show(5)
```

預期的輸出內容：

Transformation 2: Analyzing traffic sources...

Traffic Source Aggregation Sample:

traffic_source	traffic_medium	session_count	transactions	total_revenue	revenue_per_session	unique_visitors
(direct)	(none)	2166	42	8872040000.00		
mail.google.com	referral	2	1	17960000.00		
google.com.tw	referral	1	0	NULL		
analytics.google.com	referral	57	0	NULL		
quora.com	referral	6	0	NULL		

only showing top 5 rows

7. 地理區域分析

這段程式碼會依國家/地區對 Google Analytics 資料執行地理分析，計算工作階段數、網頁瀏覽總次數、網站停留總時間、平均單次工作階段時間和不重複訪客，然後重新命名資料欄並依工作階段數排序。

```
print("Transformation 3: Geographic analysis...")
geo_agg = ga_df.groupBy("geoNetwork.country", "geoNetwork.region") \
    .agg(
        count("*").alias("session_count"),
        sum("totals.pageviews").alias("total_pageviews"),
        sum("totals.timeOnSite").alias("total_time_on_site"),
        (sum("totals.timeOnSite")/count("*")).alias("avg_time_per_session"),
        countDistinct("fullVisitorId").alias("unique_visitors")
    ) \
    .withColumnRenamed("country", "country") \
    .withColumnRenamed("region", "region") \
    .orderBy("session_count", ascending=False)

print("\nGeographic Aggregation Sample:")
geo_agg.show(5)
```

預期的輸出內容：

Transformation 3: Geographic analysis...

Geographic Aggregation Sample:

+-----+-----+-----+-----+-----+					
+-----+-----+					
country					
region	session_count	total_pageviews	total_time_on_site	avg_time_per_session	unique_visitors
+-----+-----+-----+-----+-----+					
+-----+-----+					
United States	not available in ...	564	2326		
97829	173.45567375886526	494			
United States	California	420	3102		
116563	277.5309523809524	347			
United States	New York	109	845		
39976	366.7522935779817	84			
United Kingdom	not available in ...	82	161		
7791	95.01219512195122	79			
India	not available in ...	62	139		
2869	46.274193548387096	61			
+-----+-----+-----+-----+-----+					
+-----+-----+					
only showing top 5 rows					

8. 以時間為準的分析

這段程式碼會從 `visitStartTime` 欄位擷取小時，然後依小時分組資料，計算每個小時的工作階段數、交易次數、總收益和總網頁瀏覽量，最後依小時排序結果，執行時間分析。

```
print("Transformation 4: Time-based analysis...")
hourly_agg = ga_df.withColumn("hour", date_format(col("visitStartTime").cast("timestamp"),
"H")) \
    .groupBy("hour") \
    .agg(
        count("*").alias("session_count"),
        sum("totals.transactions").alias("transactions"),
        sum("totals.totalTransactionRevenue").cast(DecimalType(20,2)).alias("total_revenue"),
        sum("totals.pageviews").alias("total_pageviews")
    ) \
    .orderBy("hour")

print("\nHourly Aggregation Sample:")
hourly_agg.show(5)
```

預期輸出內容：

```
Transformation 4: Time-based analysis...

Hourly Aggregation Sample:
+----+-----+-----+-----+-----+
|hour|session_count|transactions|total_revenue|total_pageviews|
+----+-----+-----+-----+-----+
|  0 |          87 |         NULL |         NULL |          372 |
|  1 |         102 |         NULL |         NULL |          494 |
| 10 |          67 |         NULL |         NULL |          149 |
| 11 |          73 |         NULL |         NULL |          167 |
| 12 |          99 |         NULL |         NULL |          313 |
+----+-----+-----+-----+-----+
only showing top 5 rows
```

9. 將結果寫入 BigQuery 資料表

這段程式碼會使用直接寫入方法，將四個匯總資料架構 (`device_agg` 、 `traffic_source_agg` 、 `geo_agg` 和 `hourly_agg`) 匯出至 Google BigQuery 中的個別資料表，並覆寫現有資料表 (如有)。

```
# Write to BigQuery tables
print("\nLoading data to BigQuery...")

# Set output tables
device_output_table = f"{project_id}.analytics_sample.device_aggregation"
traffic_output_table = f"{project_id}.analytics_sample.traffic_source_aggregation"
geo_output_table = f"{project_id}.analytics_sample.geo_aggregation"
hourly_output_table = f"{project_id}.analytics_sample.hourly_aggregation"

dataset_id = "demo" # Replace with your BigQuery dataset ID

# Set BigQuery output table
device_output_table = f"{project_id}.{dataset_id}.device_aggregation"
traffic_output_table = f"{project_id}.{dataset_id}.traffic_source_aggregation"
geo_output_table = f"{project_id}.{dataset_id}.geo_aggregation"
hourly_output_table = f"{project_id}.{dataset_id}.hourly_aggregation"

# Write each DataFrame to BigQuery
device_agg.write \
    .format("bigquery") \
    .option("table", device_output_table) \
    .option("writeMethod", "direct") \
    .mode("overwrite") \
    .save()

traffic_source_agg.write \
    .format("bigquery") \
    .option("table", traffic_output_table) \
    .option("writeMethod", "direct") \
    .mode("overwrite") \
    .save()

geo_agg.write \
    .format("bigquery") \
    .option("table", geo_output_table) \
    .option("writeMethod", "direct") \
    .mode("overwrite") \
    .save()

hourly_agg.write \
    .format("bigquery") \
    .option("table", hourly_output_table) \
    .option("writeMethod", "direct") \
    .mode("overwrite") \
    .save()
```

在 BigQuery 中檢查輸出資料表，確認資料在轉換後已成功儲存

demo

device_aggregation

geo_aggregation

hourly_aggregation

traffic_source_aggregation

translate

☆

⋮

☆

⋮

☆

⋮

☆

⋮

☆

⋮

device_aggregation 表格

device_aggregation

Query

Open in

Share

Copy

Snapshot

Delete

Export

Schema	Details	Preview	Table Explorer	Preview	Insights	Lineage	Data Profile	Data Quality	
Row	device_browser	total_sessions	total_visits	total_hits	total_pagevie...	total_bounces	total_time_o...	unique_visitors	avg_time_per...
1	Mozilla Compatible Agent	1	1	1	1	1	null	1	null
2	Android Browser	2	2	3	3	1	36	2	18.0
3	Nokia Browser	2	2	3	3	1	177	2	88.5
4	Coc Coc	2	2	2	2	2	null	2	null
5	YaBrowser	2	2	6	6	null	386	2	193.0
6	UC Browser	6	6	22	14	4	210	6	35.0
7	Safari (in-app)	10	10	33	29	4	1448	8	144.8
8	Opera	16	16	55	49	6	3531	11	220.6875
9	Android Webview	19	19	363	211	8	2454	17	129.1578947...
10	Opera Mini	21	21	29	28	16	864	21	41.14285714...
11	Edge	23	23	63	55	12	2623	23	114.0434782...
12	Internet Explorer	54	54	107	102	36	5589	50	103.5
13	Firefox	101	101	390	343	59	10659	95	105.5346534...
14	Safari	397	397	1260	1137	218	43150	364	108.6901763...
15	Chrome	1900	1900	10896	8956	870	354691	1689	186.6794736...

地理區域匯總資料表

Schema	Details	Preview	Table Explorer	Preview	Insights	Lineage	Data Profile	Data Quality
Row	country	region	session_count	total_pagevie...	total_time_o...	avg_time_per...	unique_visitors	
1	Singapore	Jakarta	1	7	269	269.0	1	
2	Trinidad & Tobago	not available in demo dataset	1	2	13	13.0	1	
3	Ethiopia	(not set)	1	2	null	null	1	
4	Iceland	not available in demo dataset	1	9	1221	1221.0	1	
5	Kosovo	(not set)	1	1	null	null	1	
6	Hong Kong	not available in demo dataset	1	1	null	null	1	
7	Georgia	not available in demo dataset	1	1	null	null	1	
8	Panama	not available in demo dataset	1	1	null	null	1	
9	Martinique	not available in demo dataset	1	1	null	null	1	
10	Iraq	not available in demo dataset	1	15	493	493.0	1	
11	St. Lucia	(not set)	1	1	null	null	1	
12	Indonesia	(not set)	1	1	null	null	1	
13	Ethiopia	not available in demo dataset	1	2	41	41.0	1	
14	Moldova	not available in demo dataset	1	1	null	null	1	
15	Kazakhstan	not available in demo dataset	1	1	null	null	1	
16	Lebanon	not available in demo dataset	1	5	113	113.0	1	
17	United States	Taipei City	1	1	null	null	1	
18	Malaysia	(not set)	1	1	null	null	1	
19	Tanzania	not available in demo dataset	1	1	null	null	1	
20	Oman	not available in demo dataset	1	2	103	103.0	1	
21	Guinea	not available in demo dataset	1	1	null	null	1	
22	Azerbaijan	not available in demo dataset	1	1	null	null	1	
23	Bahrain	not available in demo dataset	1	1	null	null	1	
24	Guatemala	not available in demo dataset	1	1	null	null	1	
25	Jordan	not available in demo dataset	1	1	null	null	1	
26	Bosnia & Herzegovina	not available in demo dataset	1	2	36	36.0	1	
27	Taiwan	California	2	11	989	494.5	1	
28	Qatar	not available in demo dataset	2	2	null	null	1	
29	Puerto Rico	not available in demo dataset	2	4	42	21.0	1	
30	Colombia	not available in demo dataset	2	12	467	233.5	2	

Results per page: 501 – 50 of 142

hourly_aggregation 資料表

Schema		Details	Preview	Table Explorer	Preview	Insights	Lineage
Row	hour	session_count	transactions	total_revenue	total_pagevie...		
1	1	102	null	null	494		
2	8	69	null	null	179		
3	10	67	null	null	149		
4	0	87	null	null	372		
5	3	99	null	null	382		
6	7	96	null	null	372		
7	6	91	null	null	297		
8	12	99	null	null	313		
9	11	73	null	null	167		
10	9	73	null	null	168		
11	23	99	1	238530000	371		
12	5	96	1	34790000	389		
13	13	121	1	17960000	338		
14	4	79	2	157680000	480		
15	15	129	2	386570000	547		
16	2	84	3	228770000	405		
17	19	135	3	255900000	660		
18	18	144	3	88190000	612		
19	20	156	3	117120000	713		
20	14	138	5	202730000	567		
21	16	121	5	1491780000	686		
22	22	121	5	940320000	686		
23	21	130	5	1337580000	859		
24	17	147	6	3392080000	733		

traffic_source_aggregation

Schema	Details	Preview	Table Explorer	Preview	Insights	Lineage	Data Profile	Data Quality
Row	traffic_source	traffic_medium	session_count	transactions	total_revenue	revenue_per_...	unique_visitors	
1	(direct)	(none)	2166	42	8872040000	4096048.01	1943	
2	Partners	affiliate	52	0	null	null	49	
3	dfa	cpm	15	0	null	null	8	
4	bing	organic	1	0	null	null	1	
5	ask	organic	2	0	null	null	2	
6	yahoo	organic	2	0	null	null	2	
7	baidu	organic	5	0	null	null	5	
8	google.com.tw	referral	1	0	null	null	1	
9	docs.google.com	referral	1	0	null	null	1	
10	support.google.com	referral	1	0	null	null	1	
11	sashihara.jp	referral	1	0	null	null	1	
12	ph.search.yahoo.com	referral	1	0	null	null	1	
13	m.baidu.com	referral	1	0	null	null	1	
14	int.search.tb.ask.com	referral	1	0	null	null	1	
15	dealspotr.com	referral	1	0	null	null	1	
16	google.com.vn	referral	1	0	null	null	1	
17	datastudio.google.com	referral	1	0	null	null	1	
18	productforums.google.com	referral	1	0	null	null	1	
19	away.vk.com	referral	1	0	null	null	1	
20	pinterest.com	referral	1	0	null	null	1	
21	lm.facebook.com	referral	2	0	null	null	2	
22	mail.google.com	referral	2	1	17960000	8980000	2	
23	adwords.google.com	referral	2	0	null	null	2	
24	m.facebook.com	referral	5	0	null	null	3	
25	blog.golang.org	referral	3	0	null	null	3	
26	l.facebook.com	referral	3	0	null	null	3	
27	groups.google.com	referral	4	0	null	null	4	
28	reddit.com	referral	4	0	null	null	4	
29	qita.com	referral	5	0	null	null	4	
30	quora.com	referral	6	0	null	null	5	

10. 協調 BigQuery Studio 筆記本程式碼 (選用)

您可以透過下列方式協調 BigQuery Studio 筆記本程式碼：

- 透過 Google Cloud 控制台排定筆記本程式碼 (適用 [筆記本定價](#)) 。
- 以 Dataproc Serverless 批次工作負載的形式執行筆記本程式碼 (適用 [Dataproc Serverless 定價](#)) 。

在本程式碼研究室中，我們將使用 Google Cloud 控制台排定筆記本程式碼。

1. 在「Notebook」(筆記本) 工具列中，按一下「Schedule」(排程)。
2. 在「排定記事本」窗格的「排程名稱」欄位中，輸入排程名稱。
3. 在「Authentication」(驗證) 部分，使用 Google 帳戶使用者憑證或服務帳戶授權筆記本。
4. 如要使用 Google 帳戶使用者憑證 ([預覽](#))，請選取「以我的使用者憑證執行」。
5. 如要使用服務帳戶，請選取「以所選服務帳戶執行」，然後選取服務帳戶。
6. 在「筆記本選項」部分，於「執行階段範本」欄位中，選取 Colab 筆記本執行階段範本或預設執行階段規格。如要瞭解如何建立 Colab 筆記本執行階段範本，請參閱「[建立執行階段範本](#)」。
7. 在「Cloud Storage bucket」欄位中，按一下「Browse」(瀏覽)，然後選取或建立 Cloud Storage bucket。所選服務帳戶必須獲得所選值區的「Storage 管理員 (roles/storage.admin)」IAM 角色。詳情請參閱「[啟用筆記本排程](#)」。
8. 在「排程頻率」部分，執行下列操作：
9. 在「重複」選單中，選取排定筆記本執行的頻率。
10. 在「At time」(時間) 欄位中，輸入排定筆記本執行的時間。
11. 在「時區」選單中，選取時間表的時區。
12. 按一下「建立時間表」。如果驗證方法選取「使用我的使用者憑證執行」，您必須[授權給 Google 帳戶](#) ([預覽](#)) 。

Schedule notebook



Create one-time or recurring notebook execution using BigQuery Studio.

Schedule name *

test

?

Authentication

Preview

Choose one of the options below

- ☒ Execute with user credentials of msaipulr90@gmail.com
- ☐ Execute with selected service account

Notebook options



Runtime template *

Default runtime specifications

▼

Name	Default runtime specifications
Machine type	e2-standard-4
GPU type	—
Data disk type	100 GB Standard Disk (pd-standard)
Idle shutdown	—
Personal credentials	Disabled
Secure boot	Disabled
Network tags	—
Network	—
Subnetwork	—
External IP ?	Enabled
Reservation	—
Encryption type	Google-managed

Notebook will be executed in the us-central1 region.

Cloud storage bucket *

demo-spark-bigquerystudio-msr-123

Browse

Scheduled notebook results will be stored in this bucket.

Schedule frequency

Repeats

Daily

▼

At time *

00.00

Timezone

Coordinated Universal Time (UTC) ▼

Jobs scheduled to run every day at 12:00 AM.

Schedules will execute the deployed version of your Notebook.
Deploy your Notebook after saving it to incorporate the latest

Create schedule

Close

11. 清除

如要避免系統向您的 Google Cloud 帳戶收取本程式碼研究室所用資源的費用，請按照下列步驟操作：

1. 在 Google Cloud 控制台中前往「管理資源」頁面。
 2. 在專案清單中選取要刪除的專案，然後點按「刪除」。
 3. 在對話方塊中輸入專案 ID，然後按一下「Shut down」(關機) 即可刪除專案。
-

12. 恭喜

您已在 BigQuery Studio 筆記本中，運用 Apache Spark 無伺服器功能完成資料轉換和分析作業。您已探索 Google Cloud 的公開資料集，並在 BigQuery Studio 筆記本中，使用 Apache Spark 執行無伺服器 ETL，以及協調 BigQuery Studio 筆記本。太棒了！

後續步驟：

- 使用[服務帳戶](#)協調管理筆記本，以利自動化作業。
- 執行 ETL 工作時，新增監控時間長度的指令碼。
- 部署[筆記本](#)。
- 在 BigQuery Studio 筆記本中，使用 [DataprocSparkSession](#) 搭配 Serverless Dataproc，充分發揮 Apache Spark 的分散式功能。
- 在 BigQuery Studio 中建立 [Apache Spark 適用的預存程序](#)。這樣一來，您就能套用 OOP 原則來建構 PySpark 程式碼，進而提升程式碼的組織性、可重複使用性和可維護性。

參考資料：

- <https://cloud.google.com/bigquery/docs/use-spark>
 - <https://cloud.google.com/bigquery/docs/orchestrate-notebooks#explorer-pane>
 - <https://cloud.google.com/bigquery/docs/spark-procedures>
 - <https://cloud.google.com/bigquery/docs/service-dependencies#manually-enable-code-assets>
 - Gemini
-