

運用 AlloyDB、Vector Search 和 Vertex AI 建構專利搜尋應用程式！

來源：<https://codelabs.developers.google.com/patent-search-alloydb-gemini?hl=zh-tw>

步驟數：10

透過這個程式碼研究室，我們將示範如何搭配使用 Gemini 1.5 Pro、AlloyDB 和 Vertex AI，建構專利搜尋應用程式。

目錄

1. [1. 總覽](#)
2. [2. 事前準備](#)
3. [3. 準備 AlloyDB 資料庫](#)
4. [4. 將專利資料載入資料庫](#)
5. [5. 為專利資料建立嵌入](#)
6. [6. 執行向量搜尋](#)
7. [7. 將應用程式帶到網頁](#)
8. [8. 測試應用程式](#)
9. [9. 清除所用資源](#)
10. [10. 恭喜](#)

1. 總覽

在各行各業中，專利研究都是瞭解競爭環境、發掘潛在授權或收購機會，以及避免侵犯現有專利的重要工具。

專利研究範圍廣泛且複雜，從無數技術摘要中篩選出相關創新內容，是一項艱鉅的任務。傳統的關鍵字搜尋往往不準確且耗時。摘要冗長且技術性高，難以快速掌握核心概念。這可能會導致研究人員錯過重要專利，或在不相關的結果上浪費時間。

這項革命背後的祕密武器就是 Vector Search。向量搜尋不會比對關鍵字，而是將文字轉換為數值表示法 (嵌入)，這項技術可讓我們根據查詢的意義進行搜尋，而不只是查詢中使用的特定字詞。在文獻搜尋領域，這是一項重大突破。舉例來說，即使文件中沒有使用「穿戴式心率監測器」這個確切詞組，您也能找到相關專利。

目標


在本程式碼研究室中，我們將運用 AlloyDB、pgvector 擴充功能、Gemini 1.5 Pro、Embeddings 和 Vector Search，讓專利搜尋程序更快、更直覺，且精確度極高。

建構項目

本實驗室的學習內容包括：

1. 建立 AlloyDB 執行個體並載入專利公開資料集資料
2. 在 AlloyDB 中啟用 pgvector 和生成式 AI 模型擴充功能
3. 從洞察資料生成嵌入
4. 針對使用者搜尋文字執行即時餘弦相似度搜尋
5. 在無伺服器 Cloud Functions 中部署解決方案

下圖說明實作時的資料流和步驟。



High level diagram representing the flow of the Patent Search Application with AlloyDB

需求條件

- [Chrome](#) 或 [Firefox](#) 瀏覽器
 - 已啟用計費功能的 Google Cloud 專案。
-

2. 事前準備

建立專案

1. 在 [Google Cloud 控制台](#) 的專案選取器頁面中，選取或建立 Google Cloud [專案](#)。
2. 確認 Cloud 專案已啟用計費功能。瞭解如何[檢查專案是否已啟用計費功能](#)。
3. 您將使用 [Cloud Shell](#)，這是 Google Cloud 中執行的指令列環境，預先載入了 bq。點選 Google Cloud 控制台頂端的「啟用 Cloud Shell」。



4. 連至 Cloud Shell 後，請使用下列指令確認驗證已完成，專案也已設為獲派的專案 ID：

```
gcloud auth list
```

5. 在 Cloud Shell 中執行下列指令，確認 gcloud 指令已瞭解您的專案。

```
gcloud config list project
```

6. 如果未設定專案，請使用下列指令來設定：

```
gcloud config set project <YOUR_PROJECT_ID>
```

7. 啟用必要的 API。您可以在 Cloud Shell 終端機中使用 gcloud 指令：

```
gcloud services enable alloydb.googleapis.com \  
compute.googleapis.com \  
cloudresourcemanager.googleapis.com \  
servicenetworking.googleapis.com \  
run.googleapis.com \  
cloudbuild.googleapis.com \  
cloudfunctions.googleapis.com \  
aiplatform.googleapis.com
```

除了使用 gcloud 指令，您也可以透過控制台搜尋各項產品，或使用這個[連結](#)。

如要瞭解 gcloud 指令和用法，請參閱[說明文件](#)。

步驟 3 · 約 0 分鐘

3. 準備 AlloyDB 資料庫

我們來建立 AlloyDB 叢集、執行個體和資料表，以便載入專利資料集。

建立 AlloyDB 物件

使用叢集 ID 「`patent-cluster`」、密碼 「`alloydb`」、PostgreSQL 15 相容性，以及 「`us-central1`」區域，建立叢集和執行個體，並將網路設為 「`default`」。將執行個體 ID 設為 「`patent-instance`」。按一下「建立叢集」。如需建立叢集的詳細資料，請參閱：<https://cloud.google.com/alloydb/docs/cluster-create>。

建立資料表

您可以在 AlloyDB Studio 中使用下列 DDL 陳述式建立資料表：

```
CREATE TABLE patents_data ( id VARCHAR(25), type VARCHAR(25), number VARCHAR(20), country
VARCHAR(2), date VARCHAR(20), abstract VARCHAR(300000), title VARCHAR(100000), kind
VARCHAR(5), num_claims BIGINT, filename VARCHAR(100), withdrawn BIGINT) ;
```

啟用擴充功能

建構專利搜尋應用程式時，我們會使用 `pgvector` 和 `google_ml_integration` 擴充功能。[pgvector 擴充功能](#)可讓您儲存及搜尋向量嵌入。[google_ml_integration](#) 擴充功能提供多種函式，可存取 Vertex AI 預測端點，並在 SQL 中取得預測結果。執行下列 DDL，[啟用](#)這些擴充功能：

```
CREATE EXTENSION vector;
CREATE EXTENSION google_ml_integration;
```

授予權限

執行下列陳述式，授予「`embedding`」函式的執行權：

```
GRANT EXECUTE ON FUNCTION embedding TO postgres;
```

為 AlloyDB 服務帳戶授予 Vertex AI 使用者角色

在 Google Cloud IAM 控制台，將「Vertex AI 使用者」角色授予 AlloyDB 服務帳戶 (格式為 `service-
<<PROJECT_NUMBER>>@gcp-sa-alloydb.iam.gserviceaccount.com`)。PROJECT_NUMBER 會顯示您的專案編號。

或者，您也可以使用 `gcloud` 指令授予存取權：

```
PROJECT_ID=$(gcloud config get-value project)

gcloud projects add-iam-policy-binding $PROJECT_ID \
  --member="serviceAccount:service-$(gcloud projects describe $PROJECT_ID --
format="value(projectNumber)")@gcp-sa-alloydb.iam.gserviceaccount.com" \
  --role="roles/aiplatform.user"
```

修改資料表，新增用來儲存嵌入的向量資料欄

執行下列 DDL，將 abstract_embeddings 欄位新增至剛建立的資料表。這個資料欄可儲存文字的向量值：

```
ALTER TABLE patents_data ADD column abstract_embeddings vector(3072);
```

4. 將專利資料載入資料庫

我們將使用 BigQuery 上的 [Google 專利公開資料集](#) 做為資料集。我們將使用 AlloyDB Studio 執行查詢。[alloydb-pgvector](#) 存放區包含 `insert_into_patents_data.sql` 指令碼，我們將執行該指令碼來載入專利資料。

1. 在 Google Cloud 控制台中，開啟「AlloyDB」[AlloyDB](#) 頁面。
 2. 選取新建立的叢集，然後按一下執行個體。
 3. 在 AlloyDB 導覽選單中，按一下「AlloyDB Studio」。使用憑證登入。
 4. 按一下右側的「新增分頁」圖示，開啟新分頁。
 5. 從上述 `insert_into_patents_data.sql` 指令碼複製 `insert` 查詢陳述式，並貼到編輯器。您可以複製 50 到 100 個插入陳述式，快速展示這個用途。
 6. 按一下「執行」。查詢結果會顯示在「結果」表格中。
-

5. 為專利資料建立嵌入

首先，請執行下列範例查詢，測試嵌入函式：

```
SELECT embedding( 'gemini-embedding-001', 'AlloyDB is a managed, cloud-hosted SQL database service.');
```

這應該會傳回查詢中範例文字的嵌入向量，看起來像是浮點數陣列。如下所示：

▶ RUN

Close tab

FORMAT

CLEAR

1 SELECT embedding('textembedding-gecko@001', 'AlloyDB is a managed, cloud-hosted SQL database service.');

RESULTS

embedding
-0.029143702,-0.0071177855,-0.024524968,0.053128935,0.025651122,-0.04028945,-0.0009277421,0.030361904,-0.017621059,0.001031713,0.022722546,-0.00539576,0.044950195,-0.023410132,0.01799109,0.030719345,-0.047324233,-0.021004232,-0.039721053,0.017794741,-0.09268643,-0.061628487,0.0009791466,0.01794383,

Query Result for the Embedding Function Call

更新 abstract_embeddings 向量欄位

執行下列 DML，更新資料表中的專利摘要，並加入對應的嵌入內容：

```
UPDATE patents_data set abstract_embeddings = embedding( 'gemini-embedding-001', abstract);
```

6. 執行向量搜尋

現在資料表、資料和嵌入都已準備就緒，讓我們對使用者搜尋文字執行即時向量搜尋。您可以執行下列查詢來測試這項功能：

```
SELECT id || ' - ' || title as literature FROM patents_data ORDER BY abstract_embeddings <=> embedding('gemini-embedding-001', 'A new Natural Language Processing related Machine Learning Model')::vector LIMIT 10;
```

在這項查詢中，

- 1. 使用者搜尋文字：「新的自然語言處理相關機器學習模型」。
- 2. 我們使用模型：gemini-embedding-001，在 embedding() 方法中將其轉換為嵌入。
- 3. 「<=>」代表使用餘弦相似度距離法。
- 4. 我們會將嵌入方法的結果轉換為向量型別，使其與資料庫中儲存的向量相容。
- 5. LIMIT 10 代表我們選取與搜尋文字最接近的 10 個相符項目。

結果如下：

```
1 SELECT id || ' - ' || title as literature FROM patents_data ORDER BY abstract_embeddings <=> embedding('textembedding-gecko@001', 'A new Natural Language Processing related Machine Learning Model')::vector LIMIT 10
```

RESULTS

literature
10007660 - Contextual language understanding for multi-turn language tasks
10990852 - Method and apparatus for training model for object classification and detection
9817812 - Identifying word collocations in natural language texts
6560586 - Multiresolution learning paradigm and signal prediction
9805717 - Voice-based input using natural language processing for interfacing with one or more devices
10347243 - Apparatus and method for analyzing utterance meaning

Query Result for the matching Vector Search query

如搜尋結果所示，相符項目與搜尋文字相當接近。

7. 將應用程式帶到網頁

準備好將這個應用程式帶到網路上嗎？步驟如下：

1. 前往 Cloud Shell 編輯器，然後按一下編輯器左下角 (狀態列) 的「Cloud Code - Sign in」圖示。選取已啟用帳單的現有 Google Cloud 專案，並確認您也從 Gemini 登入同一個專案 (狀態列的右下角)。
2. 按一下 Cloud Code 圖示，然後等待 Cloud Code 對話方塊彈出。選取「New Application」(新增應用程式)，然後在「Create New Application」(建立新應用程式) 快顯視窗中，選取「Cloud Functions application」(Cloud Functions 應用程式)：




Image of the Create New Application pop up

在「Create New Application」(建立新的應用程式) 快顯視窗的第 2/2 頁面中，選取「Java: Hello World」，並在偏好的位置輸入專案名稱「alloydb-pgvector」，然後按一下「OK」：




Image of the project folder name pop up

3. 在產生的專案結構中，搜尋 [pom.xml](#)，然後將其內容替換為存放區檔案的內容。除了其他幾個依附元件外，還應包含下列依附元件：

```
<!-- Add the connector with the latest version -->
<dependency>
  <groupId>com.google.cloud</groupId>
  <artifactId>alloydb-jdbc-connector</artifactId>
  <version>1.1.1</version>
</dependency>

<!-- Add the driver with the latest version -->
<dependency>
  <groupId>org.postgresql</groupId>
  <artifactId>postgresql</artifactId>
  <version>42.6.0</version>
</dependency>
```

4. 將 HelloWorld.java 檔案替換為 [repo](#) 檔案的內容。

請注意，您必須將下列值替換為實際值：

```
String ALLOYDB_DB = "postgres";
String ALLOYDB_USER = "postgres";
String ALLOYDB_PASS = "*****";
String ALLOYDB_INSTANCE_NAME = "projects/<<YOUR_PROJECT_ID>>/locations/us-
centrall/clusters/<<YOUR_CLUSTER>>/instances/<<YOUR_INSTANCE>>";
//Replace YOUR_PROJECT_ID, YOUR_CLUSTER, YOUR_INSTANCE with your actual values
```

請注意，函式會將搜尋文字做為輸入內容參數，並以「search」做為鍵。在這個實作中，我們只會從資料庫傳回最接近的相符項目：

```
// Get the request body as a JSON object.
JsonObject requestJson = new Gson().fromJson(request.getReader(), JsonObject.class);
String searchText = requestJson.get("search").getAsString();

//Sample searchText: "A new Natural Language Processing related Machine Learning Model";
BufferedWriter writer = response.getWriter();
String result = "";
HikariDataSource dataSource = AlloyDbJdbcConnector();

try (Connection connection = dataSource.getConnection()) {
    //Retrieve Vector Search by text (converted to embeddings) using "Cosine Similarity"
    method
    try (PreparedStatement statement = connection.prepareStatement("SELECT id || ' - ' ||
title as literature FROM patents_data ORDER BY abstract_embeddings <=> embedding('tgemini-
embedding-001', '" + searchText + "' )::vector LIMIT 1")) {
        ResultSet resultSet = statement.executeQuery();
        resultSet.next();
        String lit = resultSet.getString("literature");
        result = result + lit + "\n";
        System.out.println("Matching Literature: " + lit);
    }
    writer.write("Here is the closest match: " + result);
}
}
```

5. 如要部署剛建立的 Cloud 函式，請從 Cloud Shell 終端機執行下列指令。請務必先使用下列指令，前往對應的專案資料夾：

```
cd alloydb-pgvector
```

然後執行下列指令：

```
gcloud functions deploy patent-search --gen2 --region=us-central1 --runtime=java11 --source=.
--entry-point=cloudcode.helloworld.HelloWorld --trigger-http
```

重要步驟：

設定部署作業後，您應該就能在 Google [Cloud Run Functions 控制台](#)中看到函式。搜尋並開啟新建立的函式，編輯設定並變更下列項目：

1. 前往「執行階段、建構作業、連線和安全性設定」
2. 將逾時時間增加至 180 秒
3. 前往「連線」分頁：



Runtime, build, connections and security settings



BUILD

CONNECTIONS

SECURITY AND IMAGE REPO



Ingress settings ?

- ☒ Allow all traffic
- ☐ Allow internal traffic only
Only traffic from VPC networks in the same project or the same VPC SC perimeter is allowed.
- ☐ Allow internal traffic and traffic from Cloud Load Balancing
Traffic from VPC networks in the same project, the same VPC SC perimeter or from Cloud Load Balancing is allowed.

Egress settings ?

By default, your function can send requests to the Internet, but not to resources in VPC networks. To send requests to resources in your VPC network, create or select a VPC connector already created in the same region as the function.

Network

default: Serverless VPC Access connector alloydb-test-conn (in this proje... ▼

Access resources on a VPC. [Learn more](#)

- ☐ Only route requests to private IPs through the VPC connector
- ☒ Route all traffic through the VPC connector

- 在 Ingress 設定下方，確認已選取「允許所有流量」。
- 在「輸出設定」下方，按一下「網路」下拉式選單，然後選取「新增虛擬私有雲連接器」選項，並按照彈出式對話方塊中顯示的操作說明進行操作：

Create connector

Name *

Region *

us-central1

A region is a specific geographical location where you can run your resources.

Network *

default

Subnet *

Select an unused /28 subnet or create a new one by entering an unused /28 IP range. The VPC Connector will create connector instances on this subnet.

✓ SHOW SCALING SETTINGS

CREATE

CANCEL

6. 提供 VPC 連接器的名稱，並確認區域與執行個體相同。將「網路」值保留為預設值，並將「子網路」設為「自訂 IP 範圍」，IP 範圍為 10.8.0.0 或類似的可用範圍。
7. 展開「顯示縮放設定」，確認設定完全符合下列條件：

Scaling Settings

Minimum instances *

2

The minimum number of instances provisioned at any time. The connector will automatically scale out if more capacity is needed. Minimum number of instances cannot be decreased later. Larger values increase your cost.

Maximum instances *

3

The maximum number of instances provisioned at any time. The connector will not automatically scale out above this value. Maximum number of instances cannot be decreased later. This setting limits your maximum cost.



Connectors don't scale down automatically or manually. Once the connector has reached maximum number of instances it will remain at this number.

Instance type *

f1-micro

Larger instances support higher bandwidth but raise your costs. [Learn more](#)

^ HIDE SCALING SETTINGS

CREATE

CANCEL

8. 按一下「CREATE」，這個連接器現在應該會列在輸出設定中。
 9. 選取新建立的連接器
 10. 選擇透過這個虛擬私有雲連接器轉送所有流量。
-

步驟 8 · 約 0 分鐘

8. 測試應用程式


部署完成後，您應該會看到下列格式的端點：

https://us-central1-YOUR_PROJECT_ID.cloudfunctions.net/patent-search

您可以在 Cloud Shell 終端機中執行下列指令進行測試：

```
gcloud functions call patent-search --region=us-central1 --gen2 --data '{"search": "A new Natural Language Processing related Machine Learning Model"}'
```

結果：




Cloud Shell Terminal result for the gcloud functions call command of the patent search function

您也可以從 [Cloud Functions](#) 清單進行測試。選取已部署的函式，然後前往「測試」分頁標籤。在「Configure triggering event」（設定觸發事件）區段的「request json」（要求 JSON）文字方塊中，輸入下列內容：

```
{"search": "A new Natural Language Processing related Machine Learning Model"}
```

按一下「測試函式」按鈕，即可在頁面右側查看結果：



大功告成！在 AlloyDB 資料上使用 Embeddings 模型執行相似度向量搜尋，就是這麼簡單。

步驟 9 · 約 0 分鐘

9. 清除所用資源

如要避免系統向您的 Google Cloud 帳戶收取本文章所用資源的費用，請按照下列步驟操作：

1. 前往 Google Cloud 控制台的「管理」
 2. [資源](#)頁面。
 3. 在專案清單中選取要刪除的專案，然後點按「刪除」。
 4. 在對話方塊中輸入專案 ID，然後按一下「Shut down」(關機) 即可刪除專案。
-

步驟 10 · 約 0 分鐘

10. 恭喜

恭喜！您已使用 AlloyDB、pgvector 和向量搜尋功能，成功執行相似度搜尋。結合 [AlloyDB](#)、[Vertex AI](#) 和 [Vector Search](#) 的功能，我們在文學搜尋領域取得重大進展，讓搜尋作業更易於存取、效率更高，且真正以意義為導向。
