

使用 NVIDIA NIM 在 GKE 部署 AI 模型

來源：<https://codelabs.developers.google.com/codelabs/nvidia-nim-google-cloud?hl=zh-tw>

步驟數：9

本實驗室的目標是透過 Google Kubernetes Engine (GKE) 探索 NVIDIA NIM

目錄

1. [1. 簡介](#)
2. [2. 學習目標](#)
3. [3. 瞭解元件](#)
4. [4. 必要條件](#)
5. [5. 建立搭載 GPU 的 GKE 叢集](#)
6. [6. 設定 NVIDIA NGC API 金鑰](#)
7. [7. 部署及測試 NVIDIA NIM](#)
8. [8. 清除所用資源](#)
9. [9. 後續步驟](#)

1. 簡介

本程式碼實驗室將引導您使用 [NVIDIA NIM™ 微服務](#)，在 Google Kubernetes Engine (GKE) 上部署及管理容器化 AI 模型。

本教學課程適用於想達成下列目標的開發人員和資料科學家：

- 簡化 AI 推論部署作業：瞭解如何使用預先建構的 NIM，在 GKE 上更快更輕鬆地將 AI 模型部署到正式環境。
 - 提升 NVIDIA GPU 的效能：實際操作，在 GKE 叢集內部署 NIM，並使用 NVIDIA TensorRT 最佳化 GPU 推論作業。
 - 擴充 AI 推論工作負載：瞭解如何使用 Kubernetes 自動調度資源及管理運算資源，根據需求擴充 NIM 部署作業。
-

步驟 2 · 約 0 分鐘

2. 學習目標

完成本教學課程後，您將能：

1. 在 GKE 上部署 NIM：將預先建構的 NVIDIA NIM 部署至 GKE 叢集，執行各種推論工作。
 2. 管理 NIM 部署作業：使用 kubectl 指令管理、監控及調度已部署的 NIM。
 3. 擴充推論工作負載：運用 Kubernetes 功能，根據流量需求自動調度 NIM 部署作業。
-

步驟 3 · 約 0 分鐘

3. 瞭解元件

Google Kubernetes Engine (GKE) 中的 GPU

[GPU](#) 可加速處理節點上執行的特定工作負載，例如機器學習和資料處理。GKE 提供多種機型選項，可供節點設定使用，包括搭載 [NVIDIA H100](#)、[L4](#) 和 [A100 GPU](#) 的機型。

NVIDIA NIM

[NVIDIA NIM](#) 是一組易於使用的推論微服務，可加速在任何雲端或資料中心部署基礎模型，並協助確保資料安全。

NVIDIA AI Enterprise

[NVIDIA AI Enterprise](#) 是端對端的雲端原生軟體平台，可加速資料科學管道，並簡化正式環境輔助程式和其他生成式 AI 應用程式的開發和部署作業。可透過 [GCP Marketplace](#) 取得。

4. 必要條件

- **專案**：已啟用計費功能的 Google Cloud 專案。
 - **權限**：有足夠的權限可建立 GKE 叢集和其他相關資源。
 - **Helm**：Helm 是 Kubernetes 的套件管理工具。
 - **NVIDIA GPU 運算子**：Kubernetes 外掛程式，可自動管理佈建 GPU 時所需的所有 NVIDIA 軟體元件。
 - **NVIDIA API 金鑰**：按一下[這個連結](#)，然後按照說明建立帳戶並產生 API 金鑰。下載 NIM 容器時需要 API 金鑰。
 - **NVIDIA GPU**：下列其中一個 GPU 應可正常運作 (請注意，如果 GPU 不足，可以按照[這些步驟](#)要求增加配額)
 - [NVIDIA L4 GPU \(1\)](#)
 - [NVIDIA A100 40GB GPU \(1\)](#)
 - [NVIDIA H100 80GB GPU \(1\)](#)
 - **選用 - GCloud SDK**：如果您未使用 Google Cloud Platform 入口網站中的 Cloud Shell，請務必安裝及設定 Google Cloud SDK。
 - **選用 - kubectl**：如果您未使用 GCP 入口網站中的 Cloud Shell，請務必安裝及設定 kubectl 指令列工具。
-

5. 建立搭載 GPU 的 GKE 叢集

1. 開啟 **Cloud Shell** 或終端機。
2. 請指定以下參數：

```
export PROJECT_ID=<YOUR PROJECT ID>
export REGION=<YOUR REGION>
export ZONE=<YOUR ZONE>
export CLUSTER_NAME=nim-demo
export NODE_POOL_MACHINE_TYPE=g2-standard-16
export CLUSTER_MACHINE_TYPE=e2-standard-4
export GPU_TYPE=nvidia-l4
export GPU_COUNT=1
```

請注意，您可能必須根據使用的運算執行個體和 GPU 類型，變更 **NODE_POOL_MACHINE_TYPE**、**CLUSTER_MACHINE_TYPE** 和 **GPU_TYPE** 的值。

3. 建立 GKE 叢集：

```
gcloud container clusters create ${CLUSTER_NAME} \
  --project=${PROJECT_ID} \
  --location=${ZONE} \
  --release-channel=rapid \
  --machine-type=${CLUSTER_MACHINE_TYPE} \
  --num-nodes=1
```

4. 建立 GPU 節點集區：

```
gcloud container node-pools create gpupool \
  --accelerator type=${GPU_TYPE},count=${GPU_COUNT},gpu-driver-version=latest \
  --project=${PROJECT_ID} \
  --location=${ZONE} \
  --cluster=${CLUSTER_NAME} \
  --machine-type=${NODE_POOL_MACHINE_TYPE} \
  --num-nodes=1
```

步驟 6 · 約 0 分鐘

6. 設定 NVIDIA NGC API 金鑰

您可以使用 NGC API 金鑰，從 NVIDIA NGC 提取自訂映像檔。如要指定金鑰：

```
export NGC_CLI_API_KEY="<YOUR NGC API KEY>"
```

這是產生的金鑰，屬於必要條件的一部分。

7. 部署及測試 NVIDIA NIM

1. 擷取 NIM LLM Helm 資訊套件：

```
helm fetch https://helm.ngc.nvidia.com/nim/charts/nim-llm-1.3.0.tgz --
username='$oauthtoken' --password=$NGC_CLI_API_KEY
```

2. 建立 NIM 命名空間：

```
kubectl create namespace nim
```

3. 設定密鑰：

```
kubectl create secret docker-registry registry-secret --docker-server=nvcr.io --docker-
username='$oauthtoken' --docker-password=$NGC_CLI_API_KEY -n nim

kubectl create secret generic ngc-api --from-literal=NGC_API_KEY=$NGC_CLI_API_KEY -n nim
```

4. 設定 NIM 配置：

```
cat <<EOF > nim_custom_value.yaml
image:
  repository: "nvcr.io/nim/meta/llama3-8b-instruct" # container location
  tag: 1.0.0 # NIM version you want to deploy
model:
  ngcAPISecret: ngc-api # name of a secret in the cluster that includes a key named
NGC_CLI_API_KEY and is an NGC API key
persistence:
  enabled: true
imagePullSecrets:
  - name: registry-secret # name of a secret used to pull nvcr.io images, see
https://kubernetes.io/docs/tasks/      configure-pod-container/pull-image-private-registry/
EOF
```

5. 啟動 NIM 部署作業：

```
helm install my-nim nim-llm-1.1.2.tgz -f nim_custom_value.yaml --namespace nim
```

確認 NIM Pod 正在執行：

```
kubectl get pods -n nim
```

6. 測試 NIM 部署作業：

確認 NIM 服務已成功部署後，我們就可以提出推論要求，瞭解 NIM 服務會提供哪種意見回饋。為此，我們會在服務上啟用通訊埠轉送，以便透過通訊埠 8000 從本機主機存取 NIM：

```
kubectrl port-forward service/my-nim-nim-llm 8000:8000 -n nim
```

接著，我們可以在 Cloud Shell 中開啟另一個終端機或分頁，然後嘗試下列要求：

```
curl -X 'POST' \
  'http://localhost:8000/v1/chat/completions' \
  -H 'accept: application/json' \
  -H 'Content-Type: application/json' \
  -d '{
    "messages": [
      {
        "content": "You are a polite and respectful chatbot helping people plan a
vacation.",
        "role": "system"
      },
      {
        "content": "What should I do for a 4 day vacation in Spain?",
        "role": "user"
      }
    ],
    "model": "meta/llama3-8b-instruct",
    "max_tokens": 128,
    "top_p": 1,
    "n": 1,
    "stream": false,
    "stop": "\n",
    "frequency_penalty": 0.0
  }'
```

如果從 NIM 服務取得對話完成結果，表示服務運作正常！

步驟 8 · 約 0 分鐘

8. 清除所用資源

刪除 GKE 叢集：

```
gcloud container clusters delete $CLUSTER_NAME --zone=$ZONE
```

步驟 9 · 約 0 分鐘

9. 後續步驟

詳情請參閱下列文章：

- [Google Kubernetes Engine \(GKE\)](#)
 - [NVIDIA GPU](#)
 - [NVIDIA AI Enterprise](#)
 - [NVIDIA NIM](#)
-