

運用 AlloyDB 和 Vertex AI Agent Builder 打造智慧購物助理 - 第 1 部分

來源：<https://codelabs.developers.google.com/smart-shop-agent-alloydb?hl=zh-tw>

步驟數：13

在本程式碼研究室中，您將建構知識導向的聊天應用程式，用於回答客戶問題、引導產品探索過程，並為電子商務資料集量身打造搜尋結果

目錄

1. [1. 總覽](#)
2. [2. 架構](#)
3. [3. 事前準備](#)
4. [4. 資料庫設定](#)
5. [5. 資料擷取](#)
6. [6. 背景資訊](#)
7. [7. 為情境建立嵌入](#)
8. [8. 執行向量搜尋](#)
9. [9. 使用 LLM 驗證比對結果](#)
10. [10. 將應用程式帶到網頁](#)
11. [11. 測試應用程式](#)
12. [12. 清除所用資源](#)
13. [13. 恭喜](#)

1. 總覽

在現今快速變化的零售環境中，提供卓越的客戶服務並打造個人化購物體驗至關重要。我們將帶您踏上技術之旅，瞭解如何建立知識驅動的聊天應用程式，回答顧客問題、引導產品探索，以及提供量身打造的搜尋結果。這項創新解決方案結合了 AlloyDB 的資料儲存功能、用於瞭解情境的內部分析引擎、用於驗證相關性的 Gemini (大型語言模型)，以及用於快速啟動智慧對話式助理的 Google 代理程式建構工具。

挑戰：現代零售業顧客期望獲得即時回覆，以及符合個人偏好的產品推薦。傳統的搜尋方法往往無法提供這種程度的個人化服務。

解決方案：我們的知識導向即時通訊應用程式可直接解決這項挑戰。這項功能會運用從零售資料衍生的豐富知識庫，瞭解顧客意圖、智慧回覆，並提供極為相關的結果。

建構項目

在本實驗室 (第 1 部分) 中，您將：

1. 建立 AlloyDB 執行個體並載入電子商務資料集
2. 在 AlloyDB 中啟用 pgvector 和生成式 AI 模型擴充功能
3. 根據產品說明生成嵌入
4. 針對使用者搜尋文字執行即時餘弦相似度搜尋
5. 在無伺服器 Cloud Run 函式中部署解決方案

實驗室的第二部分將介紹 Agent Builder 的步驟。

需求條件

- [Chrome](#) 或 [Firefox](#) 瀏覽器
 - 已啟用計費功能的 Google Cloud 專案。
-

步驟 2 · 約 0 分鐘

2. 架構

資料流程：讓我們進一步瞭解資料在系統中的流動方式：

擷取：

首先，請將零售資料 (包括庫存、產品說明和顧客互動) 擷取至 AlloyDB。

Analytics Engine：

我們將使用 AlloyDB 做為分析引擎，執行下列作業：

1. 擷取背景資訊：引擎會分析 AlloyDB 中儲存的資料，瞭解產品、類別、消費者行為等之間的關係 (如適用)。
2. 建立嵌入：系統會為使用者查詢和 AlloyDB 中儲存的資訊產生嵌入 (文字的數學表示)。
3. 向量搜尋：引擎會執行相似度搜尋，比較查詢嵌入項目與產品說明、評論和其他相關資料的嵌入項目。這會找出 25 個最相關的「最鄰近項目」。

Gemini 驗證：

這些可能的回答會送交 Gemini 評估。Gemini 會判斷這些資訊是否確實相關，以及是否適合分享給使用者。

生成回覆：

經過驗證的回應會建構為 JSON 陣列，整個引擎則會封裝到無伺服器 Cloud Run 函式中，並從 Agent Builder 叫用。

對話式互動：

Agent Builder 會以自然語言格式向使用者呈現回覆，方便進行來回對話。我們會在後續實驗室中說明這部分內容。

3. 事前準備

建立專案

1. 在 [Google Cloud 控制台](#) 的專案選取器頁面中，選取或建立 Google Cloud [專案](#)。
2. 確認 Cloud 專案已啟用計費功能。瞭解如何[檢查專案是否已啟用計費功能](#)。
3. 您將使用 [Cloud Shell](#)，這是 Google Cloud 中執行的指令列環境，預先載入了 bq。點選 Google Cloud 控制台頂端的「啟用 Cloud Shell」。



4. 連至 Cloud Shell 後，請使用下列指令確認驗證已完成，專案也已設為獲派的專案 ID：

```
gcloud auth list
```

5. 在 Cloud Shell 中執行下列指令，確認 gcloud 指令已瞭解您的專案。

```
gcloud config list project
```

6. 如果未設定專案，請使用下列指令來設定：

```
gcloud config set project <YOUR_PROJECT_ID>
```

7. 啟用必要的 API。

```
gcloud services enable alloydb.googleapis.com \  
compute.googleapis.com \  
cloudresourcemanager.googleapis.com \  
servicenetworking.googleapis.com \  
run.googleapis.com \  
cloudbuild.googleapis.com \  
cloudfunctions.googleapis.com \  
aiplatform.googleapis.com
```

除了使用 gcloud 指令，您也可以透過控制台搜尋各項產品，或使用這個[連結](#)。

如果遺漏任何 API，您隨時可以在導入過程中啟用。

若要瞭解 gcloud 指令和用法，請參閱[說明文件](#)。

步驟 4 · 約 0 分鐘


4. 資料庫設定

在本實驗室中，我們將使用 AlloyDB 做為資料庫，儲存零售資料。並使用「叢集」保存所有資源，例如資料庫和記錄檔。每個叢集都有一個「主要執行個體」，可做為資料的存取點。資料表會保存實際資料。

我們來建立 AlloyDB 叢集、執行個體和資料表，以便載入電子商務資料集。

建立叢集和執行個體

1. 在 Cloud 控制台中前往 AlloyDB 頁面。如要在 Cloud 控制台尋找大部分的頁面，只要使用控制台的搜尋列搜尋即可。
2. 在該頁面中選取「建立叢集」：



3. 畫面上會顯示類似下方的內容。使用下列值建立叢集和執行個體：

- 叢集 ID：「shopping-cluster」
- 密碼：「alloydb」
- 與 PostgreSQL 15 相容
- 區域：「us-central1」
- 網路：「default」

Configure your cluster

Cluster ID *

Use lowercase letters, numbers, and hyphens. Start with a letter.

Password *



[GENERATE](#)

Set a password for the default "postgres" user. A password is required for the user to log in.

Database version *

PostgreSQL 15 compatible



Location

For better performance, keep your data close to the services that need it. Choice is permanent.

Region *

us-east4 (Northern Virginia)



Networking

Clusters can only be configured with a private IP network path. [Learn more](#)

Network *



[SHOW ADVANCED OPTIONS](#)

4. 選取預設網路後，畫面上會顯示如下資訊。選取「設定連線」

Networking

Clusters can only be configured with a private IP network path. [Learn more](#)

Network *

default



Private services access connection required

Your network "default" requires a private services access connection. This connection enables your services to communicate exclusively by using internal IP addresses. [Learn more](#)

[SET UP CONNECTION](#)

。

5. 然後選取「使用系統自動分配的 IP 範圍」，並點選「繼續」。確認資訊後，選取「建立連結」。

✓ **Enable Service Networking API**

2 **Allocate an IP range**

Google will use this allocated IP range to create subnets.

☐ Select one or more existing IP ranges or create a new one

Select or create an IP range ▼

☒ Use an automatically allocated IP range

Google will automatically allocate an IP range of prefix-length /20 and use the name "default-ip-range".

CONTINUE

3 **Create a connection**

CREATE CONNECTION

CANCEL

6. 設定網路後，即可繼續建立叢集。點按「建立叢集」，完成叢集設定，如下所示：

Configure your primary instance

Name your instance

Give your instance an ID.

Instance ID *
shopping-cluster-primary

Choice is permanent. Use lowercase letters, numbers, and hyphens. Start with a letter.

Zonal availability

- ☐ Single zone
In case of outage, no failover. Not recommended for production.
- ☒ Multiple zones (Highly available)
Automatic failover to another zone within your selected region. Recommended for production instances. Increases cost.

Machine

AlloyDB's superior performance lets you run your existing workloads on smaller machines.

Machine Type *
8 vCPU, 64 GB

Connectivity

Private IP Connectivity

- ☒ Enable Private IP (always enabled)
Connect from applications and clients within the associated network. [Learn more](#)


CREATE CLUSTER

CANCEL

請務必將執行個體 ID 變更為「shopping-instance」。

請注意，建立叢集約需 10 分鐘。成功後，畫面應會顯示類似下方的訊息：

Overview




Clusters are groups of instances of virtual machines that can include a primary instance and multiple read pool instances. All cluster resources share a storage layer, which scales as needed. [Learn more](#)

Status	Ready
Cluster ID	shopping-cluster
Version	PostgreSQL-15 compatible
Cluster type	Primary cluster
High availability	Highly available (multi-zone)
Location	us-central1 (Iowa) Low CO2
Total storage used	52.27 MB
Network	default
Issues	No issues found
Maintenance	Upcoming: No maintenance currently scheduled. EDIT
SHOW DETAILS	

步驟 5 · 約 0 分鐘

5. 資料擷取


現在要新增包含商店資料的表格。前往 AlloyDB，選取主要叢集，然後選取 AlloyDB Studio：



您可能需要等待執行個體建立完成。完成後，請使用建立叢集時建立的憑證登入 AlloyDB。使用下列資料向 PostgreSQL 進行驗證：

- 使用者名稱：「postgres」
- 資料庫：「postgres」
- 密碼：「alloydb」

成功驗證 AlloyDB Studio 後，即可在編輯器中輸入 SQL 指令。如要新增多個編輯器視窗，請按一下最後一個視窗右側的加號。



您會在編輯器視窗中輸入 AlloyDB 指令，並視需要使用「執行」、「格式化」和「清除」選項。

啟用擴充功能

我們會使用 `pgvector` 和 `google_ml_integration` 擴充功能建構這個應用程式。[pgvector 擴充功能](#)可讓您儲存及搜尋向量嵌入。[google_ml_integration](#) 擴充功能提供多種函式，可存取 Vertex AI 預測端點，並在 SQL 中取得預測結果。執行下列 DDL，[啟用](#)這些擴充功能：

```
CREATE EXTENSION IF NOT EXISTS google_ml_integration CASCADE;  
CREATE EXTENSION IF NOT EXISTS vector;
```

如要查看資料庫已啟用的擴充功能，請執行下列 SQL 指令：


```
select extname, extversion from pg_extension;
```

建立資料表

使用下列 DDL 陳述式建立資料表：

```
CREATE TABLE  
  apparels ( id BIGINT,  
             category VARCHAR(100),  
             sub_category VARCHAR(50),  
             uri VARCHAR(200),  
             image VARCHAR(100),  
             content VARCHAR(2000),  
             pdt_desc VARCHAR(5000),  
             embedding vector(768) );
```

成功執行上述指令後，您應該就能在資料庫中查看資料表。螢幕截圖範例如下：




擷取資料

在本實驗室中，我們在 [SQL 檔案](#) 中提供約 200 筆記錄的測試資料。其中包含 `id`, `category`, `sub_category`, `uri`, `image` 和 `content`。其他欄位會在實驗室的後續部分填寫。

從該處複製 20 行/插入陳述式，然後將這些行貼到空白的編輯器分頁中，並選取「執行」。

如要查看資料表內容，請展開「Explorer」專區，直到看到名為 `apparels` 的資料表為止。選取三點圖示 (:)，即可查看查詢資料表的選項。系統會在新編輯器分頁中開啟 `SELECT` 陳述式。



授予權限

執行下列陳述式，將 `embedding` 函式的執行權授予使用者 `postgres`：

```
GRANT EXECUTE ON FUNCTION embedding TO postgres;
```

為 AlloyDB 服務帳戶授予 Vertex AI 使用者角色

前往 Cloud Shell 終端機並輸入下列指令：

```
PROJECT_ID=$(gcloud config get-value project)
```

```
gcloud projects add-iam-policy-binding $PROJECT_ID \  
  --member="serviceAccount:service-$(gcloud projects describe $PROJECT_ID --  
format="value(projectNumber)")@gcp-sa-alloydb.iam.gserviceaccount.com" \  
  --role="roles/aiplatform.user"
```

6. 背景資訊

返回 AlloyDB 執行個體頁面。

如要建立嵌入內容，我們需要 `context`，也就是要納入單一欄位的所有資訊。我們會建立產品說明 (以下稱為 `pdt_desc`) 來完成這項作業。在本範例中，我們會使用每項產品的所有資訊，但您使用自己的資料時，可以隨意設計資料，只要對您的業務有意義即可。

從新建立執行個體的 AlloyDB Studio 執行下列陳述式。這會使用比對內容資料更新 `pdt_desc` 欄位：

```
UPDATE
  apparels
SET
  pdt_desc = CONCAT('This product category is: ', category, ' and sub_category is: ',
    sub_category, '. The description of the product is as follows: ', content, '. The product
    image is stored at: ', uri)
WHERE
  id IS NOT NULL;
```

這項 DML 會使用資料表中的所有可用欄位和其他依附元件 (如果您的用途有任何依附元件) 的資訊，建立簡單的內容摘要。如要更精確地分類資訊及建立內容，請隨意設計資料，找出對貴商家有意義的資料。

7. 為情境建立嵌入

電腦處理數字比處理文字容易得多。嵌入系統會將文字轉換為一系列浮點數，這些數字應代表文字，無論文字的措辭、使用的語言等為何。

例如描述海邊的地點。例如「水上」、「海濱」、「從房間走到海邊」、「sur la mer」、「на берегу океана」等。這些字詞看起來不同，但元件資訊或機器學習術語 (即嵌入) 應該非常接近。

資料和內容都準備就緒後，我們將執行 SQL，將產品說明的嵌入內容新增至 `embedding` 欄位中的資料表。您可以使用各種嵌入模型。我們使用 Vertex AI 的 `text-embedding-004`。請務必在整個專案中使用相同的嵌入模型！

注意：如果您使用先前建立的 Google Cloud 專案，可能需要繼續使用舊版文字嵌入模型，例如 `textembedding-gecko`。

```
UPDATE
  apparels
SET
  embedding = embedding( 'text-embedding-004',
    pdt_desc)
WHERE
  TRUE;
```

再次查看 `apparels` 表格，即可看到一些嵌入內容。請務必重新執行 `SELECT` 陳述式，查看變更。

```
SELECT
  id,
  category,
  sub_category,
  content,
  embedding
FROM
  apparels;
```

這項查詢應會傳回嵌入向量，看起來像是浮點數陣列，如下所示：

select id, category, sub_category, content, embedding from apparels;				
RESULTS				
Apparel	Topwear	Girls Tops	Pink Casual Palm Tree Girls Pink Top	[0.014596316,-0.03846882,-0.038603388,0.0060634837,0.03886954,0.0040010866,0.073628664,-0.01995821,-8.1448394e-05,0.054226466,0.07164986,-0.004241335,0.0019124502,0.0039123986,-0.0024608225,-0.045527022,0.017409893,0.031920653,0.04763973,-0.042894326,0.007723384,-0.006228419,0.016617483,-0.020080574,-0.0012002785,-0.008212429,0.014974915,-0.03253931,-0.02873162,-0.0030522568,-0.06529046,0.031061204,-0.018363003,0.029087069,-0.0038010685,-0.04053071,-0.0068419403,0.010498182,0.06123379,0.06135948,-0.017419688,0.020212132,-0.014141041,-0.025288673,0.007944778,-0.0031779595,-0.0034434984,0.00860807,0.00043757434,-0.059628054,-0.015224135,0.017263819,0.0466727,-0.04255475,0.009060793,-0.05668718,0.02130441,0.01461606,-0.02464654,-0.013048486,-0.03157506,-0.0077514537,-0.008257657,0.024717083,-0.012033532,-0.013686471,0.01648141,0.023388749,0.0761798,-0.023578823,-0.027780239,-0.038580347,0.044714082,-0.029784098,-0.0048513813,-0.070841506,-0.027332483,0.03883139,0.025170851,-0.014740545,-0.013489334,-0.008596852,0.0077242726,-0.03619594,-0.058110435,0.

注意：在免費方案下建立的 Google Cloud 專案，可能會遇到配額問題，也就是每秒允許的嵌入要求數量。建議您使用 ID 的篩選查詢，然後在產生嵌入內容時，選擇性地選取 1 到 5 筆記錄等。

8. 執行向量搜尋

資料表、資料和嵌入都已準備就緒，現在就來對使用者搜尋文字執行即時向量搜尋。

假設使用者提出以下問題：

「I want womens tops, pink casual only pure cotton.」(我想要女裝上衣，粉紅色休閒款，材質為純棉。)

您可以執行下列查詢來找出相符項目：

```
SELECT
  id,
  category,
  sub_category,
  content,
  pdt_desc AS description
FROM
  apparels
ORDER BY
  embedding <=> embedding('text-embedding-004',
    'I want womens tops, pink casual only pure cotton.'):vector
LIMIT
  5;
```

讓我們詳細瞭解這項查詢：

在這項查詢中，

- 1. 使用者的搜尋文字為：「I want womens tops, pink casual only pure cotton.」(我想要女裝上衣，僅限粉紅色休閒款，材質為純棉)。
- 2. 我們要在 `embedding()` 方法中使用模型 `text-embedding-004`，將其轉換為嵌入。上一個步驟中，我們已將嵌入函式套用至表格中的所有項目，因此這個步驟應該很熟悉。
- 3. 「`<=>`」代表使用「餘弦相似度」距離方法。如要查看所有可用的相似度測量方式，請參閱 [pgvector 說明文件](#)。
- 4. 我們會將嵌入方法的結果轉換為向量型別，使其與資料庫中儲存的向量相容。
- 5. `LIMIT 5` 代表我們要為搜尋文字擷取 5 個最鄰近的項目。

結果如下所示：

RESULTS					
id	category	sub_category	content	description	
63	Apparel	Topwear	Girls Tops White Casual Gini Jony Girls Printed White Top	This product category is: Apparel and sub_category is: Topwear. The d...	▼
56	Apparel	Topwear	Girls Tops Pink Casual Gini and Jony Girls Pink Top	This product category is: Apparel and sub_category is: Topwear. The d...	▼
57	Apparel	Topwear	Girls Tops Pink Casual Gini and Jony Girls Pretty Pink Top	This product category is: Apparel and sub_category is: Topwear. The d...	▼
94	Apparel	Topwear	Girls Tops White Casual Gini and Jony Girls Printed Whit...	This product category is: Apparel and sub_category is: Topwear. The d...	▼
12	Apparel	Topwear	Girls Tops Pink Casual Gini and Jony Girls Pretty Bloss...	This product category is: Apparel and sub_category is: Topwear. The d...	▼

如您在結果中看到的，相符項目與搜尋文字相當接近。請嘗試變更顏色，看看結果會如何變化。

重要注意事項：

假設我們現在想使用 **ScaNN** 索引，提高這項向量搜尋結果的效能 (查詢時間)、效率和召回率。請參閱這篇[網誌](#)中的步驟，比較有索引和沒有索引的結果差異。為方便您操作，以下列出建立索引的步驟：

1. 由於我們已建立叢集、執行個體、內容和嵌入，因此只需使用下列陳述式安裝 ScaNN 擴充功能：

```
CREATE EXTENSION IF NOT EXISTS alloydb_scann;
```

2. 接著，我們要建立索引 (ScaNN)：

```
CREATE INDEX apparel_index ON apparels
```

```
USING scann (embedding cosine)
```

```
WITH (num_leaves=54);
```

在上述 DDL 中，apparel_index 是索引的名稱

「apparels」是我的表格

「scann」是索引方法

「embedding」是我要建立索引的表格欄

「cosine」是我要用於索引的距離方法

「54」是要套用至這個索引的分區數量。請設為 1 到 1048576 之間的任何值。如要進一步瞭解如何決定這個值，請參閱「[調整 ScaNN 索引](#)」。

我使用資料點數的平方根，如 [ScaNN 存放區](#) 中建議 (分割時，num_leaves 應約為資料點數的平方根)。

3. 使用下列查詢檢查索引是否已建立：

```
SELECT * FROM pg_stat_ann_indexes;
```

4. 使用與不含索引時相同的查詢，執行向量搜尋：

```
select * from apparels
```

```
ORDER BY embedding <=> CAST(embedding('textembedding-gecko', 'white tops for girls without any print') as vector(768))
```

```
LIMIT 20
```

上述查詢與實驗室步驟 8 中使用的查詢相同。不過，現在我們已為該欄位建立索引。

5. 使用簡單的搜尋查詢測試索引 (方法是捨棄索引)：

```
white tops for girls without any print
```

在 INDEXED 嵌入資料中，使用上述搜尋文字查詢 Vector Search，可獲得優質的搜尋結果並提升效率。使用索引後，效率大幅提升 (執行時間：**不使用 ScaNN** 時為 10.37 毫秒，**使用 ScaNN** 時為 0.87 毫秒)。如要進一步瞭解這個主題，請參閱這篇[網誌](#)。

9. 使用 LLM 驗證比對結果

在繼續操作並建立服務，以便向應用程式傳回最佳相符項目之前，請先使用生成式 AI 模型驗證這些潛在回覆是否確實相關，且可安全地與使用者分享。

確認執行個體已設定為 Gemini

請先檢查叢集和執行個體是否已啟用 Google ML 整合。在 AlloyDB Studio 中，輸入下列指令：

```
show google_ml_integration.enable_model_support;
```

如果值顯示為「on」，您可以略過接下來的 2 個步驟，直接設定 AlloyDB 和 Vertex AI 模型整合。

- 1. 前往 AlloyDB 叢集的主要執行個體，然後按一下「編輯主要執行個體」

Clusters

CREATE CLUSTER

MIGRATE DATABASE

INSTALL ALLOYDB OMNI

EXPLORE GEMINI

Clusters are groups of instances of virtual machines that power your workload, and can include a primary instance and multiple read pool instances. All cluster resources share a storage layer, which scales to suit your needs. [Learn more](#)

Filter

Enter property name or value

Resource name

Resource type

Location

Read pool nodes

Maintenance

Is

Actions

shopping-cluster	Primary cluster	us-central1				
shopping-instance	Primary instance	us-central1-a				

Edit

Restart

Failover

Delete


- 2. 前往「進階設定選項」中的「Flags」部分。並確認 google_ml_integration.enable_model_support flag 已設為「on」，如下所示：

← Edit primary instance

Flags

Use flags to customise your instance, if needed. [Learn more](#)

Enable the columnar engine flag to improve performance and query speed of HTAP and OLAP workloads. [Learn more](#)



^ New database flag

Choose a flag *
google_ml_integration.enable_model_support

Value *
on

DONE

如果未設為「on」，請設為「on」，然後按一下「UPDATE INSTANCE」按鈕。這個步驟需要幾分鐘才能完成。

整合 AlloyDB 和 Vertex AI 模型

現在您可以連線至 AlloyDB Studio，並執行下列 DML 陳述式，從 AlloyDB 設定 Gemini 模型存取權 (請使用標示位置的專案 ID)。執行指令前，系統可能會警告您有語法錯誤，但指令應該可以正常執行。

首先，我們建立 Gemini 1.5 模型連線，如下所示。請記得將下方指令中的 `$PROJECT_ID` 替換為您的 Google Cloud 專案 ID。

```
CALL
google_ml.create_model( model_id => 'gemini-1.5',
  model_request_url => 'https://us-central1-
aiplatform.googleapis.com/v1/projects/$PROJECT_ID/locations/us-
central1/publishers/google/models/gemini-1.5-pro:streamGenerateContent',
  model_provider => 'google',
  model_auth_type => 'alloydb_service_agent_iam');
```

您可以在 AlloyDB Studio 中執行下列指令，查看設定可存取的模型：

```
select model_id,model_type from google_ml.model_info_view;
```

最後，我們需要授予資料庫使用者執行 `ml_predict_row` 函式的權限，透過 Google Vertex AI 模型執行預測。執行下列指令：

```
GRANT EXECUTE ON FUNCTION ml_predict_row to postgres;
```

注意：如果您使用現有的 **Google Cloud** 雲端專案和現有的 **AlloyDB** 叢集/執行個體，且這些項目是先前建立的，可能需要捨棄 **gemini-1.5** 模型舊的參照，並使用上述 **CALL** 陳述式重新建立，然後再次對函式 **ml_predict_row** 執行授權，以免在後續叫用 **gemini-1.5** 時發生問題。

評估回覆

雖然我們會在下一節中使用一個大型查詢，確保查詢的回應合理，但查詢可能難以理解。我們現在就來看看這些片段，並在幾分鐘內瞭解它們如何整合。

1. 首先，我們會向資料庫傳送要求，取得與使用者查詢最接近的 5 個結果。為了簡化操作，我們將查詢硬式編碼，但請放心，稍後我們會將其插入查詢中。我們將納入 **apparels** 資料表中的產品說明，並新增兩個欄位，一個是說明與索引的組合，另一個則是原始要求。所有資料都會儲存在名為 **xyz** 的資料表中 (這只是暫時的資料表名稱)。

```
CREATE TABLE
  xyz AS
SELECT
  id || ' - ' || pdt_desc AS literature,
  pdt_desc AS content,
  'I want womens tops, pink casual only pure cotton.' AS user_text
FROM
  apparels
ORDER BY
  embedding <=> embedding('text-embedding-004',
    'I want womens tops, pink casual only pure cotton.')::vector
LIMIT
  5;
```

這項查詢的輸出內容會是與使用者查詢最相似的 5 列。新資料表 **xyz** 會包含 5 個資料列，每個資料列都會有下列資料欄：

- **literature**
- **content**
- **user_text**

2. 為判斷回覆的有效性，我們會使用複雜的查詢，說明如何評估回覆。並在 **xyz** 資料表中，將 **user_text** 和 **content** 用於查詢。

```
"Read this user search text: ', user_text,
' Compare it against the product inventory data set: ', content,
' Return a response with 3 values: 1) MATCH: if the 2 contexts are at least 85% matching or
not: YES or NO 2) PERCENTAGE: percentage of match, make sure that this percentage is accurate
3) DIFFERENCE: A clear short easy description of the difference between the 2 products.
Remember if the user search text says that some attribute should not be there, and the record
has it, it should be a NO match."
```

3. 接著，我們將使用該查詢，檢查 **xyz** 資料表中的回應「品質」。

```

CREATE TABLE
  x AS
SELECT
  json_array_elements( google_ml.predict_row( model_id => 'gemini-1.5',
    request_body => CONCAT('{
"contents": [
  { "role": "user",
    "parts":
      [ { "text": "Read this user search text: ', user_text, ' Compare it against the
product inventory data set: ', content, ' Return a response with 3 values: 1) MATCH: if the 2
contexts are at least 85% matching or not: YES or NO 2) PERCENTAGE: percentage of match, make
sure that this percentage is accurate 3) DIFFERENCE: A clear short easy description of the
difference between the 2 products. Remember if the user search text says that some attribute
should not be there, and the record has it, it should be a NO match."
      } ]
    }
  ] }'
)::json))-> 'candidates' -> 0 -> 'content' -> 'parts' -> 0 -> 'text'
AS LLM_RESPONSE
FROM
  xyz;

```

4. `predict_row` 會以 JSON 格式傳回結果。程式碼「`-> 'candidates' -> 0 -> 'content' -> 'parts' -> 0 -> 'text'`」用於從該 JSON 擷取實際文字。如要查看實際傳回的 JSON，可以移除這段程式碼。
5. 最後，如要取得 LLM 欄位，只要從 `x` 資料表擷取即可：

```

SELECT
  LLM_RESPONSE
FROM
  x;

```

6. 這可以合併為單一的下一個查詢，如下所示。

如果您已執行上述查詢來檢查中繼結果，請先從 AlloyDB 資料庫中刪除/移除 `xyz` 和 `x` 資料表，再執行這項查詢。

```
SELECT
  LLM_RESPONSE
FROM (
  SELECT
    json_array_elements( google_ml.predict_row( model_id => 'gemini-1.5',
      request_body => CONCAT('{
        "contents": [
          { "role": "user",
            "parts":
              [ { "text": "Read this user search text: ', user_text, ' Compare it against the
product inventory data set: ', content, ' Return a response with 3 values: 1) MATCH: if the 2
contexts are at least 85% matching or not: YES or NO 2) PERCENTAGE: percentage of match, make
sure that this percentage is accurate 3) DIFFERENCE: A clear short easy description of the
difference between the 2 products. Remember if the user search text says that some attribute
should not be there, and the record has it, it should be a NO match."
              } ]
            }
          } ] }'
      )::json)) -> 'candidates' -> 0 -> 'content' -> 'parts' -> 0 -> 'text'
  AS LLM_RESPONSE
  FROM (
    SELECT
      id || ' - ' || pdt_desc AS literature,
      pdt_desc AS content,
      'I want womens tops, pink casual only pure cotton.' user_text
    FROM
      apparels
    ORDER BY
      embedding <=> embedding('text-embedding-004',
        'I want womens tops, pink casual only pure cotton.')::vector
    LIMIT
      5 ) AS xyz ) AS X;
```

雖然這可能還是有點難懂，但希望您能稍微瞭解。結果會顯示是否有相符的內容、相符的百分比，以及評分的說明。

請注意，Gemini 模型預設會啟用串流功能，因此實際回覆會分散在多行：

RESULTS
llm_response
"Here"
"s a breakdown of the comparison:\n\n**1) MATCH: NO**"
"\n\n**2) PERCENTAGE: 65%**\n\n**3)"
") DIFFERENCE:**\n\n**Target Audience:** The user explicitly wants \"womens tops\", while the product is a girls' top. This is a significant mismatch"
"\n\n**Fabric:** The user desires \"pure cotton\" but the product description doesn't mention the fabric composition.\n\n**Style Detail:** "
"The product description includes \"Doodle\" and \"Retro\" which are not mentioned in the user's search. \n\n**Explanation of Percentage:** While \"pink\", \"casual\", and \"tops\" align, the core mismatches in"
" demographics and missing fabric information make it less than an 85% match. \n"
"

10. 將應用程式帶到網頁

準備好將這個應用程式帶到網路上嗎？請按照下列步驟，使用 Cloud Run 函式將這個知識引擎設為無伺服器：

1. 前往 Google Cloud 控制台的 Cloud Run Functions，**建立新的 Cloud Run Function**，或使用連結：
<https://console.cloud.google.com/functions/add>。
2. 選取「Cloud Run function」做為環境。提供函式名稱「retail-engine」，並選擇「us-central1」做為區域。將「驗證」設為「允許未經驗證的叫用」，然後按一下「下一步」。選擇「Java 17」做為執行階段，並選擇「Inline Editor」做為原始碼。
3. 根據預設，進入點會設為「gcfv2.HelloHttpFunction」。請將 Cloud Run 函式 `HelloHttpFunction.java` 和 `pom.xml` 中的預留位置程式碼，分別換成 [Java 檔案](#) 和 [XML](#) 中的程式碼。
4. 請記得在 Java 檔案中，將 **\$PROJECT_ID** 預留位置和 AlloyDB 連線憑證換成您的值。AlloyDB 憑證是我們在本程式碼研究室一開始使用的憑證。如果使用不同的值，請在 Java 檔案中修改。
5. 按一下「Deploy」（部署）。

部署完成後，為了允許 Cloud 函式存取 AlloyDB 資料庫執行個體，我們將建立 **VPC 連接器**。

重要步驟：

設定部署作業後，您應該就能在 Google [Cloud Run Functions 控制台](#) 中看到函式。搜尋新建立的函式（`retail-engine`），點選該函式，然後按一下「編輯」並變更下列項目：

1. 前往「執行階段、建構作業、連線和安全性設定」
2. 將逾時時間增加至 180 秒
3. 前往「連線」分頁：



Runtime, build, connections and security settings



BUILD

CONNECTIONS

SECURITY AND IMAGE REPO

Ingress settings

- ☒ Allow all traffic
- ☐ Allow internal traffic only
Only traffic from VPC networks in the same project or the same VPC SC perimeter is allowed.
- ☐ Allow internal traffic and traffic from Cloud Load Balancing
Traffic from VPC networks in the same project, the same VPC SC perimeter or from Cloud Load Balancing is allowed.

Egress settings

By default, your function can send requests to the Internet, but not to resources in VPC networks. To send requests to resources in your VPC network, create or select a VPC connector already created in the same region as the function.

Network

default: Serverless VPC Access connector alloydb-test-conn (in this proje... ▼

Access resources on a VPC. [Learn more](#) 

- ☐ Only route requests to private IPs through the VPC connector
- ☒ Route all traffic through the VPC connector

- 在 Ingress 設定下方，確認已選取「允許所有流量」。
- 在「輸出設定」下方，按一下「網路」下拉式選單，然後選取「新增虛擬私有雲連接器」選項，並按照彈出式對話方塊中顯示的操作說明進行操作：

Create connector

Name *

Region *

us-central1

A region is a specific geographical location where you can run your resources.

Network *

default

Subnet *

Select an unused /28 subnet or create a new one by entering an unused /28 IP range. The VPC Connector will create connector instances on this subnet.

▼ SHOW SCALING SETTINGS

CREATE

CANCEL

6. 提供 VPC 連接器的名稱，並確認區域與執行個體相同。將「網路」值保留為預設值，並將「子網路」設為「自訂 IP 範圍」，IP 範圍為 10.8.0.0 或類似的可用範圍。
7. 展開「顯示縮放設定」，確認設定完全符合下列條件：

Scaling Settings

Minimum instances *

2

The minimum number of instances provisioned at any time. The connector will automatically scale out if more capacity is needed. Minimum number of instances cannot be decreased later. Larger values increase your cost.

Maximum instances *

3

The maximum number of instances provisioned at any time. The connector will not automatically scale out above this value. Maximum number of instances cannot be decreased later. This setting limits your maximum cost.



Connectors don't scale down automatically or manually. Once the connector has reached maximum number of instances it will remain at this number.

Instance type *

f1-micro

Larger instances support higher bandwidth but raise your costs. [Learn more](#)

^ HIDE SCALING SETTINGS

CREATE

CANCEL

8. 按一下「CREATE」，這個連接器現在應該會列在輸出設定中。
 9. 選取新建立的連接器
 10. 選擇透過這個虛擬私有雲連接器轉送所有流量。
 11. 依序點選「NEXT」和「DEPLOY」。
-

步驟 11 · 約 0 分鐘

11. 測試應用程式

部署更新後的 Cloud 函式後，您應該會看到下列格式的端點：

```
https://us-central1-YOUR_PROJECT_ID.cloudfunctions.net/retail-engine
```

您可以在 Cloud Shell 終端機中執行下列指令進行測試：

```
gcloud functions call retail-engine --region=us-central1 --gen2 --data '{"search": "I want some kids clothes themed on Disney"}'
```

或者，您也可以按照下列步驟測試 Cloud Run 函式：

```
PROJECT_ID=$(gcloud config get-value project)

curl -X POST https://us-central1-$PROJECT_ID.cloudfunctions.net/retail-engine \
  -H 'Content-Type: application/json' \
  -d '{"search": "I want some kids clothes themed on Disney"}' \
  | jq .
```

結果如下：

```
[
  {
    "id": "164",
    "category": "Apparel",
    "sub_category": "Topwear",
    "uri": "http://assets.myntassets.com/v1/images/style/properties/cf8defc53a6242dc720dc826c169ca11_images.jpg",
    "description": "This product category is: Apparel and sub_category is: Topwear. The description of the product is as follows: Girls Tops Pink Casual Disney Kids",
    "literature": "\"'s a breakdown of the comparison:\\n\\n**1) MATCH:** YES\\n\\n\""
  },
  {
    "id": "191",
    "category": "Apparel",
    "sub_category": "Topwear",
    "uri": "http://assets.myntassets.com/v1/images/style/properties/f68af9cde009efeb220efeldd197a7f4_images.jpg",
    "description": "This product category is: Apparel and sub_category is: Topwear. The description of the product is as follows: Girls Tops Blue Casual Disney Kids",
    "literature": "\"**1) MATCH: YES**\\n\\n**2) PERCENTAGE: 9\\n\""
  },
  {
    "id": "100",
    "category": "Apparel",
    "sub_category": "Topwear",
    "uri": "http://assets.myntassets.com/v1/images/style/properties/d2c388bcd6a795e0d0cea56392d352a6_images.jpg",
    "description": "This product category is: Apparel and sub_category is: Topwear. The description of the product is as follows: Girls Tops White Casual Disney Kids",
    "literature": "\" MATCH:** YES\\n\\n**2) PERCENTAGE:** 90% \\n\\n\""
  },
  {
    "id": "119",
    "category": "Apparel",
    "sub_category": "Topwear",
    "uri": "http://assets.myntassets.com/v1/images/style/properties/9dfcd501502405f6befacbefbc8bec12_images.jpg",
    "description": "This product category is: Apparel and sub_category is: Topwear. The description of the product is as follows: Girls Tops Pink Casual Disney Kids",
    "literature": "\"'s a breakdown of the comparison:\\n\\n**1) MATCH:** YES\\n\\n\""
  },
  {
    "id": "130",
    "category": "Apparel",
    "sub_category": "Topwear",
    "uri": "http://assets.myntassets.com/v1/images/style/properties/35e3b397144b0e2f810be458cea913bc_images.jpg",
    "description": "This product category is: Apparel and sub_category is: Topwear. The description of the product is as follows: Girls Tops Red Casual Disney Kids",
    "literature": "\" MATCH:** YES\\n\\n**2) PERCENTAGE:** 90% \\n\\n\""
  }
]
```

大功告成！在 AlloyDB 資料上使用 Embeddings 模型執行相似度向量搜尋，就是這麼簡單。

建構對話式代理！

服務專員是在本實驗室的第 2 部分中建構。

12. 清除所用資源

如果您打算完成本實驗室的第 2 部分，請略過這個步驟，因為這會刪除目前的專案。

如要避免系統向您的 Google Cloud 帳戶收取本文章所用資源的費用，請按照下列步驟操作：

1. 在 Google Cloud 控制台中前往「管理資源」頁面。
 2. 在專案清單中選取要刪除的專案，然後點按「刪除」。
 3. 在對話方塊中輸入專案 ID，然後按一下「Shut down」(關機) 即可刪除專案。
-

13. 恭喜

恭喜！您已使用 AlloyDB、pgvector 和向量搜尋功能，成功執行相似度搜尋。結合 [AlloyDB](#)、[Vertex AI](#) 和 [Vector Search](#) 的功能，我們在提供情境和向量搜尋功能方面取得重大進展，讓這類搜尋功能更易於使用、效率更高，且真正以意義為導向。本實驗室的下一部分將說明如何建構代理程式。
