

如何搭配 Cloud Run GPU 使用 Ollama 做為輔助容器，並以 Open WebUI 做為前端 ingress 容器

來源：<https://codelabs.developers.google.com/codelabs/how-to-use-ollama-sidecar-open-webui-frontend-cloud-run-gpu?hl=zh-tw>

步驟數：9

瞭解如何使用 Cloud Run GPU 和 Open WebUI 做為前端輸入容器，將 Ollama 當做補充資訊使用

目錄

1. [簡介](#)
2. [設定環境變數並啟用 API](#)
3. [建立 GCS bucket 來儲存 Gemma 2 2B 模型](#)
4. [建立儲存空間 bucket](#)
5. [建立 Ollama 映像檔](#)
6. [建立 Open WebUI 前端映像檔](#)
7. [將多重容器服務部署至 Cloud Run](#)
8. [恭喜！](#)
9. [清除所用資源](#)

1. 簡介

總覽

Cloud Run 最近新增了 GPU 支援功能。目前僅開放公開測試，且須先加入候補名單。如有興趣試用這項功能，請[填寫這份表單](#)，加入等候名單。Cloud Run 是 Google Cloud 的容器平台，可讓您輕鬆在容器中執行程式碼，不必管理叢集。

我們目前提供的 GPU 是 Nvidia L4 GPU，具有 24 GB 的 vRAM。每個 Cloud Run 執行個體都有一個 GPU，且 Cloud Run 自動調整資源配置功能仍適用。包括最多擴充至 5 個執行個體 (可申請提高配額)，以及在沒有任何要求時縮減至零個執行個體。

GPU 的用途之一是執行您自己的開放式大型語言模型 (LLM)。本教學課程會逐步引導您部署執行 LLM 的服務。

在本程式碼研究室中，您會部署多容器服務，使用 Open WebUI 做為前端 ingress 容器，並在輔助容器中使用 Ollama，提供儲存在 Google Cloud Storage bucket 中的 Gemma 2 2B 模型。

注意：這個範例使用 Open WebUI，不需要驗證。如果您打算讓 Open WebUI 應用程式可透過公開網際網路存取，建議您為應用程式新增[驗證](#)。

課程內容

- 如何在 Cloud Run 中建立多容器服務
 - 如何部署 Ollama 做為輔助容器，提供 Gemma 2 2B 模型服務
 - 如何部署 Open WebUI 做為前端 ingress 容器
-

步驟 2 · 約 0 分鐘

2. 設定環境變數並啟用 API

升級 gcloud CLI

首先，您必須安裝最新版本的 gcloud CLI。執行下列指令即可更新 CLI：



```
gcloud components update
```

設定環境變數

您可以設定本程式碼實驗室全程都會使用的環境變數。



```
PROJECT_ID=<YOUR_PROJECT_ID>  
REGION=us-central1  
gcloud config set project $PROJECT_ID
```

啟用 API

開始進行本程式碼研究室之前，請先啟用數個 API。本程式碼研究室需要使用下列 API。執行下列指令即可啟用這些 API：



```
gcloud services enable run.googleapis.com \  
  cloudbuild.googleapis.com \  
  storage.googleapis.com \  
  artifactregistry.googleapis.com
```

為本程式碼研究室建立目錄。

```
mkdir ollama-sidecar-codelab  
cd ollama-sidecar-codelab
```

步驟 3 · 約 0 分鐘

3. 建立 GCS bucket 來儲存 Gemma 2 2B 模型

首先，請安裝 Ollama 來下載模型。這會將模型下載至 `/home/$USER/.ollama/models`

```
curl -fsSL https://ollama.com/install.sh | sh
```

現在執行下列指令，即可執行 Ollama：

```
ollama serve
```

Ollama 會開始監聽通訊埠 11434。

開啟第二個終端機視窗，將 Gemma 2 2B 模型下拉至

```
ollama pull gemma2:2b
```

(選用) 您可以執行下列指令，透過指令列與 Gemma 互動

```
ollama run gemma2:2b
```

與 Gemma 對話完畢後，輸入

```
/bye
```

步驟 4 · 約 0 分鐘

4. 建立儲存空間 bucket

模型下載完成後，即可將模型移至 GCS bucket。

首先，請建立 bucket。

```
gcloud storage buckets create gs://$PROJECT_ID-gemma2-2b-codelab
```

現在，請將 models 資料夾移至 GCS。

```
gsutil cp -r /home/$USER/.ollama/models gs://$PROJECT_ID-gemma2-2b-codelab
```

步驟 5 · 約 0 分鐘

5. 建立 Ollama 映像檔

建立含有下列內容的 Dockerfile

```
FROM --platform=linux/amd64 ollama/ollama

# Listen on all interfaces, port 11434
ENV OLLAMA_HOST 0.0.0.0:11434

# Store model weight files in /models
ENV OLLAMA_MODELS /models

# Reduce logging verbosity
ENV OLLAMA_DEBUG false

# Never unload model weights from the GPU
ENV OLLAMA_KEEP_ALIVE -1
```

建立 Artifact Registry 存放區，用於儲存服務映像檔。

```
gcloud artifacts repositories create ollama-sidecar-codelab-repo --repository-format=docker \
  --location=us-central1 --description="Ollama + OpenWebUI website demo" \
  --project=$PROJECT_ID
```

建構 ollama Sidecar 映像檔

```
gcloud builds submit \
  --tag us-central1-docker.pkg.dev/$PROJECT_ID/ollama-sidecar-codelab-repo/ollama-gemma-2b \
  --machine-type e2-highcpu-32
```

步驟 6 · 約 0 分鐘

6. 建立 Open WebUI 前端映像檔

在本節中，您將使用 Open WebUI 建立前端 Ingress 容器。

使用 Docker 下拉 Open WebUI 映像檔。

```
docker pull ghcr.io/open-webui/open-webui:main
```

然後設定 Docker，使用 Google Cloud 憑證向 Artifact Registry 進行驗證。這樣就能使用 Docker 將映像檔推送至 Artifact Registry 存放區。

```
gcloud auth configure-docker us-central1-docker.pkg.dev
```

為映像檔加上標記，然後推送至 Artifact Registry。

```
docker tag ghcr.io/open-webui/open-webui:main us-central1-  
docker.pkg.dev/$PROJECT_ID/ollama-sidecar-codelab-repo/openwebui  
  
docker push us-central1-docker.pkg.dev/$PROJECT_ID/ollama-sidecar-codelab-  
repo/openwebui
```

步驟 7 · 約 0 分鐘

7. 將多重容器服務部署至 Cloud Run

使用 YAML 檔案部署多容器服務

建立含有以下內容的 `service.yaml` 。

```
apiVersion: serving.knative.dev/v1
kind: Service
metadata:
  name: ollama-sidecar-codelab
  labels:
    cloud.googleapis.com/location: us-central1
spec:
  template:
    metadata:
      annotations:
        autoscaling.knative.dev/maxScale: '5'
        run.googleapis.com/cpu-throttling: 'false'
        run.googleapis.com/startup-cpu-boost: 'true'
        run.googleapis.com/container-dependencies: '{"openwebui":["ollama-sidecar"]}'
    spec:
      containerConcurrency: 80
      timeoutSeconds: 300
      containers:
        - name: openwebui
          image: us-central1-docker.pkg.dev/YOUR_PROJECT_ID/ollama-sidecar-codelab/openwebui
          ports:
            - name: http1
              containerPort: 8080
          env:
            - name: OLLAMA_BASE_URL
              value: http://localhost:11434
            - name: WEBUI_AUTH
              value: 'false'
          resources:
            limits:
              memory: 1Gi
              cpu: 2000m
          volumeMounts:
            - name: in-memory-1
              mountPath: /app/backend/data
          startupProbe:
            timeoutSeconds: 240
            periodSeconds: 240
            failureThreshold: 1
            tcpSocket:
              port: 8080
        - name: ollama-sidecar
          image: us-central1-docker.pkg.dev/YOUR_PROJECT_ID/ollama-sidecar-codelab/ollama-gemma-2b
          env:
            - name: OLLAMA_MODELS
              value: /root/.ollama/models
```

```
resources:
  limits:
    cpu: '6'
    nvidia.com/gpu: '1'
    memory: 16Gi
  volumeMounts:
  - name: gcs-1
    mountPath: /root/.ollama
  startupProbe:
    timeoutSeconds: 1
    periodSeconds: 10
    failureThreshold: 3
    tcpSocket:
      port: 11434
  volumes:
  - name: gcs-1
    csi:
      driver: gcsfuse.run.googleapis.com
      volumeAttributes:
        bucketName: YOUR_PROJECT_ID-gemma2-2b-codelab
  - name: in-memory-1
    emptyDir:
      medium: Memory
      sizeLimit: 10Gi
  nodeSelector:
    run.googleapis.com/accelerator: nvidia-l4
```

更新 service.yaml，將 PROJECT_ID 替換為您的專案 ID：

```
sed -i "s/YOUR_PROJECT_ID/${PROJECT_ID}/g" service.yaml
```

使用下列指令部署至 Cloud Run。

```
gcloud beta run services replace service.yaml
```

測試 Cloud Run 服務

現在，請在網路瀏覽器中開啟服務網址。

使用者介面載入完成後，請在「選取模型」下方選擇「Gemma 2 2B」。

現在向 Gemma 提出問題，例如「為什麼天空是藍色的？」

步驟 8 · 約 0 分鐘

8. 恭喜！

恭喜您完成本程式碼研究室！

建議您參閱 [Cloud Run functions](#) 說明文件

涵蓋內容

- 如何在 Cloud Run 中建立多容器服務
 - 如何部署 Ollama 做為輔助容器，提供 Gemma 2 2B 模型服務
 - 如何部署 Open WebUI 做為前端 ingress 容器
-

步驟 9 · 約 0 分鐘

9. 清除所用資源

為避免產生意外費用 (例如，Cloud Run 服務意外叫用次數超過[免費層級的每月 Cloud Run 叫用次數配額](#))，您可以刪除 Cloud Run，或刪除您在步驟 2 中建立的專案。

如要刪除 Cloud Run 函式，請前往 Cloud Run Cloud 控制台 (<https://console.cloud.google.com/run>)，然後刪除 `ollama-sidecar-codelab` 服務。

如要刪除整個專案，請前往 <https://console.cloud.google.com/cloud-resource-manager>，選取您在步驟 2 中建立的專案，然後選擇「刪除」。刪除專案後，您必須在 Cloud SDK 中變更專案。如要查看所有可用專案的清單，請執行 `gcloud projects list`。
