

使用 Workflows 平行執行 BigQuery 工作

來源：<https://codelabs.developers.google.com/codelabs/cloud-bigquery-workflows-parallel?hl=zh-tw>

步驟數：7


在本程式碼研究室中，您將瞭解如何同時對 Wikipedia 資料集執行 BigQuery 工作，以及 Workflows 的平行疊代功能。

目錄

1. [簡介](#)
2. [設定和需求](#)
3. [探索維基百科資料集](#)
4. [定義工作流程來執行多個查詢](#)
5. [使用 Workflows 執行多個查詢](#)
6. [使用平行步驟平行處理多個查詢](#)
7. [恭喜](#)

1. 簡介

Workflows 的**平行步驟**功能受《Google Cloud 服務條款》的[正式發布前產品條款](#)規範。正式發布前的功能只提供部分支援，對正式發布前的功能所做的變更可能與其他正式發布前的版本不相容。詳情請參閱「[推出階段說明](#)」。



Workflows 是一項全代管的自動化調度管理服務，可按照您定義的順序執行 Google Cloud 或外部服務。

BigQuery 是全代管的企業資料倉儲，內建機器學習、地理空間分析和商業智慧等功能，有助於管理及分析數兆位元組的資料。

在本程式碼研究室中，您將對公開的 Wikipedia 資料集執行一些 BigQuery 查詢。接著，您會瞭解如何在 Workflows 協調流程中，以序列方式依序執行多個 BigQuery 查詢。最後，您將使用 Workflows 的平行疊代功能平行處理查詢，最多可提升 5 倍速度。

課程內容

- 如何針對 Wikipedia 資料集執行 BigQuery 查詢。
 - 如何以工作流程調度管理服務的一部分，依序執行多個查詢。
 - 如何使用 Workflows 平行疊代功能平行處理查詢，最多可提升 5 倍速度。
-

2. 設定和需求

自修實驗室環境設定

1. 登入 [Google Cloud 控制台](#)，然後建立新專案或重複使用現有專案。如果沒有 Gmail 或 Google Workspace 帳戶，請先[建立帳戶](#)。

The screenshot shows the Google Cloud Platform interface. At the top, there's a blue header with the Google Cloud Platform logo and a 'Select a project' button, which is circled in blue. Below this, the 'Select a project' section includes a search bar. The 'New Project' section is below that, featuring a 'Project name' field with the text 'my-kubernetes-codelab' entered, which is also circled in blue. Below the name field, the 'Project ID' is displayed as 'my-kubernetes-codelab' with a note that it cannot be changed later. The 'Location' is set to 'No organization'. At the bottom of the 'New Project' section are 'CREATE' and 'CANCEL' buttons.

- **專案名稱**是這個專案參與者的顯示名稱。這是 Google API 未使用的字元字串。你隨時可以更新該位置資訊。
- **專案 ID** 在所有 Google Cloud 專案中不得重複，且設定後即無法變更。Cloud 控制台會自動產生不重複的字串，通常您不需要在意這個字串。在大多數程式碼研究室中，您需要參照專案 ID (通常會標示為 `PROJECT_ID`)。如果您不喜歡產生的 ID，可以產生另一個隨機 ID。你也可以嘗試自訂名稱，看看是否可用。完成這個步驟後就無法變更，且專案期間都會維持這個設定。
- 請注意，部分 API 會使用第三個值，也就是「專案編號」。如要進一步瞭解這三種值，請參閱[說明文件](#)。

注意：專案 ID 在全域中不得重複，選定後即為專屬 ID，其他使用者無法使用。您是該 ID 的唯一使用者。即使刪除專案，該 ID 也無法再使用

注意：如果您使用 Gmail 帳戶，可以將預設位置設為「沒有機構」。如果您使用 Google Workspace 帳戶，請選擇適合貴機構的位置。

2. 接著，您需要在 Cloud 控制台中[啟用帳單](#)，才能使用 Cloud 資源/API。完成本程式碼研究室的費用應該不高，甚至完全免費。如要關閉資源，避免產生本教學課程以外的費用，您可以刪除自己建立的資源，或刪除整個專案。Google

Cloud 新使用者可參加[價值\\$300 美元的免費試用計畫](#)。

啟動 Cloud Shell

雖然可以透過筆電遠端操作 Google Cloud，但在本程式碼研究室中，您將使用 [Google Cloud Shell](#)，這是可在雲端執行的指令列環境。

在 [Google Cloud 控制台](#) 中，點選右上工具列的 Cloud Shell 圖示：



佈建並連線至環境的作業需要一些時間才能完成。完成後，您應該會看到如下的內容：

A screenshot of a web browser window showing the Google Cloud Shell terminal. The browser tab is titled 'qwiklabs-gcp-b3de7b9575cb8d19 x'. The terminal text reads: 'Welcome to Cloud Shell! Type "help" to get started.' followed by the prompt 'google87764_student@qwiklabs-gcp-b3de7b9575cb8d19:~\$' with a red cursor.


這部虛擬機器搭載各種您需要的開發工具，並提供永久的 5GB 主目錄，而且可在 Google Cloud 運作，大幅提升網路效能並強化驗證功能。您可以在瀏覽器中完成本程式碼研究室的所有作業。您不需要安裝任何軟體。

步驟 3 · 約 5 分鐘


3. 探索維基百科資料集

首先，請在 BigQuery 中探索 Wikipedia 資料集。

前往 Google Cloud 控制台的 [BigQuery 專區](#)：



在「bigquery-samples」下方，您應該會看到各種公開資料集，包括一些與維基百科相關的資料集：



在 `wikipedia_pageviews` 資料集下方，您可以看到不同年份的網頁瀏覽次數表格：



您可以選取其中一個資料表 (例如 `201207`)，然後預覽資料：

201207

QUERY

SHARE

COPY

SNAPSHOT

DELETE

EXPORT

SCHEMA		DETAILS			PREVIEW		
Row	year	month	day	wikimedia_project	language	title	views
1	2012	7	5	wp	cs	Diskuse:Jiří_Verberger	2
2	2012	7	5	wp	cs	Diskuse:Lenka_Velínská	1
3	2012	7	5	wp	cs	Diskuse:Mistrovství_Československa_(lední_hokej)	1
4	2012	7	5	wp	cs	Diskuse:Nakadžima_Ki-84	1
5	2012	7	5	wp	cs	Diskuse:Ostrava	1
6	2012	7	5	wp	cs	Diskuse:Pitbull_(rapper)	4
7	2012	7	5	wp	cs	Diskuse:Podvazkový_řád	1
8	2012	7	5	wp	cs	Diskuse:Purkrabí	1
9	2012	7	5	wp	cs	Diskuse:Vatikán	2
10	2012	7	5	wp	cs	Diskuse:Škoda_125	3
11	2012	7	5	wp	cs	Diskuse:Žvahlav	7

您也可以查詢資料表。舉例來說，這項查詢會選取觀看次數最多的前 100 個影片：

```
SELECT TITLE, SUM(views)
FROM bigquery-samples.wikipedia_pageviews.201207h
GROUP BY TITLE
ORDER BY SUM(VIEWS) DESC
LIMIT 100
```

執行查詢後，大約需要 20 秒才能載入資料：

RUN

SAVE

SHARE

SCHEDULE

MORE

1

SELECT TITLE, SUM(views)

2

FROM `bigquery-samples.wikipedia\_pageviews.201207h`

3

GROUP BY TITLE

4

ORDER BY SUM(VIEWS) DESC

5

LIMIT 100

Query results

JOB INFORMATION		RESULTS	JSON	EXECUTION DETAILS
Row	TITLE	f0_		
1	en	1212538506		
2	ja	333338523		
3	Main_Page	231591590		
4	Special:Search	115491896		
5	Special:Random	113246774		
6	es	99789463		
7	de	94750380		

步驟 4 · 約 5 分鐘

4. 定義工作流程來執行多個查詢

對單一資料表執行查詢很簡單，不過，針對多個資料表執行多項查詢並彙整結果，可能會相當繁瑣。為協助完成這項作業，Workflows 提供 [疊代](#) 語法！

在 Cloud Shell 中建立 `workflow-serial.yaml` 檔案，建構工作流程，針對多個資料表執行多項查詢：

```
touch workflow-serial.yaml
```

接著，您可以使用 Cloud Shell 中的編輯器編輯檔案：



在 `workflow-serial.yaml` 檔案中，於第一個 `init` 步驟建立 `results` 對應，追蹤以表格名稱為鍵的每個疊代。此外，請定義 `tables` 陣列，其中包含要執行查詢的表格清單。在本例中，我們選擇 5 個資料表：

```
main:
  steps:
  - init:
      assign:
        - results : {}
        - tables:
            - 201201h
            - 201202h
            - 201203h
            - 201204h
            - 201205h
```

接著，定義 `runQueries` 步驟。這個步驟會逐一疊代每個資料表，並使用 Workflows 的 BigQuery 連接器執行查詢，找出每個資料表中網頁瀏覽次數最多的前 100 個標題。然後將每個資料表中的熱門標題和瀏覽次數儲存至結果對應：

```

- runQueries:
  for:
    value: table
    in: ${tables}
    steps:
      - runQuery:
        call: googleapis.bigquery.v2.jobs.query
        args:
          projectId: ${sys.get_env("GOOGLE_CLOUD_PROJECT_ID")}
          body:
            useLegacySql: false
            useQueryCache: false
            timeoutMs: 30000
            # Find the top 100 titles with most views on Wikipedia
            query: ${
              "SELECT TITLE, SUM(views)
              FROM `bigquery-samples.wikipedia_pageviews.` + table + "`
              WHERE LENGTH(TITLE) > 10
              GROUP BY TITLE
              ORDER BY SUM(VIEWS) DESC
              LIMIT 100"
            }
          result: queryResult
      - returnResult:
        assign:
          # Return the top title from each table
          - results[table]: {}
          - results[table].title: ${queryResult.rows[0].f[0].v}
          - results[table].views: ${queryResult.rows[0].f[1].v}

```

最後一個步驟是傳回 `results` 對應：

```

- returnResults:
  return: ${results}

```

如需完整原始碼，請按這裡：[workflow-serial.yaml](#)。

步驟 5 · 約 7 分鐘

5. 使用 Workflows 執行多個查詢

部署及執行工作流程前，請務必啟用 Workflows API。您可以透過 Google Cloud 控制台啟用，或在 Cloud Shell 中使用 `gcloud` 啟用：

```
gcloud services enable workflows.googleapis.com
```

建立 Workflows 專用的服務帳戶：

```
SERVICE_ACCOUNT=workflows-bigquery-sa
gcloud iam service-accounts create $SERVICE_ACCOUNT \
  --display-name="Workflows BigQuery service account"
```

請確認服務帳戶具備記錄及執行 BigQuery 工作的角色：


```
PROJECT_ID=your-project-id
gcloud projects add-iam-policy-binding $PROJECT_ID \
  --role roles/logging.logWriter \
  --role roles/bigquery.jobUser \
  --member serviceAccount:$SERVICE_ACCOUNT@$PROJECT_ID.iam.gserviceaccount.com
```

使用服務帳戶部署工作流程：

```
gcloud workflows deploy bigquery-serial \
  --source=workflow-serial.yaml \
  --service-account=$SERVICE_ACCOUNT@$PROJECT_ID.iam.gserviceaccount.com
```

最後，您就可以執行工作流程了。

在 Cloud 控制台的「工作流程」部分下方，找到 `bigquery-serial` 工作流程，然後按下 `Execute` 按鈕：



或者，您也可以在 Cloud Shell 中使用 `gcloud` 執行工作流程：

```
gcloud workflows run bigquery-serial
```

您應該會看到工作流程執行時間約為 1 分鐘 (每個資料表 20 秒，共 5 個資料表)。

最後，您會看到每個表格的輸出內容，其中包含熱門影片和觀看次數：

bigquery-serial: 0b9a138d-7b01-4bc4-aa3a-48378cf89e9a



Execution ID 0b9a138d-7b01-4bc4-aa3a-48378cf89e9a

Execution state ✔ Succeeded

Execution start Jun 21, 2022, 10:12:25 AM

Execution end Jun 21, 2022, 10:13:39 AM

Execution duration 1 minute

Workflow name bigquery-serial

Input

null



Output



```
{
  "201201h": {
    "title": "Special:Search",
    "views": "14591339"
  },
  "201202h": {
    "title": "Special:Search",
    "views": "132765420"
  },
  "201203h": {
    "title": "Special:Search",
    "views": "123316818"
  },
  "201204h": {
    "title": "Special:Search",
    "views": "116830614"
  },
  "201205h": {
    "title": "Special:Search",
```

bigquery-serial

METRICS

EXECUTIONS

LOGS

DETAILS

TRIGGERS

Filter Filter executions

State	Execution ID	Workflow revision
Running	0b9a138d-7b01-4bc4-aa3a-48378cf89e9a	000001-500

6. 使用平行步驟平行處理多個查詢

由於上一個步驟的工作流程執行了 5 個查詢，每個查詢耗時 20 秒，因此總共耗時約 1 分鐘。由於這些是獨立查詢，您可以使用 Workflows 的平行疊代功能，實際平行執行這些查詢。

將 `workflow-serial.yaml` 檔案複製到新的 `workflow-parallel.yaml` 檔案。在新檔案中，您會進行幾項變更，將連續步驟轉換為平行步驟。

在 `workflow-parallel.yaml` 檔案中，變更 `runQueries` 步驟。請先新增 `parallel` 關鍵字。這樣一來，`for` 迴圈的每次疊代就能平行執行。其次，將 `results` 變數宣告為 `shared` 變數。這樣一來，分支就能寫入變數。我們會將每個結果附加至這個變數。

```
- runQueries:
  parallel:
    shared: [results]
    for:
      value: table
      in: ${tables}
```

如需完整原始碼，請按這裡：[workflow-parallel.yaml](#)。

部署平行工作流程：

```
gcloud workflows deploy bigquery-parallel \
  --source=workflow-parallel.yaml \
  --service-account=$SERVICE_ACCOUNT@$PROJECT_ID.iam.gserviceaccount.com
```

執行工作流程：

```
gcloud workflows run bigquery-parallel
```

您應該會看到工作流程執行作業持續約 20 秒。這是因為 5 個查詢會同時執行。只要變更幾行程式碼，速度就能提升 5 倍！

最後，您會看到每個表格的輸出內容相同，但執行時間短得多：

←

Execution details

▶ EXECUTE AGAIN

↺

bigquery-parallel: 1e432830-41a4-4443-8e1f-a4adc23e6692

↗

Execution ID

1e432830-41a4-4443-8e1f-a4adc23e6692

Execution state

✔ Succeeded

Execution start

Jun 21, 2022, 10:37:58 AM

Execution end

Jun 21, 2022, 10:38:15 AM

Execution duration

17.419 seconds

Workflow name

bigquery-parallel

Workflow revision

000001-629

Call logging level

No logs

Input

null

📄

Output

```
{
  "201201h": {
    "title": "Special:Search",
    "views": "14591339"
  },
  "201202h": {
    "title": "Special:Search",
    "views": "132765420"
  }
}
```

📄

Severity

步驟 7 · 約 1 分鐘

7. 恭喜

恭喜，您已完成本程式碼研究室！詳情請參閱 [Workflows 說明文件中的平行步驟](#)。

涵蓋內容

- 如何針對 Wikipedia 資料集執行 BigQuery 查詢。
 - 如何以工作流程調度管理服務的一部分，依序執行多個查詢。
 - 瞭解如何使用 Workflows 平行疊代功能平行處理查詢，最多可提升 5 倍速度。
-