

透過 Cloud Dataproc (指令列) 佈建及使用代管 Hadoop/Spark 叢集

來源：<https://codelabs.developers.google.com/codelabs/cloud-dataproc-gcloud?hl=zh-tw>

步驟數：12

在這個程式碼研究室中，您將瞭解如何使用 Dataproc 啟動代管 Spark/Hadoop 叢集、提交 Spark 範例工作，以及使用指令列關閉叢集。

目錄

1. [總覽](#)
2. [設定和需求](#)
3. [啟用 Cloud Dataproc 和 Google Compute Engine API](#)
4. [啟動 Cloud Shell](#)
5. [建立 Cloud Dataproc 叢集](#)
6. [將 Spark 工作提交至叢集](#)
7. [列出工作並重新連線](#)
8. [調整叢集大小](#)
9. [透過 SSH 連線至叢集](#)
10. [檢查代碼](#)
11. [關閉叢集](#)
12. [恭喜！](#)

步驟 1 · 約 1 分鐘

1. 總覽

Cloud Dataproc 是一項代管的 Spark 和 Hadoop 服務，能夠讓您妥善運用開放原始碼資料工具，進行批次處理、查詢、串流及機器學習作業。Cloud Dataproc 自動化功能可協助您快速建立叢集、輕鬆管理叢集，並在不需要叢集時關閉叢集來節省支出。省下管理作業所需的時間與費用之後，您就能專心處理工作與資料。

本教學課程改編自 <https://cloud.google.com/dataproc/overview>

課程內容

- 如何建立代管 Cloud Dataproc 叢集 ([需預先安裝 Apache Spark](#))。
- 如何提交 Spark 工作
- 如何調整叢集大小
- 如何透過 SSH 連線至 Dataproc 叢集的主要節點
- 如何使用 gcloud 檢查叢集、作業和防火牆規則
- 如何關閉叢集

軟硬體需求

- [Chrome](#) 或 [Firefox](#) 瀏覽器
-

步驟 2 · 約 6 分鐘

2. 設定和需求

自修實驗室環境設定

1. 登入 [Cloud 控制台](#)，建立新專案或重複使用現有專案。(如果沒有 Gmail 或 G Suite 帳戶，請先[建立帳戶](#))。

注意：記住以下網址，即可輕鬆存取 Cloud 控制台：console.cloud.google.com。

The screenshot shows the Google Cloud Platform interface for creating a new project. The top navigation bar is blue with the Google Cloud Platform logo and a 'Select a project' dropdown menu. Below this, the 'Select a project' section features a search bar and a 'NEW PROJECT' button. The 'New Project' form is displayed below, with the following fields:

- Project name ***: A text input field containing 'my-kubernetes-codelab'.
- Project ID**: A text input field containing 'my-kubernetes-codelab'. This field is circled in blue, and a blue arrow points to it from the 'NEW PROJECT' button. Below the field, it says 'Project ID: my-kubernetes-codelab. It cannot be changed later. EDIT'.
- Location ***: A dropdown menu showing 'No organization' with a 'BROWSE' button next to it.

At the bottom of the form are two buttons: 'CREATE' and 'CANCEL'.

請記住專案 ID，這是所有 Google Cloud 專案中不重複的名稱 (上述名稱已遭占用，因此不適用於您，抱歉！)。本程式碼研究室稍後會將其稱為 `PROJECT_ID`。

注意：如果您使用 Gmail 帳戶，可以將預設位置設為「沒有機構」。如果您使用 G Suite 帳戶，請選擇適合貴機構的位置。

2. 接著，您必須在 Cloud 控制台中[啟用帳單](#)，才能使用 Google Cloud 資源。

完成本程式碼研究室的費用應該不高，甚至完全免費。請務必按照「清除」部分的指示操作，瞭解如何停用資源，避免在本教學課程結束後繼續產生帳單費用。Google Cloud 新使用者可參加[價值\\$300 美元的免費試用計畫](#)。


步驟 3 · 約 0 分鐘

3. 啟用 Cloud Dataproc 和 Google Compute Engine API


按一下畫面左上方的「選單」圖示。




從下拉式選單中選取「API 管理工具」。



按一下「啟用 API 和服務」。



在搜尋框中搜尋「Compute Engine」。在顯示的結果清單中，按一下「Google Compute Engine API」。



在 Google Compute Engine 頁面中，按一下「啟用」

[←](#) API Library



Google Compute Engine API

Google

Compute Engine API

[ENABLE](#)[TRY THIS API](#)

Type
[APIs & services](#)

Last updated

Overview

Creates and runs virtual machines on Google Cloud Platform.

About Google

啟用後，請點選向左箭頭返回。

現在搜尋「Google Cloud Dataproc API」，並啟用這項 API。

[←](#) API Library

1 result



Google Cloud Dataproc API

Google

Manages Hadoop-based clusters and jobs on Google Cloud Platform.

步驟 4 · 約 1 分鐘



4. 啟動 Cloud Shell

這部以 Debian 為基礎的虛擬機器，搭載各種您需要的開發工具，並提供永久的 5GB 主目錄，而且可在 Google Cloud 運作，大幅提升網路效能並強化驗證功能。也就是說，您只需要瀏覽器 (Chromebook 也可以) 就能完成本程式碼研究室。

1. 如要從 Cloud 控制台啟用 Cloud Shell，只要按一下「啟用 Cloud Shell」



即可 (佈建並連線至環境的作業需要一些時間才能完成)。



連至 Cloud Shell 後，您應該會看到驗證已完成，專案也已設為獲派的專案 ID `PROJECT_ID`。

```
gcloud auth list
```

指令輸出

```
Credentialed accounts:
- <myaccount>@<mydomain>.com (active)
```

注意：Cloud Shell 已預先安裝 `gcloud` 指令列工具，並支援 Tab 鍵完成功能，相信您一定會喜歡。詳情請參閱 [gcloud 指令列工具總覽](#)。

```
gcloud config list project
```


指令輸出

```
[core]
project = <PROJECT_ID>
```

如果專案未設定，請發出下列指令：

```
gcloud config set project <PROJECT_ID>
```

在尋找「`PROJECT_ID`」嗎？請檢查您在設定步驟中使用的 ID，或在 Cloud 控制台資訊主頁中尋找：



Cloud Shell 也會預設設定部分環境變數，這些變數在您執行後續指令時可能很有用。

```
echo $GOOGLE_CLOUD_PROJECT
```

指令輸出

```
<PROJECT_ID>
```

2. 最後，設定預設可用區和專案。

```
gcloud config set compute/zone us-central1-f
```

你可以選擇各種不同區域。詳情請參閱「[地區和區域](#)」。

注意：如果在自己的機器上執行 `gcloud`，各個工作階段都會保留這些設定。但在 Cloud Shell 中，每次啟動新工作階段或重新連線時，都必須重新設定。

步驟 5 · 約 3 分鐘

5. 建立 Cloud Dataproc 叢集

啟動 Cloud Shell 後，您可以使用指令列叫用 Cloud SDK `gcloud` 指令，或叫用虛擬機器執行個體提供的其他工具。

選擇要在本實驗室使用的叢集名稱：

```
$ CLUSTERNAME=${USER}-dplab
```

首先，請建立新的叢集：

```
$ gcloud dataproc clusters create ${CLUSTERNAME} \  
  --region=us-central1 \  
  --scopes=cloud-platform \  
  --tags codelab \  
  --zone=us-central1-c
```

預設的叢集設定包含兩個工作站節點，應能滿足本教學課程的需求。上述指令包含 `--zone` 選項，可指定要建立叢集的地理區域，以及兩個進階選項 `--scopes` 和 `--tags`。使用這些選項啟用的功能時，我們會說明這些選項。如要瞭解如何使用指令列旗標來自訂叢集設定，請參閱 Cloud SDK `gcloud dataproc clusters create` 指令。

6. 將 Spark 工作提交至叢集

您可以透過 Cloud Dataproc API `jobs.submit` 要求、使用 `gcloud` 指令列工具，或從 [Google Cloud Platform 主控台](#) 提交工作。您也可以使用 SSH [連線至叢集中的機器執行個體](#)，然後從該執行個體執行工作。

接著，我們將透過 Cloud Shell 指令列的 `gcloud` 工具提交工作：

```
$ gcloud dataproc jobs submit spark --cluster ${CLUSTERNAME} \  
  --class org.apache.spark.examples.SparkPi \  
  --jars file:///usr/lib/spark/examples/jars/spark-examples.jar -- 1000
```

作業執行時，Cloud Shell 視窗會顯示輸出內容。

輸入 Control-C 中斷輸出內容。這會停止 `gcloud` 指令，但工作仍會在 Dataproc 叢集上執行。

除了透過指令列或以程式輔助方式透過 API 呼叫提交工作，您也可以直接從 Google Cloud 控制台提交工作，請參閱 [Dataproc 快速入門導覽課程](#) 中的範例。

步驟 7 · 約 2 分鐘

7. 列出工作並重新連線


列印工作清單：

```
$ gcloud dataproc jobs list --cluster ${CLUSTERNAME}
```

最近提交的工作會顯示在清單頂端。複製作業 ID，並貼到下方指令的「`jobId`」位置。這項指令會重新連線至指定工作，並顯示其輸出內容：

```
$ gcloud dataproc jobs wait jobId
```

工作完成後，輸出內容會包含圓周率的近似值。



```
16/03/30 04:07:32 INFO org.apache.hadoop.yarn.client.api.impl.YarnClientImpl: Submitted application application_1459310748325_0001
Pi is roughly 3.14148792
16/03/30 04:07:55 INFO akka.remote.RemoteActorRefProvider$RemotingTerminator: Shutting down remote daemon.
16/03/30 04:07:55 INFO akka.remote.RemoteActorRefProvider$RemotingTerminator: Remote daemon shut down; proceeding with flushing remote transports.
16/03/30 04:07:55 INFO akka.remote.RemoteActorRefProvider$RemotingTerminator: Remoting shut down.
Job [8f78c882-57b2-4878-8d6a-e6f601339557] finished successfully.
driverControlFilesUri: gs://dataproc-15572ede-6e00-46e0-b05b-ac8f1fc266bb-us/google-cloud-dataproc-metainfo/ab8372d3-c3d3-41cb-9bc0-024220c1e827/jobs/8f78c882-57b2-4878-8d6a-e6f601339557/
driverOutputResourceUri: gs://dataproc-15572ede-6e00-46e0-b05b-ac8f1fc266bb-us/google-cloud-dataproc-metainfo/ab8372d3-c3d3-41cb-9bc0-024220c1e827/jobs/8f78c882-57b2-4878-8d6a-e6f601339557/driveroutput
placement:
  clusterName: dplab
  clusterUuid: ab8372d3-c3d3-41cb-9bc0-024220c1e827
reference:
  jobId: 8f78c882-57b2-4878-8d6a-e6f601339557
  projectId: kkam-demo-project
sparkJob:
  args:
  - '1000'
  jarFileUri:
  - file:///usr/lib/spark/lib/spark-examples.jar
  loggingConfig: {}
  mainClass: org.apache.spark.examples.SparkPi
status:
  state: DONE
  stateStartTime: '2016-03-30T04:08:08.696Z'
statusHistory:
- state: PENDING
  stateStartTime: '2016-03-30T04:07:19.980Z'
- state: SETUP_DONE
  stateStartTime: '2016-03-30T04:07:20.121Z'
- details: Agent reported job success
  state: RUNNING
  stateStartTime: '2016-03-30T04:07:30.543Z'
kathycarper@kkam-demo-project:~$
```

步驟 8 · 約 2 分鐘

8. 調整叢集大小

如要執行較大的運算作業，建議在叢集中新增更多節點，以加快運算速度。Dataproc 可讓您隨時在叢集中新增及移除節點。

檢查叢集設定：

```
$ gcloud dataproc clusters describe ${CLUSTERNAME}
```

新增一些先佔節點，擴大叢集：

```
$ gcloud dataproc clusters update ${CLUSTERNAME} --num-secondary-workers=2
```

再次檢查叢集：

```
$ gcloud dataproc clusters describe ${CLUSTERNAME}
```

請注意，除了原始叢集說明中的 `workerConfig` 之外，現在還有 `secondaryWorkerConfig`，其中包含先占 worker 的兩個 `instanceNames`。新節點啟動時，Dataproc 會將叢集狀態顯示為就緒。

您一開始有兩個節點，現在有四個，因此 Spark 工作執行速度應該會快上兩倍。

步驟 9 · 約 1 分鐘

9. 透過 SSH 連線至叢集

透過 SSH 連線至主節點，執行個體名稱一律為叢集名稱加上 `-m`：

```
$ gcloud compute ssh ${CLUSTERNAME}-m --zone=us-central1-c
```

首次在 Cloud Shell 執行 ssh 指令時，系統會為您的帳戶產生 ssh 金鑰。您可以選擇通關密語，也可以暫時使用空白通關密語，日後再透過 `ssh-keygen` 變更。

在執行個體上檢查主機名稱：

```
$ hostname
```

由於您在建立叢集時指定了 `--scopes=cloud-platform`，因此可以在叢集上執行 `gcloud` 指令。列出專案中的叢集：

```
$ gcloud dataproc clusters list
```

完成後，請登出 SSH 連線：

```
$ logout
```

步驟 10 · 約 1 分鐘

10. 檢查代碼

建立叢集時，您加入了 `--tags` 選項，可為叢集中的每個節點新增標記。標記用於將防火牆規則附加至每個節點。您在本 Codelab 中未建立任何相符的防火牆規則，但仍可檢查節點上的標記和網路上的防火牆規則。

列印主節點的說明：

```
$ gcloud compute instances describe ${CLUSTERNAME}-m --zone us-central1-c
```

在輸出內容結尾附近尋找 `tags:`，確認其中包含 `codelab`。

列印防火牆規則：

```
$ gcloud compute firewall-rules list
```

請注意 `SRC_TAGS` 和 `TARGET_TAGS` 欄。只要將標記附加至防火牆規則，即可指定該規則應套用至所有具有該標記的節點。

步驟 11 · 約 2 分鐘

11. 關閉叢集

您可以透過 Cloud Dataproc API `clusters.delete` 要求、使用 `gcloud dataproc clusters delete` 可執行檔從指令列，或從 [Google Cloud Platform 主控台](#) 關閉叢集。

讓我們使用 Cloud Shell 指令列關閉叢集：

```
$ gcloud dataproc clusters delete ${CLUSTERNAME} --region us-central1
```

步驟 12 · 約 0 分鐘

12. 恭喜！

您已瞭解如何建立 Dataproc 叢集、提交 Spark 工作、調整叢集大小、使用 SSH 登入主要節點、使用 gcloud 檢查叢集、工作和防火牆規則，以及使用 gcloud 關閉叢集！

瞭解詳情

- Dataproc 說明文件：<https://cloud.google.com/dataproc/overview>
- [透過控制台開始使用 Dataproc](#) 程式碼研究室

授權

這項內容採用的授權為創用 CC 姓名標示 3.0 通用授權和 Apache 2.0 授權。
