

開始使用 BigQuery 機器學習

來源：<https://codelabs.developers.google.com/codelabs/bqml-intro?hl=zh-tw>

步驟數：7

在本程式碼研究室中，您將瞭解如何使用 BigQuery 建立 Analytics 360 資料集的機器學習模型。

目錄

1. [1. 總覽](#)
2. [2. 設定和需求](#)
3. [3. 建立資料集](#)
4. [4. 建立模型](#)
5. [5. 評估模型](#)
6. [6. 使用模型](#)
7. [7. 恭喜！](#)

步驟 1 · 約 2 分鐘

1. 總覽

BigQuery ML (BQML) 可讓使用者透過 SQL 查詢，在 BigQuery 中建立及執行機器學習模型，目標是讓 SQL 使用者能透過現有的工具建立模型，而且不必移動資料，可加快開發速度，使所有人都能輕鬆使用機器學習技術。

建構項目

您將使用 [Analytics 360 樣本資料集](#) 建立模型，預測訪客是否會完成交易。

課程內容

如何在 BigQuery 建立、評估與使用機器學習模型

軟硬體需求

- [Chrome](#) 或 [Firefox](#) 瀏覽器
 - SQL 或 BigQuery 的基本知識
 - BigQuery ML [說明文件](#)
-

步驟 2 · 約 5 分鐘

2. 設定和需求

自修實驗室環境設定

1. 登入 [Cloud 控制台](#)，建立新專案或重複使用現有專案。如果沒有 Gmail 或 Google Workspace 帳戶，請先[建立帳戶](#)。

注意：記住以下網址，即可輕鬆存取 Cloud 控制台：`console.cloud.google.com`。

The screenshot shows the Google Cloud Platform interface. At the top, there's a blue header with the Google Cloud Platform logo and a 'Select a project' dropdown menu. Below this, there's a 'Select a project' dialog. The dialog has a search bar labeled 'Search projects and folders'. Below the search bar, there's a 'New Project' section. In this section, the 'Project name' field is filled with 'my-kubernetes-codelab' and has a question mark icon. The 'Project ID' field shows 'my-kubernetes-codelab' and is circled in blue. Below the Project ID, it says 'It cannot be changed later.' and there's an 'EDIT' link. The 'Location' field is set to 'No organization' and has a 'BROWSE' link. At the bottom, there are 'CREATE' and 'CANCEL' buttons. The 'CREATE' button is highlighted.

請記住專案 ID，這是所有 Google Cloud 專案中不重複的名稱 (上述名稱已遭占用，因此不適用於您，抱歉！)。本程式碼研究室稍後會將其稱為 `PROJECT_ID`。


注意：如果您使用 Gmail 帳戶，可以將預設位置設為「沒有機構」。如果您使用 Google Workspace 帳戶，請選擇適合貴機構的位置。

2. 接著，您必須在 Cloud 控制台中[啟用帳單](#)，才能使用 Google Cloud 資源。


完成本程式碼研究室的費用應該不高，甚至完全免費。請務必按照「清除」部分的指示操作，瞭解如何停用資源，避免在本教學課程結束後繼續產生帳單費用。Google Cloud 新使用者可參加[價值\\$300 美元的免費試用計畫](#)。

開啟 BigQuery 控制台

在 Google 開發人員控制台中，按一下畫面左上方的「選單」圖示。



向下捲動選單至底部，然後點選「BigQuery」：



瀏覽器會開啟新的分頁，顯示 BigQuery 控制台，如下所示：

COMPOSE QUERY

Query History

Job History

BigQuery Lab



No datasets found in this project.

Please create a dataset or select a new project from the menu above.

Recent Queries


No recent queries to display. To start a new query, click "Compose Query".

但裡面什麼都沒有！幸運的是，BigQuery 中有大量的公開資料集可供探索。

步驟 3 · 約 1 分鐘

3. 建立資料集

如要建立資料集，請點選專案名稱旁的箭頭，然後選取「建立新資料集」。



接著，將資料集命名為 bqml_codelab，然後按一下「確定」。

COMPOSE QUERY

Query History

Job History

Filter by ID or label

Demo Project

demo

bigquery-public-data

Public Datasets

Queries

☐ Show queries for all users

Query History

Saved Queries

Project Queries

Sort by: Date

1 - 50 of 514

Filter queries

✓ SELECT t0.gender, t0.name, t0.name_total, t0.year FROM (#standardSQL SELECT name, year...	Open Query	Jun 21
✓ #standardSQL SELECT name, year, gender, SUM(number) AS name_total FROM `bigquery-pu...	Open Query	Jun 21
✓ #standardSQL SELECT subject, COUNT(*) AS num_duplicates FROM `bigquery-public-data.git...	Open Query	Jun 20
	Open Query	Mar 19
	Open Query	Feb 23
	Open Query	Feb 23
	Open Query	Feb 22
	Open Query	Feb 13
	Open Query	Jan 18
	Open Query	Jan 18
	Open Query	Jan 18
✓ #standardSQL SELECT project, SUM(questions) / downloads AS dpq, SUM(questions) AS total...	Open Query	Jan 18
✓ #standardSQL SELECT project, SUM(questions) / downloads AS dpq, SUM(questions) AS total...	Open Query	Jan 18
✓ #standardSQL SELECT project, SUM(questions) / downloads AS dpq, SUM(questions) AS total...	Open Query	Jan 18
✓ #standardSQL SELECT project, SUM(questions) / downloads AS dpq, SUM(questions) AS total...	Open Query	Jan 18
✓ #standardSQL SELECT project, SUM(questions) / downloads AS dpq, SUM(questions) AS total...	Open Query	Jan 18
✓ #standardSQL SELECT file.project AS project, url, details FROM `the-psf.pypl.downloads20170...	Open Query	Jan 18

Create Dataset

Dataset ID

bqml_codelab

Data location

us

Data expiration

☒ Never☐ In

days.

OK

Cancel

步驟 4 · 約 5 分鐘

4. 建立模型

Analytics 360 的邏輯迴歸

接著來執行工作。以下說明如何建立模型，預測訪客是否會完成交易。

```
#standardSQL
CREATE OR REPLACE MODEL `bqml_codelab.sample_model`
OPTIONS(model_type='logistic_reg') AS
SELECT
  IF(totals.transactions IS NULL, 0, 1) AS label,
  IFNULL(device.operatingSystem, "") AS os,
  device.isMobile AS is_mobile,
  IFNULL(geoNetwork.country, "") AS country,
  IFNULL(totals.pageviews, 0) AS pageviews
FROM
  `bigquery-public-data.google_analytics_sample.ga_sessions_*`
WHERE
  _TABLE_SUFFIX BETWEEN '20160801' AND '20170631'
LIMIT 100000;
```

這裡使用下列條件判斷訪客是否會完成交易：訪客裝置使用的作業系統、該裝置是否為行動裝置、訪客的國家/地區，以及網頁瀏覽次數。

在本例中，「codelab」是資料集名稱，「sample_model」則是模型名稱。指定的模型類型為二元邏輯迴歸。在本例中，`label` 是我們調整的依據。請注意，如果您只想處理 1 欄資料，可以改用這種方式設定 `input_label_cols`。此外，我們也會將訓練資料限縮為 2016 年 8 月 1 日到 2017 年 6 月 31 日收集的資料，以保留最後一個月的資料來做「預測」。此外，為節省時間，我們將資料點限制為 100,000 個。如果時間充裕，可以移除最後一行。

執行 CREATE MODEL 指令後，非同步執行的查詢工作會隨即建立，方便您關閉或重新整理 BigQuery UI 視窗等。

[非必要] 模型資訊與訓練統計資料

如果感興趣，您可以點選 UI 中 `bqml_codelab` 資料集下方的 `sample_model`，取得模型資訊。在「詳細資料」下，您會找到一些基本的模型資訊，以及用於產生模型的訓練選項。在「訓練統計資料」下方，您會看見類似下方的資料表：

Row	Iteration	Training Data Loss	Evaluation Data Loss	Learn Rate	Completion Time (seconds)
1	10	0.0394	0.0384	12.8000	12.56
2	9	0.0396	0.0385	12.8000	13.57
3	8	0.0401	0.0391	51.2000	11.26
4	7	0.0413	0.0399	25.6000	11.27
5	6	0.0440	0.0428	12.8000	10.09
6	5	0.0505	0.0498	6.4000	10.10
7	4	0.0644	0.0642	3.2000	15.25
8	3	0.0943	0.0945	1.6000	11.74
9	2	0.1671	0.1673	0.8000	11.09
10	1	0.3188	0.3190	0.4000	10.88
11	0	0.5206	0.5207	0.2000	10.93

5. 評估模型

評估模型

```
#standardSQL
SELECT
  *
FROM
  ml.EVALUATE(MODEL `bqml_codelab.sample_model`, (
SELECT
  IF(totals.transactions IS NULL, 0, 1) AS label,
  IFNULL(device.operatingSystem, "") AS os,
  device.isMobile AS is_mobile,
  IFNULL(geoNetwork.country, "") AS country,
  IFNULL(totals.pageviews, 0) AS pageviews
FROM
  `bigquery-public-data.google_analytics_sample.ga_sessions_`
WHERE
  _TABLE_SUFFIX BETWEEN '20170701' AND '20170801'));
```

如果搭配使用線性迴歸模型，上述查詢會傳回下列資料

欄：`mean_absolute_error`、`mean_squared_error`、`mean_squared_log_error`、`median_absolute_error`、`r2_score`、`explained_variance`。如果搭配使用邏輯迴歸模型，上述查詢會傳回下列資料

欄：`precision`、`recall`、`accuracy`、`f1_score`、`log_loss`、`roc_auc`。請參閱「[機器學習詞彙表](#)」或使用 Google 搜尋，瞭解這些指標的計算方式與意義。

具體來說，您會發現查詢中的 `SELECT` 和 `FROM` 部分與訓練時相同。`WHERE` 部分會反映時間範圍內的變化，而 `FROM` 部分顯示目前正在呼叫 `ml.EVALUATE`。您會看見類似下方的資料表：

Row	precision	recall	accuracy	f1_score	log_loss	roc_auc
1	0.4573643410852713	0.10531012940651495	0.9717447755657228	0.17120058034095031	0.07833478875470493	0.969531

6. 使用模型

預測各國家/地區的購買量

接下來，這項查詢可預測各國家/地區訪客的交易量、排序結果，並選出購買量前 10 多的國家/地區。

```
#standardSQL
SELECT
  country,
  SUM(predicted_label) as total_predicted_purchases
FROM
  ml.PREDICT(MODEL `bqml_codelab.sample_model`, (
  SELECT
    IFNULL(device.operatingSystem, "") AS os,
    device.isMobile AS is_mobile,
    IFNULL(totals.pageviews, 0) AS pageviews,
    IFNULL(geoNetwork.country, "") AS country
  FROM
    `bigquery-public-data.google_analytics_sample.ga_sessions_*`
  WHERE
    _TABLE_SUFFIX BETWEEN '20170701' AND '20170801'))
GROUP BY country
ORDER BY total_predicted_purchases DESC
LIMIT 10;
```

您會發現，這項查詢與前一部分示範的評估查詢很類似。我們在這裡使用 `ml.PREDICT` 而非 `ml.EVALUATE`，並以標準 SQL 指令包裝查詢的 BQML 部分。具體來說，我們想瞭解交易國家/地區和各自的總購買量，所以選擇 `SELECT`、`GROUP BY` 和 `ORDER BY`。這裡使用 `LIMIT`，確保只會傳回前 10 個結果。您會看見類似下方的資料表：

Row	country	total_predicted_purchases
1	United States	467
2	Canada	8
3	Taiwan	6
4	India	5
5	United Kingdom	3
6	Turkey	3
7	Japan	2
8	Germany	2
9	Hong Kong	2
10	Singapore	2

預測各使用者的購買量

再來看看另一個例子。這次，我們將嘗試預測各訪客的交易量、排序結果，並選出交易量排名 10 的訪客。

```
#standardSQL
SELECT
  fullVisitorId,
  SUM(predicted_label) as total_predicted_purchases
FROM
  ml.PREDICT(MODEL `bqml_codelab.sample_model`, (
SELECT
  IFNULL(device.operatingSystem, "") AS os,
  device.isMobile AS is_mobile,
  IFNULL(totals.pageviews, 0) AS pageviews,
  IFNULL(geoNetwork.country, "") AS country,
  fullVisitorId
FROM
  `bigquery-public-data.google_analytics_sample.ga_sessions_*`
WHERE
  _TABLE_SUFFIX BETWEEN '20170701' AND '20170801'))
GROUP BY fullVisitorId
ORDER BY total_predicted_purchases DESC
LIMIT 10;
```

您會看見類似下方的資料表：

Row	fullVisitorId	total_predicted_purchases
1	2537542953699076910	4
2	9681060687378784629	3
3	710224483954829635	3
4	9360335725081440162	3
5	0069486905584188344	3
6	0456807427403774085	2
7	934912509102719437	2
8	0115482077220804034	2
9	8946235742138524977	2
10	358494047576346947	2

步驟 7 · 約 0 分鐘

7. 恭喜！

您已完成本程式碼研究室。想接受挑戰嗎？嘗試使用 BigQuery ML 建立線性迴歸模型。

涵蓋內容

- 建立二元邏輯迴歸模型
- 評估模型
- 使用模型進行預測

後續步驟

- 如要進一步瞭解 BigQuery ML，請參閱[說明文件](#)。
-