

# 在 BigQuery 查詢 Wikipedia 資料集

來源：<https://codelabs.developers.google.com/codelabs/cloud-bigquery-wikipedia?hl=zh-tw>

步驟數：9

在本程式碼研究室中，您將瞭解 BigQuery 的基本概念，以及如何使用 BigQuery 查詢 TB 規模的資料，例如 Wikipedia 資料集。

---

# 目錄

1. [1. 總覽](#)
2. [2. 設定和需求](#)
3. [3. 建立資料集](#)
4. [4. 使用 bq 指令列程式載入資料](#)
5. [5. 預覽資料集](#)
6. [6. 撰寫查詢](#)
7. [7. 更進階的查詢](#)
8. [8. 正在清除所用資源](#)
9. [9. 恭喜！](#)

步驟 1 · 約 1 分鐘

## 1. 總覽

BigQuery 是 Google 的全代管 NoOps 數據分析資料庫，價格實惠，您可以使用 BigQuery 查詢 TB 規模的資料，不必管理基礎架構，也不需要資料庫管理員。BigQuery 使用熟悉的 SQL 語法，並提供「即付即用」模式。您可專心分析資料，找出有意義的深入分析結果。

在本程式碼實驗室中，您將使用 BigQuery 探索 Wikipedia 資料集。

### 課程內容

- 如何使用 BigQuery
- 如何將實際資料集載入 BigQuery
- 如何編寫查詢，深入瞭解大型資料集

### 軟硬體需求

- 具備 Google Cloud 專案
- 瀏覽器，例如 [Google Chrome](#) 或 [Firefox](#)

### 問卷調查

---

步驟 2 · 約 5 分鐘

## 2. 設定和需求

### 啟用 BigQuery

如果沒有 Google 帳戶，請先[建立帳戶](#)。

1. 登入 [Google Cloud 控制台](#)，然後前往 BigQuery。您也可以在瀏覽器中輸入下列網址，直接開啟 BigQuery 網頁版 UI。

```
https://console.cloud.google.com/bigquery
```

2. 接受服務條款。
3. 您必須先建立專案，才能使用 BigQuery。請依照提示建立新專案。

選擇專案名稱，並記下專案 ID。

### New Project

Project Name \*

my-codelab-project ?

Project ID: my-codelab-project-207619. It cannot be changed later. [EDIT](#)

Billing account \*

所有 Google Cloud 專案的專案 ID 都是不重複的名稱。本程式碼研究室稍後會將其稱為 `PROJECT_ID`。

本程式碼研究室使用的 BigQuery 資源，皆在 [BigQuery 沙箱限制](#)內。不需要帳單帳戶。如要移除沙箱限制，請註冊 Google Cloud 免費試用方案，並新增帳單帳戶。


您會在下一節載入維基百科資料集。

步驟 3 · 約 2 分鐘

### 3. 建立資料集

首先，請在專案中建立新的資料集。資料集由多個資料表組成。

1. 如要建立資料集，請按一下資源窗格中的專案名稱，然後點選「建立資料集」：



2. 輸入 lab 做為資料集 ID：

Google Cloud Platform

Demo Project

SANDBOX

Set up billing to upgrade to the full BigQuery editor

BigQuery

FEATURES & INFO

SHORTCUTS

Query history

Saved queries

Job history

Transfers

Scheduled queries

BI Engine

Resources

+ ADD DATA

Search for your tables and datas...

your-project-id

Query editor

1

Run

Create dataset

Dataset ID

lab

Data location (Optional)

United States (US)

Default table expiration

60 days (maximum for sandbox)

Number of days after table creation:

60

Encryption

Data is encrypted automatically. Select an encryption key management solution.

Google-managed key

No configuration required

Customer-managed key

Manage via Google Cloud Key Management Service

Create dataset

Cancel

3. 按一下「建立資料集」，建立空白資料集。

步驟 4 · 約 5 分鐘

## 4. 使用 bq 指令列程式載入資料

### 啟用 Cloud Shell


1. 在 Cloud 控制台，點選「啟用 Cloud Shell」圖示



。



如果您是首次啟動 Cloud Shell，系統會顯示中繼畫面 (位於摺疊式選單下方)，說明這個指令列環境。點選「繼續」後，這則訊息日後就不會再出現。以下是這個初次畫面的樣子：



佈建並連至 Cloud Shell 預計只需要幾分鐘。



```
Welcome to Cloud Shell! For help, visit https://cloud.google.com/cloud-shell/help.  
testuser003@codelab-test003:~$ gcloud auth list
```

這部虛擬機器搭載您需要的所有開發工具，並提供永久的 5GB 主目錄，而且可在 Google Cloud 運作，大幅提升網路效能並強化驗證功能。本程式碼研究室幾乎所有工作都可在瀏覽器或 Chromebook 上完成。

連線至 Cloud Shell 後，您應會發現自己通過驗證，且專案已設為您的專案 ID。

2. 在 Cloud Shell 中執行下列指令，確認您已通過驗證：

```
gcloud auth list
```

指令輸出

#### Credentialed Accounts

ACTIVE ACCOUNT

```
* <my_account>@<my_domain.com>
```

To set the active account, run:

```
$ gcloud config set account `ACCOUNT`
```

**注意：** `gcloud` 指令列工具是 Google Cloud 中功能強大的整合式指令列工具，並已預先安裝於 Cloud Shell。你會發現它支援 Tab 鍵自動完成功能。詳情請參閱 [gcloud 指令列工具總覽](#)。

3. 在 Cloud Shell 中執行下列指令，確認 `gcloud` 指令知道您的專案：

```
gcloud config list project
```

#### 指令輸出

```
[core]
project = <PROJECT_ID>
```

如未設定，請輸入下列指令手動設定專案：

```
gcloud config set project <PROJECT_ID>
```

#### 指令輸出

```
Updated property [core/project].
```

## 將資料載入 BigQuery

為方便作業，我們已將 2019 年 4 月 10 日的部分資料上傳至 Google Cloud Storage (位置：`gs://cloud-samples-data/third-party/wikimedia/pageviews/pageviews-20190410-140000.gz`)，這些資料來自 [Wikimedia 網頁瀏覽資料集](#)。資料檔案是經過 GZip 壓縮的 CSV 檔案。您可以使用 `bq` 指令列公用程式直接載入這個檔案。您也可以載入指令中說明檔案的結構定義。

您可以從 API 控制台或指令列找到專案 ID：「`gcloud config list`」，然後尋找「`project`」的值。

此外，首次執行 `bq` 時，系統可能會要求您選取預設專案。選取後，即可重新執行上述指令來載入資料。

```
bq load \  
  --source_format CSV \  
  --field_delimiter " " \  
  --allow_jagged_rows \  
  --quote "" \  
  --max_bad_records 3 \  
  $GOOGLE_CLOUD_PROJECT:lab.pageviews_20190410_140000 \  
  gs://cloud-samples-data/third-party/wikimedia/pageviews/pageviews-20190410-140000.gz \  
  wiki,title,requests:integer,zero:integer
```

資料載入作業可能需要幾分鐘才能完成。等待作業完成。

您使用了幾個進階選項來載入網頁瀏覽檔案：

- 設定為 `--source_format CSV`，表示檔案應剖析為 CSV 檔案。CSV 是預設格式，因此這個步驟為選用步驟。
- 將 `--field_delimiter " "` 設為以單一空格做為欄位分隔符號。
- 設定 `--allow_jagged_rows`，納入資料欄數較少的資料列，並在載入 CSV 檔案時忽略錯誤。
- 將 `--quote ""` 設為表示字串未加上引號。
- 將 `--max_bad_records 3` 設為在剖析 CSV 檔案時最多忽略 3 個錯誤。


如要進一步瞭解 bq 指令列，請參閱[說明文件](#)。

---

## 5. 預覽資料集

在 BigQuery 控制台中，開啟您剛載入的其中一個資料表。

- 1. 展開專案。
- 2. 展開資料集。
- 3. 選取資料表。



您可以在「結構定義」分頁中查看資料表結構定義。4. 前往「詳細資料」分頁標籤，即可查看資料表中的資料量：

Google Cloud Platform Demo Project

SANDBOX Set up billing to upgrade to the full BigQuery experience. [Learn more](#) DISMISS UPGRADE

BigQuery FEATURES & INFO SHORTCUTS + COMPOSE NEW QUERY

Query history

Saved queries

Job history

Transfers

Scheduled queries

BI Engine

Resources + ADD DATA

Search for your tables and datasets

your-project-l 1 hour, 41 minutes remaining

lab

pageviews\_20190410\_140000

pageviews\_20190410\_150000

bigquery-public-data

Query editor SHOW EDITOR FULL SCREEN

pageviews\_20190410\_140000

Schema Details Preview

Description Labels

None None

Table info

|                  |                                                    |
|------------------|----------------------------------------------------|
| Table ID         | groovy-vector-197119:lab.pageviews_20190410_140000 |
| Table size       | 691.41 MB                                          |
| Number of rows   | 16,233,992                                         |
| Created          | Oct 2, 2019, 3:32:00 PM                            |
| Table expiration | Dec 1, 2019, 2:32:00 PM                            |
| Last modified    | Oct 2, 2019, 3:34:19 PM                            |
| Data location    | US                                                 |

5. 開啟「預覽」分頁，即可查看資料表中的部分資料列。

Google Cloud Platform

Demo Project

SANDBOX

Set up billing to upgrade to the full BigQuery experience. [Learn more](#)

DISMISS

UPGRADE

BigQuery

FEATURES & INFO

SHORTCUTS

+ COMPOSE NEW QUERY

Query history

Saved queries

Job history

Transfers

Scheduled queries

BI Engine

Resources

+ ADD DATA

Search for your tables and datasets

your-project-id

lab

pageviews\_20190410\_1400...

pageviews\_20190410\_1500...

bigquery-public-data

Query editor

SHOW EDITOR

FULL SCREEN

pageviews\_20190410\_140000

EXPORT

Schema

Details

Preview


| Row | wiki | title                                 | requests | zero |
|-----|------|---------------------------------------|----------|------|
| 1   | ab   | Алахэыла:MacMed                       | 1        | 0    |
| 2   | ab   | Мысра_(ақыта)                         | 1        | 0    |
| 3   | ab   | Цастәи:Ссылки_сюда/Акатеропиа:User_az | 1        | 0    |
| 4   | ab   | Цәыббра_20                            | 1        | 0    |
| 5   | ab.m | Аһсуаа                                | 2        | 0    |
| 6   | ace  | Kawan:User_tly                        | 1        | 0    |
| 7   | ace  | Marit_Ureuëng_Ngui:WhisperToMe        | 1        | 0    |
| 8   | ace  | Mongolia                              | 2        | 0    |
| 9   | ace  | Seunaleuëk:Lang-qu                    | 1        | 0    |
| 10  | ace  | Seunaleuëk:Langname                   | 2        | 0    |

Rows per page: 10 1 - 10 of 16233992 First page < > >| Last page


步驟 6 · 約 5 分鐘

## 6. 撰寫查詢

1. 按一下「撰寫新查詢」：




系統會顯示「查詢編輯器」：



2. 如要找出 2019 年 4 月 10 日下午 2 點到 3 點的維基媒體總瀏覽次數，請編寫下列查詢：

```
SELECT SUM(requests)
FROM `lab.pageviews_20190410_140000`
```

3. 按一下「執行」：



幾秒後，結果就會列在底部，並顯示處理的資料量：

| Query results                            |          |  SAVE RESULTS ▼ |  EXPLORE WITH DATA STUDIO |
|------------------------------------------|----------|--------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|
| Query complete (0.7 sec elapsed, cached) |          |                                                                                                  |                                                                                                            |
| Job information                          |          | Results                                                                                          | JSON   Execution details                                                                                   |
| Row                                      | f0_      |                                                                                                  |                                                                                                            |
| 1                                        | 56129112 |                                                                                                  |                                                                                                            |

即使資料表大小為 691.4 MB，這項查詢處理的資料量仍為 123.9 MB。BigQuery 只會處理查詢中使用的資料欄位元組，因此處理的資料總量可能遠小於資料表大小。使用[分群](#)和[分區](#)，可進一步減少處理的資料量。

每個月可免費處理/查詢最多 1 TB 的資料。詳情請參閱 [BigQuery 定價頁面](#)。

步驟 7 · 約 5 分鐘

## 7. 更進階的查詢

### 尋找維基百科網頁瀏覽次數

Wikimedia 資料集包含所有 [Wikimedia 專案](#) (包括維基百科、維基詞典、維基教科書和維基語錄) 的網頁瀏覽次數。新增 `WHERE` 陳述式，將查詢範圍縮小至僅限英文維基百科頁面：

```
SELECT SUM(requests), wiki
FROM `lab.pageviews_20190410_140000`
WHERE wiki = "en"
GROUP BY wiki
```

Query editor

HIDE EDITOR

FULL SCREEN

```
1 SELECT SUM(requests), wiki
2 FROM `lab.pageviews_20190410_140000`
3 WHERE wiki = "en"
4 GROUP BY wiki
5
```

Run

Save query

Save view

Schedule query

More

This query will process 204 MB when run.

✓

Query results

SAVE RESULTS

EXPLORE WITH DATA STUDIO

Query complete (0.2 sec elapsed, cached)

Job information

Results

JSON

Execution details

| Row | f0_      | wiki |
|-----|----------|------|
| 1   | 12147724 | en   |

請注意，查詢額外資料欄 `wiki` 後，處理的資料量從 124 MB 增加到 204 MB。

BigQuery 支援許多常見的 SQL 子句，例如 `CONTAINS`、`GROUP BY`、`ORDER BY` 和多種匯總函式。此外，您也可以使用規則運算式查詢文字欄位！請嘗試下列方法：

```
SELECT title, SUM(requests) requests
FROM `lab.pageviews_20190410_140000`
WHERE
  wiki = "en"
  AND REGEXP_CONTAINS(title, 'Red.*t')
GROUP BY title
ORDER BY requests DESC
```

如要進一步瞭解 BigQuery 語法，請參閱 [BigQuery 查詢參考資料說明文件](#)。

## 查詢多個資料表

您可以使用 [萬用字元資料表](#) 選取資料表範圍，形成聯集。

1. 首先，載入下一個小時的網頁瀏覽次數，建立第二個資料表以供查詢：

```
bq load \  
  --source_format CSV \  
  --field_delimiter " " \  
  --quote "" \  
  $GOOGLE_CLOUD_PROJECT:lab.pageviews_20190410_150000 \  
  gs://cloud-samples-data/third-party/wikimedia/pageviews/pageviews-20190410-150000.gz \  
  wiki,title,requests:integer,zero:integer
```

2. 在「查詢編輯器」中，使用「`pageviews_2019`」前置字串查詢資料表，即可查詢載入的兩個資料表：

```
SELECT title, SUM(requests) requests  
FROM `lab.pageviews_2019*`  
WHERE  
  wiki = "en"  
  AND REGEXP_CONTAINS(title, 'Red.*t')  
GROUP BY title  
ORDER BY requests DESC
```

您可以使用 [\\_TABLE\\_SUFFIX](#) 虛擬資料欄，[更精確地篩選資料表](#)。這項查詢會限制為與 4 月 10 日相應的表格。

```
SELECT title, SUM(requests) requests  
FROM `lab.pageviews_2019*`  
WHERE  
  _TABLE_SUFFIX BETWEEN '0410' AND '0410_9999999'  
  AND wiki = "en"  
  AND REGEXP_CONTAINS(title, 'Red.*t')  
GROUP BY title  
ORDER BY requests DESC
```

步驟 8 · 約 2 分鐘

## 8. 正在清除所用資源

(選用) 使用 `bq rm` 指令刪除您建立的資料集。使用 `-r` 旗標移除其中包含的所有資料表。

```
bq rm -r lab
```

---

步驟 9 · 約 0 分鐘

## 9. 恭喜！

您已使用 BigQuery 和 SQL 查詢真實的維基百科網頁瀏覽資料集。您有權查詢 PB 規模的資料集！

### 瞭解詳情

- 歡迎前往 [BigQuery 子論壇](#)，瞭解其他人目前如何使用 BigQuery。
  - 尋找 [BigQuery 中提供的公開資料集](#)。
  - 瞭解如何[將資料載入 BigQuery](#)。
-