

使用 Vertex AI 建立 AutoML 預測模型

來源：<https://codelabs.developers.google.com/codelabs/automl-forecasting-with-vertex-ai?hl=zh-tw>

步驟數：5

在本實驗室中，您將瞭解如何使用 Vertex AI 中的 AutoML 訓練及部署預測模型。

目錄

1. [1. 總覽](#)
2. [2. 查看資料](#)
3. [3. 匯入資料](#)
4. [4. 訓練模型](#)
5. [5. 預測](#)

步驟 1 · 約 1 分鐘

1. 總覽

本實驗室的學習內容如下：

- 建立代管資料集
 - 從 Google Cloud Storage 值區匯入資料
 - 更新欄中繼資料，以便適當搭配 AutoML 使用
 - 使用預算和最佳化目標等選項訓練模型
 - 進行線上批次預測
-

2. 查看資料

本實驗室會使用 BigQuery 公開資料集的[愛荷華州酒類銷售量資料集](#)。這個資料集包含 2012 年以來，美國愛荷華州批發酒類購買交易的資料。

選取「查看資料集」即可查看原始資料。如要存取表格，請在左側導覽列中依序前往「bigquery-public-datasets」專案、「iowa_liquor_sales」資料集和「sales」表格。選取「預覽」即可查看資料集中的部分資料列。

iowa_liquor_sales

sales

irs_990

labeled_patents

libraries_io

london_bicycles

london_crime

london_fire_brigade

sales

SchemaDetailsPreview

Row	invoice_and_item_number	date	store_number	store_name
1	INV-17405400008	2019-02-07	3814	Costco Wholesale #788 / WDM
2	S31021500029	2016-03-01	2602	Hy-Vee Food Store / Webster City
3	S31201800066	2016-03-14	2191	Keokuk Spirits
4	INV-19479400030	2019-05-20	5505	Liquor Barn II
5	INV-19542900066	2019-05-22	5257	MAD Ave Quik Shop

在本實驗室中，我們已完成一些基本資料前處理作業，將購買交易依日期分組。我們會使用從 BigQuery 資料表匯出的 CSV 檔案。CSV 檔案中的資料欄如下：


- **ds**：日期
- **y**：當天所有購買交易的總金額 (以美元計)
- **holiday**：日期是否為美國節日的布林值
- **id**：時間序列 ID (支援多個時間序列，例如依商店或產品)。在本例中，我們只會預測單一時間序列的整體購買量，因此每列的 ID 都會設為 0。

步驟 3 · 約 10 分鐘

3. 匯入資料

步驟 1：前往 Vertex AI 資料集

在 [Cloud 控制台](#) 的左側導覽列中，存取 **Vertex AI** 選單中的「資料集」。



步驟 2：建立資料集

建立新的資料集，選取「表格資料」，然後選取「預測」問題類型。選擇 `iowa_daily` 或其他偏好的名稱。

Create dataset

Dataset name *

iowa_daily

Can use up to 128 characters.

Select a data type and objective


First select the type of data your dataset will contain. Then select an objective, which is the outcome that you want to achieve with the trained model. [Learn more about model types](#)

IMAGE

TABULAR

TEXT

VIDEO



☐ **Regression/classification**

Predict a target column's value. Supports tables with hundreds of columns and millions of rows.



☒ **Forecasting**

Predict the likelihood of certain events or demand.

Region

us-central1 (Iowa)



CREATE

CANCEL

步驟 3：匯入資料

下一步是將資料匯入資料集。選擇「選取 Cloud Storage 中的 CSV 檔案」選項。然後前往 AutoML Demo Alpha bucket 中的 CSV 檔案，並貼上 **automl-demo-240614-lcm/iowa_liquor/iowa_daily.csv**。

4. 訓練模型

步驟 1：設定模型功能

幾分鐘後，AutoML 會通知您匯入作業已完成。屆時即可設定模型功能。

- 選取要當做 **ID** 的「時間序列 ID 欄」。我們的資料集中只有一個時間序列，因此這只是形式上的做法。
- 選取要 **ds** 的「時間」欄。

然後選取「產生統計資料」。程序完成後，您會看到「缺少 %」和「相異值」統計資料。這項程序可能需要幾分鐘，因此你可以先進行下一個步驟。

步驟 2：訓練模型

選取「訓練模型」即可開始訓練程序。確認已選取 AutoML，然後按一下「繼續」。

Train new model

- 1 Choose training method
- 2 Define your model
- 3 Choose training options
- 4 Compute and pricing

START TRAINING CANCEL

Dataset
iowa_daily

Please refer to the pricing guide for more details (and available deployment options) for each method.

1 Custom training with a managed dataset is not currently available. [Learn more about custom model training](#)

☒ AutoML
Train high-quality models with minimal effort and machine learning expertise. Just specify how long you want to train. [Learn more](#)

☐ Custom training (advanced)
Run your TensorFlow, scikit-learn, and XGBoost training applications in the cloud. Train with one of Google Cloud's pre-built containers or use your own. [Learn more](#)

CONTINUE

步驟 3：定義模型

- 選取要設為 **y** 的「目標資料欄」。這就是我們要預測的值。
- 如果先前未設定，請將「時間序列 ID」欄設為 **id**，並將「時間戳記」欄設為 **ds**。
- 將「資料精細程度」設為「天」，並將「預測期間」設為「7」。這個欄位會指定模型可預測的未來週期數。
- 將「背景期間」設為 **7** 天。模型會使用過去 30 天的資料進行預測。較短和較長的區間各有優缺點，一般建議選取預測期間的 1 至 10 倍。
- 勾選「將測試資料集匯出至 BigQuery」方塊。您可以將其留空，系統會在專案中自動建立資料集和資料表 (或指定您選擇的位置)。
- 選取「繼續」。

Train new model

☒ Training method

☒ Model details

☐ Training options

☐ Compute and pricing

START TRAINING

CANCEL

Model name *
iowa_daily_2021520184412



Target column *
y



Series identifier column *
id



Timestamp column *
ds



Forecasting configuration

Data granularity *
Daily



The granularity level of the timestamp column. Granularity must be the same for all rows. For example, if "days" is selected, timestamps must be within one day of each other. Data granularity also sets the time period granularity for the forecast horizon and context window.

Forecast horizon *
7

The number of time periods into the future for which forecasts will be created. Future periods start from the most recent timestamp in the dataset.

Context window *
7

Defines the input lags to the model for each time series. For most use cases, the context window is between 0-5 times the forecast horizon value. For a starting point, try setting the context window equal to the forecast horizon value. [Learn more](#)

☒ Export test dataset to BigQuery

BigQuery Table

BROWSE

Data validation options

AutoML Forecast can perform multiple validations on your dataset to ensure the best model quality


☒ Cancel training
If data validation fails, then model training will be canceled

☐ Ignore validation
Bypass the data validations

Data split

☒ Chronological
The dataset is sorted by timestamp. The earliest 80% of rows are assigned to training, the next 10% to validation and the most recent 10% to test. [Learn more](#)

☐ Training 80% ☐ Validation 10% ☐ Testing 10%



☐ Manual
You assign each data row for training, validation, and testing. [Learn more](#)

[^ SHOW LESS](#)[CONTINUE](#)

步驟 4：設定訓練選項

在這個步驟中，您可以指定更多模型訓練方式的詳細資料。

- 將「holiday」欄位設為「Available」，因為我們事先知道指定日期是否為假日。
- 將「最佳化目標」變更為「MAE」。相較於均方誤差，平均絕對誤差 (MAE) 對離群值的容錯能力較高。由於我們處理的是每日購買資料，這類資料的波動幅度可能很大，因此 MAE 是合適的指標。
- 選取「繼續」。

Train new model

☒ Training method☒ Model details☒ Training options☒ Compute and pricing[START TRAINING](#)[CANCEL](#)

i Before continuing, use the Transformation column to review and specify the data types in your dataset. If unspecified, AutoML will try to apply the most relevant transformation option.

Filter Enter property name or value

☐	Column name [↑]	Transformation	Feature type [?]	Available at forecast [?]	Missing % (count) [?]	Distinct values [?]	
☐	ds Timestamp column	Timestamp ▾	Covariate ▾	Available ▾	-	-	
☐	holiday	Auto ▾	Covariate ▾	Available ▾	-	-	⊖
☐	id Series identifier				-	-	
☐	y Target	Numeric ▾	Covariate ▾	Not Available ▾	-	-	

Total 3 feature columns are included in the training

Weight column

Select a column ▾

Optimization objective

☐ RMSE (Default)

Capture more extreme values accurately

☒ MAE

View extreme values as outliers with less impact on the model

☐ RMSLE

Penalize error on relative size rather than absolute value. Especially helpful when both predicted and actual values can be quite large. It is undefined when the predicted or ground truth is less than 0.

☐ RMSPE

Similar to RMSE, but relative to target magnitude. Useful when the range of values is large.

☐ WAPE

Measures the absolute error ratio of a target aggregated over time. Useful when the actual values are low.

☐ Quantile loss

A quantile is the value below which a fraction of observations in a group falls. For example, a prediction for quantile 0.9 should over-predict 90% of the times. Input comma separated values, e.g. 0.5, 0.75, 0.9

[^ SHOW LESS](#)

[CONTINUE](#)

步驟 5：啟動訓練

設定所需預算，在本例中，**1 個節點時數**就足以訓練模型。接著開始訓練程序。

步驟 6：評估模型

訓練程序可能需要 1 到 2 小時才能完成 (包括任何額外的設定時間)。訓練完成後，你會收到電子郵件通知。準備就緒後，您就可以查看所建模型的準確度。

5. 預測

步驟 1：查看測試資料的預測結果

前往 [BigQuery 控制台](#)，查看測試資料的預測結果。系統會在專案中自動建立新資料集，命名方式為：
export_evaluated_data_items + <model name> + <timestamp>。您可以在該資料集中找到 **evaluated_data_items** 資料表，查看預測結果。

這份表格新增了幾個資料欄：

- predicted_on_[date column]：預測日期。舉例來說，如果 predicted_on_ds 為 11/4，而 ds 為 11/8，則預測提前 4 天。
- predicted_[目標資料欄].tables.value：預測值

evaluated_data_items

Schema Details <u>Preview</u>						
Row	ds	holiday	id	predicted_on_ds	y	predicted_y.tables.value
501	11/8/19	0	0	11/4/19	1457920.75	1118400.25
502	12/2/19	0	0	12/1/19	1227092.23	1118430.375
503	12/2/19	0	0	11/30/19	1227092.23	1118413.625
504	12/2/19	0	0	12/2/19	1227092.23	1118420.875
505	12/2/19	0	0	11/29/19	1227092.23	1118254.0
506	12/2/19	0	0	11/27/19	1227092.23	1118391.5
507	12/2/19	0	0	11/28/19	1227092.23	1118400.25
508	12/2/19	0	0	11/26/19	1227092.23	1118365.875

步驟 2：執行批次預測

最後，您會想使用模型進行預測。

輸入檔案包含要預測日期的空值，以及歷來資料：

ds	holiday	id	y
2020 年 5 月 15 日	0	0	1751315.43
2020 年 5 月 16 日	0	0	0
2020 年 5 月 17 日	0	0	0

2020 年 5 月 18 日	0	0	1612066.43
2020 年 5 月 19 日	0	0	1773885.17
2020 年 5 月 20 日	0	0	1487270.92
2020 年 5 月 21 日	0	0	1024051.76
2020 年 5 月 22 日	0	0	1471736.31
2020 年 5 月 23 日	0	0	<empty>
2020/5/24	0	0	<empty>
2020 年 5 月 25 日	1	0	<empty>
2020 年 5 月 26 日	0	0	<empty>
2020/5/27	0	0	<empty>
2020/5/28	0	0	<empty>
2020 年 5 月 29 日	0	0	<empty>

在 AI Platform (Unified) 左側導覽列中，選取「批次預測」項目，即可建立新的批次預測。

系統已在儲存空間 bucket 中為您建立範例輸入檔案：[automi-demo-240614-lcm/iowa_liquor/iowa_daily_automi_predict.csv](#)

您可以提供這個來源檔案位置。接著，您可以選擇將預測結果匯出至雲端儲存空間 (CSV 格式) 或 BigQuery。在本實驗室中，請選取「BigQuery」，然後選擇「您的 Google Cloud 專案 ID」。

New batch prediction

Batch prediction name *

iowa_daily

Model name *

iowa_daily_2020121435846

Select source

☐ BigQuery table

☒ File on Cloud Storage (CSV)

File on Cloud Storage (CSV)

Your CSV file should contain the names of your feature columns as its first row. [More info on data formats](#)

Source path *

☒ gs://

automl-demo-240614-lcm/iowa_liquor/iowa_daily_automl_predict

BROWSE

Select a Cloud Storage location

Prediction results will be stored in the selected Cloud Storage bucket

Output format

BigQuery

Google Cloud project ID *

automl-demo-240614

ADVANCED OPTIONS

CREATE

CANCEL

批次預測程序需要幾分鐘才能完成。完成後，您可以點選批次預測工作來查看詳細資料，包括「匯出位置」。在 BigQuery 中，您需要前往左側導覽列中的專案 / 資料集 / 資料表，才能存取預測結果。

這項作業會在 BigQuery 中建立兩個不同的資料表。一個包含有錯誤的列，另一個則包含預測結果。以下是「預測」表格的輸出範例：

Schema		Details		Preview		
Row	ds	holiday	id	y	predicted_y.value	
1	05/23/20	0	0	null	245.98123168945312	
2	05/24/20	0	0	null	-22.84345817565918	
3	05/26/20	0	0	null	1494670.875	
4	05/27/20	0	0	null	1524374.625	
5	05/28/20	0	0	null	1436531.625	
6	05/29/20	0	0	null	1437240.875	
7	05/25/20	1	0	null	142179.375	

步驟 3：結論

恭喜！您已成功使用 AutoML 建構及訓練預測模型。在本實驗室中，我們介紹了如何匯入資料、建構模型及進行預測。

您已準備好建構自己的預測模型！

