

使用 BigQuery 查詢 GitHub 資料

來源：<https://codelabs.developers.google.com/codelabs/bigquery-github?hl=zh-tw>

步驟數：6

以 GitHub 修訂版本資料為例，瞭解 BigQuery 的基本概念，以及如何查詢 TB 規模的公開資料。

目錄

1. [簡介](#)
2. [做好準備](#)
3. [預覽 GitHub 資料](#)
4. [查詢 GitHub 資料](#)
5. [更多公開資料](#)
6. [恭喜！](#)

步驟 1 · 約 0 分鐘

1. 簡介

BigQuery 是 Google 的全代管低成本數據分析資料庫。您可以使用 BigQuery 查詢 TB 規模的資料，不必管理基礎架構，也不需要資料庫管理員。BigQuery 使用熟悉的 SQL，並採用「即付即用」的計費模式。您可專心分析資料，找出有意義的深入分析結果。

在本程式碼研究室中，您將瞭解如何查詢 [GitHub 公開資料集](#)，這是 [BigQuery 中提供的眾多公開資料集](#) 之一。

課程內容

- 如何使用 BigQuery
- 如何編寫查詢，深入瞭解大型資料集

軟硬體需求

- 具備 Google Cloud 專案
 - [Chrome](#) 或 [Firefox](#) 瀏覽器
-

步驟 2 · 約 5 分鐘

2. 做好準備

啟用 BigQuery

如果您沒有 Google 帳戶 (Gmail 或 Google 應用程式)，請先[建立帳戶](#)。

- 登入 Google Cloud Platform 控制台 (console.cloud.google.com)，然後前往 BigQuery。您也可以直接在瀏覽器中輸入下列網址，直接開啟 BigQuery 網頁版 UI。

```
https://console.cloud.google.com/bigquery
```

- 接受服務條款。
- 您必須先建立專案，才能使用 BigQuery。請依照提示建立新專案。

選擇專案名稱，並記下專案 ID。

New Project

Project Name *

my-codelab-project 

Project ID: my-codelab-project-207619. It cannot be changed later. [EDIT](#)

Billing account *

所有 Google Cloud 專案的專案 ID 都是不重複的名稱。本程式碼研究室稍後會將其稱為 `PROJECT_ID`。

本程式碼研究室使用的 BigQuery 資源，不會超出 [BigQuery 沙箱限制](#)。不需要帳單帳戶。如要移除沙箱限制，請註冊 Google Cloud Platform 免費試用方案，並新增帳單帳戶。

3. 預覽 GitHub 資料

在 BigQuery 網頁版 UI 中開啟 GitHub 資料集。

https://console.cloud.google.com/bigquery?p=bigquery-public-data&d=github_repos&t=commits&page=table

快速預覽資料的樣貌。

請勿使用 `SELECT *` 查看資料表中的資料列。即使使用 `LIMIT` 子句，BigQuery 仍會掃描資料表中所有資料列的所有資料欄，這會用盡免費查詢配額。

commits

QUERY TABLECOPY TABLEDELETE TABLEEXPORT

SchemaDetailsPreview

Use the Preview tab rather than a SELECT * query.


Row	commit	tree	parent
1	1b65b8fb19b39c5ea6609c895775a14715b1d40b	0d17625cd23c2f498cfeeca08851a910fd659feb	7e2c9e79e52a
2	77861dab33abcab3636d4088e478d2d69230f501	0bb96efde649cfec2c86c80062389edf36275c7d	bf6458a0083e
3	e5d3b5bd3d0319d1a4243da5748de632fbf57cde	fc0fef538bee3d2a59a7b2e229842ce0d63b9832	237cb68266b7
4	f4771c370d419b34e09ce13f9d565dfe24b5d4e0	c0830f346d14d9057ffeb10670d29246c186c096	1f7766caa29a
			5a631e45ab04
5	3d34925fc44dad0c04e3f5bbaecb17b33aad60c9	2cb9c09c0ef5acf831b65e03b6e0854cb2a0f717	fe1027960eb2l
6	12310c288f68d65ef089fdac2b4cf239de14cb75	f9bf9b67fb8c0da77d8d2cb41a7dbcbcb963dc4bc	904d7760c49b
7	609a2f18767ce9d993418df6d46b4cbbae79261d	0b4a9d1a62c503cae100d596a1f211c286e97848	0444817a39c2
8	976303a9bc6b8a13c24584fe721263b9eb18fe83	41512e4d2045034e92a5f434cb85df7110e0b899	339797d5d7f9
9	6440807f0e4d2001b4b8af924a59ea8b691a9dac	8abe433a64a94b0db979a2c19f3ef67db04c6e2c	71f166fb35ea6
10	0914978edebf024f4a4fdbb70406e07eb3a2055b	d890e0cf947a1c8a0634c45c785304fb18fc89b2	4cf55a9ee805

Rows per page: 101 - 10 of 219881560

步驟 4 · 約 5 分鐘

4. 查詢 GitHub 資料

開啟查詢編輯器。



輸入下列查詢，找出 [GitHub 公開資料集](#) 中最常見的提交訊息：

```
SELECT subject AS subject,  
       COUNT(*) AS num_duplicates  
FROM `bigquery-public-data.github_repos.sample_commits`  
GROUP BY subject  
ORDER BY num_duplicates DESC  
LIMIT 100
```

由於 GitHub 資料集很大，因此在實驗時使用較小的樣本資料集，有助於節省成本。使用編輯器下方的處理位元組數，預估查詢費用。

Query editor

HIDE EDITOR

FULL SCREEN

1 SELECT subject AS subject,

2 COUNT(*) AS num_duplicates

3 FROM `bigquery-public-data.github\_repos.sample\_commits`

4 GROUP BY subject

5 ORDER BY num_duplicates DESC

6 LIMIT 100

Run

Save query

Save view

Schedule query

More

This query will process 35.8 MB when run.

按一下「執行」按鈕。

結果會在幾秒後顯示在底部，並說明處理的資料量和所需時間。

Run

Save query

Save view

Schedule query

More

This query will process 35.8 MB when run.

Query results

SAVE RESULTS

Query complete (0.1 sec elapsed, cached)

Job information

Results

JSON

Execution details

Row	subject
1	Merge git://git.kernel.org/pub/scm/linux/kernel/git/davem/net
2	Merge git://git.kernel.org/pub/scm/linux/kernel/git/davem/net-2.6
3	Merge master.kernel.org:/home/rmk/linux-2.6-arm
4	Merge branch 'drm-fixes' of git://people.freedesktop.org/~airlied/linux
5	Merge branch 'for-linus' of git://git.kernel.org/pub/scm/linux/kernel/git/dtor/input
6	Merge branch 'master' of master.kernel.org:/pub/scm/linux/kernel/git/davem/net-2.6
7	Merge commit for internal changes
8	Merge master.kernel.org:/pub/scm/linux/kernel/git/davem/net-2.6
9	Merge branch 'for-linus' of git://git.kernel.org/pub/scm/linux/kernel/git/tiwai/sound-2.6
10	Merge branch 'unstream' of git://ftn.linux-mips.org/pub/scm/unstream-linux

即使 sample_commits 資料表為 2.49 GB，查詢處理的資料量也只有 35.8 MB。BigQuery 只會處理查詢中使用的資料欄位元組，因此處理的資料總量可能遠小於資料表大小。使用[分群](#)和[分區](#)，可進一步減少處理的資料量。

步驟 5 · 約 2 分鐘

5. 更多公開資料

現在請嘗試查詢其他資料集，例如其他[公開資料集](#)。

舉例來說，下列查詢會在 [Libraries.io 公開資料集](#) 中，找出仍做為其他專案依附元件的熱門已淘汰或未維護專案：

```
SELECT
  name,
  dependent_projects_count,
  language,
  status
FROM
  `bigquery-public-data.libraries_io.projects_with_repository_fields`
WHERE status IN ('Deprecated', 'Unmaintained')
ORDER BY dependent_projects_count DESC
LIMIT 100
```

其他機構也在 BigQuery 中公開資料。舉例來說，[Github 的 GH Archive 資料集](#)可用於分析 GitHub 上的公開事件，例如提取要求、存放區星號和開啟的問題。您可以使用 [Python 軟體基金會的 PyPI 資料集](#)，分析 Python 套件的下載要求。

步驟 6 · 約 0 分鐘

6. 恭喜！

您已使用 BigQuery 和 SQL 查詢 GitHub 公開資料集。您有權查詢 PB 規模的資料集！

涵蓋內容

- 使用 SQL 語法查詢 GitHub 提交記錄
- 撰寫查詢，深入瞭解大型資料集

瞭解詳情

- 透過 [Kaggle 的 SQL 簡介](#) 學習 SQL。
 - 請參閱 [BigQuery 說明文件](#)。
 - 如要瞭解其他使用者如何運用 GitHub 資料集，請參閱 [這篇網誌文章](#)。
 - 在 [TIL with BigQuery](#) 中探索天氣資料、犯罪資料等。
 - 瞭解如何 [使用 BigQuery 指令列工具將資料載入 BigQuery](#)。
 - 歡迎前往 [BigQuery 子論壇](#)，瞭解其他人目前如何使用 BigQuery。
-