

使用 Cloud Data Fusion 將 CSV 資料擷取至 BigQuery - 批次擷取

來源：<https://codelabs.developers.google.com/codelabs/batch-csv-cdf-bq?hl=zh-tw>

步驟數：10

在本程式碼研究室中，我們會實作資料擷取模式，使用 Cloud Data Fusion 將 CSV 格式的醫療照護資料載入 BigQuery。

目錄

1. [1. 簡介](#)
2. [2. 設定 GCP 專案](#)
3. [3. Cloud Data Fusion 環境設定](#)
4. [4. 建構轉換結構定義](#)
5. [5. 為管道建構節點](#)
6. [6. 建構批次資料管道](#)
7. [7. 設定、部署、執行/排定管道](#)
8. [8. 驗證](#)
9. [9. 正在清除所用資源](#)
10. [10. 恭喜](#)

1. 簡介



上次更新時間：2020 年 2 月 28 日

本程式碼研究室會示範資料擷取模式，將 CSV 格式的醫療保健資料大量擷取至 BigQuery。在本實驗室中，我們將使用 Cloud Data Fusion 批次資料管道。我們已產生真實的醫療保健測試資料，並放在 Google Cloud Storage bucket (`gs://hcls_testing_data_fhir_10_patients/csv/`) 中供您使用。

在本程式碼研究室中，您將學到：

- 如何使用 **Cloud Data Fusion**，從 GCS 擷取 CSV 資料 (批次排程載入) 並載入 BigQuery。
- 瞭解如何使用 **Cloud Data Fusion**，以視覺化方式建構資料整合管道，大量載入、轉換及遮蓋醫療照護資料。

執行本程式碼研究室需要哪些條件？

- 您必須有 GCP 專案的存取權。
- 您必須獲派 GCP 專案的擁有者角色。
- CSV 格式的健康資料，包括標頭。

如果您沒有 GCP 專案，請按照[這些步驟](#)建立新的 GCP 專案。

CSV 格式的健康照護資料已預先載入 GCS bucket (`gs://hcls_testing_data_fhir_10_patients/csv/`)。每個資源 CSV 檔案都有專屬的結構定義。舉例來說，Patients.csv 的結構定義與 Providers.csv 不同。預先載入的結構定義檔案位於 `gs://hcls_testing_data_fhir_10_patients/csv_schemas`。

如需新資料集，隨時可以使用 [SyntheaTM](#) 產生。然後上傳至 GCS，而不是在「複製輸入資料」步驟中從值區複製。

Reference:

使用 Google Cloud Platform 主控台在 [Cloud Data Fusion](#) 中執行基本作業 (快速入門導覽課程)。

步驟 2 · 約 0 分鐘

2. 設定 GCP 專案

為環境初始化殼層變數。

如要尋找「PROJECT_ID」PROJECT_ID，請參閱「[識別專案](#)」一文。



```
<!-- CODELAB: Initialize shell variables -->
<!-- Your current GCP Project ID -->
export PROJECT_ID=<PROJECT_ID>
<!-- A new GCS Bucket in your current Project - INPUT -->
export BUCKET_NAME=<BUCKET_NAME>
<!-- A new BQ Dataset ID - OUTPUT -->
export DATASET_ID=<DATASET_ID>
```

使用 **gsutil** 工具建立 GCS bucket，儲存輸入資料和錯誤記錄。



```
gsutil mb -l us gs://$BUCKET_NAME
```

取得合成資料集存取權。

1. 使用登入 Cloud Console 的電子郵件地址，傳送電子郵件至 hcls-solutions-external+subscribe@google.com，要求加入。
2. 您會收到一封電子郵件，內含如何確認動作的操作說明。

[Join This Group](#)

3. 使用該選項回覆電子郵件，即可加入群組。請勿點選該按鈕。
4. 收到確認電子郵件後，即可繼續執行程式碼研究室的下一個步驟。

複製輸入資料。

```
gsutil -m cp -r gs://hcls_testing_data_fhir_10_patients/csv gs://$BUCKET_NAME
```

建立 BigQuery 資料集。

```
bq mk --location=us --dataset $PROJECT_ID:$DATASET_ID
```

提醒：您隨時可以使用 [SyntheaTM](#) 為本實驗室產生一組新的真實測試資料。為方便起見，我們在 GCS 中提供資料集：**`gs://hcls_testing_data_fhir_10_patients/csv`**

步驟 3 · 約 0 分鐘

3. Cloud Data Fusion 環境設定


請按照下列步驟啟用 Cloud Data Fusion API 並授予必要權限：

啟用 API。

1. 前往 [GCP 主控台的 API 程式庫](#)。
2. 從專案清單中選取您的專案。
3. 在 API 程式庫中，選取您要啟用的 API。如果找不到 API，請使用搜尋欄位和/或篩選器。
4. 在 API 頁面中，按一下「啟用」。

建立 Cloud Data Fusion 執行個體。

1. 在 GCP 主控台中選取 ProjectID。
2. 從左側選單選取 Data Fusion，然後按一下頁面中央的「CREATE AN INSTANCE」(建立執行個體) 按鈕 (首次建立)，或按一下頂端選單的「CREATE INSTANCE」(建立執行個體) 按鈕 (額外建立)。



3. 提供執行個體名稱。選取「Enterprise」。

Google Cloud Platform

dp-workspace

Data Fusion

Create Data Fusion instance

Instance name

Instance name is required

Instance ID

Description

us-west1-a

Zone in which the instance is created

Edition

☐ Basic

This edition provides comprehensive data integration capabilities. Users can build batch data pipelines; connect to any data source; perform code-free transformations. Limitation on simultaneous pipeline runs. Recommended for non-critical environments.

☒ Enterprise

This edition provides all the functionality provided in the Basic edition. In addition, includes support for realtime data pipelines; interactions with data lineage; no limitations on simultaneous pipeline runs; and high availability. Recommended for critical environments.

SHOW ADVANCED OPTIONS

CREATE

CANCEL

4. 按一下「建立」按鈕。

注意：執行個體建立程序最多可能需要 30 分鐘才能完成。

設定執行個體權限。

建立執行個體後，請按照下列步驟，將專案上的執行個體權限授予與其相關聯的服務帳戶：

注意：這個授予權限的步驟僅需在專案中進行一次即可。

1. 按一下執行個體名稱，前往執行個體詳細資料頁面。

Google Cloud Platform

dp-workspace

Data Fusion

Instances

CREATE INSTANCE

REFRESH

DELETE

Select which instance of Cloud Data Fusion you want to view.

☐	☒	Instance name ↑	Action	Location	Edition	Created	Last Updated	Labels
☐	☒	dp-csv-bq-test	View Instance	us-central1	Enterprise	Jun 10, 2019, 3:36:44 PM	Jun 10, 2019, 3:49:52 PM	--

2. 複製服務帳戶。

dp-csv-bq-test

Instance ID	dp-csv-bq-test
Instance URL	View Instance
Description	--
Edition	ENTERPRISE
Zone	us-central1-f
Created	Jun 10, 2019, 3:36:44 PM
Last updated	Jun 10, 2019, 3:49:52 PM
Stackdriver logs	Disabled
Stackdriver monitoring	Disabled
Service Account	cloud-datafusion-management-sa@k541dcf9e63f16fe4-tp.iam.gserviceaccount.com
Version	6.0.1.0

3. 移至專案的 [IAM] (身分與存取權管理) 頁面。

4. 在 IAM 權限頁面上，我們現在要將服務帳戶新增為成員，並授予「Cloud Data Fusion API 服務代理人」角色。按一下「新增」按鈕，然後將「服務帳戶」貼到「新成員」欄位，並選取「服務管理」->「Cloud Data Fusion API 伺服器代理人」角色。

Add members, roles to "hcls-solutions-test-project" project

Enter one or more members below. Then select a role for these members to grant them access to your resources. Multiple roles allowed. [Learn more](#)

New members

cloud-datafusion-management-sa@ca2c3cc00b9c17b03-tp.iam.gserviceaccount.com

Select a role

Resource Manager
Roles
Serverless VPC Access
Service Accounts
Service Consumer Man...
Service Management

AutoML Service Agent
Compute Engine Service Agent
Kubernetes Engine Service Agent
Cloud Dataflow Service Agent
Cloud Data Fusion API Service ...
Dataproc Service Agent

Condition

Cloud Data Fusion API Service Agent

Gives Cloud Data Fusion service account access to Service Networking, Dataproc, Storage, BigQuery, Spanner and BigTable resources.

6. 按一下 [儲存]。

完成上述步驟後，您就可以在 Cloud Data Fusion 執行個體頁面，或執行個體詳細資料頁面上按一下「View Instance」(檢視執行個體) 連結，開始使用 Cloud Data Fusion。

設定防火牆規則。

1. 前往 GCP 主控台 -> 「VPC Network」 (VPC 網路) -> 「Firewall rules」 (防火牆規則)，檢查是否有 default-allow-ssh 規則。

☐	Name	Type	Targets	Filters	Protocols / ports	Action	Priority	Network ^
☐	default-allow-ssh	Ingress	Apply to all	IP ranges: 0.0.0.0/0	tcp:22	Allow	1000	default

2. 如果沒有，請新增防火牆規則，允許所有連入的 SSH 流量進入預設網路。

使用指令列：

```
gcloud beta compute --project={PROJECT_ID} firewall-rules create default-allow-ssh --
direction=INGRESS --priority=1000 --network=default --action=ALLOW --rules=tcp:22 --
source-ranges=0.0.0.0/0 --enable-logging
```

使用 UI：按一下「建立防火牆規則」，然後填寫資訊：

VPC network

Firewall rules

[+ CREATE FIREWALL RULE](#)

[REFRESH](#)

[DELETE](#)

← Firewall rule details

[EDIT](#)

[DELETE](#)

default-allow-ssh

Description

Allow SSH from anywhere

Logs

Off

[view](#)

Network

default

Priority

1000

Direction

Ingress

Action on match

Allow

Source filters

IP ranges

0.0.0.0/0

Protocols and ports

tcp:22

Enforcement

Enabled

Applicable to instances


The following table shows only the VM instances that you have permission to view. The "default" network might contain other instances that aren't being displayed.

步驟 4 · 約 0 分鐘


4. 建構轉換結構定義

現在我們在 GCP 中有 Cloud Fusion 環境，接著來建構結構定義。我們需要這個結構定義，才能轉換 CSV 資料。


1. 在 Cloud Data Fusion 視窗中，按一下「動作」欄中的「查看執行個體」連結。系統會將你重新導向至其他頁面。按一下提供的網址，開啟 Cloud Data Fusion 執行個體。在歡迎彈出式視窗中，選擇點按「開始導覽」或「不用了」按鈕。
2. 展開「漢堡」選單，選取「Pipeline」->「Studio」




3. 在左側「外掛程式」調色盤的「轉換」部分下方，按兩下 Wrangler 節點，該節點就會顯示在「資料管道」UI 中。



4. 將游標移至 Wrangler 節點，然後按一下「Properties」(屬性)。按一下「Wrangle」按鈕，然後選取 .csv 來源檔案 (例如 patients.csv)，該檔案必須包含所有資料欄位，才能建構所需的結構定義。
5. 點選每個欄名 (例如 body) 旁的向下箭頭 (欄轉換)。



6. 根據預設，系統會假設資料檔案中只有一個資料欄。如要將其剖析為 CSV，請依序選擇「剖析」→「CSV」，然後選取分隔符號，並視需要勾選「將第一列設為標頭」方塊。按一下「套用」按鈕。
7. 點選「內文」欄位旁的向下箭頭，然後選取「刪除資料欄」移除「內文」欄位。此外，您也可以試用其他轉換功能，例如移除資料欄、變更部分資料欄的資料類型 (預設為「字串」類型)、分割資料欄、設定資料欄名稱等。



8. 「資料欄」和「轉換步驟」分頁會顯示輸出結構定義和 Wrangler 的配方。按一下右上角的「套用」。按一下「驗證」按鈕。綠色的「未發現錯誤」表示成功。

Wrangler Properties 4.1.3
Wrangler - A interactive tool for data cleansing and transformation.

No errors found. [Validate](#)

Properties Documentation

Input Schema
No Schema Available

Label *
Wrangler

Input Selection and Prefilters

Input field name *
*

Precondition *
false

Directives

Recipe

```
1 parse-as-csv :body ',' true
2 drop body
```

Output Schema *

Name	Type	Null
Id	string	☒
BIRTHDATE	string	☒
DEATHDATE	string	☒
SSN	string	☒
DRIVERS	string	☒
PASSPORT	string	☒
PREFIX	string	☒
FIRST	string	☒
LAST	string	☒
SUFFIX	string	☒
MAIDEN	string	☒

9. 在 Wrangler 屬性中，按一下「動作」下拉式選單，將所需結構匯出至本機儲存空間，以便日後視需要匯入。

10. 儲存 Wrangler 食譜，以供日後使用。


```
parse-as-csv :body ',' true
drop body
```

11. 如要關閉 Wrangler 屬性視窗，請按一下「X」X 按鈕。


5. 為管道建構節點

在本節中，我們將建構管道元件。

1. 在 Data Pipelines UI 中，您應該可以在左上角看見選定的管道類型為「Data Pipeline - Batch」(資料管道 - 批次)。




2. 左側面板有篩選器、來源、轉換、數據分析、接收器、條件和動作、錯誤處理常式和快訊等不同區段，您可以在其中選取管道的節點。



來源節點

1. 選取「來源」節點。
2. 在左側外掛程式調色盤的「來源」部分下方，按兩下「Google Cloud Storage」節點，該節點會顯示在 Data Pipelines UI 中。
3. 將游標移至 GCS 來源節點，接著按一下「Properties」(屬性)。



4. 填寫必填欄位。設定下列欄位：

- 標籤 = {任何文字}
- 參考名稱 = {任何文字}
- 專案 ID = 自動偵測
- 路徑 = 目前專案中值區的 GCS 網址。例如 gs://\$BUCKET_NAME/csv/
- 格式 = 文字
- 路徑欄位 = 檔案名稱
- **Path Filename Only** = true
- **Read Files Recursively** = true

5. 按一下 + 按鈕，將「filename」欄位新增至 GCS 輸出結構定義。
6. 如需詳細說明，請按一下「說明文件」。按一下「驗證」按鈕。綠色的「未發現錯誤」表示成功。
7. 如要關閉 GCS 屬性，請按一下「X」X 按鈕。

轉換 node

1. 選取「Transform」(變形) 節點。
2. 在左側「外掛程式」調色盤的「轉換」部分下方，按兩下「Wrangler」 **Wrangler**節點，該節點會顯示在「資料管道」UI 中。將 GCS 來源節點連結至 Wrangler 轉換節點。
3. 將游標移至 Wrangler 節點，然後按一下「Properties」(屬性)。
4. 按一下「動作」下拉式選單，然後選取「匯入」，匯入已儲存的結構定義 (例如：
gs://hcls_testing_data_fhir_10_patients/csv_schemas/ schema (Patients).json)，並貼上上一節中儲存的食譜。
5. 或者，重複使用「建立轉換的結構定義」一節中的 **Wrangler** 節點。
6. 填寫必填欄位。設定下列欄位：

- **Label = {any text}**
- **輸入欄位名稱 = {*}**
- **前置條件 = {filename != "patients.csv"}**，用來區分每個輸入檔案 (例如 *patients.csv*、*providers.csv*、*allergies.csv* 等) 與來源節點。

Wrangler Properties 4.1.3
Wrangler - A interactive tool for data cleansing and transformation.

Properties Documentation

Input Schema

Name	Type	Null
offset	long	☐
body	string	☐
filename	string	☐

Label *

Patients

Input Selection and Prefilters


Input field name *

*

Precondition *

filename != "patients.csv"

7. 新增 JavaScript 節點，執行使用者提供的 JavaScript，進一步轉換記錄。在本程式碼研究室中，我們會使用 JavaScript 節點，取得每筆記錄更新的時間戳記。將 Wrangler 轉換節點連結至 JavaScript 轉換節點。開啟 JavaScript **Properties**，並新增下列函式：



```
function transform(input, emitter, context) {  
  input.TIMESTAMP = (new Date()).getTime()*1000;  
  emitter.emit(input);  
}
```

8. 按一下 + 符號，將名為 TIMESTAMP 的欄位新增至輸出結構定義 (如果不存在)。選取時間戳記做為資料類型。

ZIP	string	▼	☒		+
TIM	timestamp	▼	☐		+

- 如需詳細說明，請按一下「說明文件」。按一下「驗證」按鈕，驗證所有輸入資訊。綠色的「未發現任何錯誤」表示成功。
- 如要關閉「轉換屬性」視窗，請按一下「X」**X**按鈕。

資料遮蓋和去識別化

- 點選資料欄中的向下箭頭，然後根據需求在「遮蓋資料」選單中套用遮蓋規則，即可選取個別資料欄 (例如：社會安全號碼資料欄)。

Data

Insights

	String	String	String
☐	☐ DEATHDATE ☐	☒ SSN ☐	☒ DRIVERS ☐
		9-92-8791	S99994421
		9-74-2735	S99949400
		9-22-3903	S99916152

Parse

Set character encoding

Change data type

Format

Calculate

Custom transform

Filter

Send to error

Find and replace

Fill null or empty cells

Copy column

Delete column

Keep column

Join two columns

Swap two column names

Extract fields

Explode

Define variable

Set counter

Mask data

Encode

Decode

Show last 4 characters only

Show last 2 characters only

Custom selection

By shuffling

2. 您可以在 **Wrangler** 節點的「Recipe」視窗中新增更多指令。舉例來說，使用雜湊指令和雜湊演算法，並遵循以下語法進行去識別化：

```
hash <column> <algorithm> <encode>
```

<column>: name of the column

<algorithm>: Hashing algorithm (i.e. MD5, SHA-1, etc.)

<encode>: default is true (hashed digest is encoded as hex with left-padding zeros). To disable hex encoding, set <encode> to false.

Recipe


```
1 parse-as-csv :body ',' true
2 drop body
3 hash BIRTHDATE SHA-1
4 hash DRIVERS MD5 false
5 mask-number SSN xxxxxxxx####
```

Wrangle

注意：True 代表剖析主體資料欄時，已勾選「將第一列設為標題」選項。

接收器節點

1. 選取接收器節點。
2. 在左側外掛程式面板的「接收器」區段下方，按兩下 BigQuery 節點，該節點就會顯示在資料管道 UI 中。
3. 將游標移至 BigQuery 接收器節點，然後按一下「Properties」(屬性)。



4. 填寫必填欄位。設定下列欄位：
 - 標籤 = {任何文字}
 - 參考名稱 = {任何文字}
 - 專案 ID = 自動偵測
 - 資料集 = 目前專案中使用的 BigQuery 資料集 (即 DATASET_ID)
 - Table = {資料表名稱}
5. 如需詳細說明，請按一下「說明文件」。按一下「驗證」按鈕，驗證所有輸入資訊。綠色的「未發現任何錯誤」表示成功。

BigQuery Properties 0.13.2

This sink writes to a BigQuery table. BigQuery is Google's serverless, highly scalable, enterprise data warehouse. Data is first written to a temporary table and then moved to the target table.

Properties

Documentation

Input Schema

Name	Type	Null
Id	string	☒
BIRTHDATE	string	☒
DEATHDATE	string	☒
SSN	string	☒
DRIVERS	string	☒
PASSPORT	string	☒
PREFIX	string	☒
FIRST	string	☒
LAST	string	☒
SUFFIX	string	☒
MAIDEN	string	☒

Label *

BigQuery

Basic

Reference Name *

BQ1

Project ID

auto-detect

Dataset *

hn_dataset

Table *

Patients


6. 如要關閉 BigQuery 屬性，請按一下「X」X 按鈕。

步驟 6 · 約 0 分鐘

6. 建構批次資料管道

連結管道中的所有節點

1. 將來源節點右側的連結箭頭「>」拖曳至目標節點左側。
2. 管道可以有多個分支，這些分支會從同一個 GCS 來源節點取得輸入檔案。



注意：為每個輸入 .csv 檔案，從管道中的來源節點建構一個分支

3. 為管道命名。

注意：在此過程中，結構定義會在您建構管道時自動傳播。您也可以匯入所需的結構定義。

就是這麼簡單！您已成功建立第一個批次資料管道，現在可以開始部署及執行這個管道。


透過電子郵件傳送管道快訊 (選用)

如要使用 Pipeline Alert SendEmail 功能，設定時必須先設定郵件伺服器，才能從虛擬機器執行個體傳送郵件。詳情請參閱下方參考連結：

[從執行個體傳送電子郵件 | Compute Engine 說明文件](#)

在本程式碼研究室中，我們將透過 Mailgun 設定郵件轉發服務，步驟如下：

1. 請按照「[使用 Mailgun 傳送電子郵件 | Compute Engine 說明文件](#)」中的操作說明，設定 Mailgun 帳戶並設定電子郵件轉發服務。其他修改項目如下。
2. 將所有收件者的電子郵件地址加入 Mailgun 的授權清單。如要查看這份清單，請依序前往 Mailgun>Sending>Overview (左側面板)。



Authorized Recipients

Email address

bob@gmail.com

Save Recipient

shpaka@google.com

Verified



收件者點選 *support@mailgun.net* 寄來的電子郵件中的「我同意」後，系統就會將他們的電子郵件地址儲存到授權清單，以便接收管道快訊電子郵件。

Hi there,

Mailgun account "Google" provided your address to test their integration with Mailgun.

Please click the link below if you agree to receive emails from their account.

I Agree

If you didn't expect this email, please [unsubscribe](#).

Thanks, Mailgun Team

3. 「事前準備」一節的步驟 3 - 建立防火牆規則，如下所示：

smtp-egress

Logs ?

Off

[view](#)

Network

default

Priority

1000

Direction

Egress

Action on match

Allow

Destination filters

IP ranges

0.0.0.0/0


Protocols and ports

tcp:2525

Enforcement

Enabled

4. 「使用 Postfix 將 Mailgun 設為郵件轉發」的步驟 3。選取「網際網路網站」或「網際網路 (使用智慧主機)」，而非操作說明中提及的「僅限本機」。




5. 「使用 Postfix 將 Mailgun 設為郵件轉發」的步驟 4。編輯 `vi /etc/postfix/main.cf`，在 `mynetworks` 結尾新增 `10.128.0.0/9`。

```
mydestination = $myhostname, instance-1.us-central1-a.c.data-fusion2.internal, localhost.us-central1-a.c.data-fusion2.internal, localhost
relayhost = [smtp.mailgun.org]:2525
mynetworks = 127.0.0.0/8 [::ffff:127.0.0.0]/104 [::1]/128 10.128.0.0/9
mailbox_size_limit = 0
```

6. 編輯 `vi /etc/postfix/master.cf`，將預設的 SMTP (25) 變更為通訊埠 587。

```
smtp      inet  n       -       y       -       -       smtpd
#smtpd    inet  n       -       y       -       -       smtpd
#smtpd    inet  n       -       y       -       -       smtpd
```

7. 在 Data Fusion 工作室的右上角，按一下「設定」。按一下「管道快訊」，然後按一下「+」按鈕，開啟「快訊」視窗。選取「傳送電子郵件」 **SendEmail**。



The image shows a configuration window titled "Alerts" with a close button (X) in the top right corner. Below the title bar, there are three steps indicated by numbered circles: 1 Select Alert, 2 Configure, and 3 Confirm. Under the "1 Select Alert" step, there are three buttons: "Send Email", "Run Database Query", and "Make HTTP Call".

8. 填寫「電子郵件」設定表單。從各個快訊類型的「執行條件」下拉式選單中，選取「完成」、「成功」或「失敗」。如果「Include Workflow Token」(包含工作流程權杖) = *false*，系統只會傳送「Message」(訊息) 欄位中的資訊。如果「Include Workflow Token」(納入工作流程權杖) = *true*，系統會傳送「Message」(訊息) 欄位中的資訊和工作流程權杖詳細資訊。「通訊協定」必須使用小寫。在「寄件者」欄位中，使用公司電子郵件地址以外的「虛假」電子郵件。

Email 2.2.1-SNAPSHOT

Sends an email after a pipeline run.

Select Alert

Run Condition

completion

Sender *

john@abc.com

Recipients *

jane@xyz.com

Subject *

Pipeline run completed

Message *

1 Any information can be added here.

Username

Password



Protocol

smtp

Host

Internal IP address of your Compute Engine VM instance


Port

587


Include Workflow Token

false


7. 設定、部署、執行/排定管道




1. 在 Data Fusion 工作室的右上角，按一下「設定」。在「引擎設定」中選取「Spark」。在「設定」視窗中按一下「儲存」。



2. 按一下「預覽」即可預覽資料，再次按一下「預覽」即可切換回上一個視窗。您也可以預覽模式下 **執行** 管道。



3. 按一下「記錄」即可查看記錄。
4. 按一下「儲存」即可儲存所有變更。
5. 建立新管道時，按一下「匯入」即可匯入已儲存的管道設定。
6. 按一下「匯出」，匯出管道設定。
7. 按一下「Deploy」（部署）即可部署管道。
8. 完成部署作業後，按一下「執行」，並靜待管道執行完畢。



注意：執行管道時，Cloud Data Fusion 會佈建暫時的 Cloud Dataproc 叢集，並在該叢集上執行管道，然後拆散叢集。這可能需要幾分鐘的時間才會完成。在這段時間內，您會發現管道的狀態從「佈建中」變更為「啟動中」，然後變成「執行中」，再從「取消佈建中」變更為「成功」。


9. 如要複製管道，請選取「動作」按鈕下方的「複製」。
10. 選取「動作」按鈕下方的「匯出」，即可匯出管道設定。
11. 按一下 Studio 視窗左側或右側邊緣的「Inbound triggers」或「Outbound triggers」，即可視需要設定管道觸發條件。
12. 按一下「排定時間」，即可排定管道執行時間，並定期載入資料。

13. 「摘要」會顯示執行記錄、記錄、錯誤記錄和警告的圖表。

步驟 8 · 約 0 分鐘

8. 驗證

1. 驗證管道已順利執行。



2. 驗證 BigQuery 資料集是否包含所有資料表。

```
bq ls $PROJECT_ID:$DATASET_ID
```

tableId	Type	Labels	Time Partitioning
Allergies	TABLE		
Careplans	TABLE		
Conditions	TABLE		
Encounters	TABLE		
Imaging_Studies	TABLE		
Immunizations	TABLE		
Medications	TABLE		
Observations	TABLE		
Organizations	TABLE		
Patients	TABLE		
Procedures	TABLE		
Providers	TABLE		

3. 接收快訊電子郵件 (如有設定)。

查看結果

如要在管道執行完畢後查看結果，請執行以下操作：

- 在 BigQuery UI 中查詢資料表。[前往 BigQuery UI](#)
- 將下方查詢中的專案名稱、資料集和資料表更新為您自己的。

Query editor

1

Select * from bq_dataset.patients

Run

Save query

Save view

Schedule query

More

This query will process 2.6 KB when run.

Query results

SAVE RESULTSEXPLORE IN DATA STUDIO

Query complete (0.7 sec elapsed, 2.6 KB processed)

Job information

Results

JSON

Execution details

Row	Id	BIRTHDATE	DEATHDATE	SSN	DRIVERS	PASSPORT	PREFIX	FIRST	LAST	SUFFIX	MAIDEN	MARITAL	RACE
1	36c21120-0f76-4ded-a03f-cc825b03ffe0	2003-07-03		999-74-9091				Spencer878	McClure239				white
2	7e264c78-275f-43f4-b742-438959142cae	2012-08-17		999-63-6044				Roland928	Howe413				white
3	1ab1cc70-63e2-46ba-8016-caa44efb5cb0	2012-10-13		999-21-8944				Tod265	Altenwerth646				white
4	5e6574eb-b0d6-47b5-940e-5eb21a750923	1987-10-23		999-62-8929	S99963297	X29102006X	Mr.	Karl184	Waelchi213			S	white
5	460e0d88-562a-46dd-bb48-aba534684098	1944-03-20	2017-10-03	999-59-9055	S99925142	X48042629X	Mr.	Renato359	Welch179			S	white
6	2f36c1b7-598e-4715-b6cd-66c3f22b7e1e	1944-03-20		999-92-8791	S99994421	X88591555X	Mr.	Jackie93	Williamson769			M	white
7	0eb4ec3a-9df0-4c9f-b731-51fb3e8740d8	1947-10-10		999-22-3903	S99916152	X56790450X	Mr.	Justin359	D'Amore443			M	white
8	2f9b4deb-fca3-4964-9997-a3146451682a	1975-11-17	2010-10-23	999-57-8708	S99994228	X40457446X	Ms.	Pamelia915	Bartell116			S	white
9	6301a702-1100-4000-b700-600000000000	2000-01-01		999-99-9999	S99999999	X99999999X	Mr.	John123	Smith456				white

Rows per page: 1001 - 12 of 12First page<>>Last page

9. 正在清除所用資源

如要避免系統向您的 Google Cloud Platform 帳戶收取您在本教學課程中所用資源的相關費用：

完成教學課程後，您可以清除在 GCP 上建立的資源，這樣資源就不會占用配額，您日後也無須為其付費。下列各節將說明如何刪除或停用這些資源。

刪除 BigQuery 資料集

按照這些操作說明[刪除您在本教學課程中建立的 BigQuery 資料集](#)。

刪除 GCS bucket

請按照這些操作說明[刪除](#)在本教學課程中建立的 GCS 儲存空間。

刪除 Cloud Data Fusion 執行個體

請按照[刪除 Cloud Data Fusion 執行個體](#)一文的操作說明進行。

刪除專案

如要避免付費，最簡單的方法就是刪除您為了本教學課程所建立的專案。

如要刪除專案，請進行以下操作：

警告：刪除專案會出現以下結果：

- **專案中的所有內容都會遭到刪除。**如果您之前使用現有的專案來進行本教學課程，當您刪除該專案時，也會一併刪除您在該專案中完成的所有其他工作。
- **自訂專案 ID 不復存在。**您建立這個專案時，可能已建立日後使用的自訂專案 ID。如要保留使用該專案 ID 的網址 (例如 **appspot.com** 網址)，請刪除在該專案中選取的資源，而不是刪除整個專案。

如果打算進行多個教學課程及快速入門導覽課程，重複使用專案有助於避免超出專案配額限制。

1. 前往 GCP 主控台的「Projects」(專案) 頁面。[前往「PROJECTS」\(專案\) 頁面](#)
 2. 在專案清單中選取要刪除的專案，然後點按「Delete」(刪除)。
 3. 在對話方塊中輸入專案 ID，然後按一下「Shut down」(關閉) 即可刪除專案。
-

步驟 10 · 約 0 分鐘

10. 恭喜

恭喜！您已成功完成程式碼研究室，瞭解如何使用 Cloud Data Fusion 將醫療保健資料擷取至 BigQuery。

您已將 Google Cloud Storage 中的 CSV 資料匯入 BigQuery。

您以視覺化方式建構資料整合管道，以便大量載入、轉換及遮蓋醫療保健資料。

您現在已瞭解在 Google Cloud Platform 上使用 BigQuery 展開醫療保健資料分析之旅的必要步驟。
